

### Analysis

— Sommersemester 2017 —

Prof. Dr. Karl Stroetmann

17. Mai 2017

Dieses Skript ist einschließlich der LATEX-Quellen sowie der in diesem Skript diskutierten Programme unter

https://github.com/karlstroetmann/Analysis

im Netz verfügbar. Das Skript wird laufend überarbeitet. Wenn Sie auf Ihrem Rechner git installieren und mein Repository mit Hilfe des Befehls

git clone https://github.com/karlstroetmann/Analysis.git klonen, dann können Sie durch Absetzen des Befehls

git pull

die aktuelle Version meines Skripts aus dem Netz laden.

# Inhaltsverzeichnis

1	Einle	eitung 3									
	1.1	Überblick über die Vorlesung									
	1.2	Ziel der Vorlesung									
	1.3	Notation									
	1.4	Eine Bitte									
2	Die	reellen Zahlen 6									
_	2.1	Axiomatische Charakterisierung der reellen Zahlen									
	2.2	Die formale Konstruktion der reellen Zahlen*									
	2.3	Geschichte									
	2.5	describence									
3	Folg	gen und Reihen 24									
	3.1	Folgen									
	3.2	Berechnung der Quadrat-Wurzel									
	3.3	Reihen									
		3.3.1 Absolute Konvergenz									
	3.4	Potenz-Reihen									
	3.5	Berechnung der Fibonacci-Zahlen									
2	Stetige Funktionen 63										
	4.1	Motivation und Definition der Stetigkeit									
	4.2	Bestimmung von Nullstellen									
		4.2.1 Implementierung des Intervall-Halbierungs-Verfahrens									
		4.2.2 Die Regula Falsi									
		4.2.3 Das Sekanten-Verfahren									
		4.2.4 Das Illinois-Verfahren									
5	Diff	erenzierbare Funktionen 80									
•	5.1	Der Begriff der Ableitung									
	5.2	Mittelwert-Sätze									
	5.3	Monotonie und Konvexität									
	5.4	Die Exponential-Funktion									
	0.1	2. Exponential Familion 1.1.1.1.1.1.1.1.1.1.1.1.1.1.1.1.1.1.1.									
6		vendungen 104									
	6.1	Taylor-Reihen									
		6.1.1 Der Abbruch-Fehler bei der Taylor-Reihe									
	6.2	Beispiele von Taylor-Entwicklungen									
		6.2.1 Berechnung des natürlichen Logarithmus									
		6.2.2 Berechnung des Arcus-Tangens									
		6.2.3 Berechnung von $\pi^*$									
	6.3	Polynom-Interpolation									
		6.3.1 Interpolation nach Newton*									
		6.3.2 Der Interpolations-Fehler									

#### INHALTSVERZEICHNIS

	6.4	Der Banach'sche Fixpunkt-Satz	126 127 129								
7 Integral-Rechnung											
	7.1	1 Einführung des Integral-Begriffs									
	7.2	Regeln zur Berechnung von Integralen	145								
		7.2.1 Die Substitutions-Regel	146								
		7.2.2 Partielle Integration	148								
		7.2.3 Das Integral von Umkehr-Funktionen*	149								
		7.2.4 Berechnung der Fläche eines Kreises	150								
	7.3	Berechnung der Bogenlänge									
	7.4	Uneigentliche Integrale	154								
	7.5	Numerische Integration*	156								
		7.5.1 Die Trapez-Regel*	156								
		7.5.2 Die Simpson'sche Regel*	159								
8	Die	Zahlen $\pi$ und $e$ sind irrational	162								
	8.1	Die Euler'sche Zahl $e$ ist irrational	162								
	8.2	Die Kreiszahl $\pi$ ist irrational*									
	8.3	Transzendente Zahlen									
9	Four	rier-Analyse	170								
	9.1	•	171								
	9.2	Konvergenz*									
	9.3	Beispiele									
	3.0	9.3.1 Fourier-Analyse der Sägezahn-Funktion									
10	Run	dungsfehler	179								

# Kapitel 1

# Einleitung

Der vorliegende Text ist das Skript zu meiner Analysis-Vorlesung für Informatiker. Ich habe mich bei der Ausarbeitung dieser Vorlesung im Wesentlichen auf die folgenden Lehrbücher gestützt:

- 1. Analysis I von Otto Forster [1].
- 2. Differential- und Integralrechnung I von Hans Grauert und Ingo Lieb [2].
- 3. Differential and Integral Calculus, Volume 1 von Richard Courant [3].
- 4. Advanced Calculus von Richard Wrede und Murray R. Spiegel [4].

Den Studenten empfehle ich das erste Buch in dieser Liste, denn dieses Buch ist auch in elektronischer Form in unserer Bibliothek vorhanden. Bei dem Buch von Richard Courant ist das Copyright mittlerweile abgelaufen, so dass Sie es im Netz unter

https://archive.org/details/DifferentialIntegralCalculusVolI

finden können. Schließlich enthält das Buch von Wrede und Spiegel eine Vielzahl gelöster Aufgaben und bietet sich daher besonders zum Üben an.

### 1.1 Überblick über die Vorlesung

Im Rahmen der Vorlesung werden die folgenden Gebiete behandelt:

- 1. Da sich die Analysis mit den reellen Zahlen beschäftigt, beginnen wir damit, dass wir die Menge ℝ der reellen Zahlen zunächst axiomatisch als vollständig geordneten Körper charakterisieren und dann die Menge ℝ mit Hilfe von Dedekindschen-Schnitten definieren. Aus Zeitgründen werden wir die Diskussion der Dedekindschen-Schnitte allerdings nur anreißen können.
- 2. Anschließend führen wir den für den Rest der Vorlesung grundlegenden Begriff des Grenzwerts einer Folge ein. Wir werden beispielsweise sehen, dass die Folge  $(b_1,b_2,b_3,\cdots)$ , die induktiv durch

$$b_1 := 1 \quad \text{ und } \quad b_{n+1} := \frac{1}{2} \cdot \left( b_n + \frac{2}{b_n} \right) \text{ für alle } n \in \mathbb{N}$$

definiert ist, gegen die Zahl  $\sqrt{2}$  konvergiert. Im Anschluss daran betrachten wir Reihen. Wir werden beispielsweise sehen, dass für reelle Zahlen q, für die |q| < 1 ist, die Gleichung

$$\sum_{n=0}^{\infty} q^n = \frac{1}{1-q}$$

gilt.

3. Das vierte Kapitel diskutiert die Begriffe Stetigkeit und Differenzierbarkeit.

4. Das fünfte Kapitel zeigt verschiedene Anwendungen der bis dahin dargestellten Theorie. Insbesondere werden Taylor-Reihen diskutiert. Diese können beispielsweise zur Berechnung der trigonometrischen Funktionen verwendet werden. So werden wir beispielsweise sehen, dass wir für eine reelle Zahl x den Wert  $\sin(x)$  durch den Ausdruck

$$\sum_{n=0}^{\infty} (-1)^n \cdot \frac{x^{2 \cdot n + 1}}{(2 \cdot n + 1)!} = x - \frac{1}{3!} \cdot x^3 + \frac{1}{5!} \cdot x^5 \mp \cdots$$

berechnen können. Außerdem diskutieren wir in diesem Kapitel Verfahren zur numerischen Lösung von Gleichungen. Beispielsweise zeigen wir, wie wir die Gleichung

$$\cos(x) = x$$

numerisch mit Hilfe einer Fixpunkt-Iteration lösen können.

- 5. Das sechste Kapitel beschäftigt sich mit der Integralrechnung. Die Integralrechnung beschäftigt sich mit der Berechnung von Flächen unter einer Kurve.
- 6. Im siebten Kapitel zeigen wir, dass die Kreiszahl  $\pi$  und die Eulersche Zahl e keine rationalen Zahlen sind.
- 7. Im achten Kapitel diskutieren wir Fourier-Reihen. Unter anderem werden wir zeigen, dass

$$\sum_{n=1}^{\infty} \frac{1}{n^2} = \frac{\pi^2}{6}$$

gilt. Fourierreihen sind eine der Grundlage der Theorie der digitalen Signalverarbeitung.

8. Das letzte Kapitel gibt einen kurzen Ausblick auf Rundungs-Fehler.

### 1.2 Ziel der Vorlesung

Es ist nicht möglich, im zeitlichen Rahmen der Vorlesung alle Aspekte der Analysis zu behandeln. Insbesondere werden wir viele interessante Anwendungen der Analysis in der Informatik nicht diskutieren können. Eine vollständige Darstellung der Analysis ist aber auch gar nicht das Ziel, das ich mir für diese Vorlesung gesetzt habe: Mir geht es vor allem darum, Ihnen die Fähigkeit zu vermitteln, sich selbstständig in mathematische Fachliteratur einarbeiten zu können. Dazu müssen Sie in der Lage sein, mathematische Beweise sowohl zu verstehen als auch selber entwickeln zu können. Dies ist ein wesentlicher Unterschied zu der Mathematik, an die sich viele von Ihnen auf der Schule gewöhnt haben: Dort werden primär Verfahren vermittelt, mit denen sich spezielle Probleme lösen lassen. Die Kenntnis solcher Verfahren ist allerdings in der Praxis nicht mehr so wichtig wie früher, denn heutzutage werden solche Verfahren als Software-Pakete implementiert und daher besteht kaum mehr Bedarf dafür, diese Verfahren von Hand anzuwenden. Stattdessen wird in dieser Vorlesung der mathematische Beweis-Begriff im Vordergrund stehen. Die Analysis dient uns daher vor allem als ein Beispiel einer mathematischen Theorie, anhand derer wir das mathematische Denken üben können.

#### 1.3 Notation

Genau wie in der Linearen Algrebra auch definieren wir die Menge der natürlichen Zahlen  $\mathbb N$  über die Formel

$$\mathbb{N} := \{0, 1, 2, 3, \cdots\}.$$

Im Übrigen schließt dieses Skript an mein Skript zur linearen Algebra an und verwendet dieselben Notationen, die ich dort zur Definition von Mengen eingeführt habe.

1.4. Eine Bitte Kapitel 1. Einleitung

### 1.4 Eine Bitte

Dieses Skript enthält sicher noch den einen oder anderen Fehler. Sollte Ihnen ein Fehler auffallen, so bitte ich um einen Hinweis unter der Adresse

karl.stroetmann@dhbw-mannheim.de.

Es bringt mir wenig, wenn Sie mich innerhalb meiner Vorlesung auf einen Tipp- oder Rechtschreibfehler hinweisen, denn bis ich dazu komme, einen solchen Fehler zu korrigieren, habe ich ihn meistens schon wieder vergessen. Daher habe ich die Bitte, dass Sie mir etwaige Fehler per Email oder per Discord mitteilen. Wenn Sie mit github vertraut sind, können Sie mir auch gerne einen *Pull Request* schicken.

# Kapitel 2

# Die reellen Zahlen

Bevor wir mit der eigentlichen Analysis beginnen, müssen wir klären, was genau reelle Zahlen überhaupt sind. Anschaulich werden reelle Zahlen zur Angabe von Längen benötigt, denn in der Geometrie reicht es nicht, mit den rationalen Zahlen zu arbeiten. Das liegt daran, dass die Diagonale eines Quadrats der Seitenlänge 1 nach dem Satz des Pythagoras die Länge  $\sqrt{2}$  hat. Wir hatten im ersten Semester aber gesehen, dass es keine rationale Zahl r gibt, so dass  $r^2=2$  ist, denn die Zahl  $\sqrt{2}$  ist irrational. Folglich reichen die rationalen Zahlen für die Geometrie nicht aus. Es gibt mehrere Wege, die Menge  $\mathbb R$  der reellen Zahlen so zu konstruieren, so dass die Gleichung

$$r^{2} = 2$$

eine Lösung in  $\mathbb R$  hat. Bevor wir mit dieser Konstruktion beginnen, wollen wir die Menge der reellen Zahlen axiomatisch charakterisieren. Dazu definieren wir den Begriff des

#### vollständig geordneten Körpers.

Hierbei handelt es sich um ein System von Axiomen, aus dem sich <u>alle</u> weiteren Eigenschaften der reellen Zahlen ableiten lassen. Es lässt sich nämlich zeigen, dass diese Axiomatisierung in dem folgenden Sinne *vollständig* ist: Ist  $\mathbb{K}$  ein vollständig angeordneter Körper, so ist  $\mathbb{K}$  *isomorph* zu  $\mathbb{R}$ : Im Klartext heißt dies, dass es eine Abbildung

$$\varphi: \mathbb{K} \to \mathbb{R}$$

gibt, die jedem Element  $\alpha \in \mathbb{K}$  genau ein Element  $\varphi(\alpha) \in \mathbb{R}$  zuordnet und die mit der Addition, der Multiplikation und der Ordnungs-Relation verträglich ist, für alle  $x,y \in \mathbb{K}$  gilt also

- 1.  $\varphi(x+y) = \varphi(x) + \varphi(y)$ .
- 2.  $\varphi(x \cdot y) = \varphi(x) \cdot \varphi(y)$ ,
- 3.  $\varphi(x) < \varphi(y) \leftrightarrow x < y$ .

Die rein axiomatische Charakterisierung der reellen Zahlen ist philosophisch unbefriedigend, denn dabei bleiben zwei Fragen offen:

- Gibt es überhaupt eine Struktur K, die den Axiomen eines vollständig geordneten Körpers genügt?
   Solange wir nicht sicher sind, dass diese Frage mit "Ja" beantwortet wird, steht unsere gesamte Theorie auf wackeligen Füßen, denn es könnte dann sein, dass es sich um die Theorie der leeren Menge handelt.
- 2. Was genau sind reelle Zahlen?

Es zeigt sich, dass wir die zweite Frage zuerst beantworten müssen, bevor wir die Beantwortung der ersten Frage in Angriff nehmen können.

Wir werden im zweiten Abschnitt zeigen, wie sich die reellen Zahlen aus den rationalen Zahlen mit Hilfe von *Dedekind-Schnitten* erzeugen lassen. Da diese Konstruktion jedoch technisch aufwendig ist, werden wir diesen Abschnitt im Rahmen der Vorlesung aus Zeitgründen nicht in voller Länge diskutieren. Die dort präsentierten Details sind zwar eine gute Übung zur Mengenlehre, werden aber für den weiteren Verlauf der Vorlesung nicht mehr benötigt.

### 2.1 Axiomatische Charakterisierung der reellen Zahlen

Wir erinnern zunächst an die im ersten Semester gegebene Definition eines Körpers.

**Definition 1 (Körper)** Eine Struktur  $\mathcal{K} = \langle K, 0, 1, +, \cdot \rangle$  ist ein *Körper*, falls gilt:

- 1. K ist eine Menge.
- 2.  $0 \in K$  und  $1 \in K$ .
- 3. + und  $\cdot$  sind binäre Operatoren auf K, wir haben

$$+: K \times K \to K \quad \text{ und } \quad \cdot: K \times K \to K.$$

4.  $\langle K, 0, + \rangle$  ist eine *kommutative Gruppe*.

Im Detail heißt dies, dass die folgenden Axiome gelten:

- (a) (x+y) + z = x + (y+z),
- (b) x + y = y + x,
- (c) 0 + x = x,
- (d)  $\exists y \in K : y + x = 0.$

Dasjenige  $y \in K$ , für welches y + x = 0 gilt, wird als das additive Inverse von x bezeichnet und ist, wie wir in der Vorlesung zur linearen Algebra gesehen haben, eindeutig bestimmt. Wir schreiben das additive Inverse des Elements x als -x.

5.  $\langle K \setminus \{0\}, 1, \cdot \rangle$  ist ebenfalls eine *kommutative Gruppe*,

Im Detail sind also die folgenden Axiome erfüllt:

- (a)  $(x \cdot y) \cdot z = x \cdot (y \cdot z)$ ,
- (b)  $x \cdot y = y \cdot x$ ,
- (c)  $1 \cdot x = x$ ,
- (d)  $x \neq 0 \rightarrow \exists y \in K : y \cdot x = 1$ .

Falls  $x \neq 0$  ist, so ist das  $y \in K$ , für welches  $y \cdot x = 1$  gilt, eindeutig bestimmt. Es wird als das *multiplikative Inverse* von x bezeichnet. Wir schreiben das multiplikative Inverse des Elements x als  $x^{-1}$ .

6. Es gilt das *Distributiv-Gesetz*: Für alle  $x, y, z \in K$  haben wir

$$x \cdot (y+z) = x \cdot y + x \cdot z.$$

Weiter benötigen wir die Definition einer linearen Ordnung, die wir ebenfalls wiederholen.

**Definition 2 (Lineare Ordnung)** Ein Paar  $\langle M, \leq \rangle$  ist eine *lineare Ordnung*, falls gilt:

1. M ist eine Menge und  $\leq$  ist eine binäre Relation auf M, es gilt also

$$< \subset M \times M$$
.

2. Zusätzlich gelten die folgenden Axiome:

(a)  $x \le x$ , (Reflexivität)

(b)  $x \le y \land y \le x \to x = y$ , (Anti-Symmetrie)

(c)  $x \le y \land y \le z \to x \le z$ , (Transitivität)

(d) 
$$x \le y \lor y \le x$$
.  $\diamond$  (Linearität)

Die nächste Definition kombiniert die algebraischen Eigenschaften eines Körpers mit den Anordnungs-Axiomen einer linearen Ordnung.

#### Definition 3 (Geordneter Körper)

Eine Struktur  $\mathcal{K} = \langle K, 0, 1, +, \cdot, \leq \rangle$  ist ein *geordneter Körper*, falls

- 1.  $\langle K, 0, 1, +, \cdot, \rangle$  ein Körper und
- 2.  $\langle K, \leq \rangle$  eine lineare Ordnung ist, die mit den arithmetischen Operationen + und  $\cdot$  *verträglich* ist. Dazu müssen die beiden folgenden Bedingungen erfüllt sein:

(a) 
$$\forall x, y, z \in K : (x \le y \to x + z \le y + z),$$

(b) 
$$\forall x, y \in K : (0 \le x \land 0 \le y \to 0 \le x \cdot y).$$

Bevor wir ein Beispiel eines geordneten Körpers präsentieren, geben wir einige Eigenschaften an, die aus den Axiomen eines geordneten Körpers gefolgert werden können. Das folgende Lemma zeigt, dass sich eine Ungleichung bei Multiplikation mit -1 umdreht.

**Lemma 4** Es sei  $\mathcal{K} = \langle K, 0, 1, +, \cdot, \leq \rangle$  ein *geordneter Körper*. Dann gilt

$$x \le y \to -y \le -x$$
 für alle  $x, y \in K$ .

Beweis: Wir gehen davon aus, dass

$$x \leq y$$

gilt und zeigen, dass daraus  $-y \le -x$  folgt. Addieren wir auf beiden Seiten der Ungleichung  $x \le y$  den Wert -y, was nach dem Axiom (A1) erlaubt ist, so erhalten wir die Ungleichung

$$x - y \le 0$$
.

Addieren wir auf beiden Seiten dieser Ungleichung den Wert -x, so erhalten wir

$$-y \le -x$$

und das ist die Behauptung.

Das nächste Lemma zeigt, dass in einem geordneten Körper die Addition mit der Relation  $\leq$  verträglich ist.

**Lemma 5** Es sei  $\mathcal{K} = \langle K, 0, 1, +, \cdot, \leq \rangle$  ein geordneter Körper. Dann gilt

$$x_1 \leq y_1 \wedge x_2 \leq y_2 \to x_1 + x_2 \leq y_1 + y_2 \quad \text{ für alle } x_1, x_2, y_1, y_2 \in K.$$

**Beweis**: Wir setzen voraus, dass sowohl  $x_1 \le y_1$  als auch  $x_2 \le y_2$  gilt und zeigen, dass daraus  $x_1 + x_2 \le y_1 + y_2$  folgt. Addieren wir auf beiden Seiten der Ungleichung

$$x_1 \leq y_1$$

den Wert  $x_2$ , so erhalten wir die Ungleichung

$$x_1 + x_2 \le y_1 + x_2. \tag{1}$$

Addieren wir auf beiden Seiten der Ungleichung

$$x_2 \leq y_2$$

den Wert  $y_1$ , so erhalten wir die Ungleichung

$$y_1 + x_2 \le y_1 + y_2. \tag{2}$$

Setzen wir die Ungleichungen (1) und (2) zusammen, so folgt aus der Transitivität der Relation  $\leq$ , dass

$$x_1 + x_2 \le y_1 + y_2$$

gilt und das war zu zeigen.

Das nächste Lemma zeigt, dass die Relation  $\leq$  mit der Multiplikation nicht-negativer Zahlen verträglich ist.

**Lemma 6** Es sei  $\mathcal{K} = \langle K, 0, 1, +, \cdot, \leq \rangle$  ein geordneter Körper. Dann gilt

$$x \le y \land 0 \le z \to x \cdot z \le y \cdot z$$
 für alle  $x, y, z \in K$ .

**Beweis**: Wir setzen voraus, dass  $x \le y$  und  $0 \le z$  gilt und zeigen, dass in einem geordneten Körper dann auch  $x \cdot z \le y \cdot z$  gelten muss. Addieren wir auf beiden Seiten der Ungleichung

$$x \leq y$$

den Wert -x, so erhalten wir die Ungleichung

$$0 \le y - x$$
.

Zusammen mit der Ungleichung  $0 \le z$  zeigt das Axiom (A2) nun, dass

$$0 \le (y - x) \cdot z$$

gilt, was wegen dem Distributiv-Gesetz zu

$$0 \le y \cdot z - x \cdot z$$

äquivalent ist. Addieren wir auf beiden Seiten dieser Ungleichung den Wert  $x \cdot z$ , so erhalten wir

$$x \cdot z \le y \cdot z$$
.

**Lemma 7** Es sei  $\mathcal{K} = \langle K, 0, 1, +, \cdot, \leq \rangle$  ein geordneter Körper. Dann gilt

$$0 \le x_1 \le y_1 \land 0 \le x_2 \le y_2 \to x_1 \cdot x_2 \le y_1 \cdot y_2$$
 für alle  $x_1, x_2, y_1, y_2 \in K$ .

**Beweis**: Wir setzen voraus, dass sowohl  $0 \le x_1 \le y_1$  als auch  $0 \le x_2 \le y_2$  gilt und zeigen, dass daraus  $x_1 \cdot x_2 \le y_1 \cdot y_2$  folgt. Multiplizieren wir die Ungleichung  $x_1 \le y_1$  mit  $x_2$ , so sehen wir unter Anwendung des gerade bewiesenen Lemmas, dass

$$x_1 \cdot x_2 \le y_1 \cdot x_2 \tag{1}$$

gilt. Multiplizieren wir stattdessen die Ungleichung  $x_2 \leq y_2$  mit  $y_1$ , so erhalten wir die Ungleichung

$$y_1 \cdot x_2 \le y_1 \cdot y_2. \tag{2}$$

Aus den beiden Ungleichungen (1) und (2) folgt mit der Transitivität der Relation  $\leq$  nun

$$x_1 \cdot x_2 \leq y_1 \cdot y_2$$

und das ist die Behauptung.

Das nächste Lemma zeigt, dass sich Ungleichungen bei Multiplikation mit negativen Zahlen umdrehen.

**Lemma 8** Es sei  $\mathcal{K} = \langle K, 0, 1, +, \cdot, \leq \rangle$  ein geordneter Körper. Dann gilt

$$x \le y \land z \le 0 \rightarrow y \cdot z \le x \cdot z$$
 für alle  $x, y, z \in K$ .

**Beweis**: Wenn wir zu beiden Seiten der Ungleichung  $z \le 0$  die Zahl -z addieren, so erhalten wir die Ungleichung

$$0 < -z$$
.

Mit Lemma 6 folgt aus  $x \le y$  und  $0 \le -z$  die Ungleichung

$$x \cdot (-z) \le y \cdot (-z)$$
,

was wir auch als

$$-x \cdot z \le -y \cdot z$$

schreiben können. Daraus folgt mit Lemma 4 die Ungleichung

$$y \cdot z < x \cdot z$$
.

Nun zeigen wir, dass ein Quadrat nie negativ ist.

**Lemma 9** Es sei  $\mathcal{K} = \langle K, 0, 1, +, \cdot, \leq \rangle$  ein geordneter Körper. Dann gilt

$$0 \le x \cdot x$$
 für alle  $x \in K$ .

**Beweis**: Da < eine lineare Ordnung ist, haben wir

$$0 \le x \lor x \le 0.$$

Wir führen eine Fallunterscheidung durch.

1. Fall:  $0 \le x$ .

Multiplizieren wir die Ungleichung  $0 \le x$  mit der Ungleichung  $0 \le x$ , so folgt aus dem Axiom (A2) sofort die Behauptung

$$0 \le x \cdot x$$
.

2. Fall:  $x \le 0$ .

Nach Lemma 4 folgt dann

$$0 < -x$$
.

Multiplizieren wir diese Ungleichung mit sich selbst, so folgt aus dem Axiom (A2)

$$0 \le (-x) \cdot (-x)$$

und wegen  $(-x) \cdot (-x) = x \cdot x$  ist das die Behauptung.

Die letzten Sätze haben die Beziehung zwischen dem additiven Inversen und der Relation  $\leq$  analysiert. Das nächste Lemma zeigt, in welcher Weise die Relation  $\leq$  mit dem multiplikativen Inversen verträglich ist.

**Lemma 10** Es sei  $\mathcal{K} = \langle K, 0, 1, +, \cdot, \leq \rangle$  ein geordneter Körper. Dann gilt

$$0 \leq x \wedge x \neq 0 \to 0 \leq x^{-1} \quad \text{ für alle } x \in K.$$

**Beweis**: Es gelte  $0 \le x$ . Aus der Tatsache, dass  $x \ne 0$  ist, folgt, dass  $x^{-1}$  definiert ist. Nach dem letzten Lemma gilt daher

$$0 < x^{-1} \cdot x^{-1}$$

Multiplizieren wir diese Ungleichung mit x, so zeigt Lemma 6, dass dann auch

$$0 \cdot x \leq x^{-1} \cdot x^{-1} \cdot x$$

gilt und wegen  $0 \cdot x = 0$  und  $x^{-1} \cdot x^{-1} \cdot x$  ist diese Aussage äquivalent zu der Behauptung.

 $\Diamond$ 

**Lemma 11** Es sei  $\mathcal{K} = \langle K, 0, 1, +, \cdot, \leq \rangle$  ein geordneter Körper. Dann gilt

$$0 \le x \le y \land x \ne 0 \rightarrow y^{-1} \le x^{-1}$$
 für alle  $x, y \in K$ .

Aufgabe 1: Beweisen Sie diese Behauptung.

**Beispiel**: Die Struktur  $\langle \mathbb{Q}, 0, 1, +, \cdot, \leq \rangle$  ist ein geordneter Körper, wenn wir die Operationen + und und die Relation  $\leq$  wie im ersten Semester vorgeführt auf den rationalen Zahlen definieren.

**Aufgabe 2**: Zeigen Sie, dass es nicht möglich ist, auf der Menge  $\mathbb C$  der komplexen Zahlen eine Relation  $\leq$  so zu definieren, dass  $\langle \mathbb C, 0, 1, +, \cdot, \leq \rangle$  ein geordneter Körper ist.

**Definition 12 (Absolut-Betrag)** Es sei  $\mathcal{K} = \langle K, 0, 1, +, \cdot, \leq \rangle$  ein *geordneter Körper*. Dann definieren wir den *Absolut-Betrag* |x| eines Elements  $x \in K$  wie folgt:

$$|x| := \left\{ \begin{array}{rl} x & \text{falls } 0 \le x; \\ -x & \text{sonst.} \end{array} \right. \diamond$$

**Aufgabe 3**: Es sei  $\mathcal{K} = \langle K, 0, 1, +, \cdot, \leq \rangle$  ein *geordneter Körper*. Weisen Sie die folgenden Eigenschaften des Absolut-Betrags nach:

- (a)  $0 \le |x|$
- (b)  $x \le |x|$  und  $-x \le |x|$
- (c) |-x| = |x|
- (d)  $|x| = 0 \leftrightarrow x = 0$
- (e)  $|x \cdot y| = |x| \cdot |y|$
- (f)  $|x+y| \le |x| + |y|$

**Hinweis**: Wir haben die Funktion  $x \mapsto |x|$  durch eine Fall-Unterscheidung definiert. Daher können Sie die oben angegebenen Behauptungen am Besten mit Hilfe von Fall-Unterscheidungen nachweisen.  $\diamond$ 

Die Struktur  $\langle \mathbb{Q}, 0, 1, +, \cdot, \leq \rangle$  ist für die Zwecke der Analysis nicht ausreichend, da sie in einer noch näher zu spezifizierenden Weise *unvollständig* ist. Zur Präzisierung dieser Aussage benötigen wir den Begriff einer *vollständigen Ordnung*, die ihrerseits auf dem Begriff des *Supremums* basiert, welchselben wir jetzt einführen.

**Definition 13 (Supremum)** Es sei  $\langle M, \leq \rangle$  eine lineare Ordnung. Wir nennen die Menge  $A \subseteq M$  nach oben beschränkt, falls es ein  $y \in M$  gibt, so dass gilt:

$$\forall x \in A : x \leq y$$
.

Dieses y bezeichnen wir dann als eine *obere Schranke* der Menge A. Ein Element  $s \in M$  ist das *Supremum* der Menge A, wenn s die *kleinste obere Schranke* der Menge A ist, wenn also

$$\forall x \in A: x \leq s \quad \text{ und } \quad \forall y \in M: \Big( \big( \forall x \in A: x \leq y \big) \rightarrow s \leq y \Big)$$

gilt. In diesem Fall schreiben wir

$$s = \sup(A)$$
.

**Bemerkung**: Gelegentlich kommt in der Vorlesung an dieser Stelle die Frage, wie sich das Supremum zu dem Maximum verhält. Falls eine Menge M ein Maximum hat, dann ist dieses Maximum natürlich auch das Supremum der Menge. Umgekehrt gilt: Ist das Supremum s einer Menge M ein Element von M, so ist das Supremum auch das Maximum. Allerdings gibt es sehr wohl Mengen, die zwar nach oben beschränkt sind, aber trotzdem kein Maximum haben. Diese Mengen können aber trotzdem ein

Supremum besitzen. Beispielsweise ist die Menge

$$A := \{ r \in \mathbb{Q} \mid x < 0 \}$$

nach oben beschränkt. Diese Menge hat aber kein Maximum, denn für jedes  $x \in A$  gilt einerseits

$$x < \frac{x}{2}$$
 und andererseits  $\frac{x}{2} \in A$ .

Damit kann x nicht Maximum der Menge A sein. Offenbar ist die Menge A aber nach oben beschränkt. Das Supremum dieser Menge ist die Zahl 0.

Es folgt der zentrale Begriff dieses Abschnitts.

**Definition 14 (Vollständige Ordnung)** Ein Paar  $\langle M, \leq \rangle$  bestehend aus einer Menge M und einer Relation  $\leq \subseteq M \times M$  ist eine *vollständige* Ordnung genau denn, wenn folgendes gilt:

- 1. Das Paar  $\langle M, \leq \rangle$  ist eine lineare Ordnung.
- 2. Zu jeder nicht-leeren und nach oben beschränkten Menge  $A\subseteq M$  existiert ein Supremum in M.

**Bemerkung**: Das Paar  $\langle \mathbb{Q}, \leq \rangle$  ist <u>keine</u> vollständige Ordnung, denn wenn wir die Menge A als

$$A := \{ r \in \mathbb{Q} \mid r^2 \le 2 \}$$

definieren, so ist die Menge A nach oben beschränkt, weil die Zahl 2 eine obere Schranke von A ist. Die Menge A hat aber keine kleinste obere Schranke. Anschaulich liegt das daran, dass die kleinste obere Schranke der Menge A die Zahl  $\sqrt{2}$  ist, aber aus dem ersten Semester wissen wir, dass  $\sqrt{2}$  keine rationale Zahl ist.

Analog zum Begriff des Supremums können wir auch den Begriff des Infimums definieren.

**Definition 15 (Infimum)** Es sei  $\langle M, \leq \rangle$  eine lineare Ordnung. Wir nennen die Menge  $B \subseteq M$  nach unten beschränkt, falls es ein  $y \in M$  gibt, so dass

$$\forall x \in B : y \leq x$$

gilt. Ein solches y bezeichnen wir als *untere Schranke* von B. Ein Element  $i \in M$  ist das *Infimum* einer Menge B, wenn i die größte untere Schranke von B ist, wenn also

$$\forall x \in B : i \le x \quad \text{ und } \quad \forall y \in M : \left( \left( \forall x \in B : y \le x \right) \to y \le i \right)$$

gilt. In diesem Fall schreiben wir

$$i = \inf(B)$$
.

**Aufgabe 4**: Es sei  $\langle M, \leq \rangle$  eine vollständige lineare Ordnung. Zeigen Sie, dass für jede Teilmenge  $B \subseteq M$ , die nicht-leer und nach unten beschränkt ist, ein Infimum existiert.

Hinweis: Betrachten Sie die Menge

$$A := \{ x \in M \mid \forall y \in B : x \le y \}$$

der unteren Schranken von B. Diese Menge ist nicht leer, denn nach Voraussetzung ist B nach unten beschränkt. Außerdem ist A nach oben beschränkt, denn jedes Element aus der Menge B ist eine obere Schranke von A. Da nach Voraussetzung das Paar  $\langle M, \leq \rangle$  eine vollständige lineare Ordnung ist, besitzt A also ein Supremum. Zeigen Sie, dass dieses Supremum auch das Infimum von B ist.

Wir kommen nun zur zentralen Definition dieses Abschnitts.

#### Definition 16 (Vollständig angeordneter Körper)

Eine Struktur  $\mathcal{K} = \langle K, 0, 1, +, \cdot, \leq \rangle$  ist ein vollständig angeordneter Körper genau dann, wenn gilt:

1. Die Struktur  $\mathcal{K}$  ist ein geordneter Körper.

**\rightarrow** 

2. Das Paar  $\langle K, \leq \rangle$  ist eine vollständige Ordnung.

**Theorem 17** Die Struktur  $\langle \mathbb{R}, 0, 1, +, \cdot, \leq \rangle$  der reellen Zahlen ist ein vollständig geordneter Körper.  $\diamond$ 

Einen Beweis diese Behauptung können wir jetzt noch nicht erbringen, denn wir haben bisher gar nicht gesagt, wie die Menge  $\mathbb R$  der reellen Zahlen formal definiert wird. Die Definition der reellen Zahlen werden wir im nächsten Abschnitt mit Hilfe der sogenannten *Dedekind-Schnitte* liefern. Für praktische Rechnungen sind Dedekind-Schnitte viel zu schwerfällig. Wir skizzieren daher zum Abschluss dieses Abschnitts noch eine andere Konstruktion der reellen Zahlen als *unendliche Dezimalbrüche*, die auf Simon Stevin (1548-1620) zurück geht. Um diese Konstruktion verstehen zu können, betrachten wir eine positive reelle Zahl  $x \in \mathbb{R}$  abstrakt als gegeben und untersuchen, wie wir x in der Form

$$x = m + \sum_{k=1}^{\infty} b_k \cdot \frac{1}{10^k}$$

so darstellen können, dass folgendes gilt:

- 1.  $m \in \mathbb{N}$  und
- 2.  $b_k \in \{0, \cdots, 9\}$ .

Die Zahl  $b_k$  kann damit als die k-te Stelle von x hinter dem Komma interpretiert werden. Die Berechnung der Zahlen m und  $b_k$  verläuft für ein gegebenes positives  $x \in \mathbb{R}$  wie folgt:

- 1.  $m := \max(\{n \in \mathbb{N} \mid n \le x\})$ . m ist also die größte ganze Zahl, die nicht größer als x ist.
- 2. Die Zahlen  $b_k$  werden für alle  $k \in \mathbb{N} \setminus \{0\}$  induktiv definiert.

I.A.: k = 1. Wir setzen

$$b_1 := \max \left( \left\{ z \in \{0, 1, \cdots, 9\} \mid m + z \cdot \frac{1}{10} \le x \right\} \right).$$

I.S.:  $k\mapsto k+1$ . Nach Induktions-Voraussetzung sind die Zahlen  $b_1,\, \cdots,\, b_k$  bereits definiert. Daher können wir  $b_{k+1}$  als

$$b_{k+1} := \max \Big( \Big\{ z \in \{0, 1, \dots, 9\} \mid m + \sum_{i=1}^{k} b_i \cdot \frac{1}{10^i} + z \cdot \frac{1}{10^{k+1}} \le x \Big\} \Big).$$

definieren.

Insgesamt gilt mit dieser Konstruktion

$$x = m + \sum_{k=1}^{\infty} b_k \cdot \frac{1}{10^k}.$$

Diese Behauptung können wir allerdings zum jetzigen Zeitpunkt nicht beweisen, denn wir haben ja noch gar nicht formal definiert, welchen Wert wir einer unendlichen Reihe der Form

$$\sum_{k=1}^{\infty} b_k \cdot \frac{1}{10^k}$$

zuordnen. Stattdessen können wir sagen, dass

$$x = \sup \left( \left\{ m + \sum_{i=1}^{k} b_i \cdot \frac{1}{10^i} \mid k \in \mathbb{N} \right\} \right)$$

gilt, denn die Menge

$$\left\{ m + \sum_{i=1}^{k} b_i \cdot \frac{1}{10^i} \mid k \in \mathbb{N} \right\}$$

ist offenbar durch x nach oben beschränkt und es lässt sich zeigen, dass es keine obere Schranke y für diese Menge gibt, die kleiner als x ist. Für den Rest der Vorlesung reicht es aus, wenn Sie sich die reellen Zahlen wie oben skizziert als unendliche Dezimalbrüche vorstellen.

#### 2.2 Die formale Konstruktion der reellen Zahlen\*

Bis jetzt haben wir so getan, als wüssten wir schon, was reelle Zahlen sind und haben Ihre Eigenschaften in Form von Axiomen angegeben. Wir wissen aber noch gar nicht, ob es tatsächlich eine Struktur gibt, die diesen Axiomen genügt. Diesen Nachweis werden wir jetzt mit Hilfe der Mengenlehre erbringen. Dabei gehen wir von folgendem Beispiel aus: Wir wissen, dass  $\sqrt{2}$  kein Element der rationalen Zahlen ist. Wir können aber  $\sqrt{2}$  durch zwei Mengen rationaler Zahlen beschreiben, wenn wir

$$M_1 := \{ q \in \mathbb{Q} \mid q \le 0 \lor q^2 < 2 \}$$
 und  $M_2 := \{ q \in \mathbb{Q} \mid q \ge 0 \land 2 < q^2 \},$ 

definieren, denn dann liegt  $\sqrt{2}$  gerade zwischen  $M_1$  und  $M_2$ . Versuchen wir die diesem Beispiel zugrunde liegende Idee zu präzisieren, so kommen wir zur nun folgende Definition eines *Dedekind'schen-Schnittes*.

#### **Definition 18 (Dedekind-Schnitt)**

Ein Paar  $\langle M_1, M_2 \rangle$  heißt Dedekind-Schnitt (Richard Dedekind, 1831-1916) falls folgendes gilt:

- 1.  $M_1 \subseteq \mathbb{Q}$ ,  $M_2 \subseteq \mathbb{Q}$ .
- 2.  $M_1 \neq \emptyset$ ,  $M_2 \neq \emptyset$ .
- 3.  $\forall x_1 \in M_1 : \forall x_2 \in M_2 : x_1 < x_2$ .

Diese Bedingung besagt, dass alle Elemente aus  $M_1$  kleiner als alle Elemente aus  $M_2$  sind. Diese Bedingung bezeichnen wir als die *Trennungs-Eigenschaft*.

- 4.  $M_1 \cup M_2 = \mathbb{Q}$ .
- 5.  $M_1$  hat kein Maximum.

Da alle Elemente aus  $M_1$  kleiner als alle Elemente von  $M_2$  sind und da darüber hinaus  $M_2 \neq \emptyset$  ist, ist  $M_1$  sicher nach oben beschränkt. Aber wenn für ein y

$$\forall x \in M_1 : x \leq y$$

gilt, dann darf y eben kein Element von  $M_1$  sein. Als Formel schreibt sich das als

$$\forall y \in \mathbb{Q} : ((\forall x \in M_1 : x \le y) \to y \notin M_1).$$

Beispiel: Definieren wir

$$M_1 := \{ x \in \mathbb{Q} \mid x \le 0 \lor x^2 < 2 \}$$
 und  $M_2 := \{ x \in \mathbb{Q} \mid x > 0 \land x^2 > 2 \},$ 

so enthält  $M_1$  alle die Zahlen, die kleiner als  $\sqrt{2}$  sind, während  $M_2$  alle Zahlen enthält, die größer als  $\sqrt{2}$  sind. Das Paar  $\langle M_1, M_2 \rangle$  ist dann ein Dedekind-Schnitt. Intuitiv spezifiziert dieser Dedekind-Schnitt die Zahl  $\sqrt{2}$ .

Bei einem Dedekind-Schnitt  $\langle M_1, M_2 \rangle$  ist die Menge  $M_2$  durch die Angabe von  $M_1$  bereits vollständig festgelegt, denn aus der Gleichung  $M_1 \cup M_2 = \mathbb{Q}$  folgt sofort  $M_2 = \mathbb{Q} \backslash M_1$ . Die Frage ist nun, welche Eigenschaften eine Menge M haben muss, damit umgekehrt das Paar  $\langle M, \mathbb{Q} \backslash M \rangle$  ein Dedekind-Schnitt ist. Die Antwort auf diese Frage wird in der nun folgenden Definition einer *Dedekind-Menge* gegeben.

**Definition 19 (Dedekind-Menge)** Eine Menge  $M \subseteq \mathbb{Q}$  ist eine *Dedekind-Menge* genau dann, wenn die folgenden Bedingungen erfüllt sind.

- 1.  $M \neq \emptyset$ ,
- 2.  $M \neq \mathbb{O}$ .

3.  $\forall x, y \in \mathbb{Q} : (y < x \land x \in M \to y \in M).$ 

Die letzte Bedingung besagt, dass M nach unten abgeschlossen ist: Wenn eine Zahl x in M liegt, dann liegt auch jede Zahl, die kleiner als x ist, in M.

4. Die Menge M hat kein Maximum, es gibt also kein  $m \in M$ , so dass

$$x \le m$$
 für alle  $x \in M$  gilt.

Diese Bedingung können wir auch etwas anders formulieren: Wenn  $x \in M$  ist, dann finden wir immer ein  $y \in M$ , dass noch größer als x ist, denn sonst wäre x ja das Maximum von M. Formal können wir das als

$$\forall x \in M : \exists y \in M : x < y$$

schreiben.

**Aufgabe 5**: Zeigen Sie, dass eine Menge  $M\subseteq\mathbb{Q}$  genau dann eine Dedekind-Menge ist, wenn das Paar  $\langle M,\mathbb{Q}\backslash M\rangle$  ein Dedekind-Schnitt ist.

**Lösung**: Da es sich bei der zu beweisenden Aussage um eine Äquivalenz-Aussage handelt, zerfällt der Beweis in zwei Teile.

" $\Rightarrow$ ": Zunächst nehmen wir an, dass  $M\subseteq \mathbb{Q}$  eine Dedekind-Menge ist. Wir haben zu zeigen, dass dann  $\langle M, \mathbb{Q} \backslash M \rangle$  ein Dedekind-Schnitt ist. Von den zu überprüfenden Eigenschaften ist nur die Trennungs-Eigenschaft nicht offensichtlich. Sei als  $x\in M$  und  $y\in \mathbb{Q}\backslash M$ . Wir haben zu zeigen, dass dann

gilt. Wir führen diesen Nachweis indirekt und nehmen an, dass  $y \leq x$ . Da M nach unten abgeschlossen ist, folgt daraus aber  $y \in M$ , was im Widerspruch zu  $y \in \mathbb{Q} \backslash M$  steht. Dieser Widerspruch zeigt, dass x < y ist und das war zum Nachweis der Trennungs-Eigenschaft zu zeigen.

" $\Leftarrow$ ": Nun nehmen wir an, dass  $\langle M, \mathbb{Q} \backslash M \rangle$  ein Dedekind-Schnitt ist und zeigen, dass dann M eine Dedekind-Menge sein muss. Von den zu überprüfenden Eigenschaften ist nur Tatsache, dass M nach unten abgeschlossen ist, nicht offensichtlich. Sei also  $x \in M$  und y < x. Wir haben zu zeigen, dass dann y ebenfalls ein Element von M ist. Wir führen diesen Nachweis indirekt und nehmen  $y \in \mathbb{Q} \backslash M$  an. Aufgrund der Trennungs-Eigenschaft des Dedekind-Schnitts  $\langle M, \mathbb{Q} \backslash M \rangle$  muss dann

gelten, was im Widerspruch zu y < x steht. Dieser Widerspruch zeigt, dass  $y \in M$  gilt und das war zu zeigen.  $\Box$ 

Die letzte Aufgabe hat gezeigt, dass Dedekind-Schnitte und Dedekind-Mengen zu einander äquivalent sind. Daher werden wir im Folgenden mit Dedekind-Mengen arbeiten, denn das macht die Notation einfacher. Wir definieren dazu  $\mathcal D$  als die Menge aller rationalen Dedekind-Mengen, wir setzen also

$$\mathcal{D}:=\left\{M\in 2^{\mathbb{Q}}\mid M \text{ ist Dedekind-Menge}\right\}.$$

Wir wollen zeigen, dass wir die Menge  $\mathbb R$  der reellen Zahlen als die Menge  $\mathcal D$  definieren können. Dazu müssen wir nun zeigen, wie sich auf der Menge  $\mathcal D$  die arithmetischen Operationen Addition, Subtraktion, Multiplikation und Division definieren lassen und wie die Relation  $\leq$  für zwei Dedekind-Schnitte festgelegt werden kann. Zusätzlich müssen wir nachweisen, dass wir mit diesen Definitionen einen vollständig angeordneten Körper konstruieren. Wir beginnen mit der Definition der Relation  $\leq$ .

**Aufgabe 6**: Auf der Menge  $\mathcal{D}$  definieren wir eine binäre Relation  $\leq$  durch die Festsetzung

$$A \leq B \ \stackrel{\mathrm{def}}{\Longleftrightarrow} \ A \subseteq B \quad \text{ für alle } A, B \in \mathcal{D}.$$

 $\Diamond$ 

Zeigen Sie, dass die so definierte Relation  $\leq$  eine lineare Ordnung auf der Menge  $\mathcal{D}$  ist.

**Lösung**: Es ist zu zeigen, dass die Relation  $\leq$  reflexiv, anti-symmetrisch und transitiv ist und dass außerdem die Linearitäts-Eigenschaft

$$A \leq B \vee B \leq A$$
 für alle Dedekind-Mengen  $A, B \in \mathcal{D}$ 

gilt. Die Reflexivität, Anti-Symmetrie und Transitivität der Relation  $\leq$  folgen sofort aus der Reflexivität, Anti-Symmetrie und Transitivität der Teilmengen-Relation  $\subseteq$ . Es bleibt, den Nachweis der Linearitäts-Eigenschaft zu führen. Seien also  $A,B\in\mathcal{D}$  gegeben. Falls A=B ist, gilt sowohl  $A\subseteq B$  als auch  $B\subseteq A$ , woraus sofort  $A\leq B$  und  $B\leq A$  folgt. Wir nehmen daher an, dass  $A\neq B$  ist. Dann gibt es zwei Möglichkeiten:

1. Fall: Es existiert ein  $x \in \mathbb{Q}$  mit  $x \in A$  und  $x \notin B$ .

Wir zeigen, dass dann  $B\subseteq A$ , also  $B\le A$  gilt. Zum Nachweis der Beziehung  $B\subseteq A$  nehmen wir an, dass  $y\in B$  ist und müssen  $y\in A$  zeigen.

Wir behaupten, dass y < x ist und führen den Beweis dieser Behauptung indirekt, nehmen also  $x \le y$  an. Da die Dedekind-Menge B nach unten abgeschlossen ist und  $y \in B$  ist, würde daraus

$$x \in B$$

folgen, was im Widerspruch zu der in diesem Fall gemachten Annahme  $x \not\in B$  steht. Also haben wir

$$y < x$$
.

Da die Menge A als Dedekind-Menge nach unten abgeschlossen ist und  $x \in A$  ist, folgt

$$y \in A$$
,

so dass wir  $B \subseteq A$  gezeigt haben.

2. Fall: Es existiert ein  $x \in \mathbb{Q}$  mit  $x \in B$  und  $x \notin A$ .

Dieser Fall ist offenbar analog zum ersten Fall.

**Aufgabe 7**: Zeigen Sie, dass jede nicht-leere und in  $\mathcal{D}$  nach oben beschränkte Menge  $\mathcal{M}\subseteq\mathcal{D}$  ein Supremum  $S\in\mathcal{D}$  hat.

**Hinweis**: Sie können das Supremum von  $\mathcal M$  als die Vereinigung aller Mengen aus  $\mathcal M$  definieren. Es gilt also

$$\sup(\mathcal{M}) = | \mathsf{J}\mathcal{M} := \{ x \in \mathbb{Q} \mid \exists A \in \mathcal{M} : x \in A \}.$$

Als nächstes definieren wir eine Addition auf Dedekind-Mengen.

#### Definition 20 (Addition von Dedekind-Mengen)

Es seien A und B Dedekind-Mengen. Dann definieren wir die Summe A+B wie folgt:

$$A + B := \{ x + y \mid x \in A \land y \in B \}.$$

**Aufgabe 8**: Es seien  $A, B \in \mathcal{D}$ . Zeigen Sie, dass dann auch  $A + B \in \mathcal{D}$  ist.

**Lösung**: Wir zeigen, dass A + B eine Dedekind-Menge ist.

1. Wir zeigen  $A + B \neq \{\}$ .

Da A eine Dedekind-Menge ist, gibt es ein Element  $a \in A$  und da B ebenfalls eine Dedekind-Menge ist, gibt es auch ein Element  $b \in B$ . Nach Definition von A+B folgt dann  $a+b \in A+B$  und damit gilt  $A+B \neq \{\}$ .

2. Wir zeigen  $A + B \neq \mathbb{Q}$ 

Da A und B Dedekind-Mengen sind, gilt  $A \neq \mathbb{Q}$  und  $B \neq \mathbb{Q}$ . Also gibt es  $x,y \in \mathbb{Q}$  mit  $x \notin A$  und  $y \notin B$ . Wir zeigen, dass dann  $x+y \notin A+B$  ist und führen diesen Nachweis indirekt. Wir nehmen also an, dass

$$x + y \in A + B$$

gilt. Nach Definition der Menge A+B gibt es dann ein  $a \in A$  und ein  $b \in B$ , so dass

$$x + y = a + b$$

ist. Aus  $x \not\in A$  und  $a \in A$  folgt, dass

ist, denn da A eine Dedekind-Menge ist, würde aus  $x \leq a$  sofort  $x \in A$  folgern. Weil B eine Dedekind-Menge ist, gilt dann auch

$$b < y$$
.

Addieren wir diese beiden Ungleichungen, so erhalten wir

$$a+b < x+y$$
,

was im Widerspruch zu der Gleichung x + y = a + b steht.

3. Wir zeigen, dass die Menge A+B nach unten abgeschlossen ist.

Sei also  $x \in A+B$  und y < x. Nach Definition von A+B gibt es dann ein  $a \in A$  und ein  $b \in B$ , so dass x=a+b gilt. Wir definieren

$$c:=x-y, \quad u:=a-\frac{1}{2}\cdot c \quad \text{ und } \quad v:=b-\frac{1}{2}\cdot c.$$

Aus y < x folgt zunächst c > 0 und daher gilt u < a und v < b. Da  $a \in A$  ist und die Menge A als Dedekind-Menge nach unten abgeschlossen ist, folgt  $u \in A$ . Analog sehen wir, dass auch  $v \in B$  ist. Insgesamt folgt dann

$$u + v \in A + B$$
.

Wir haben aber

$$u+v = a - \frac{1}{2} \cdot c + b - \frac{1}{2} \cdot c$$

$$= a+b-c$$

$$= a+b-(x-y) \qquad \text{denn } c = x-y$$

$$= x-(x-y) \qquad \text{denn } x = a+b$$

$$= y$$

Wegen  $u+v \in A+B$  haben wir insgesamt  $y \in A+B$  nachgewiesen, was zu zeigen war.

4. Wir zeigen, dass die Menge A+B kein Maximum enthält.

Wir führen den Beweis indirekt und nehmen an, dass ein  $m \in A+B$  existiert, so dass  $m=\max(A+B)$  gilt. Nach Definition der Menge A+B gibt es dann ein  $a \in A$  und ein  $b \in B$  so dass m=a+b ist. Sei nun  $u \in A$ . Wir wollen zeigen, dass  $u \leq a$  ist. wäre u > a, dann würde auch

$$u + b > a + b$$

gelten, und da  $u+b\in A+B$  ist, könnte m dann nicht das Maximum der Menge A+B sein. Also gilt  $u\leq a$ . Dann ist aber a das Maximum der Menge A und außerdem in A enthalten. Dies ist ein Widerspruch zu der Voraussetzung, dass A eine Dedekind-Menge ist.

Aufgabe 9: Zeigen Sie, dass die Menge

$$O := \{ x \in \mathbb{Q} \mid x < 0 \}$$

eine Dedekind-Menge ist.

**Lösung**: Wir zeigen, dass O eine Dedekind-Menge ist, indem wir die einzelnen Eigenschaften einer Dedekind-Menge nachweisen.

- 1.  $O \neq \{\}$ , denn es gilt  $-1 \in O$ .
- 2.  $O \neq \mathbb{Q}$ , denn es gilt  $1 \notin O$ .
- 3. Die Menge O ist nach unten abgeschlossen.

Sei  $x \in O$  und y < x. Nach Definition von O haben wir x < 0 und aus y < x und x < 0 folgt y < 0, also gilt nach Definition der Menge O auch  $y \in O$ .

4. Die Menge O enthält kein Maximum, denn falls m das Maximum der Menge O wäre, dann wäre m<0 und daraus folgt sofort  $\frac{1}{2}\cdot m<0$ . Damit wäre dann nach Definition der Menge O auch

$$\frac{1}{2} \cdot m \in O.$$

 ${\sf Da}\ m < 0$  ist gilt andererseits aber

$$m < \frac{1}{2} \cdot m$$

und dann kann m nicht das Maximum der Menge O sein. Folglich hat die Menge O kein Maximum

**Aufgabe 10**: Zeigen Sie, dass die Menge O das links-neutrale Element bezüglich der Addition von Dedekind-Mengen ist.

Lösung: Wir zeigen, dass

$$O + A = A$$

gilt. Wir spalten den Nachweis dieser Mengen-Gleichheit in den Nachweis zweier Inklusionen auf.

1. " $\subseteq$ ": Es sei  $u \in O + A$ . Wir müssen  $u \in A$  zeigen.

Nach Definition von O+A existiert ein  $o\in O$  und ein  $a\in A$  mit u=o+a. Aus  $o\in O$  folgt o<0. Also haben wir

und da A als Dedekind-Menge nach unten abgeschlossen ist, folgt  $u \in A$ .

2. " $\supseteq$ ": Sei nun  $a \in A$ . Zu zeigen ist  $a \in O + A$ .

Da die Menge A eine Dedekind-Menge ist, kann a nicht das Maximum der Menge A sein. Folglich gibt es ein  $b \in A$ , dass größer als a ist, wir haben also

$$a < b$$
.

Wir definieren u := a - b. Aus a < b folgt dann u < 0 und damit gilt  $u \in O$ . Also haben wir

$$u+b \in O+A$$
.

Andererseits gilt

$$u + b = (a - b) + b = a,$$

so dass wir insgesamt  $a \in O + A$  gezeigt haben.

 $\Diamond$ 

**Aufgabe 11**: Zeigen Sie, dass für die Addition von Dedekind-Mengen sowohl das Kommutativ-Gesetz als auch das Assoziativ-Gesetz gilt.

Als nächstes überlegen wir, wie wir für eine Dedekind-Menge A das additive Inverse -A definieren können. Ist  $A \in \mathcal{D}$  eine Dedekind-Menge, die wir als die reelle Zahl x interpretieren wollen, so gilt

$$A = \{ q \in \mathbb{Q} \mid q < x \}.$$

Daher liegt es nahe zu fordern, dass

$$-A = \{ q \in \mathbb{Q} \mid q < -x \}$$

gilt. Wir betrachten zunächst den Fall, dass  $x \notin \mathbb{Q}$  ist. Dann gilt

$$\begin{array}{cccc} q < -x & \Leftrightarrow & \neg(-x \leq q) \\ & \Leftrightarrow & \neg(-x < q \vee -x = q) \\ & \Leftrightarrow & \neg(-x < q) & \mathrm{denn} \ x \not \in \mathbb{Q} \\ & \Leftrightarrow & \neg(x > -q) \\ & \Leftrightarrow & \neg(-q < x) \\ & \Leftrightarrow & \neg(-q \in A) \\ & \Leftrightarrow & -q \not \in A. \end{array}$$

In diesem Fall können wir daher -A als

$$-A := \{ q \in \mathbb{Q} \mid -q \not\in A \}$$

definieren. Leider funktioniert diese Definition dann nicht mehr, wenn die Menge

$$\{q \in \mathbb{Q} \mid -q \notin A\}$$

ihr Maximum enthält. Dieser Fall würde beispielsweise eintreten, wenn wir

$$A := \{ q \in \mathbb{Q} \mid q < 1 \}$$

hätten, denn die Bedingung

$$\neg (-q < 1)$$
 ist zu  $q \le -1$ 

äquivalent und die Menge

$$\{q \in \mathbb{Q} \mid q < -1\}$$

ist keine Dedekind-Menge, da das Maximum dieser Menge -1 ist und diese Zahl ist selber ein Element dieser Menge. Daher definieren wir zunächst für eine beliebige Menge  $A\subseteq \mathbb{Q}$  die Menge  $A^*$ , die aus A dadurch entsteht, dass wir das Maximum der Menge A aus A entfernen, wenn es erstens existiert und zweitens ein Element der Menge A ist.

$$A^* := \left\{ \begin{array}{ll} A - \{ \max(A) \} & \text{falls } \max(A) \text{ existiert und } \max(A) \in A \text{ ist,} \\ A & \text{sonst.} \end{array} \right.$$

Damit können wir nun -A durch die Festlegung

$$-\!A := \{q \in \mathbb{Q} \mid -q \not \in A\}^* = \{-q \in \mathbb{Q} \mid q \not \in A\}^*$$

definieren.

**Satz 21** Die Menge -A ist eine Dedekind-Menge.

Beweis: Wir zeigen zunächst, dass die Menge

$$B := \{ q \in \mathbb{Q} \mid -q \not\in A \}$$

nach unten abgeschlossen ist. Sei also  $x \in B$  und y < x. Wir führen den Nachweis indirekt und nehmen  $y \notin B$  an. Aus  $y \notin B$  folgt

$$-y \in A$$
.

Aus  $x \in B$  folgt

$$-x \not\in A$$
.

Aus y < x folgt

$$-x < -y$$

Da A nach unten abgeschlossen ist, folgt aus  $-y \in A$  und -x < -y

$$-x \in A$$
,

was im Widerspruch zu  $-x \notin A$  steht. Also muss  $y \in B$  gelten und wir haben gezeigt, dass die Menge B tatsächlich nach unten abgeschlossen ist.

1. Wir zeigen  $-A \neq \emptyset$ .

Da A eine Dedekind-Menge ist, ist  $A \neq \mathbb{Q}$ . Daher gibt es ein  $y \in \mathbb{Q}$  mit  $y \notin A$ . Definieren wir x := -y, so gilt

$$x \in \{q \in \mathbb{Q} \mid -q \not\in A\} = B.$$

Falls  $\max(B) \notin B$  ist, haben wir -A = B und  $x \in -A$ .

Sollte  $-A = B \setminus \{ \max(B) \}$  und außerdem  $x = \max(B)$  gelten, so gilt x-1 < x und da die Menge B nach unten abgeschlossen ist, ist dann auch  $x-1 \in B$ . Außerdem ist dann  $x-1 < \max(B)$  und damit gilt  $x-1 \in -A$ .

2. Wir zeigen  $-A \neq \mathbb{Q}$ .

Da A eine Dedekind-Menge ist, gilt  $A \neq \emptyset$ . Also gibt es ein  $y \in A$ . Wir definieren

$$q := -y$$
.

Nach der Definition von B folgt nun, dass q kein Element von B ist. Da  $-A \subseteq B$  ist, ist q dann sicher auch kein Element von -A und damit gilt  $-A \neq \mathbb{Q}$ .

3. Wir zeigen, dass die Menge -A nach unten abgeschlossen ist.

Sei  $x \in -A$  und y < x. Wegen  $-A \subseteq B$  folgt  $x \in B$ . Wir haben oben schon gesehen, dass die Menge B nach unten abgeschlossen ist. Also gilt dann auch  $y \in B$  und da y sicher nicht das Maximum von B ist, folgt  $y \in -A$ .

4. Wir zeigen, dass -A kein Maximum hat.

Hier gibt es zwei Fälle zu unterscheiden.

- (a) Die Menge B hat kein Maximum. Dann gilt -A=B und damit hat -A sicher auch kein Maximum.
- (b) Es sei  $m:=\max(B)$  und es gelte  $m\in B$ . Dann haben wir  $-A:=B\setminus\{m\}$  und müssen zeigen, dass auch -A kein Maximum besitzt. Sei dazu  $x\in -A$ . Dann folgt

$$x \in B$$
 und  $x < m$ ,

denn m ist ja das Maximum vom B. für das arithmetische Mittel von x und m gilt dann

$$x < \frac{1}{2} \cdot (x+m) < m$$

und da B nach unten abgeschlossen ist und  $m \in B$  ist, folgt zunächst  $\frac{1}{2} \cdot (x+m) \in B$  und dann auch

$$\frac{1}{2} \cdot (x+m) \in -A$$
,

denn die Mengen -A und B unterscheiden sich ja nur um m. Insgesamt haben wir jetzt zu beliebigem  $x \in -A$  ein  $y := \frac{1}{2} \cdot (x+m)$  gefunden, für das x < y und  $y \in -A$  gilt. Damit kann die Menge -A kein Maximum haben.

**Satz 22** für jede Dedekind-Menge A gilt die Gleichung

$$A + (-A) = O.$$

Beweis: Wir spalten den Nachweis dieser Mengengleicheit in zwei Teile auf.

1. " $\subseteq$ ": Es sei  $x + y \in A + -A$ , also  $x \in A$  und  $y \in -A$ . Wir haben zu zeigen, dass  $x + y \in O$  ist und das ist gleichbedeutend mit x + y < 0.

Wegen  $y \in -A$  gilt nach Definition der Menge -A

$$-y \not\in A$$

wäre  $-y \le x$ , so würde aus der Tatsache, dass A nach unten abgeschlossen und  $x \in A$  ist, sofort  $-y \in A$  folgen, was nicht sein kann. Also gilt

$$-y > x$$

und daraus folgt 0 > x + y, was zu zeigen war.

2. " $\supseteq$ ": Es sei nun  $o \in O$ , also o < 0. Wir müssen ein  $x \in A$  und ein  $y \in -A$  finden, so dass o = x + y gilt, denn dann haben wir  $o \in A + (-A)$  gezeigt.

Wir definieren

$$r := -\frac{1}{2} \cdot o$$
.

Da o < 0 ist, folgt r > 0 und außerdem gilt  $r \in \mathbb{Q}$ . Wir definieren die Menge M als

$$M := \{ n \in \mathbb{Z} \mid n \cdot r \in A \}$$

Da  $A \neq \mathbb{Q}$  ist, gibt es ein  $z \in \mathbb{Q}$  so dass  $z \notin A$  ist. für die Zahlen  $n \in \mathbb{Z}$ , für die  $n \cdot r > z$  ist, folgt dann  $n \notin M$ . Folglich ist die Menge M nach oben beschränkt. Da die Menge A nach unten abgeschlossen ist, ist M sicher nicht leer. Als beschränkte und nicht-leere Menge von natürlichen Zahlen hat M ein Maximum. Wir definieren

$$\widehat{n} := \max(M)$$
.

Dann gilt  $\widehat{n} + 1 \not\in M$ , also

$$(\widehat{n}+1)\cdot r\not\in A.$$

Wir definieren jetzt

$$x := \widehat{n} \cdot r$$
 und  $y := -(\widehat{n} + 2) \cdot r$ .

Nach Definition von  $\widehat{n}$  und M gilt dann  $x \in A$  und aus  $(\widehat{n}+1) \cdot r \not\in A$  folgt

$$-y-r = (\widehat{n}+2) \cdot r - r = (\widehat{n}+1) \cdot r \notin A$$

so dass  $y+r\in B:=\{q\in\mathbb{Q}\mid -q\not\in A\}$  ist. Wegen  $-A:=B^*$  könnte es sein, dass  $y+r\not\in -A$  ist. Dies wäre dann der Fall, wenn  $y+r=\max(B)$  wäre. Da B nach unten abgeschlossen, gilt aber sicher  $y\in B$  und da y< y+r ist, haben wir  $y\ne \max(B)$ . Also gilt  $y\in -A$ . Damit haben wir  $x+y\in A+(-A)$ . Außerdem gilt

$$x + y = \widehat{n} \cdot r - (\widehat{n} + 2) \cdot r = -2 \cdot r = 0$$
, also  $o \in A + (-A)$ .

Damit haben wir  $O \subseteq A + -A$  gezeigt.

Wir überlegen uns nun, wie sich auf der Menge  $\mathcal D$  eine Multiplikation so definieren lässt, so dass  $\mathcal D$  mit dieser Multiplikation und der oben definierten Addition ein Körper wird. Dazu nennen wir eine Dedekind-Menge A positiv, wenn  $0 \in A$  gilt. für zwei positive Dedekind-Mengen A und B lässt sich die Multiplikation  $A \cdot B$  als

$$A \cdot B := \{x \cdot y \mid x \in A \land y \in B \land x > 0 \land y > 0\} \cup \{z \in \mathbb{O} \mid z < 0\}$$

definieren. Wir zeigen, dass die so definierte Menge  $A \cdot B$  eine Dedekind-Menge ist. Dazu weisen wir die einzelnen Eigenschaften getrennt nach.

1. Wir zeigen  $A \cdot B \neq \{\}$ .

Nach Definition von  $A \cdot B$  gilt  $0 = 0 \cdot 0 \in A \cdot B$ . Daraus folgt sofort  $A \cdot B \neq \{\}$ .

2. Wir zeigen  $A \cdot B \neq \mathbb{Q}$ .

Da A und B als Dedekind-Mengen von der Menge  $\mathbb Q$  verschieden sind, gibt es  $u,v\in\mathbb Q$  mit  $u\not\in A$  und  $v\not\in B$ . Wir definieren  $w:=\max(u,v)$ . Dann gilt

$$(\forall x \in A : x < w) \land (\forall y \in B : y < w)$$

Daraus folgt sofort, dass für alle  $x \in A$  und  $y \in B$  die Ungleichung

$$x \cdot y < w \cdot w$$

gilt. Das heißt aber  $w^2 \notin A \cdot B$  und damit ist  $A \cdot B \neq \mathbb{Q}$ .

3. Wir zeigen, dass  $A\cdot B$  nach unten abgeschlossen ist.

Es sei  $x \cdot y \in A \cdot B$  und  $z \in \mathbb{Q}$  mit  $z < x \cdot y$ . Wir müssen  $z \in A \cdot B$  zeigen. Wir führen eine Fall-Unterscheidung danach durch, ob z > 0 ist.

(a) Fall: z > 0. Dann definieren wir

$$\alpha := \frac{z}{x \cdot y}$$

Aus  $z < x \cdot y$  folgt  $\alpha < 1$ . Wir setzen  $u := \alpha \cdot x$  und folglich gilt u < x. Da A nach unten abgeschlossen ist, folgt  $u \in A$ . Damit haben wir insgesamt  $u \cdot y \in A \cdot B$ . Es gilt aber

$$u\cdot y=\alpha\cdot x\cdot y=\frac{z}{x\cdot y}\cdot x\cdot y=z,$$

so dass wir insgesamt  $z \in A \cdot B$  gezeigt haben.

- (b) Fall:  $z \leq 0$ . Dann folgt unmittelbar aus der Definition von  $A \cdot B$ , dass  $z \in A \cdot B$  ist.
- 4. Wir zeigen, dass  $A \cdot B$  kein Maximum hat.

Wir führen den Nachweis indirekt und nehmen an, dass die Menge  $A\cdot B$  eine Maximum c hat. Es gilt dann

$$c \in A \cdot B$$
 und  $\forall z \in A \cdot B : z \le c$ .

Nach Definition von  $A\cdot B$  gibt es dann ein  $a\in A$  und ein  $b\in B$  mit  $c=a\cdot b$ . Wir zeigen, dass a das Maximum der Menge A ist. Sei also  $u\in A$ . Dann gilt

$$u \cdot b \in A \cdot B$$
 und folglich gilt  $u \cdot b \le c = a \cdot b$ .

Teilen wir die letzte Ungleichung durch b, so folgt

$$u \leq a$$

und damit wäre a das Maximum der Menge A. Das ist eine Widerspruch zu der Tatsache, dass A eine Dedekind-Menge ist.

Bisher haben wir das Produkt  $A \cdot B$  nur für den Fall definiert, dass A und B beide positiv sind. Falls A oder B gleich O ist, definieren wir das Produkt wie folgt:

$$A \cdot O := O \cdot B := O.$$

Falls A weder positiv noch gleich O ist, sagen wir, dass A negativ ist. In einem solchen Fall ist -A positiv. Falls A oder B negativ ist, lautet die Definition wie folgt:

2. Fall: A ist positiv, aber B negativ. Dann ist -B positiv und wir können

$$A \cdot B := -(A \cdot (-B))$$

definieren.

3. Fall: B ist positiv, aber A ist negativ. Dann setzen wir

$$A \cdot B := -((-A) \cdot B).$$

4. Fall: A und B sind negativ. Wir definieren

$$A \cdot B := (-A) \cdot (-B).$$

Nun müssten wir noch nachweisen, dass für die so definierte Multiplikation zusammen mit der oben definierten Addition die Körper-Axiome gelten. Bei diesen Beweisen tauchen keine Ideen auf, die wir nicht schon gesehen haben. Daher verzichten wir aus Zeitgründen darauf, diese Beweise im Detail auszuführen und verweisen stattdessen auf die unten angegebene Literatur.

#### Literatur-Hinweise

In dem Buch Grundlagen der Analysis von Edmund Landau [5] wird die oben skizzierte Konstruktion der reellen Zahlen im Detail beschrieben. Auch das Buch "*Principles of Mathematical Analysis*" von Walter Rudin [6] diskutiert die Konstruktion der reellen Zahlen mit Hilfe von Dedekind-Mengen ausführlicher als dies in dem zeitlichen Rahmen meiner Vorlesung möglich ist.

#### 2.3 Geschichte

Die Konstruktion der reellen Zahlen mit Hilfe von Schnitten geht auf Richard Dedekind zurück, der die nach ihm benannten Schnitte in dem Buch Stetigkeit und irrationale Zahlen [7], das im Jahre 1872 erschienen ist, beschrieben hat. Damit war erstmals eine formale Definition des Begriffs der reellen Zahlen gefunden worden. Diese Definition ermöglichte es, die Analysis auf ein solides Fundament zu stellen.

# Kapitel 3

# Folgen und Reihen

Die Begriffe *Folgen* und *Reihen* sowie der Begriff des *Grenzwerts* bilden die Grundlage, auf der die Analysis aufgebaut ist. Da Reihen nichts anderes sind als spezielle Folgen, beginnen wir unsere Diskussion mit den Folgen.

### 3.1 Folgen

Anschaulich können wir uns Folgen als unendlich lange Listen vorstellen. Ein Beispiel für eine solche Folge wäre die Liste

$$\left[\frac{1}{1}, \frac{1}{2}, \frac{1}{3}, \cdots, \frac{1}{n}, \frac{1}{n+1}, \cdots\right].$$

Diese Notation ist zwar suggestiv, aber nicht formal genug. Formal definieren wir Folgen daher als Funktionen, die auf den positiven natürlichen Zahlen definiert sind.

**Definition 23 (Folge)** Eine Funktion  $f: \mathbb{N} \setminus \{0\} \to \mathbb{R}$  bezeichnen wir als eine *reellwertige Folge*. Eine Funktion  $f: \mathbb{N} \setminus \{0\} \to \mathbb{C}$  bezeichnen wir als eine *komplexwertige Folge*.  $\diamond$ 

**Bemerkung**: Da es mir zu aufwändig ist, die Menge der positiven natürlichen Zahlen als  $\mathbb{N}\setminus\{0\}$  zu schreiben, definiere ich statt dessen

$$\mathbb{N}^* := \mathbb{N} \setminus \{0\}$$

und kann damit die Menge der positiven natürlichen Zahlen kürzer als  $\mathbb{N}^*$  schreiben.

Ist die Funktion f ein Folge, so schreiben wir dies kürzer als  $\big(f(n)\big)_{n\in\mathbb{N}^*}$  oder  $\big(f_n\big)_{n\in\mathbb{N}^*}$  oder noch kürzer als  $\big(f_n\big)_n$ . Dabei ist  $f_n$  als Abkürzung für f(n) zu verstehen.

#### Beispiele:

- $1. \ \ \text{Die Funktion} \ a: \mathbb{N}^* \to \mathbb{R} \text{, die durch} \ a(n) = \frac{1}{n} \ \text{definiert ist, schreiben wir als die Folge} \ \left(\frac{1}{n}\right)_{n \in \mathbb{N}^*}.$
- 2. Die Funktion  $a: \mathbb{N}^* \to \mathbb{R}$ , die durch  $a(n) = (-1)^n$  definiert ist, schreiben wir als die Folge  $\left((-1)^n\right)_{n \in \mathbb{N}^*}$ .
- 3. Die Funktion  $a:\mathbb{N}^* \to \mathbb{R}$ , die durch a(n)=n definiert ist, schreiben wir als die Folge  $(n)_{n\in\mathbb{N}^*}$ .

Folgen können auch induktiv definiert werden. Um die Gleichung  $x = \cos(x)$  zu lösen, können wir eine Folge  $(x_n)_{n \in \mathbb{N}^*}$  induktiv wie folgt definieren:

1. Induktions-Anfang: n=1. Wir setzen

$$x_1 := 1$$
.

2. Induktions-Schritt:  $n\mapsto n+1$ . Nach Induktions-Voraussetzung ist  $x_n$  bereits definiert. Wir definieren  $x_{n+1}$  als

$$x_{n+1} := \cos(x_n).$$

Wir können die ersten 39 Glieder dieser Folge mit dem in Abbildung 3.1 gezeigten SETLX-Programm berechnen. Wir erhalten dann die in der Tabelle 3.1 auf Seite 25 gezeigten Ergebnisse. Bei näherer Betrachtung der Ergebnisse stellen wir fest, dass die Folge  $(x_n)_{n\in\mathbb{N}^*}$  in einem gewissen Sinne gegen einen festen Grenzwert strebt. Diese Beobachtung wollen wir in der folgenden Definition präzisieren. Vorab bezeichnen wir die Menge der positiven reellen Zahlen mit  $\mathbb{R}^*_+$ , es gilt also

```
\mathbb{R}_+^* = \{ x \in \mathbb{R} \mid x > 0 \}.
```

Abbildung 3.1: Berechnung der durch  $x_1 = 1$  und  $x_{n+1} = \cos(x_n)$  definierten Folge.

n	$x_n$	n	$x_n$	n	$x_n$	n	$x_n$
		10	0.731404	20	0.738938	30	0.739082
1	1.000000	11	0.744237	21	0.739184	31	0.739087
2	0.540302	12	0.735605	22	0.739018	32	0.739084
3	0.857553	13	0.741425	23	0.739130	33	0.739086
4	0.654290	14	0.737507	24	0.739055	34	0.739085
5	0.793480	15	0.740147	25	0.739106	35	0.739086
6	0.701369	16	0.738369	26	0.739071	36	0.739085
7	0.763960	17	0.739567	27	0.739094	37	0.739085
8	0.722102	18	0.738760	28	0.739079	38	0.739085
9	0.750418	19	0.739304	29	0.739089	39	0.739085

Tabelle 3.1: Die ersten 39 Glieder der durch  $x_1 = 1$  und  $x_{n+1} = \cos(x_n)$  definierten Folge.

#### Definition 24 (Grenzwert, Bernard Bolzano (1781–1848))

Eine Folge  $(a_n)_{n\in\mathbb{N}^*}$  konvergiert gegen den Grenzwert g, falls gilt:

$$\forall \varepsilon \in \mathbb{R}_{+}^{*} : \exists K \in \mathbb{R} : \forall n \in \mathbb{N}^{*} : (n \geq K \rightarrow |a_{n} - g| < \varepsilon).$$

In diesem Fall schreiben wir

$$\lim_{n \to \infty} a_n = g.$$

Anschaulich besagt diese Definition, dass fast alle Glieder  $a_n$  der Folge  $\left(a_n\right)_{n\in\mathbb{N}^*}$  einen beliebig kleinen Abstand zu dem Grenzwert g haben. Für die oben induktiv definierte Folge  $x_n$  können wir den Nachweis der Konvergenz erst in einem späteren Kapitel antreten. Wir betrachten statt dessen ein einfacheres Beispiel und beweisen, dass

$$\lim_{n \to \infty} \frac{1}{n} = 0$$

gilt.

**Beweis**: Für jedes  $\varepsilon > 0$  müssen wir eine Zahl K angeben, so dass für alle natürlichen Zahlen n, die größer-gleich K sind, die Abschätzung

$$\left|\frac{1}{n} - 0\right| < \varepsilon$$

gilt. Wir definieren

$$K := \frac{1}{\varepsilon} + 1.$$

Damit ist K wohldefiniert, denn da  $\varepsilon$  positiv ist, gilt sicher auch  $\varepsilon \neq 0$ . Nun benutzen wir die Voraussetzung  $n \geq K$  für  $K = \frac{1}{\varepsilon} + 1$ :

$$n \ge \frac{1}{\varepsilon} + 1$$

$$\Rightarrow n > \frac{1}{\varepsilon} \qquad | \cdot \varepsilon$$

$$\Rightarrow n \cdot \varepsilon > 1 \qquad | \cdot \frac{1}{n}$$

$$\Rightarrow \varepsilon > \frac{1}{n}$$

Da andererseits  $0 < \frac{1}{n}$  gilt, haben wir insgesamt für alle n > K

$$0 < \frac{1}{n} < \varepsilon$$

$$\Rightarrow \left| \frac{1}{n} \right| < \varepsilon$$

$$\Rightarrow \left| \frac{1}{n} - 0 \right| < \varepsilon$$

gezeigt und damit ist der Beweis abgeschlossen.

#### Aufgabe 12:

(a) Beweisen Sie unter Rückgriff auf die Definition des Grenzwert-Begriffs, dass

$$\lim_{n\to\infty}\frac{1}{2^n}=0$$

gilt.

(b) Beweisen Sie unter Rückgriff auf die Definition des Grenzwert-Begriffs, dass

$$\lim_{n\to\infty}\frac{1}{\sqrt{n}}=0$$

gilt. ♦

Wir formulieren und beweisen einige unmittelbare Folgerungen aus der obigen Definition des Grenzwerts.

#### Satz 25 (Eindeutigkeit des Grenzwerts)

Konvergiert die Folge  $(a_n)_{n\in\mathbb{N}^*}$  sowohl gegen den Grenzwert  $g_1$  als auch gegen den Grenzwert  $g_2$ , so gilt  $g_1=g_2$ .

 $\Diamond$ 

**Beweis**: Wir führen den Beweis indirekt und nehmen an, dass  $g_1 \neq g_2$  ist. Dann definieren wir

$$\varepsilon = \frac{1}{2} \cdot |g_2 - g_1|$$

und aus der Annahme  $g_1 \neq g_2$  folgt  $\varepsilon > 0$ . Aus der Voraussetzung, dass  $(a_n)_{n \in \mathbb{N}^*}$  gegen  $g_1$  konvergiert, folgt, dass es ein  $K_1$  gibt, so dass

$$\forall n \in \mathbb{N}^* : (n \ge K_1 \to |a_n - g_1| < \varepsilon)$$

gilt. Analog folgt aus der Voraussetzung, dass  $(a_n)_{n\in\mathbb{N}^*}$  gegen  $g_2$  konvergiert, dass es ein  $K_2$  gibt, so dass

$$\forall n \in \mathbb{N}^* : (n \ge K_2 \to |a_n - g_2| < \varepsilon)$$

gilt. Wir setzen  $K := \max(K_1, K_2)$ . Alle  $n \in \mathbb{N}^*$ , die größer-gleich K sind, sind dann sowohl größer-gleich  $K_1$  als auch größer-gleich  $K_2$ . Unter Benutzung der *Dreiecksungleichung*<sup>1</sup> erhalten wir für alle  $n \geq K$  die folgende Kette von Ungleichungen:

$$\begin{array}{lcl} 2 \cdot \varepsilon & = & |g_2 - g_1| \\ & = & |(g_2 - a_n) + (a_n - g_1)| \\ & \leq & |g_2 - a_n| + |a_n - g_1| \\ & < & \varepsilon + \varepsilon \\ & = & 2 \cdot \varepsilon \end{array} \tag{Dreiecksungleichung}$$

Aus dieser Ungleichungs-Kette würde aber  $2 \cdot \varepsilon < 2 \cdot \varepsilon$  folgen und das ist ein Widerspruch. Somit ist die Annahme  $g_1 \neq g_2$  falsch und es muss  $g_1 = g_2$  gelten.

**Bemerkung**: Die Schreibweise  $\lim_{n \to \infty} a_n = g$  wird erst durch den letzten Satz gerechtfertigt.

**Aufgabe 13**: Zeigen Sie, dass die Folge  $((-1)^n)_{n\in\mathbb{N}^*}$  nicht konvergent ist.

**Lösung**: Wir führen den Beweis indirekt und nehmen an, dass die Folge  $\left((-1)^n\right)_{n\in\mathbb{N}^*}$  konvergiert. Bezeichnen wir diesen Grenzwert mit s, so gilt also

$$\forall \varepsilon \in \mathbb{R}_{+}^{*} : \exists K \in \mathbb{R} : \forall n \in \mathbb{N}^{*} : (n \geq K \rightarrow |(-1)^{n} - s| < \varepsilon)$$

Daher gibt es für  $\varepsilon = 1$  eine Zahl K, so dass

$$\forall n \in \mathbb{N}^* : n \ge K \to |(-1)^n - s| < 1$$

gilt. Da aus  $n \geq K$  sicher auch  $2 \cdot n \geq K$  und  $2 \cdot n + 1 \geq K$  folgt, hätten wir dann für  $n \geq K$  die beiden folgenden Ungleichungen:

$$\left|(-1)^{2\cdot n}-s\right|<1\quad\text{und}\quad \left|(-1)^{2\cdot n+1}-s\right|<1$$

Wegen  $(-1)^{2 \cdot n} = 1$  und  $(-1)^{2 \cdot n+1} = -1$  haben wir also

$$|1-s| < 1$$
 und  $|-1-s| < 1$ .

Wegen  $-1-s=(-1)\cdot(1+s)$  und  $|a\cdot b|=|a|\cdot|b|$  können wir die letzte Ungleichung

$$|1 + s| < 1$$

noch zu vereinfachen. Aus den beiden Ungleichungen |1-s|<1 und |1+s|<1 erhalten wir nun einen Widerspruch:

<sup>&</sup>lt;sup>1</sup> Sind  $a, b \in \mathbb{R}$ , so gilt  $|a+b| \le |a| + |b|$ .

 $\Diamond$ 

$$\begin{array}{lll} 2 & = & \left|1+1\right| \\ & = & \left|(1-s)+(s+1)\right| \\ & \leq & \left|1-s\right|+\left|1+s\right| & \text{(Dreiecksungleichung)} \\ & < & 1+1 \\ & = & 2 \end{array}$$

Fassen wir diese Ungleichungs-Kette zusammen, so haben die (offensichtlich falsche) Ungleichung 2 < 2 abgeleitet. Damit haben wir aus der Annahme, dass die Folge gegen den Grenzwert s konvergiert, einen Widerspruch hergeleitet.

**Definition 26 (Beschränkte Folge)** Eine Folge  $(a_n)_{n\in\mathbb{N}^*}$  ist *beschränkt*, falls es eine *Schranke* S gibt, so dass

$$\forall n \in \mathbb{N}^* : \left| a_n \right| \le S$$

gilt.

#### Beispiele:

- 1. Die Folge  $\left((-1)^n\right)_{n\in\mathbb{N}^*}$  ist durch die Schranke S=1 beschränkt, denn offenbar gilt  $\left|(-1)^n\right|=1\leq 1.$
- 2. Die Folge  $(n)_{n\in\mathbb{N}^*}$  ist nicht beschränkt, denn sonst gäbe es eine Zahl S, so dass für alle natürlichen Zahlen n die Ungleichung  $n\leq S$  gilt. Da es beliebig große natürliche Zahlen gibt, kann dies nicht sein.

#### Satz 27 (Beschränktheit konvergenter Folgen) Jede konvergente Folge ist beschränkt.

**Beweis**: Es sei  $(a_n)_{n\in\mathbb{N}^*}$  eine konvergente Folge und es gelte

$$\lim_{n \to \infty} a_n = g.$$

Dann gibt es für beliebige  $\varepsilon>0$  ein K, so dass gilt

$$\forall n \in \mathbb{N}^* : (n \ge K \to |a_n - g| < \varepsilon).$$

Wir können also für  $\varepsilon = 1$  ein K finden, so dass

$$\forall n \in \mathbb{N}^* : (n \ge K \to |a_n - g| < 1)$$

gilt. Wir können ohne Einschränkung der Allgemeinheit davon ausgehen, dass K eine natürliche Zahl ist, denn wenn K keine natürliche Zahl ist, können wir K einfach durch die erste natürliche Zahl ersetzen, die größer als K ist. Dann definieren wir

$$S := \max\{|a_1|, \cdots, |a_K|, 1 + |g|\}.$$

Wir behaupten, dass S eine Schranke für die Folge  $(a_n)_{n\in\mathbb{N}^*}$  ist, wir zeigen also, dass für alle  $n\in\mathbb{N}^*$ 

$$|a_n| \leq S$$

gilt. Um diese Ungleichung nachzuweisen, führen wir eine Fall-Unterscheidung durch:

1. Fall:  $n \leq K$ . Dann gilt offenbar

$$|a_n| \in \{|a_1|, \cdots, |a_K|, 1+|g|\}.$$

und daraus folgt sofort

$$|a_n| \le \max\{|a_1|, \cdots, |a_K|, 1+|g|\} = S.$$

2. Fall: n > K. Dann haben wir

$$\begin{aligned} |a_n| &= |a_n - g + g| \\ &\leq |a_n - g| + |g| \quad \text{(Dreiecksungleichung)} \\ &< 1 + |g| \qquad \text{wegen } n > K \\ &\leq S. \qquad \square \end{aligned}$$

**Beispiel**: Aus dem letzten Satz folgt sofort, dass die Folge  $(n)_{n\in\mathbb{N}^*}$  nicht konvergiert, denn diese Folge ist noch nicht einmal beschränkt.

Satz 28 (Summe konvergenter Folgen) Sind  $(a_n)_{n\in\mathbb{N}^*}$  und  $(b_n)_{n\in\mathbb{N}^*}$  zwei Folgen, so dass

$$\lim_{n \to \infty} a_n = a \quad \land \quad \lim_{n \to \infty} b_n = b$$

gilt, dann konvergiert die Folge  $\left(a_n+b_n\right)_{n\in\mathbb{N}^*}$  gegen den Grenzwert a+b, in Zeichen:

$$\lim_{n \to \infty} (a_n + b_n) = \left(\lim_{n \to \infty} a_n\right) + \left(\lim_{n \to \infty} b_n\right).$$

**Beweis**: Es sei  $\varepsilon > 0$  fest vorgegeben. Wir suchen ein K, so dass

$$\forall n \in \mathbb{N}^* : (n \ge K \to |(a_n + b_n) - (a + b)| < \varepsilon)$$

gilt. Nach Voraussetzung gibt es für beliebige  $\varepsilon' > 0$  ein  $K_1$  und ein  $K_2$ , so dass

$$\forall n \in \mathbb{N}^* : (n \ge K_1 \to |a_n - a| < \varepsilon') \quad \text{ und } \quad \forall n \in \mathbb{N}^* : (n \ge K_2 \to |b_n - b| < \varepsilon')$$

gilt. Wir setzen nun  $arepsilon':=rac{1}{2}\cdotarepsilon$ . Dann gibt es also  $K_1$  und  $K_2$ , so dass

$$\forall n \in \mathbb{N}^* : \left(n \ge K_1 \to \left|a_n - a\right| < \frac{1}{2} \cdot \varepsilon\right) \quad \text{und}$$

$$\forall n \in \mathbb{N}^* : \left(n \ge K_2 \to \left|b_n - b\right| < \frac{1}{2} \cdot \varepsilon\right)$$

gilt. Wir definieren  $K := \max(K_1, K_2)$ . Damit gilt dann für alle  $n \ge K$ :

$$\begin{aligned} \left| \begin{pmatrix} (a_n + b_n) - (a+b) \right| &= \left| \begin{pmatrix} (a_n + b_n) - (a+b) \right| \\ &= \left| \begin{pmatrix} (a_n - a) + (b_n - b) \right| \\ &\leq \left| \begin{pmatrix} (a_n - a) \right| + \left| \begin{pmatrix} (b_n - b) \right| \end{pmatrix} \end{aligned}$$
 (Dreiecksungleichung) 
$$< \frac{1}{2} \cdot \varepsilon + \frac{1}{2} \cdot \varepsilon$$
 
$$= \varepsilon.$$

Damit ist die Behauptung gezeigt.

**Aufgabe 14**: Zeigen Sie: Sind  $(a_n)_{n\in\mathbb{N}^*}$  und  $(b_n)_{n\in\mathbb{N}^*}$  zwei Folgen, so dass

$$\lim_{n \to \infty} a_n = a \quad \land \quad \lim_{n \to \infty} b_n = b$$

gilt, dann konvergiert die Folge  $(a_n - b_n)_{n \in \mathbb{N}^*}$  gegen den Grenzwert a - b, in Zeichen:

$$\lim_{n \to \infty} (a_n - b_n) = \left(\lim_{n \to \infty} a_n\right) - \left(\lim_{n \to \infty} b_n\right).$$

Satz 29 (Produkt konvergenter Folgen) Sind  $(a_n)_{n\in\mathbb{N}^*}$  und  $(b_n)_{n\in\mathbb{N}^*}$  zwei Folgen, so dass

$$\lim_{n \to \infty} a_n = a \quad \land \quad \lim_{n \to \infty} b_n = b$$

gilt, dann konvergiert die Folge  $(a_n \cdot b_n)_{n \in \mathbb{N}^*}$  gegen den Grenzwert  $a \cdot b$ , in Zeichen:

$$\lim_{n \to \infty} (a_n \cdot b_n) = \left(\lim_{n \to \infty} a_n\right) \cdot \left(\lim_{n \to \infty} b_n\right).$$

**Beweis**: Es sei  $\varepsilon > 0$  fest vorgegeben. Wir suchen ein K, so dass

$$\forall n \in \mathbb{N}^* : (n \ge K \to |a_n \cdot b_n - a \cdot b| < \varepsilon)$$

gilt. Da die Folge  $(a_n)_{n\in\mathbb{N}^*}$  konvergent ist, ist diese Folge auch beschränkt, es gibt also eine Zahl S, so dass

$$|a_n| < S$$
 für alle  $n \in \mathbb{N}^*$ 

gilt. O.B.d.A. dürfen wir annehmen, dass S>0 ist, denn wenn S=0 wäre, dann ist S:=1 ebenfalls eine Schranke der Folge  $\left(a_n\right)_{n\in\mathbb{N}^*}$ . Nach Voraussetzung gibt es für beliebige  $\varepsilon_1>0$  ein  $K_1$  und für beliebige  $\varepsilon_2>0$  ein  $K_2$ , so dass

$$\forall n \in \mathbb{N}^* : (n \ge K_1 \to |a_n - a| < \varepsilon_1) \quad \text{ und } \quad \forall n \in \mathbb{N}^* : (n \ge K_2 \to |b_n - b| < \varepsilon_2)$$

gilt. Wir setzen nun

$$arepsilon_1 := rac{arepsilon}{2 \cdot (|b| + 1)} \quad ext{ und } \quad arepsilon_2 := rac{arepsilon}{2 \cdot S}.$$

Bei der Definition von  $\varepsilon_1$  ist es erforderlich, im Nenner die 1 zu addieren, denn es kann ja durchaus vorkommen, dass b=0 ist und durch die Addition der 1 stellen wir sicher, dass der Nenner von 0 verschieden ist. Dann existieren also Zahlen  $K_1$  und  $K_2$ , so dass

$$\forall n \in \mathbb{N}^* : \left( n \ge K_1 \to \left| a_n - a \right| < \frac{\varepsilon}{2 \cdot (|b| + 1)} \right) \quad \text{und}$$

$$\forall n \in \mathbb{N}^* : \left( n \ge K_2 \to \left| b_n - b \right| < \frac{\varepsilon}{2 \cdot S} \right)$$

gilt. Wir definieren  $K := \max(K_1, K_2)$ . Damit gilt dann für alle  $n \ge K$ :

$$\begin{aligned} |a_n \cdot b_n - a \cdot b| &= |(a_n \cdot b_n - a_n \cdot b) + (a_n \cdot b - a \cdot b)| \\ &\leq |(a_n \cdot b_n - a_n \cdot b)| + |(a_n \cdot b - a \cdot b)| \quad \text{(Dreiecksungleichung)} \\ &= |a_n| \cdot |b_n - b| + |a_n - a| \cdot |b| \\ &\leq S \cdot |b_n - b| + |a_n - a| \cdot |b| \\ &< S \cdot \frac{\varepsilon}{2 \cdot S} + \frac{\varepsilon}{2 \cdot (|b| + 1)} \cdot |b| \\ &< S \cdot \frac{\varepsilon}{2 \cdot S} + \frac{\varepsilon}{2 \cdot (|b| + 1)} \cdot (|b| + 1) \\ &\leq \frac{\varepsilon}{2} + \frac{\varepsilon}{2} \\ &= \varepsilon. \end{aligned}$$

Damit ist die Behauptung gezeigt.

**Aufgabe 15**: Zeigen Sie: Sind  $(a_n)_{n\in\mathbb{N}^*}$  und  $(b_n)_{n\in\mathbb{N}^*}$  zwei Folgen, so dass

$$\lim_{n \to \infty} a_n = a \quad \land \quad \lim_{n \to \infty} b_n = b$$

gilt und gilt  $b_n \neq 0$  für alle  $n \in \mathbb{N}^*$ , sowie  $b \neq 0$ , so konvergiert die Folge  $(a_n/b_n)_{n \in \mathbb{N}^*}$  gegen den

Grenzwert a/b, in Zeichen:

$$\lim_{n \to \infty} \frac{a_n}{b_n} = \frac{\left(\lim_{n \to \infty} a_n\right)}{\left(\lim_{n \to \infty} b_n\right)} = \frac{a}{b}.$$

**Lösung**: Zunächst können wir das Problem vereinfachen, wenn wir die Folge  $(a_n/b_n)_{n\in\mathbb{N}^*}$  als Folge von Produkten schreiben:

$$\left(\frac{a_n}{b_n}\right)_{n\in\mathbb{N}^*} = \left(a_n\right)_{n\in\mathbb{N}^*} \cdot \left(\frac{1}{b_n}\right)_{n\in\mathbb{N}^*}$$

Falls wir zeigen können, dass

$$\lim_{n \to \infty} \frac{1}{b_n} = \frac{1}{b}$$

gilt, dann folgt die Behauptung aus dem Satz über das Produkt konvergenter Folgen. Bei unserer Suche nach einem Beweis starten wir damit, dass wir die Behauptung noch einmal hinschreiben:

$$\forall \varepsilon \in \mathbb{R}_{+}^{*} : \exists K \in \mathbb{R} : \forall n \in \mathbb{N}^{*} : \left( n \ge K \to \left| \frac{1}{b_{n}} - \frac{1}{b} \right| < \varepsilon \right)$$
(3.1)

Wir müssen also für alle  $\varepsilon > 0$  ein K finden, so dass für alle natürlichen Zahlen  $n \ge K$  die Ungleichung

$$\left|\frac{1}{b_n} - \frac{1}{b}\right| < \varepsilon \tag{3.2}$$

gilt. Irgendwie müssen wir die Voraussetzung, dass die Folge  $(b_n)_{n\in\mathbb{N}^*}$  gegen b konvergiert, ausnutzen. Diese Voraussetzung lautet ausgeschrieben

$$\forall \varepsilon' \in \mathbb{R}_{+}^{*} : \exists K' \in \mathbb{R} : \forall n \in \mathbb{N}^{*} : \left( n \ge K' \to \left| b_{n} - b \right| < \varepsilon' \right)$$
(3.3)

Wir zeigen zunächst eine Abschätzung für die Beträge  $|b_n|$ , die wir später brauchen. Hier hilft uns die Voraussetzung, dass  $b \neq 0$  ist. Setzen wir in Ungleichung (3.3) für  $\varepsilon'$  den Wert  $\frac{1}{2} \cdot |b|$  ein, so erhalten wir eine Zahl  $K_1$ , so dass für alle natürlichen Zahlen  $n \geq K_1$ 

$$\left|b_n - b\right| < \frac{1}{2} \cdot |b|$$

gilt. Damit folgt:

$$|b| = |b - b_n + b_n|$$

$$\Rightarrow |b| \leq |b - b_n| + |b_n|$$

$$\Rightarrow |b| < \frac{1}{2} \cdot |b| + |b_n|$$

$$\Rightarrow \frac{1}{2} \cdot |b| < |b_n|$$

$$\Rightarrow \frac{2}{|b|} > \frac{1}{|b_n|}$$

Damit wissen wir also, dass für alle  $n>K_1$  die Ungleichung

$$\frac{1}{|b_n|} < \frac{2}{|b|}$$

gilt. Um nun für ein gegebenes  $\varepsilon>0$  die Ungleichung (3.2) zu zeigen, setzen wir in der Voraussetzung (3.3)  $\varepsilon':=\frac{1}{2}\cdot |b|^2\cdot \varepsilon$  und erhalten ein  $K_2$ , so dass für alle  $n>K_2$  die Ungleichung

$$\left|b - b_n\right| < \frac{1}{2} \cdot |b|^2 \cdot \varepsilon \tag{3.4}$$

gilt. Setzen wir  $K := \max(K_1, K_2)$ , so erhalten wir für alle n > K die folgende Ungleichungs-Kette:

$$\left| \frac{1}{b_n} - \frac{1}{b} \right| = \left| \frac{b - b_n}{b \cdot b_n} \right|$$

$$= \frac{1}{|b| \cdot |b_n|} \cdot |b - b_n|$$

$$< \frac{2}{|b| \cdot |b|} \cdot |b - b_n| \quad \text{wegen } \frac{2}{|b|} > \frac{1}{|b_n|}$$

$$< \frac{2}{|b| \cdot |b|} \cdot \frac{1}{2} \cdot |b|^2 \cdot \varepsilon \quad \text{wegen (3.4)}$$

 $\text{Damit haben wir f\"{u}r } n \geq K \text{ die Ungleichung } \left| \frac{1}{b_n} - \frac{1}{b} \right| < \varepsilon \text{ hergeleitet und der Beweis ist abgeschlossen.}$ 

Bemerkung: Die bis hierhin bewiesenen Sätze zeigen, dass bei konvergenten Folgen die Berechnung von Grenzwerten mit den arithmetischen Operationen vertauscht werden kann. Damit ermöglichen uns diese Sätze die Berechnung von Grenzwerten. Wir geben ein Beispiel:

$$\lim_{n \to \infty} \frac{n}{n+1} = \lim_{n \to \infty} \frac{1}{1 + \frac{1}{n}}$$

$$= \frac{\lim_{n \to \infty} 1}{\lim_{n \to \infty} 1 + \frac{1}{n}}$$

$$= \frac{1}{\lim_{n \to \infty} 1 + \lim_{n \to \infty} \frac{1}{n}}$$

$$= \frac{1}{1+0}$$

$$= 1$$

**Satz 30** Sind  $(a_n)_{n\in\mathbb{N}^*}$  und  $(b_n)_{n\in\mathbb{N}^*}$  zwei konvergente Folgen, so dass

$$\forall n \in \mathbb{N}^* : a_n \leq b_n$$

gilt, dann gilt auch

$$\lim_{n \to \infty} a_n \le \lim_{n \to \infty} b_n.$$

Aufgabe 16: Beweisen Sie den letzten Satz.

**Definition 31 (monoton)** Eine Folge  $(a_n)_{n\in\mathbb{N}^*}$  ist *monoton steigend* falls

$$\forall n \in \mathbb{N}^* : a_n \le a_{n+1}$$

gilt. Analog heißt eine Folge monoton fallend falls

$$\forall n \in \mathbb{N}^* : a_n \ge a_{n+1}.$$

Ein Beispiel für eine monoton fallende Folge ist die Folge  $\left(\frac{1}{n}\right)_{n\in\mathbb{N}^*}$ , denn es gilt

 $\Diamond$ 

 $\Diamond$ 

$$n+1 \geq n \qquad |\cdot \frac{1}{n}|$$

$$\Rightarrow \frac{n+1}{n} \geq 1 \qquad |\cdot \frac{1}{n+1}|$$

$$\Rightarrow \frac{1}{n} \geq \frac{1}{n+1}$$

**Satz 32** Ist die Folge  $(a_n)_{n\in\mathbb{N}^*}$  monoton fallend und beschränkt, so ist die Folge auch konvergent.

**Beweis**: Wir definieren zunächst die Menge M als die Menge aller unteren Schranken der Folge  $(a_n)_{n\in\mathbb{N}^*}$ 

$$M := \{ x \in \mathbb{R} \mid \forall n \in \mathbb{N}^* : x \le a_n \}.$$

Weil wir vorausgesetzt haben, dass die Folge  $(a_n)_{n\in\mathbb{N}^*}$  beschränkt ist, ist die Menge M sicher nicht leer. Außerdem ist die Menge M nach oben beschränkt, jedes Folgenglied  $a_n$  ist eine obere Schranke der Menge M. Da die Struktur  $\langle \mathbb{R}, 0, 1, +, \cdot, \leq \rangle$  ein vollständig geordneter Körper ist, hat die Menge M ein Supremum und wir können

$$s := \sup(M)$$

definieren. Wir zeigen, dass

$$\lim_{n \to \infty} a_n = s$$

gilt. Dazu müssen wir

$$\forall \varepsilon \in \mathbb{R}^*_{\perp} : \exists K \in \mathbb{R} : \forall n \in \mathbb{N}^* : (n > k \to |a_n - s| < \varepsilon)$$

zeigen. Sei also  $\varepsilon>0$  gegeben. Da

$$s + \varepsilon > s$$

ist und s als das Supremum der Menge M definiert ist, können wir folgern, dass  $s+\varepsilon\not\in M$  ist. Nach Definition der Menge M als Menge der unteren Schranken der Folge  $(a_n)_{n\in\mathbb{N}^*}$  ist  $s+\varepsilon$  dann keine untere Schranke der Folge  $(a_n)_{n\in\mathbb{N}^*}$ . Also gibt es eine Zahl  $\widehat{n}\in\mathbb{N}^*$ , so dass

$$a_{\widehat{n}} < s + \varepsilon$$

ist. Da die Folge monoton fallend ist, gilt dann auch

$$a_n < s + \varepsilon$$
 für alle  $n \ge \widehat{n}$ .

Andererseits ist  $s-\frac{1}{2}\cdot \varepsilon < s$ , so dass  $s-\frac{1}{2}\cdot \varepsilon$  sicher ein Element der Menge M ist, denn M ist nach unten abgeschlossen. Damit ist  $s-\frac{1}{2}\cdot \varepsilon$  dann auch eine untere Schranke der Folge  $(a_n)_{n\in\mathbb{N}^*}$ . Folglich gilt für alle  $n\in\mathbb{N}^*$ 

$$s - \varepsilon < s - \frac{1}{2} \cdot \varepsilon \le a_n.$$

Damit haben wir insgesamt

$$s - \varepsilon < a_n < s + \varepsilon \quad \text{ für alle } n \ge \widehat{n}.$$

Subtrahieren wir s von dieser Ungleichung, so erhalten wir

$$-\varepsilon < a_n - s < \varepsilon$$
 für alle  $n \ge \widehat{n}$ 

und dies können wir auch als

$$|a_n - s| < \varepsilon$$
 für alle  $n \ge \widehat{n}$ 

schreiben. Setzen wir in der Definition des Grenzwerts  $K:=\widehat{n}$ , so haben wir damit die Behauptung gezeigt.

**Bemerkung**: Der soeben bewiesene Satz ist der erste Satz, bei dem wir ausgenutzt haben, dass die reellen Zahlen vollständig sind.

**Aufgabe 17**: Die Folge  $(a_n)_{n\in\mathbb{N}^*}$  sei monoton steigend und beschränkt. Zeigen Sie, dass der Grenzwert

$$\lim_{n\to\infty} a_n$$

existiert.

#### Definition 33 (Cauchy-Folge)

Eine Folge  $(a_n)_{n\in\mathbb{N}^*}$  heißt Cauchy-Folge (Augustin-Louis Cauchy, 1789-1857), falls gilt:

$$\forall \varepsilon \in \mathbb{R}_{+}^{*} : \exists K \in \mathbb{R} : \forall m, n \in \mathbb{N}^{*} : (m \ge K \land n \ge K \to |a_{m} - a_{n}| < \varepsilon).$$

In einer Cauchy-Folge  $(a_n)_{n\in\mathbb{N}^*}$  liegen also die einzelnen Folgenglieder  $a_n$  mit wachsendem n immer dichter zusammen. Wir werden sehen, dass eine Folge genau dann konvergent ist, wenn die Folge eine Cauchy-Folge ist. Den Nachweis dieser Behauptung spalten wir in mehrere Sätze auf.

**Satz 34** Jede konvergente Folge  $(a_n)_{n\in\mathbb{N}^*}$  ist eine Cauchy-Folge.

**Beweis**: Es sei  $a:=\lim_{n\to\infty}a_n$ . Sei  $\varepsilon>0$  gegeben. Nach Definition einer Cauchy-Folge müssen wir ein K finden, so dass

$$\forall m, n \in \mathbb{N}^* : (m \ge K \land n \ge K \to |a_m - a_n| < \varepsilon)$$

gilt. Nach Voraussetzung gilt

$$\forall \varepsilon' \in \mathbb{R}_+^* : \exists K' \in \mathbb{R} : \forall n \in \mathbb{N}^* : (n \ge K' \to |a_n - a| < \varepsilon'.$$

Wir definieren  $\varepsilon' := \frac{1}{2} \cdot \varepsilon$ . Dann gibt es also ein K', so dass

$$\forall n \in \mathbb{N}^* : \left(n \ge K' \to \left|a_n - a\right| < \frac{\varepsilon}{2}\right)$$

gilt. Wir definieren nun K:=K'. Damit gilt für alle  $m,n\in\mathbb{N}^*$  mit  $m\geq K$  und  $n\geq K$  die folgende Abschätzung:

$$|a_m - a_n| = |(a_m - a) + (a - a_n)|$$

$$\leq |a_m - a| + |a - a_n|$$

$$< \frac{\varepsilon}{2} + \frac{\varepsilon}{2}$$

$$= \varepsilon$$

Damit ist gezeigt, dass  $(a_n)_{n\in\mathbb{N}^*}$  eine Cauchy-Folge ist.

Satz 35 Jede Cauchy-Folge ist beschränkt.

**Beweis**: Wenn  $(a_n)_{n\in\mathbb{N}^*}$  eine Cauchy-Folge ist, dann finden wir eine Zahl K, so dass für alle natürlichen Zahlen m,n, die größer-gleich K sind, die Ungleichung

$$|a_n - a_m| < 1$$

gilt. Sei nun h eine natürliche Zahl, die größer als K ist. Wir definieren

$$S := \max\{|a_1|, |a_2|, \cdots, |a_h|, 1 + |a_h|\}$$

und zeigen, dass S eine Schranke der Cauchy-Folge  $(a_n)_{n\in\mathbb{N}^*}$  ist, wir zeigen also

$$\forall n \in \mathbb{N}^* : |a_n| \le S.$$

 $\Diamond$ 

Falls  $n \leq h$  ist, ist diese Ungleichung evident. Für alle n > h haben wir die folgende Abschätzung:

$$|a_n| = |a_n - a_h + a_h|$$

$$\leq |a_n - a_h| + |a_h|$$

$$< 1 + |a_h|$$

$$< S.$$

Damit ist der Beweis abgeschlossen.

**Aufgabe 18** $^*$ : In dem gleich folgenden Beweis der Tatsache, dass jede Cauchy-Folge konvergent ist, werden wir zwei Eigenschaften des Supremums einer Menge M benutzen, die zwar offensichtlich sind, die wir aber auch formal beweisen sollten. Nehmen Sie an, dass Folgendes gilt:

1.  $M \subseteq \mathbb{R}$  ist nach unten abgeschlossen, es gilt also

$$y < x \land x \in M \to y \in M$$
,

- $2. \ s = \sup(M) \quad \text{ und }$
- 3.  $\varepsilon > 0$ .

Beweisen Sie, dass dann

$$s-\varepsilon\in M\quad \text{ und }\quad s+\varepsilon\not\in M$$

gilt.

Theorem 36 Jede Cauchy-Folge ist konvergent.

**Beweis**\*: Der Beweis verläuft ähnlich wie der Nachweis, dass eine monotone und beschränkte Folge konvergent ist und zerfällt in zwei Teile:

- 1. Zunächst definieren wir eine Menge M, die nicht leer und nach oben beschränkt ist und definieren s als das Supremum dieser Menge.
- 2. Anschließend zeigen wir, dass die Folge  $(a_n)_{n\in\mathbb{N}^*}$  gegen s konvergiert.

Wir definieren die Menge M wie folgt:

$$M := \{ x \in \mathbb{R} \mid \exists K \in \mathbb{N}^* : \forall n \in \mathbb{N}^* : (n \ge K \to x \le a_n) \}.$$

Anschaulich ist M die Menge aller unteren Grenzen für die Mehrheit der Folgenglieder: Ist  $x \in M$ , so müssen von einem bestimmten Index K an alle weiteren Folgenglieder  $a_n$  durch x nach unten abgeschätzt werden. Wir nennen M daher die Menge der *unteren Majoritäts-Schranken* der Folge  $(a_n)_{n \in \mathbb{N}^*}$ , denn jedes Element aus M ist eine untere Schranke für die Mehrheit der Folgenglieder. Genauer gilt für jedes  $x \in M$ , dass nur endlich viele der Folgenglieder  $a_n$  kleiner als x sind. Mathematiker sagen an dieser Stelle, dass x fast alle Folgenglieder kleiner als x sind.

Es ist klar, dass M nach unten abgeschlossen ist, es gilt

$$y < x \land x \in M \rightarrow y \in M$$
,

denn wenn x eine untere Schranke der Mehrheit aller Folgenglieder ist, dann ist sicher jede Zahl y, die kleiner als x ist, ebenfalls eine untere Schranke der Mehrheit der Folgenglieder. Wir werden diese Eigenschaft später benötigen.

Da die Folge  $(a_n)_{n\in\mathbb{N}^*}$  eine Cauchy-Folge ist, gibt es ein S, so dass die Folge durch S beschränkt ist, genauer gilt

$$\forall n \in \mathbb{N}^* : |a_n| \leq S.$$

Daher ist die Menge M nach oben durch S beschränkt, denn eine untere Grenze für die Mehrheit aller

Folgenglieder kann sicher nicht größer als S sein. Weiter impliziert die Beschränktheit der Cauchy-Folge, dass die Menge M nicht leer ist, denn wenn für alle  $n \in \mathbb{N}^*$  die Ungleichung  $|a_n| \leq S$  gilt, dann gilt insbesondere  $-S \leq a_n$  und daraus folgt sofort  $-S \in M$ . Als nicht-leere und nach oben beschränkte Menge hat M ein Supremum, denn  $\langle \mathbb{R}, \leq \rangle$  ist eine vollständige Ordnung. Wir definieren

$$s := \sup(M)$$

und zeigen, dass mit dieser Definition

$$\lim_{n \to \infty} a_n = s$$

gilt. Sei  $\varepsilon>0$  gegeben. Wir suchen eine Zahl K, so dass für alle natürlichen Zahlen  $n\geq K$  die Ungleichung

$$|a_n - s| < \varepsilon$$

gilt. Wir betrachten zunächst die Zahl  $s-\frac{\varepsilon}{2}$ . Wegen  $s-\frac{\varepsilon}{2} < s$  und  $s=\sup(M)$  folgt  $s-\frac{\varepsilon}{2} \in M$ , denn M ist nach unten abgeschlossen. Damit existiert dann nach Definition der Menge M als Menge der unteren Majoritäts-Schranken eine Zahl  $K_1$ , so dass für alle  $n\in\mathbb{N}^*$  mit  $n\geq K_1$  die Ungleichung

$$s - \frac{\varepsilon}{2} \le a_n \tag{3.5}$$

gilt. Da die Folge  $(a_n)_{n\in\mathbb{N}^*}$  eine Cauchy-Folge ist, gibt es eine Zahl  $K_2$ , so dass für alle  $m,n\in\mathbb{N}^*$  mit  $m>K_2$  und  $n>K_2$  die Ungleichung

$$\left|a_n - a_m\right| < \frac{\varepsilon}{2} \tag{3.6}$$

gilt. Wir setzen nun  $K = \max(K_1, K_2)$  und betrachten die Zahl  $s + \frac{\varepsilon}{2}$ , die wegen  $s < s + \frac{\varepsilon}{2}$  sicher kein Element von M mehr ist, denn sonst wäre s nicht das Supremum von M. Nach Definition von M finden wir dann eine natürliche Zahl m, die größer als K ist, so dass

$$a_m < s + \frac{\varepsilon}{2} \tag{3.7}$$

gilt. Für diese Zahl m gilt sicher auch die Ungleichung (3.5), so dass wir insgesamt

$$s - \frac{\varepsilon}{2} \le a_m < s + \frac{\varepsilon}{2}$$

haben. Daraus folgt sofort

$$\left|a_m - s\right| \le \frac{\varepsilon}{2}.\tag{3.8}$$

Aufgrund der Ungleichung (3.6) haben wir jetzt für alle natürlichen Zahlen n>K die folgende Kette von Ungleichungen:

$$|a_n - s| = |(a_n - a_m) + (a_m - s)|$$

$$\leq |(a_n - a_m)| + |(a_m - s)|$$

$$< \frac{\varepsilon}{2} + \frac{\varepsilon}{2}$$

$$= \varepsilon$$

Damit ist der Beweis abgeschlossen.

# 3.2 Berechnung der Quadrat-Wurzel

Wir präsentieren nun eine Anwendung der bisher entwickelte Theorie und zeigen, wie die Quadrat-Wurzel einer reellen Zahl berechnet werden kann. Es sei eine reelle Zahl a>0 gegeben. Gesucht ist eine reelle Zahl b>0, so dass  $b^2=a$  ist. Unsere Idee ist es, die Zahl b iterativ als Lösung einer Fixpunkt-Gleichung zu berechnen. Wir definieren eine Folge  $b_n$  induktiv wie folgt:

 $\mathsf{I.A.:}\ \ n=1.$ 

$$b_1 := \left\{ \begin{array}{ll} 1 & \mathsf{falls} \ a \le 1, \\ a & \mathsf{sonst.} \end{array} \right.$$

I.S.:  $n \mapsto n+1$ .

$$b_{n+1} := \frac{1}{2} \cdot \left( b_n + \frac{a}{b_n} \right).$$

Um diese Definition zu verstehen, nehmen wir zunächst an, dass der Grenzwert dieser Folge existiert und den Wert b hat, wobei  $b \neq 0$  ist. Dann gilt

$$b = \lim_{n \to \infty} b_n$$

$$= \lim_{n \to \infty} b_{n+1}$$

$$= \lim_{n \to \infty} \frac{1}{2} \cdot \left( b_n + \frac{a}{b_n} \right)$$

$$= \frac{1}{2} \cdot \left( \lim_{n \to \infty} b_n + \frac{a}{\lim_{n \to \infty} b_n} \right)$$

$$= \frac{1}{2} \cdot \left( b + \frac{a}{b} \right)$$

Damit ist b also eine Lösung der Gleichung  $b=\frac{1}{2}\cdot\left(b+\frac{a}{b}\right)$ . Wir formen diese Gleichung um:

$$b = \frac{1}{2} \cdot \left(b + \frac{a}{b}\right) \qquad | \cdot 2$$

$$\Leftrightarrow \qquad 2 \cdot b = b + \frac{a}{b} \qquad | -b$$

$$\Leftrightarrow \qquad b = \frac{a}{b} \qquad | \cdot b$$

$$\Leftrightarrow \qquad b^2 = a \qquad | \sqrt{}$$

$$\Leftrightarrow \qquad b = \sqrt{a} \vee b = -\sqrt{a}$$

Es gilt  $a_1 > 0$  und durch eine einfache Induktion lässt sich zeigen, dass

$$a_n > 0$$
 für alle  $n \in \mathbb{N}$ 

gilt. Damit ist klar, dass der Grenzwert b, wenn er denn existiert, nicht negativ werden kann. Falls also die oben definierte Folge  $\left(b_n\right)_{n\in\mathbb{N}^*}$  einen Grenzwert hat, dann ist dieser Grenzwert die Wurzel der Zahl a. Wir werden die Konvergenz der Folge nachweisen, indem wir zeigen, dass die Folge  $\left(b_n\right)_{n\in\mathbb{N}^*}$  einerseits monoton fallend und andererseits nach unten beschränkt ist. Dazu betrachten wir zunächst die Differenz  $b_{n+1}^2-a$ :

$$b_{n+1}^{2} - a = \frac{1}{4} \cdot \left(b_{n} + \frac{a}{b_{n}}\right)^{2} - a$$

$$= \frac{1}{4} \cdot \left(b_{n}^{2} + 2 \cdot a + \frac{a^{2}}{b_{n}^{2}}\right) - a$$

$$= \frac{1}{4} \cdot \left(b_{n}^{2} - 2 \cdot a + \frac{a^{2}}{b_{n}^{2}}\right)$$

$$= \frac{1}{4} \cdot \left(b_{n} - \frac{a}{b_{n}}\right)^{2}$$

$$> 0.$$

denn das Quadrat einer reellen Zahl ist immer größer-gleich Null. Addieren wir auf beiden Seiten der

Ungleichung

$$b_{n+1}^2 - a \ge 0$$

die Zahl a, so haben wir

$$b_{n+1}^2 \geq a$$
 und damit auch  $b_{n+1} \geq \sqrt{a}$  für alle  $n \in \mathbb{N}^*$ 

gezeigt. Nach unserer Definition der Folge  $(b_n)_{n\in\mathbb{N}^*}$  gilt diese Ungleichung auch für den ersten Wert n=1, so dass wir also insgesamt die Ungleichungen

$$b_n^2 \ge a$$
 und  $b_n \ge \sqrt{a}$  für alle  $n \in \mathbb{N}^*$ 

gezeigt haben. Daraus folgt, dass  $\sqrt{a}$  eine untere Schranke der Folge  $(b_n)_{n\in\mathbb{N}^*}$  ist. Dividieren wir die Ungleichung  $b_n^2\geq a$  durch  $b_n$ , so folgt

$$b_n \ge \frac{a}{b_n}$$
.

Die Zahl  $\frac{1}{2} \cdot \left(b_n + \frac{a}{b_n}\right)$  ist der arithmetische Mittelwert der Zahlen  $b_n$  und  $\frac{a}{b_n}$  und muss daher zwischen diesen beiden Zahlen liegen:

$$b_n \ge \frac{1}{2} \cdot \left(b_n + \frac{a}{b_n}\right) \ge \frac{a}{b_n}.$$

Dieser Mittelwert ist aber gerade  $b_{n+1}$ , es gilt also

$$b_n \ge b_{n+1} \ge \frac{a}{b_n}.$$

Dies zeigt, dass die Folge  $(b_n)_{n\in\mathbb{N}^*}$  monoton fallend ist und da wir oben gesehen haben, dass die Folge durch  $\sqrt{a}$  nach unten beschränkt ist, konvergiert die Folge. Wir hatten oben schon gezeigt, dass der Grenzwert dieser Folge dann den Wert  $\sqrt{a}$  haben muss, es gilt also

$$\lim_{n \to \infty} b_n = \sqrt{a}$$

Abbildung 3.3 auf Seite 39 zeigt die Definition einer Prozedur mySqrt() in SETLX, die die ersten 9 Glieder der Folge berechnet und dann jeweils mit Hilfe der Funktion nDecimalPlaces() die ersten 100 Stellen der Werte ausgibt.

Die von diesem Programm berechnete Ausgabe ist in Abbildung 3.2 gezeigt. Sie können sehen, dass die Folge sehr schnell konvergiert.  $b_2$  stimmt auf 2 Stellen hinter dem Komma mit dem Ergebnis überein, bei  $b_3$  sind es bereits 5 Stellen, bei  $b_4$  sind es 11 Stellen, bei  $b_5$  sind es 23 Stellen, bei  $b_6$  sind es 47 Stellen, bei  $b_7$  haben wir 96 Stellen und ab dem Folgeglied  $b_8$  ändern sich die ersten 100 Stellen hinter dem Komma nicht mehr.

In modernen Mikroprozessoren wird übrigens eine verfeinerte Version des in diesem Abschnitt beschriebenen Verfahrens eingesetzt. Die Verfeinerung besteht im Wesentlichen darin, dass zunächst ein guter Startwert  $b_1$  in einer Tabelle nachgeschlagen wird, die restlichen Folgeglieder werden dann in der Tat über die Rekursionsformel

$$b_{n+1} = \frac{1}{2} \cdot \left( b_n + \frac{a}{b_n} \right)$$

berechnet.

Abbildung 3.2: Berechnung der Quadrat-Wurzel mit Hilfe der Folge  $b_{n+1} = \frac{1}{2} \cdot (b_n + \frac{a}{b_n})$ .

```
mySqrt := procedure(a) {
    if (a <= 1) {
        b := 1;
    } else {
        b := a;
    }
    for (n in [1 .. 9]) {
        b := 1/2 * (b + a/b);
        print("$n$: $nDecimalPlaces(b, 100)$");
    }
    return b;
}</pre>
```

Abbildung 3.3: Ein SetlX-Programm zur iterativen Berechnung der Quadrat-Wurzel.

 $\Diamond$ 

#### Aufgabe 19:

- (a) Es seien  $a,b \in \mathbb{R}$ . Die Folge  $(a_n)_{n \in \mathbb{N}}$  werde durch Induktion wie folgt definiert:
  - (a)  $a_0 := a$ ,
  - (b)  $a_1 := b$ ,
  - (c)  $a_{n+2} := \frac{1}{2} \cdot (a_n + a_{n+1}).$

Zeigen Sie, dass die Folge  $(a_n)_{n\in\mathbb{N}}$  konvergiert und berechnen Sie den Grenzwert  $\lim_{n\to\infty}a_n$  in Abhängigkeit von den Startwerten a und b.

**Hinweis**: Die Gleichung für  $a_{n+2}$  ist eine Rekurrenz-Gleichung, die Sie über den Ansatz  $a_n=\lambda^n$  lösen können. Sie werden dabei für  $\lambda$  zwei mögliche Werte  $\lambda_1$  und  $\lambda_2$  finden, die Sie für die Lösung in der Form

$$a_n = c_1 \cdot \lambda_1^n + c_2 \cdot \lambda_2^n$$

linear kombinieren müssen. Die Koeffizienten  $c_1$  und  $c_2$  können Sie aus den Gleichungen für die Anfangswerte  $a_0$  und  $a_1$  bestimmen.

- (b) Es seien  $a, b \in \mathbb{R}$  und zusätzlich gelte a > 0 und b > 0. Die Folge  $(a_n)_{n \in \mathbb{N}}$  werde durch Induktion wie folgt definiert:
  - (a)  $a_0 := a$ ,
  - (b)  $a_1 := b$ .
  - (c)  $a_{n+2} := \sqrt{a_n \cdot a_{n+1}}$ .

Zeigen Sie, dass die Folge  $(a_n)_{n\in\mathbb{N}}$  konvergiert und berechnen Sie den Grenzwert  $\lim_{n\to\infty}a_n$  in Abhängigkeit von den Startwerten a und b.

**Bemerkung**: Für zwei positive Zahlen a und b wird die Zahl c für die

$$c := \sqrt{a \cdot b}$$

gilt, als das geometrische Mittel von a und b bezeichnet.

**Hinweis 1**: Sie können diese Teilaufgabe durch eine geeignete Transformation der Form  $x_n := f(a_n)$  in die Rekurrenz-Gleichung überführen, die Sie in Teil (a) dieser Aufgabe bereits gelöst haben.

**Hinweis 2**: Bei der Lösung müssen Sie zwei Ergebnisse benutzen, die wir erst später beweisen können. Es gilt folgendes:

(a) Ist die Funktion  $f: \mathbb{R} \to \mathbb{R}$  stetig und ist die Folge  $(a_n)_{n \in \mathbb{N}^*}$  konvergent, so ist auch die Folge  $(f(a_n))_{n \in \mathbb{N}^*}$  konvergent und es gilt

$$\lim_{n \to \infty} f(a_n) = f\left(\lim_{n \to \infty} a_n\right).$$

Was genau eine stetige Funktion ist, werden wir im nächsten Kapitel klären.

(b) Die Exponentialfunktion  $x \mapsto \exp(x)$  ist stetig.

# 3.3 Reihen

**Definition 37 (Reihe)** Ist  $(a_n)_{n\in\mathbb{N}^*}$  eine Folge, so definieren wir die Folge der *Partial-Summen*  $(s_n)_{n\in\mathbb{N}^*}$  durch die Festsetzung

$$s_n := \sum_{i=1}^n a_i.$$

Diese Folge bezeichnen wir auch als unendliche Reihe. Die Folge  $(a_n)_{n\in\mathbb{N}^*}$  bezeichnen wir als die der Reihe  $\left(\sum_{i=1}^n a_i\right)_{n\in\mathbb{N}^*}$  zugrunde liegende Folge. Falls die Folge der Partial-Summen konvergiert, so schreiben wir den Grenzwert als

$$\sum_{i=1}^{\infty} a_i := \lim_{n \to \infty} \sum_{i=1}^{n} a_i.$$

Gelegentlich treten in der Praxis Folgen  $(a_n)_{n\in\mathbb{N}^*}$  auf, für welche die Folgenglieder  $a_i$  erst ab einem Index k>1 definiert sind. Um auch aus solchen Folge bequem Reihen bilden zu können, definieren wir in einem solchen Fall die Partial-Summen  $s_n$  durch

$$s_n = \sum_{i=k}^n a_i,$$

wobei wir vereinbaren, dass  $\sum_{i=1}^n a_i = 0$  ist, falls k > n ist.

Die mit Abstand wichtigste Reihe ist die *geometrische Reihe*. Bevor wir die Konvergenz dieser Reihe nachweisen können, müssen wir die folgende Ungleichung zeigen.

Satz 38 (Bernoullische Ungleichung) Es sei  $x \in \mathbb{R}$ ,  $n \in \mathbb{N}$  und es gelte  $x \geq -1$ . Dann gilt

$$(1+x)^n > 1 + n \cdot x.$$

Diese Ungleichung wird als Bernoullische Ungleichung (Jakob Bernoulli, 1655-1705) bezeichnet.

**Beweis**: Wir beweisen die Ungleichung durch vollständige Induktion für alle  $n \in \mathbb{N}$ .

I.A.: n = 0. Es gilt

$$(1+x)^0 = 1 \ge 1 = 1 + 0 \cdot x.$$

I.S.:  $n \mapsto n+1$ . Nach Induktions-Voraussetzung gilt

$$(1+x)^n \ge 1 + n \cdot x.$$
 (3.9)

Da  $x \ge -1$  ist, folgt  $1+x \ge 0$ , so dass wir die Ungleichung 3.9 mit 1+x multiplizieren können. Dann erhalten wir die folgende Ungleichungs-Kette

$$(1+x)^{n+1} \ge (1+n \cdot x) \cdot (1+x)$$
  
=  $1+(n+1) \cdot x + n \cdot x^2$   
 $\ge 1+(n+1) \cdot x$ 

Also haben wir insgesamt

$$(1+x)^{n+1} \ge 1 + (n+1) \cdot x$$

gezeigt und das ist die Behauptung für n+1.  $\checkmark$ 

**Satz 39** Es sei  $q \in \mathbb{R}$  mit |q| < 1. Dann gilt

$$\lim_{n\to\infty} q^n = 0.$$

**Beweis**: Wir nehmen zunächst an, dass q positiv ist. Aus q < 1 folgt dann

$$1<\frac{1}{q} \quad \text{ und damit } \quad 0<\frac{1}{q}-1.$$

Wir definieren nun

$$x := \frac{1}{q} - 1.$$

Mit Hilfe der Bernoullischen Ungleichung sehen wir, dass Folgendes gilt:

$$\frac{1}{q^n} = \left(1 + \left(\frac{1}{q} - 1\right)\right)^n$$

$$\geq 1 + n \cdot \left(\frac{1}{q} - 1\right)$$

$$= 1 + n \cdot x.$$

Durch Invertierung dieser Ungleichung erhalten wir

$$q^n \le \frac{1}{1 + n \cdot x}.$$

Ist nun ein  $\varepsilon > 0$  gegeben, so definieren wir

$$K := \left(\frac{1}{\varepsilon} - 1\right) \cdot \frac{1}{x} + 1.$$

Dann gilt für alle  $n \geq K$ :

$$\left(\frac{1}{\varepsilon} - 1\right) \cdot \frac{1}{x} + 1 \leq n$$

$$\Rightarrow \qquad \left(\frac{1}{\varepsilon} - 1\right) \cdot \frac{1}{x} < n$$

$$\Rightarrow \qquad \left(\frac{1}{\varepsilon} - 1\right) < n \cdot x$$

$$\Rightarrow \qquad \frac{1}{\varepsilon} < 1 + n \cdot x$$

$$\Rightarrow \qquad \frac{1}{1 + n \cdot x} < \varepsilon$$

Insgesamt haben wir nun für alle  $n \geq K$  gezeigt, dass

$$0 < q^n \le \frac{1}{1 + n \cdot x} < \varepsilon$$

gilt, also haben wir für  $n \geq K$ 

$$|q^n| < \varepsilon$$

Für q=0 ist diese Ungleichung offenbar auch gültig und wenn q negativ ist, gilt -q>0, so dass die Ungleichung für -q gilt:

$$|(-q)^n| < \varepsilon.$$

Wegen  $|(-q)^n| = |q^n|$  folgt daraus also, dass für alle q die Ungleichung

$$|q^n| < \varepsilon$$
 für  $n \ge K$ 

gültig ist und damit ist die Behauptung bewiesen.

Beispiel: Wir betrachten die Reihe

$$\left(\sum_{i=1}^{n} \frac{1}{i \cdot (i+1)}\right)_{n \in \mathbb{N}^*}.$$

Für die Partial-Summen zeigen wir durch Induktion über n, dass

$$\sum_{i=1}^{n} \frac{1}{i \cdot (i+1)} = 1 - \frac{1}{n+1} \tag{3.10}$$

gilt.

I.A.: n = 1: Einerseits haben wir für n = 1

$$\sum_{i=1}^{n} \frac{1}{i \cdot (i+1)} = \sum_{i=1}^{1} \frac{1}{i \cdot (i+1)} = \frac{1}{1 \cdot (1+1)} = \frac{1}{2},$$

andererseits gilt

$$1 - \frac{1}{n+1} = 1 - \frac{1}{1+1} = 1 - \frac{1}{2} = \frac{1}{2}. \checkmark$$

I.S.:  $n \mapsto n+1$ : Es gilt:

$$\sum_{i=1}^{n+1} \frac{1}{i \cdot (i+1)} = \sum_{i=1}^{n} \frac{1}{i \cdot (i+1)} + \frac{1}{(n+1) \cdot (n+2)}$$

$$\stackrel{IV}{=} 1 - \frac{1}{(n+1)} + \frac{1}{(n+1) \cdot (n+2)}$$

$$= 1 - \frac{n+2-1}{(n+1) \cdot (n+2)}$$

$$= 1 - \frac{n+1}{(n+1) \cdot (n+2)}$$

$$= 1 - \frac{1}{n+2} \checkmark$$

Damit haben wir Gleichung (3.10) durch vollständige Induktion nachgewiesen. Aus Gleichung (3.10) folgt nun

$$\sum_{i=1}^{\infty} \frac{1}{i \cdot (i+1)} = \lim_{n \to \infty} \sum_{i=1}^{n} \frac{1}{i \cdot (i+1)} = \lim_{n \to \infty} \left(1 - \frac{1}{n+1}\right) = 1.$$

**Definition 40 (Geometrische Reihe)** Es sei  $q \in \mathbb{C}$ . Die Reihe

$$\left(\sum_{i=0}^{n} q^{i}\right)_{n \in \mathbb{N}^{*}}$$

heißt geometrische Reihe. Es gilt

$$\sum_{i=0}^{n} q^i = \frac{1-q^{n+1}}{1-q} \quad \text{ falls } q \neq 1 \text{ ist.}$$

Beweis: Zum Beweis der Summenformel definieren wir die Partial-Summe

$$s_n := \sum_{i=0}^n q^i.$$

Wir betrachten den Ausdruck  $(1-q) \cdot s_n$ :

 $\Diamond$ 

$$(1-q) \cdot s_n = (1-q) \cdot \sum_{i=0}^n q^i$$

$$= \sum_{i=0}^n q^i - q \cdot \sum_{i=0}^n q^i$$

$$= \sum_{i=0}^n q^i - \sum_{i=0}^n q^{i+1}$$

$$= \sum_{i=0}^n q^i - \sum_{i=1}^{n+1} q^i$$

$$= \left(q^0 + \sum_{i=1}^n q^i\right) - \left(\sum_{i=1}^n q^i + q^{n+1}\right)$$

$$= q^0 - q^{n+1}$$

$$= 1 - q^{n+1}$$

Es gilt also

$$(1-q) \cdot s_n = 1 - q^{n+1}$$
.

Da  $q \neq 1$  voraus gesetzt ist, können wir diese Gleichung durch (1-q) dividieren. Dann erhalten wir für die Partial-Summen  $s_n$  den Ausdruck:

$$\sum_{i=0}^{n} q^{i} = \frac{1 - q^{n+1}}{1 - q}$$

Falls |q|<1 ist, konvergiert die Folge  $\left(q^{n}\right)_{n\in\mathbb{N}^{*}}$  gegen 0. Damit gilt:

$$\sum_{i=0}^{\infty} q^i = \frac{1}{1-q}$$

**Bemerkung**: Die geometrische Reihe ist <u>mit Abstand</u> die wichtigste Reihe, die Ihnen in der Informatik begegnen wird.

**Aufgabe 20**: Berechnen Sie den Wert der Reihe  $\sum_{n=0}^{\infty} \frac{3}{n^2 + 3 \cdot n + 2}$ .

Hinweis: Sie können die Summe durch eine Partialbruch-Zerlegung vereinfachen.

Definition 41 (Alternierende Reihe) Hat eine Reihe die Form

$$\left(\sum_{i=1}^{n} (-1)^{i} \cdot a_{i}\right)_{n \in \mathbb{N}^{*}}$$

und gilt entweder

$$\forall i \in \mathbb{N}^* : a_i \ge 0 \quad \text{oder} \quad \forall i \in \mathbb{N}^* : a_i \le 0,$$

so haben aufeinander folgende Glieder der Reihe ein unterschiedliches Vorzeichen (es sei denn, dass die Glieder den Wert 0 haben). In diesem Fall sprechen wir daher von einer *alternierenden Reihe.* 

 $\Diamond$ 

 $\Diamond$ 

Beispiel: Die Reihe

$$\left(\sum_{i=1}^{n} \frac{(-1)^{i+1}}{i}\right)_{n \in \mathbb{N}^*}$$

ist eine alternierende Reihe, denn die Vorzeichen aufeinander folgender Reihenglieder sind alternierend positiv und negativ:

$$\sum_{i=1}^{\infty} \frac{(-1)^{i+1}}{i} = \frac{1}{1} - \frac{1}{2} + \frac{1}{3} - \frac{1}{4} \pm \cdots$$

Wir werden später sehen, dass diese Reihe gegen den Wert ln(2) konvergiert.

**Definition 42 (Null-Folge)** Die Folge  $(a_n)_{n\in\mathbb{N}^*}$  ist eine *Null-Folge* wenn gilt:

$$\lim_{n \to \infty} a_n = 0.$$

**Aufgabe 21**: Die Folge  $(a_n)_{n\in\mathbb{N}^*}$  sei eine monoton fallende *Null-Folge*. Zeigen Sie, dass dann

$$\forall n \in \mathbb{N}^* : 0 \le a_n$$

gilt.

Hinweis: Führen Sie den Beweis indirekt.

### Satz 43 (Leibniz-Kriterium, (Gottfried Wilhelm Leibniz, 1646-1716))

Wenn die Folge  $(a_n)_{n\in\mathbb{N}^*}$  eine monoton fallende Null-Folge ist, dann konvergiert die alternierende Reihe

$$\left(\sum_{i=1}^{n} (-1)^i \cdot a_i\right)_{n \in \mathbb{N}^*}$$

**Beweis**: Die Partial-Summen  $s_n$  sind durch

$$s_n = \sum_{i=1}^n (-1)^i \cdot a_i$$

definiert. Wir betrachten zunächst die Folge der Partial-Summen mit geraden Indizes, wir betrachten also die Folge  $(s_{2\cdot n})_{n\in\mathbb{N}^*}$  und zeigen, dass diese Folge monoton fallend ist. Es gilt

$$s_{2\cdot(n+1)} = s_{2\cdot n} + (-1)^{2\cdot n+1} \cdot a_{2\cdot n+1} + (-1)^{2\cdot n+2} \cdot a_{2\cdot n+2} = s_{2\cdot n} - a_{2\cdot n+1} + a_{2\cdot n+2}.$$
 (3.11)

Daraus folgt

$$\begin{array}{rclcrcl} s_{2\cdot(n+1)} & \leq & s_{2\cdot n} \\ \Leftrightarrow & s_{2\cdot n} - a_{2\cdot n+1} + a_{2\cdot n+2} & \leq & s_{2\cdot n} \\ \Leftrightarrow & & a_{2\cdot n+2} & \leq & a_{2\cdot n+1} \end{array}$$

Die letzte Ungleichung ist aber nichts anderes als die Monotonie der Folge  $(a_n)_{n\in\mathbb{N}^*}$ . Als nächstes zeigen wir durch vollständige Induktion, dass die Folge der Partial-Summen nach unten beschränkt ist, genauer gilt

$$s_n \ge -a_1$$
 für alle  $n \in \mathbb{N}^*$ .

Um diese Ungleichung nachzuweisen, zeigen wir zunächst durch vollständige Induktion, dass für alle  $n \in \mathbb{N}$  gilt:

$$s_{2\cdot n+1} \ge -a_1.$$

I.A.: n = 0.

$$s_{2\cdot 0+1} = s_1 = -a_1 \ge -a_1.$$

I.S.:  $n \mapsto n+1$ 

$$\begin{array}{lll} s_{2\cdot(n+1)+1} &=& s_{2\cdot n+1}+a_{2\cdot n+2}-a_{2\cdot n+3}\\ &\geq& -a_1+a_{2\cdot n+2}-a_{2\cdot n+3} & \text{nach Induktions-Voraussetzung}\\ &\geq& -a_1 & \text{wegen } a_{2\cdot n+2}\geq a_{2\cdot n+3}. \end{array}$$

Nun gilt für  $n \in \mathbb{N}^*$ 

$$s_{2\cdot n} = s_{2\cdot n-1} + a_{2\cdot n} \ge s_{2\cdot n-1} \ge -a_1.$$

Da wir nun gezeigt haben, dass die Folge  $\left(s_{2\cdot n}\right)_{n\in\mathbb{N}^*}$  sowohl monoton fallend als auch nach unten beschränkt ist, folgt aus Satz 32, dass diese Folge konvergent ist. Der Grenzwert dieser Folge sei s:

$$s := \lim_{n \to \infty} s_{2 \cdot n}.$$

Dann konvergiert auch die Folge  $(s_n)_{n\in\mathbb{N}^*}$  gegen s. Dies sehen wir wie folgt: Sei  $\varepsilon>0$  gegeben. Weil  $(s_{2\cdot n})_{n\in\mathbb{N}^*}$  gegen s konvergiert, gibt es eine Zahl  $K_1$ , so dass für alle  $n\geq K_1$  die Ungleichung

$$\left|s_{2\cdot n} - s\right| < \frac{1}{2} \cdot \varepsilon \tag{3.12}$$

erfüllt ist. Weil  $(a_n)_{n\in\mathbb{N}^*}$  eine Null-Folge ist, gibt es außerdem eine Zahl  $K_2$ , so dass für alle  $n\geq K_2$  die Ungleichung

$$\left|a_n - 0\right| < \frac{1}{2} \cdot \varepsilon \tag{3.13}$$

gilt. Wir setzen  $K:=\max(2\cdot K_1+1,K_2)$  und zeigen, dass für alle  $n\geq K$  die Ungleichung

$$|s_n - s| < \varepsilon$$

gilt. Wir erbringen diesen Nachweis über eine Fall-Unterscheidung:

1. n ist gerade, also gilt  $n = 2 \cdot m$ .

$$\begin{vmatrix} s_n - s \end{vmatrix} = \begin{vmatrix} s_{2 \cdot m} - s \end{vmatrix}$$

$$< \frac{1}{2} \cdot \varepsilon$$

$$< \varepsilon,$$

denn aus  $n=2\cdot m$  und  $n\geq K$  folgt  $2\cdot m\geq 2\cdot K_1+1$ , also erst recht  $2\cdot m\geq 2\cdot K_1$  und damit dann  $m\geq K_1$ .

2. n ist ungerade, also gilt  $n = 2 \cdot m + 1$ .

$$|s_n - s| = |s_{2 \cdot m+1} - s|$$

$$= |s_{2 \cdot m+1} - s_{2 \cdot m} + s_{2 \cdot m} - s|$$

$$\leq |s_{2 \cdot m+1} - s_{2 \cdot m}| + |s_{2 \cdot m} - s|$$

$$< |a_{2 \cdot m+1}| + \frac{1}{2} \cdot \varepsilon$$

$$< \frac{1}{2} \cdot \varepsilon + \frac{1}{2} \cdot \varepsilon$$

$$= \varepsilon.$$

denn aus  $n=2\cdot m+1$  und  $n\geq K$  folgt sowohl  $m\geq K_1$  als auch  $n\geq K_2$ .

Damit ist der Beweis abgeschlossen.

# Satz 44 (Cauchy'sches Konvergenz-Kriterium für Reihen)

Die Reihe  $\left(\sum_{i=0}^n a_i\right)_{n\in\mathbb{N}^*}$  ist genau dann konvergent, wenn es für alle  $\varepsilon>0$  eine Zahl K gibt, so dass

$$\forall n, l \in \mathbb{N}^* : \left( n \ge K \to \left| \sum_{i=n+1}^{n+l} a_i \right| < \varepsilon \right)$$

gilt.

**Beweis**: Nach den Sätzen aus dem Abschnitt über Folgen ist die Folge  $(s_n)_{n\in\mathbb{N}^*}$  der durch

$$s_n = \sum_{i=0}^n a_i$$

definierten Partial-Summen genau dann konvergent, wenn  $(s_n)_{n\in\mathbb{N}^*}$  eine Cauchy-Folge ist, wenn also gilt:

$$\forall \varepsilon \in \mathbb{R}_+^* : \exists K \in \mathbb{R} : \forall m, n \in \mathbb{N}^* : (m \ge K \land n \ge K \to |s_m - s_n| < \varepsilon).$$

In der letzten Formel können wir ohne Einschränkung der Allgemeinheit annehmen, dass  $n \leq m$  gilt. Dann ist m = n + l für eine natürliche Zahl l. Setzen wir hier die Definition der Partial-Summen ein, so erhalten wir

$$|s_m - s_n| = |s_{n+l} - s_n|$$

$$= \left| \sum_{i=1}^{n+l} a_i - \sum_{i=1}^n a_i \right|$$

$$= \left| \sum_{i=n+1}^{n+l} a_i \right|$$

und damit ist klar, dass die Ungleichung des Satzes äquivalent dazu ist, dass die Folge der Partial-Summen eine Cauchy-Folge ist.  $\Box$ 

#### Korollar 45

Wenn die Reihe  $\left(\sum_{i=1}^n a_i\right)_{n\in\mathbb{N}^*}$  konvergent ist, dann ist die Folge  $\left(a_n\right)_{n\in\mathbb{N}^*}$  eine Null-Folge.

Beweis: Nach dem Cauchy'schen Konvergenz-Kriterium gilt

$$\forall \varepsilon \in \mathbb{R}_+^* : \exists K \in \mathbb{R} : \forall n, l \in \mathbb{N}^* : \left( n \ge K \to \left| \sum_{i=n+1}^{n+l} a_i \right| < \varepsilon \right).$$

Setzen wir hier l=1 so haben wir insbesondere

$$\forall \varepsilon \in \mathbb{R}_+^* : \exists K \in \mathbb{R} : \forall n \in \mathbb{N}^* : \left( n \ge K \to \left| \sum_{i=n+1}^{n+1} a_i \right| < \varepsilon \right).$$

Wegen

$$\left| \sum_{i=n+1}^{n+1} a_i \right| = |a_{n+1}|$$

folgt also

$$\forall \varepsilon \in \mathbb{R}_+^* : \exists K \in \mathbb{R} : \forall n \in \mathbb{N}^* : (n \ge K \to |a_{n+1}| < \varepsilon).$$

 $\Diamond$ 

Diese Formel drückt aus, dass  $(a_n)_{n\in\mathbb{N}^*}$  eine Null-Folge ist.

Bemerkung: Mit Hilfe des letzten Satzes können wir zeigen, dass die harmonische Reihe

$$\left(\sum_{i=1}^{n} \frac{1}{i}\right)_{n \in \mathbb{N}^*}$$

divergiert. Wäre diese Reihe konvergent, so gäbe es nach dem Cauchy'schen Konvergenz-Kriterium eine Zahl K, so dass für alle  $n \geq K$  und alle l die Ungleichung

$$\sum_{i=n+1}^{n+l} \frac{1}{i} < \frac{1}{2}$$

gilt. Insbesondere würde diese Ungleichung dann für l=n gelten. Für beliebige n gilt aber die folgende Abschätzung:

$$\sum_{i=n+1}^{n+n} \frac{1}{i} \ge \sum_{i=n+1}^{2 \cdot n} \frac{1}{2 \cdot n} = n \cdot \frac{1}{2 \cdot n} = \frac{1}{2}$$

Damit erfüllt die harmonische Reihe das Cauchy'sche Konvergenz-Kriterium nicht.

Satz 46 (Majoranten-Kriterium) Für die Folgen  $(a_n)_{n\in\mathbb{N}^*}$  und  $(b_n)_{n\in\mathbb{N}^*}$  gelte:

- 1.  $\forall n \in \mathbb{N}^* : 0 \le a_n \le b_n$ .
- 2. Der Grenzwert  $\sum_{i=1}^{\infty} b_i$  existiert.

Dann existiert auch der Grenzwert  $\sum_{i=1}^{\infty} a_i$ .

Beweis: Es gilt

$$\sum_{i=1}^{n} a_i \le \sum_{i=1}^{n} b_i \le \sum_{i=1}^{\infty} b_i.$$

Also ist die Folge  $\left(\sum\limits_{i=1}^n a_i\right)_{n\in\mathbb{N}^*}$  monoton wachsend und beschränkt und damit konvergent.  $\Box$ 

Bemerkung: Oft wird im Majoranten-Kriterium die Voraussetzung

$$\forall n \in \mathbb{N}^* : 0 \le a_n \le b_n$$

abgeschwächt zu

$$\forall n \in \mathbb{N}^* : (n \ge K \to 0 \le a_n \le b_n).$$

Hierbei ist K dann eine geeignet gewählte Schranke. Die Gültigkeit dieser Form des Majoranten-Kriteriums folgt aus der Tatsache, dass das Abändern endlich vieler Glieder einer Reihe für die Frage, ob eine Reihe konvergent ist, unbedeutend ist.

**Beispiel**: Wir zeigen mit dem Majoranten-Kriterium, dass die Reihe  $\left(\sum_{i=1}^n \frac{1}{i^2}\right)_{n\in\mathbb{N}^*}$  konvergiert. Es gilt

$$i+1 \ge i \qquad | \cdot (i+1)$$
 
$$\Rightarrow (i+1)^2 \ge i \cdot (i+1) \qquad | \frac{1}{\cdot}$$
 
$$\Rightarrow \frac{1}{(i+1)^2} \le \frac{1}{i \cdot (i+1)}$$

 $\text{Damit ist die Reihe} \left( \sum_{i=1}^n \frac{1}{i \cdot (i+1)} \right)_{n \in \mathbb{N}^*} \text{ eine konvergente Majorante der Reihe} \left( \sum_{i=1}^n \frac{1}{(i+1)^2} \right)_{n \in \mathbb{N}^*}.$  Wegen

$$\sum_{i=1}^{\infty} \frac{1}{i^2} = \frac{1}{1^2} + \sum_{i=1}^{\infty} \frac{1}{(i+1)^2}$$

folgt die Konvergenz aus dem Majoranten-Kriterium.

Bemerkung: Wir werden später in dem Kapitel über Fourier-Reihen zeigen, dass

$$\sum_{i=1}^{\infty} \frac{1}{i^2} = \frac{\pi^2}{6} \quad \text{gilt.} \qquad \diamond$$

Satz 47 (Minoranten-Kriterium) Für die Folgen  $(a_n)_{n\in\mathbb{N}^*}$  und  $(b_n)_{n\in\mathbb{N}^*}$  gelte:

- 1.  $\forall n \in \mathbb{N}^* : 0 \le a_n \le b_n$ .
- 2. Der Grenzwert  $\sum_{i=1}^{\infty} a_i$  existiert nicht.

Dann existiert auch der Grenzwert  $\sum_{i=1}^{\infty} b_i$  nicht.

**Beweis**: Wir führen den Beweis indirekt und nehmen an, dass der Grenzwert  $\sum\limits_{i=1}^{\infty}b_i$  existiert. Nach dem Majoranten-Kriterium müsste dann auch der Grenzwert  $\sum\limits_{i=1}^{\infty}a_i$  existieren und dass steht im Widerspruch zur Voraussetzung.

Beispiel: Wir zeigen, dass die Reihe

$$\left(\sum_{i=1}^n \frac{1}{\sqrt{i}}\right)_{n \in \mathbb{N}^*}$$

nicht konvergiert. Dazu benutzen wir das Minoranten-Kriterium und zeigen, dass die Reihe

$$\left(\sum_{i=1}^{n} \frac{1}{i}\right)_{n \in \mathbb{N}^*}$$

eine divergente Minorante der Reihe

$$\left(\sum_{i=1}^{n} \frac{1}{\sqrt{i}}\right)_{n \in \mathbb{N}^*}$$

ist, denn es gilt:

Da die letzte Ungleichung offenbar für alle  $i \in \mathbb{N}^*$  wahr ist, ist der Beweis abgeschlossen.

Satz 48 (Quotienten-Kriterium) Es sei  $(a_n)_{n\in\mathbb{N}^*}$  eine Folge und  $q\in\mathbb{R}$  eine Zahl, so dass gilt:

- 1.  $0 \le q < 1$
- $2. \ \forall n \in \mathbb{N}^* : 0 \le a_n$
- 3.  $\forall n \in \mathbb{N}^* : a_{n+1} \leq q \cdot a_n$

Dann konvergiert die Reihe  $\left(\sum\limits_{i=1}^{n}a_{i}\right)_{n\in\mathbb{N}^{*}}.$ 

Beweis: Wir zeigen, dass die geometrische Reihe

$$\left(\sum_{i=1}^{n} a_1 \cdot q^i\right)_{n \in \mathbb{N}^*}$$

eine konvergente Majorante der Reihe

$$\left(\sum_{i=1}^{n} a_i\right)_{n \in \mathbb{N}^*}$$

ist. Dazu zeigen wir durch Induktion über n, dass folgendes gilt:

$$\forall n \in \mathbb{N}^* : a_n \le a_1 \cdot q^{n-1}$$

I.A. : n=1. Wegen  $q^0=1$  gilt trivialerweise

$$a_1 \leq a_1 \cdot q^0$$
.

I.S. :  $n \mapsto n+1$ . Es gilt:

$$a_{n+1} \le q \cdot a_n$$
 nach Voraussetzung 
$$\le q \cdot a_1 \cdot q^{n-1}$$
 nach Induktions-Voraussetzung 
$$= a_1 \cdot q^n.$$

**Bemerkung**: Beim Quotienten-Kriterium sind eigentlich nur die Beträge der Folgenglieder  $|a_n|$  wichtig, denn es lässt sich folgende Verschärfung des Quotienten-Kriteriums zeigen: Ist  $(a_n)_{n\in\mathbb{N}^*}$  eine Folge,  $q\in\mathbb{R}$  und  $K\in\mathbb{R}$ , so dass

$$0 \le q < 1 \quad \text{ und } \quad \forall n \in \mathbb{N}^* : \left( n \ge K \to \left| \frac{a_{n+1}}{a_n} \right| \le q \right)$$

gilt. Dann konvergiert die Reihe  $\left(\sum\limits_{i=1}^{n}a_{i}\right)_{n\in\mathbb{N}^{*}}$ 

Beispiel: Wir zeigen mit Hilfe des Quotienten-Kriteriums, dass die Reihe

$$\left(\sum_{i=1}^{n} \frac{z^{i}}{i!}\right)_{n \in \mathbb{N}^{*}}$$

für alle  $z\in\mathbb{C}$  konvergiert. Für z=0 ist die Konvergenz der Reihe trivial und sonst betrachten wir den Quotienten  $a_{n+1}/a_n$  für diese Reihe, setzen  $K=2\cdot|z|$  und  $q=\frac{1}{2}$  und zeigen, dass das Quotienten-Kriterium erfüllt ist, denn für alle  $n\geq K$  gilt:

$$\left| \frac{a_{n+1}}{a_n} \right| = \frac{\frac{|z^{n+1}|}{(n+1)!}}{\frac{|z^n|}{n!}} = \frac{|z^{n+1}| \cdot n!}{|z^n| \cdot (n+1)!} = \frac{|z|}{n+1} \le \frac{|z|}{K} = \frac{|z|}{2 \cdot |z|} = \frac{1}{2}.$$

Also gilt  $|a_{n+1}| \leq \frac{1}{2} \cdot |a_n|$  und damit ist das Quotienten-Kriterium erfüllt.

**Bemerkung**: Wir werden später zeigen, dass die in dem letzten Beispiel präsentierte Reihe die natürliche Exponentialfunktion berechnet, es gilt

$$e^z = \sum_{n=0}^{\infty} \frac{z^n}{n!}$$

$$\text{ für alle }z\in\mathbb{C}.$$

Satz 49 (Wurzel-Kriterium) Es sei  $(a_n)_{n\in\mathbb{N}^*}$  eine Folge und  $q\in\mathbb{R}$  eine Zahl, so dass

- 1.  $0 \le q < 1$
- $2. \ \forall n \in \mathbb{N}^* : 0 \le a_n$
- 3.  $\forall n \in \mathbb{N}^* : \sqrt[n]{a_n} \leq q$

gilt. Dann konvergiert die Reihe  $\left(\sum_{i=1}^n a_i\right)_{n\in\mathbb{N}^*}$  .

**Beweis**: Auch hier können wir den Nachweis der Konvergenz dadurch führen indem wir zeigen, dass die geometrische Reihe  $\left(\sum_{i=1}^n q^i\right)_{n\in\mathbb{N}^*}$  eine konvergente Majorante ist: Für n>0 gilt

$$a_n \le q^n \Leftrightarrow \sqrt[n]{a_n} \le q.$$

**Bemerkung**: Beim Wurzel-Kriterium sind eigentlich nur die Beträge der Folgenglieder  $|a_n|$  wichtig, denn es lässt sich folgende Verschärfung des Wurzel-Kriteriums zeigen: Ist  $(a_n)_{n\in\mathbb{N}^*}$  eine Folge,  $q\in\mathbb{R}$  und  $K\in\mathbb{R}$ , so dass

$$0 \le q < 1 \quad \land \quad \forall n \in \mathbb{N}^* : (n \ge K \to \sqrt[n]{|a_n|} \le q)$$

gilt. Dann konvergiert die Reihe  $\left(\sum\limits_{i=1}^{n}a_{i}\right)_{n\in\mathbb{N}^{*}}$ .

**Beispiel**: Wir zeigen mit dem Wurzel-Kriterium, dass die Reihe  $\left(\sum_{i=1}^n \frac{1}{i!}\right)_{n\in\mathbb{N}^*}$  konvergiert. Wir setzen

K=4 und  $q=\frac{1}{2}$ . Zunächst können Sie mit vollständiger Induktion leicht zeigen, dass für alle natürlichen Zahlen  $n\geq 4$  die Ungleichung  $n!\geq 2^n$  gilt. Damit haben wir für  $n\geq 4$ :

$$\sqrt[n]{\frac{1}{n!}} \le \frac{1}{2} \quad \Leftrightarrow \quad \frac{1}{n!} \le \left(\frac{1}{2}\right)^n \quad \Leftrightarrow \quad n! \ge 2^n.$$

**Aufgabe 22**: Im Folgenden sei  $(a_n)_{n\in\mathbb{N}^*}$  eine monoton fallende Folge nicht-negativer Zahlen, es gelte also

$$a_n > a_{n+1} > 0$$
 für alle  $n \in \mathbb{N}^*$ .

(a) Nehmen Sie an, dass die Reihe  $\sum\limits_{n=0}^{\infty}2^n\cdot a_{2^n}$  konvergiert. Zeigen Sie, dass dann auch die Reihe

$$\sum_{n=1}^{\infty} a_n$$

konvergiert.

Hinweis: Zeigen Sie zunächst, dass

$$\sum_{i=1}^{2^n} a_i \le \sum_{i=0}^n 2^i \cdot a_{2^i}$$

gilt. Der Nachweis dieser Ungleichung funktioniert ähnlich wie der Nachweis der Divergenz der harmonischen Reihe.

(b) Nehmen Sie an, dass die Reihe  $\sum_{n=1}^{\infty}a_n$  konvergiert. Zeigen Sie, dass dann auch die Reihe  $\sum_{n=0}^{\infty}2^n\cdot a_{2^n}$  konvergiert.

Hinweis: Zeigen Sie die Ungleichung

$$\sum_{i=0}^{n} 2^{i} \cdot a_{2^{i}} \le 2 \cdot \sum_{i=1}^{2^{n}} a_{i}.$$

**Bemerkung**: Die in (a) und (b) bewiesenen Aussagen können wir zu dem Kondensations-Kriterium von Cauchy zusammenfassen: Die Reihe

$$\sum_{n=1}^\infty a_n \quad \text{ konvergiert genau dann, wenn die Reihe} \quad \sum_{n=0}^\infty 2^n \cdot a_{2^n} \quad \text{ konvergiert.}$$

(c) Untersuchen Sie die Konvergenz der Reihe

$$\sum_{n=2}^{\infty} \frac{1}{n \cdot \log_2(n)}.$$

(d) Untersuchen Sie die Konvergenz der Reihe

$$\sum_{n=2}^{\infty} \frac{1}{n \cdot (\log_2(n))^2}.$$

# 3.3.1 Absolute Konvergenz

Definition 50 (Absolute Konvergenz) Eine Reihe

$$\left(\sum_{i=1}^{n} a_i\right)_{n \in \mathbb{N}^*}$$

heißt absolut konvergent genau dann, wenn die Reihe der Absolutbeträge

$$\left(\sum_{i=1}^{n} |a_i|\right)_{n \in \mathbb{N}^*}$$

 $\text{konvergiert. Falls die Reihe} \left(\sum_{i=1}^n a_i\right)_{n \in \mathbb{N}^*} \text{konvergiert, aber die Reihe der Absolutbeträge} \left(\sum_{i=1}^n |a_i|\right)_{n \in \mathbb{N}^*}$  divergent ist, dann sagen wir, dass die Reihe  $\left(\sum_{i=1}^n a_i\right)_{n \in \mathbb{N}^*}$  bedingt konvergent ist.  $\diamond$ 

#### Beispiele:

(a) Die alternierende harmonische Reihe

$$\left(\sum_{i=1}^{n} \frac{(-1)^{i+1}}{i}\right)_{n \in \mathbb{N}^*}$$

ist nach dem Leibniz-Kriterium konvergent, aber nicht absolut konvergent, denn die Reihe der Absolutbeträge ist die harmonische Reihe und die harmonische Reihe ist divergent. Folglich ist die alternierende harmonische Reihe bedingt konvergent.

(b) Die Reihe

$$\left(\sum_{i=1}^{n} \frac{(-1)^i}{i^2}\right)_{n \in \mathbb{N}^*}$$

 $\Diamond$ 

ist absolut konvergent, denn der Grenzwert  $\sum_{n=1}^{\infty} \frac{1}{n^2}$  existiert.

**Satz 51** Falls die Reihe  $\left(\sum_{i=1}^n a_i\right)_{n\in\mathbb{N}^*}$  absolut konvergent ist, dann ist sie auch konvergent.

Beweis: Nach Voraussetzung wissen wir, dass der Grenzwert

$$s := \lim_{n \to \infty} \sum_{i=1}^{n} |a_i|$$

existiert. An der Konvergenz ändert sich auch nichts, wenn wir die Reihe mit 2 multiplizieren. Weiter gilt für jedes  $i \in \mathbb{N}^*$  die Ungleichung

$$0 \le a_i + |a_i| \le 2 \cdot |a_i|,$$

denn wenn  $a_i$  positiv ist, gilt  $a_i + |a_i| = 2 \cdot |a_i|$  und wenn  $a_i$  negativ ist, dann gilt  $a_i + |a_i| = 0$ . Also ist die Reihe

$$\sum_{i=1}^n 2 \cdot |a_i|$$
 eine konvergente Majorante der Reihe  $\sum_{i=1}^n \left(a_i + |a_i|\right)$ 

und folglich konvergiert die Reihe  $\sum\limits_{i=1}^n ig(a_i+|a_i|ig)$  nach dem Majoranten-Kriterium. Nun gilt aber

$$\lim_{n \to \infty} \sum_{i=1}^{n} a_i = \lim_{n \to \infty} \sum_{i=1}^{n} (a_i + |a_i|) - \lim_{n \to \infty} \sum_{i=1}^{n} |a_i|$$

und da die Grenzwerte auf der rechten Seite dieser Gleichung existieren, existiert auch der Grenzwert auf der linken Seite dieser Gleichung.  $\Box$ 

Aufgabe 23: Zeigen Sie, dass der Grenzwert

$$\sum_{n=1}^{\infty} \frac{1 + 2 \cdot \sin(3 \cdot n + 4)}{n^2}$$

existiert.

## 3.4 Potenz-Reihen

Es bezeichne x eine Variable und  $(a_n)_{n\in\mathbb{N}^*}$  sei eine Folge von Zahlen. Dann bezeichnen wir den Ausdruck

$$\sum_{n=0}^{\infty} a_n \cdot x^n$$

als formale Potenz-Reihe. Wichtig ist hier, dass x keine feste Zahl ist, sondern eine Variable, für die wir später reelle (oder auch komplexe) Zahlen einsetzen. Wenn wir in einer Potenz-Reihe für x eine feste Zahl einsetzen, wird aus der Potenz-Reihe eine gewöhnliche Reihe. Der Begriff der Potenz-Reihen kann als eine Verallgemeinerung des Begriffs des Polynoms aufgefasst werden.

#### Beispiele:

1.  $\sum_{n=0}^{\infty} \frac{x^n}{n!}$  ist eine formale Potenz-Reihe. Wir haben oben mit Hilfe des Quotienten-Kriteriums gezeigt, dass diese Reihe für beliebige reelle und komplexe Zahlen konvergiert.

2.  $\sum_{n=1}^{\infty} \frac{x^n}{n}$  ist eine formale Potenz-Reihe. Setzen wir für x den Wert 1 ein, so erhalten wir die divergente harmonische Reihe. Für x=-1 erhalten wir eine alternierende Reihe, die nach dem Leibniz-Kriterium konvergent ist.

In der Theorie der Potenz-Reihen ist die Frage entscheidend, welche Zahlen wir für die Variable x einsetzen können, so dass die Reihe konvergiert. Diese Frage wird durch die folgenden Sätze beantwortet

#### Satz 52 Wenn die Potenz-Reihe

$$\sum_{n=0}^{\infty} a_n \cdot x^n$$

für einen Wert  $u \in \mathbb{C}$  konvergiert, dann konvergiert die Reihe auch für alle  $v \in \mathbb{C}$ , für die |v| < |u| ist.

Beweis: Da die Reihe

$$\sum_{n=0}^{\infty} a_n \cdot u^n$$

konvergiert, folgt aus dem Korollar zum Cauchy'schen Konvergenz-Kriterium, dass die Folge  $\left(a_n\cdot u^n\right)_{n\in\mathbb{N}^*}$  eine Null-Folge ist. Also gibt es eine Zahl K, so dass für alle  $n\geq K$  die Ungleichung

$$|a_n \cdot u^n| < 1$$

gilt. Wir definieren

$$q := \left| \frac{v}{u} \right|.$$

Aus |v| < |u| folgt q < 1. Dann haben wir für alle  $n \ge K$  die folgende Abschätzung:

$$|a_n \cdot v^n| = |a_n \cdot u^n| \cdot \left| \frac{v^n}{u^n} \right| = |a_n \cdot u^n| \cdot q^n \le 1 \cdot q^n = q^n.$$

Diese Abschätzung zeigt, dass die geometrische Reihe eine konvergente Majorante der Reihe

$$\sum_{n=1}^{\infty} a_n \cdot v^n$$

ist. Damit folgt die Konvergenz dieser Reihe aus dem Majoranten-Kriterium.

### Satz 53 Wenn die Potenz-Reihe

$$\sum_{n=0}^{\infty} a_n \cdot x^n$$

für einen Wert  $u \in \mathbb{C}$  divergiert, dann divergiert die Reihe auch für alle  $v \in \mathbb{C}$ , für die |u| < |v| ist.

Beweis: Würde die Reihe

$$\sum_{n=0}^{\infty} a_n \cdot v^n$$

konvergieren, dann müsste nach Satz 52 auch die Reihe

$$\sum_{n=0}^{\infty} a_n \cdot u^n$$

konvergieren, was im Widerspruch zur Voraussetzung steht.

Die letzten beiden Sätze ermöglichen es nun, den Begriff des Konvergenz-Radius zu definieren. Es sei

$$\sum_{n=0}^{\infty} a_n \cdot x^n$$

eine formale Potenz-Reihe. Wenn diese Reihe für alle  $x\in\mathbb{C}$  konvergiert, dann sagen wir, dass der Konvergenz-Radius den Wert  $\infty$  hat. Andernfalls definieren wir den Konvergenz-Radius als

$$R := \sup \Big\{ |u| \ \bigg| \ u \in \mathbb{C} \ \land \ \sum_{n=0}^{\infty} a_n \cdot u^n \text{ konvergiert} \Big\}.$$

Aus den letzten beiden Sätzen folgt dann:

1. 
$$\forall z \in \mathbb{C}: \left(|z| < R \to \sum_{n=0}^{\infty} a_n \cdot z^n \text{ konvergiert}\right)$$

2. 
$$\forall z \in \mathbb{C} : \left( |z| > R \to \sum_{n=0}^{\infty} a_n \cdot z^n \text{ divergiert} \right)$$

In der Gauß'schen Zahlen-Ebene ist die Menge  $\{z\in\mathbb{C}\mid |z|< R\}$  das Innere eines Kreises mit dem Radius R um den Nullpunkt. Der folgende Satz gibt uns eine effektive Möglichkeit, den Konvergenz-Radius zu berechnen.

Satz 54 Es sei

$$\sum_{n=0}^{\infty} a_n \cdot z^n$$

eine formale Potenz-Reihe, für alle  $n \in \mathbb{N}^*$  gelte  $a_n \neq 0$  und die Folge

$$\left(\frac{|a_n|}{|a_{n+1}|}\right)_{n\in\mathbb{N}^*}$$

konvergiere. Dann ist der Konvergenz-Radius R durch folgende Formel gegeben:

$$R = \lim_{n \to \infty} \left| \frac{a_n}{a_{n+1}} \right|.$$

**Beweis**: Es sei  $u \in \mathbb{C}$  mit |u| < R. In diesem Fall müssen wir zeigen, dass die Reihe

$$\sum_{n=0}^{\infty} a_n \cdot u^n$$

konvergiert. Wir werden diesen Nachweis mit Hilfe des Quotienten-Kriteriums erbringen. Wir setzen

$$q := \frac{|u|}{\frac{1}{2} \cdot (R + |u|)}$$

und zeigen, dass q < 1 ist:

$$\begin{aligned} q &< 1 \\ \Leftrightarrow & \frac{|u|}{\frac{1}{2} \cdot (R + |u|)} < 1 \\ \Leftrightarrow & 2 \cdot |u| < R + |u| \\ \Leftrightarrow & |u| < R \end{aligned}$$

und die letzte Ungleichung ist nach Wahl von u wahr. Da wir nur Äquivalenzumformungen benutzt haben, ist damit auch die Formel q<1 wahr. Wir zeigen weiter, dass für alle hinreichend großen n die Ungleichung

$$\frac{|a_{n+1} \cdot u^{n+1}|}{|a_n \cdot u^n|} \le q$$

erfüllt ist. Um diesen Beweis zu führen, müssen wir etwas ausholen. Zunächst folgt aus

$$R = \lim_{n \to \infty} \left| \frac{a_n}{a_{n+1}} \right|,$$

dass es für beliebige  $\varepsilon>0$  eine Zahl K gibt, so dass für alle  $n\geq K$  die Ungleichung

$$\left| \left| \frac{a_n}{a_{n+1}} \right| - R \right| < \varepsilon$$

gilt. Wir setzen  $\varepsilon:=\frac{1}{2}\cdot(R-|u|)$ . Wir zeigen, dass dann für alle  $n\geq K$  die Ungleichung  $\left|\frac{a_n}{a_{n+1}}\right|>\frac{1}{2}\cdot(R+|u|)$  gilt:

$$\left| \left| \frac{a_n}{a_{n+1}} \right| + \left( R - \left| \frac{a_n}{a_{n+1}} \right| \right) \right| = |R| = R$$

$$\Rightarrow \left| \frac{a_n}{a_{n+1}} \right| + \left| \left( R - \left| \frac{a_n}{a_{n+1}} \right| \right) \right| \ge R$$

$$\Rightarrow \left| \frac{a_n}{a_{n+1}} \right| + \varepsilon > R$$

$$\Rightarrow \left| \frac{a_n}{a_{n+1}} \right| + \frac{1}{2} \cdot (R - |u|) > R$$

$$\Rightarrow \left| \frac{a_n}{a_{n+1}} \right| > R - \frac{1}{2} \cdot (R - |u|)$$

$$\Rightarrow \left| \frac{a_n}{a_{n+1}} \right| > \frac{1}{2} \cdot (R + |u|).$$

Jetzt können wir zeigen, dass die Reihe

$$\sum_{n=0}^{\infty} a_n \cdot u^n$$

das Quotienten-Kriterium erfüllt, denn für alle  $n \geq K$  gilt:

$$\left| \frac{a_{n+1} \cdot u^{n+1}}{a_n \cdot u^n} \right| = \left| \frac{a_{n+1}}{a_n} \right| \cdot |u| = \frac{|u|}{\left| \frac{a_n}{a_{n+1}} \right|} < \frac{|u|}{\frac{1}{2} \cdot (R + |u|)} = q$$

Um den Beweis abzuschließen müssen wir noch zeigen, die Reihe

$$\sum_{n=0}^{\infty} a_n \cdot u^n$$

divergiert wenn  $R<\left|u\right|$  ist. Die Details sind Gegenstand der folgenden Aufgabe.

# Aufgabe 24: Es sei

$$\sum_{n=0}^{\infty} a_n \cdot z^n$$

eine formale Potenz-Reihe. Für alle  $n\in\mathbb{N}^*$  sei  $a_n\neq 0$  und es gelte

$$R = \lim_{n \to \infty} \left| \frac{a_n}{a_{n+1}} \right|.$$

Zeigen Sie: Ist  $u \in \mathbb{C}$  mit R < |u|, so divergiert die Reihe

$$\left(\sum_{k=0}^{n} a_k \cdot u^k\right)_{n \in \mathbb{N}^*}.$$

**Beweis**: Wir führen den Beweis indirekt und nehmen an, dass die obige Reihe konvergiert. Nach dem Korollar zum Cauchy'schen Konvergenz-Kriterium gilt dann

$$\lim_{n \to \infty} a_n \cdot u^n = 0. \tag{*}$$

Aus der Voraussetzung

$$R = \lim_{n \to \infty} \left| \frac{a_n}{a_{n+1}} \right|.$$

und der Definition des Grenzwertes folgt:

$$\forall \varepsilon \in \mathbb{R}_{+}^{*} : \exists K \in \mathbb{R} : \forall n \in \mathbb{N}^{*} : \left( n \geq K \rightarrow \left| \left| \frac{a_{n}}{a_{n+1}} \right| - R \right| < \varepsilon \right)$$

Wir definieren

$$\varepsilon := \frac{1}{2} \cdot (|u| - R).$$

Wegen R < |u| gilt  $\varepsilon > 0$ . Also finden wir ein K, so dass für alle natürlichen Zahlen n, die größer-gleich K sind, die Ungleichung

$$\left| \left| \frac{a_n}{a_{n+1}} \right| - R \right| < \frac{1}{2} \cdot (|u| - R)$$

gilt. Wir zeigen, dass dann für alle  $n \geq K$  die Ungleichung

$$\left| \frac{a_n}{a_{n+1}} \right| < \frac{1}{2} \cdot (R + |u|)$$

gilt. Zunächst haben wir:

$$\left| R + \frac{a_n}{a_{n+1}} - R \right| = \left| \frac{a_n}{a_{n+1}} \right|$$

$$\Rightarrow |R| + \left| \frac{a_n}{a_{n+1}} - R \right| \ge \left| \frac{a_n}{a_{n+1}} \right|$$

$$\Rightarrow |R| + \frac{1}{2} \cdot \left( |u| - R \right) > \left| \frac{a_n}{a_{n+1}} \right|$$

$$\Rightarrow \frac{1}{2} \cdot \left( R + |u| \right) > \left| \frac{a_n}{a_{n+1}} \right|$$

Aus dieser Ungleichung folgern wir

$$|a_{n+1}| \cdot |u| > |a_n| \cdot \frac{|u|}{\frac{1}{2} \cdot (R+|u|)}.$$
 (1)

Ersetzen wir in dieser Ungleichung n durch n+1 und multiplizieren mit |u|, so erhalten wir

$$|a_{n+2}| \cdot |u|^2 > |a_{n+1}| \cdot |u| \cdot \frac{|u|}{\frac{1}{2} \cdot (R+|u|)}.$$
 (2)

Schätzen wir in der Ungleichung (2) den Wert  $|a_{n+1}| \cdot |u|$  durch die Ungleichung (1) ab, so erhalten wir die Ungleichung

$$|a_{n+2}| \cdot |u|^2 > |a_n| \cdot \left(\frac{|u|}{\frac{1}{2} \cdot (R+|u|)}\right)^2.$$
 (3)

Diese Ungleichung können wir zu der Ungleichung

 $\Diamond$ 

$$|a_{n+h}| \cdot |u|^h > |a_n| \cdot \left(\frac{|u|}{\frac{1}{2} \cdot (R+|u|)}\right)^h. \tag{5}$$

verallgemeinern. Formal könnten wir die Ungleichung (5) durch eine triviale Induktion nach h beweisen. Wählen wir nun ein festes  $n_0$ , dass größer als K ist, so gilt für beliebige  $h \in \mathbb{N}^*$  die Ungleichung

$$|a_{n_0+h}| \cdot |u|^{n_0+h} > |a_{n_0}| \cdot |u|^{n_0} \cdot \left(\frac{|u|}{\frac{1}{2} \cdot (R+|u|)}\right)^h. \tag{6}$$

Da |u| > R ist, folgt

$$\frac{|u|}{\frac{1}{2}\cdot(R+|u|)} > 1.$$

Damit wird die rechte Seite der Ungleichung (6) beliebig groß und folglich ist

$$\left(|a_{n_0+h}|\cdot|u|^{n_0+h}\right)_{h\in\mathbb{N}^*}$$

keine Null-Folge. Dies steht im Widerspruch zu (\*). Dieser Widerspruch zeigt, dass der Grenzwert

$$\sum_{n=0}^{\infty} a_n \cdot u^n$$

nicht existieren kann.

Bemerkung: Der letzte Satz bleibt auch richtig, wenn

$$\lim_{n \to \infty} \left| \frac{a_n}{a_{n+1}} \right| = \infty$$

ist, denn dann ist die Potenz-Reihe  $\sum_{n=0}^\infty a_n \cdot u^n$  für alle  $u \in \mathbb{C}$  konvergent.

**Bemerkung**: Die Potenz-Reihe  $\sum_{n=1}^{\infty} \frac{x^n}{n}$  hat den Konvergenz-Radius R=1, denn es gilt

$$\lim_{n \to \infty} \left| \frac{\frac{1}{n}}{\frac{1}{n+1}} \right| = \lim_{n \to \infty} \frac{n+1}{n} = 1 + \lim_{n \to \infty} \frac{1}{n} = 1 + 0 = 1.$$

Satz 55 (Jacques Hadamard(1865-1963)) Es sei  $\sum_{n=0}^{\infty} a_n \cdot x^n$  eine Potenz-Reihe und die Folge  $\left(\sqrt[n]{|a_n|}\right)_{n \in \mathbb{N}^*}$ 

konvergiere. Dann gilt

$$\frac{1}{R} = \lim_{n \to \infty} \sqrt[n]{|a_n|}.$$

**Bemerkung**: Falls wir den Ausdruck  $\frac{1}{\infty}$  als 0 interpretieren, so bleibt die Formel

$$\frac{1}{R} = \lim_{n \to \infty} \sqrt[n]{|a_n|}.$$

auch in dem Fall  $\lim_{n\to\infty}\sqrt[n]{|a_n|}=0$  richtig, denn dann gilt  $R=\infty$ .

Beispiel: Die Potenz-Reihe

$$\sum_{n=1}^{\infty} \frac{x^n}{n^n}$$

hat den Konvergenz-Radius  $R=\infty$ , denn es gilt

 $\Diamond$ 

$$\lim_{n \to \infty} \sqrt[n]{\frac{1}{n^n}} = \lim_{n \to \infty} \frac{1}{n} = 0.$$

Aufgabe 25:

(a) Der Binomial-Koeffizient  $\binom{n}{k}$  ist durch die Festlegung

$$\binom{n}{k} = \frac{n!}{k! \cdot (n-k)!}$$

definiert. Beweisen Sie die Gleichung  $\binom{n+1}{k+1} = \binom{n}{k} + \binom{n}{k+1}$ .

(b) Zeigen Sie durch vollständige Induktion, dass für alle natürlichen Zahlen n die Formel

$$(a+b)^n = \sum_{k=0}^n \binom{n}{k} \cdot a^k \cdot b^{n-k}$$

gilt. Diese Gleichung wird als der binomische Lehrsatz bezeichnet.

(c) Überlegen Sie sich, wie Sie für zwei Potenz-Reihen

$$f(x) := \sum_{n=0}^{\infty} a_n \cdot x^n \quad \text{ und } \quad g(x) := \sum_{n=0}^{\infty} b_n \cdot x^n$$

das Produkt  $f(x)\cdot g(x)$  als Potenz-Reihe darstellen können. Wir suchen also eine Potenz-Reihe  $\sum_{n=0}^\infty c_n\cdot x^n$ , so dass die Formel

$$f(x) \cdot g(x) = \sum_{n=0}^{\infty} c_n \cdot x^n$$
 gültig ist.

**Hinweis**: Sie sollen sich bei Ihrer Rechnung <u>nicht</u> um die Konvergenz der Reihen kümmern. Dieser Hinweis gilt auch für die folgenden Teilaufgaben.

(d) Für alle  $x \in \mathbb{C}$  ist die Exponentialfunktion als

$$\exp(x) := \sum_{n=0}^{\infty} \frac{x^n}{n!}$$

definiert. Zeigen Sie, dass  $\exp(x) \cdot \exp(x) = \exp(2 \cdot x)$  gilt.

(e) Zeigen Sie, dass für alle  $x,y\in\mathbb{C}$  die Gleichung

$$\exp(x) \cdot \exp(y) = \exp(x+y)$$

gilt.

# 3.5 Berechnung der Fibonacci-Zahlen

Die Folge  $(a_n)_{n\in\mathbb{N}^*}$  der Fibonacci-Zahlen wird induktiv durch die Festlegung

$$a_0:=0$$
,  $a_1:=1$  und  $a_{n+2}:=a_{n+1}+a_n$  für alle  $n\in\mathbb{N}$ 

definiert. Wir hatten bereits im ersten Semester eine explizite Formel für  $a_n$  hergeleitet. Damals hatten wir die Berechnung der Fibonacci-Zahlen auf die Bestimmung von Eigenwerten zurückgeführt. In diesem Abschnitt zeigen wir einen anderen Weg auf, mit dem dieselbe Formel hergeleitet werden kann. Dazu definieren wir zunächst die der Folge  $(a_n)_{n\in\mathbb{N}^*}$  zugeordnete erzeugende Funktion f(x) als die formale Potenz-Reihe

$$f(x) := \sum_{n=0}^{\infty} a_n \cdot x^n = 0 \cdot x^0 + 1 \cdot x + 1 \cdot x^2 + 2 \cdot x^3 + 3 \cdot x^4 + 5 \cdot x^5 + \cdots$$

Die Gleichung  $a_{n+2}=a_{n+1}+a_n$  motiviert uns dazu, den Ausdruck  $x\cdot f(x)+x^2\cdot f(x)$  zu berechnen. Zunächst gilt

$$x \cdot f(x) = \sum_{n=0}^{\infty} a_n \cdot x^{n+1} = \sum_{n=1}^{\infty} a_{n-1} \cdot x^n.$$
 (1)

Multiplizieren wir diese Gleichung ein weiteres Mal mit x, so erhalten wir

$$x^{2} \cdot f(x) = \sum_{n=1}^{\infty} a_{n-1} \cdot x^{n+1} = \sum_{n=2}^{\infty} a_{n-2} \cdot x^{n}.$$
 (2)

Addieren wir die Gleichungen (1) und (2), so erhalten wir

$$(x+x^2) \cdot f(x) = a_0 \cdot x^1 + \sum_{n=2}^{\infty} (a_{n-1} + a_{n-2}) \cdot x^n.$$

An dieser Stelle können Sie sehen, warum wir f(x) mit  $x+x^2$  multipliziert haben, denn wenn wir nun berücksichtigen, dass  $a_{n-1}+a_{n-2}=a_n$  gilt, so können wir die obige Gleichungen zu

$$(x + x^2) \cdot f(x) = a_0 \cdot x_1 + \sum_{n=2}^{\infty} a_n \cdot x^n$$

vereinfachen. Wegen  $a_0=0$  fällt der erste Term weg. Lassen wir die Summe bei n=0 starten, so erhalten wir

$$(x+x^2)\cdot f(x) = \left(\sum_{n=0}^{\infty} a_n \cdot x^n\right) - a_0 \cdot x^0 - a_1 \cdot x^1.$$

Berücksichtigen wir abermals, dass  $a_0=0$  ist, so können wir dies zu

$$(x+x^2)\cdot f(x) = \left(\sum_{n=0}^{\infty} a_n \cdot x^n\right) - a_1 \cdot x$$

vereinfachen. Die Summe, die hier auftritt, ist aber gerade die erzeugende Funktion f(x). Da  $a_1=1$  ist, haben wir die Gleichung

$$(x+x^2) \cdot f(x) = f(x) - x$$

gefunden, die wir zu

$$x = (1 - x - x^2) \cdot f(x)$$

umstellen können. Teilen wir hier noch durch  $(1-x-x^2)$ , so haben wir für die erzeugende Funktion f(x) die Gleichung

$$f(x) = \frac{x}{1 - x - x^2}$$

gefunden. Der Trick besteht nun darin, eine Partialbruch-Zerlegung der rechten Seite zu finden. Dazu bestimmen wir zunächst die Nullstellen des Polynoms  $x^2 + x - 1$ :

$$x^{2} + x - 1 = 0$$

$$\Leftrightarrow x^{2} + x = 1$$

$$\Leftrightarrow x^{2} + x + \left(\frac{1}{2}\right)^{2} = 1 + \frac{1}{4}$$

$$\Leftrightarrow \left(x + \frac{1}{2}\right)^{2} = \frac{5}{4}$$

$$\Leftrightarrow x = \frac{1}{2} \cdot (\sqrt{5} - 1) \quad \forall \quad x = -\frac{1}{2} \cdot (\sqrt{5} + 1)$$

Wir definieren daher

$$x_1 := \frac{1}{2} \cdot (\sqrt{5} - 1) \quad \text{ und } \quad x_2 := -\frac{1}{2} \cdot (\sqrt{5} + 1)$$

und haben dann

$$x^{2} + x - 1 = (x - x_{1}) \cdot (x - x_{2}) = (x_{1} - x) \cdot (x_{2} - x).$$

Offenbar gilt  $x_1 \cdot x_2 = -1$ . Wir klammern in der Gleichung für  $x^2 + x - 1$  den Term  $x_1 \cdot x_2$  aus und erhalten

$$x^{2} + x - 1 = x_{1} \cdot x_{2} \cdot \left(1 - \frac{x}{x_{1}}\right) \cdot \left(1 - \frac{x}{x_{2}}\right) = -\left(1 - \frac{x}{x_{1}}\right) \cdot \left(1 - \frac{x}{x_{2}}\right).$$

Weiter definieren wir

$$\varphi := \frac{1}{x_1} = \frac{2}{\sqrt{5} - 1} = \frac{2}{\sqrt{5} - 1} \cdot \frac{\sqrt{5} + 1}{\sqrt{5} + 1} = \frac{2}{5 - 1} \cdot (\sqrt{5} + 1) = \frac{1}{2} \cdot (1 + \sqrt{5})$$

und genauso

$$\overline{\varphi} := \frac{1}{x_2} = -\frac{2}{\sqrt{5}+1} = -\frac{2}{\sqrt{5}+1} \cdot \frac{\sqrt{5}-1}{\sqrt{5}-1} = -\frac{2}{5-1} \cdot (\sqrt{5}-1) = \frac{1}{2} \cdot (1-\sqrt{5}).$$

Damit können wir die erzeugende Funktion f(x) in der Form

$$\frac{x}{1-x-x^2} = \frac{x}{(1-\varphi\cdot x)\cdot (1-\overline{\varphi}\cdot x)}$$

schreiben. Wir machen den Ansatz

$$\frac{x}{(1-\varphi\cdot x)\cdot (1-\overline{\varphi}\cdot x)} = \frac{\alpha}{1-\varphi\cdot x} + \frac{\beta}{1-\overline{\varphi}\cdot x}.$$

Um  $\alpha$  und  $\beta$  bestimmen zu können, multiplizieren wir mit dem Hauptnenner und erhalten die Gleichung

$$x = \alpha \cdot (1 - \overline{\varphi} \cdot x) + \beta \cdot (1 - \varphi \cdot x)$$

Ausmultiplizieren und Umstellen der Terme liefert

$$1 \cdot x^1 + 0 \cdot x^0 = (\alpha + \beta) \cdot x^0 - (\alpha \cdot \overline{\varphi} + \beta \cdot \varphi) \cdot x^1.$$

Da diese Gleichung für alle x gelten muss, erhalten wir durch einen Koeffizientenvergleich die beiden Gleichungen

$$\alpha + \beta = 0$$
 und  $-1 = \alpha \cdot \overline{\varphi} + \beta \cdot \varphi$ .

Aus der ersten Gleichung folgt  $\beta=-\alpha$  und wenn wir dies in die zweite Gleichung einsetzen, erhalten wir

$$-1 = \alpha \cdot (\overline{\varphi} - \varphi),$$

woraus wir folgern, dass

$$\alpha = \frac{1}{\varphi - \overline{\varphi}} = \frac{1}{\frac{1}{2} \cdot (1 + \sqrt{5}) - \frac{1}{2} \cdot (1 - \sqrt{5})} = \frac{1}{\sqrt{5}} \quad \text{ und } \quad \beta = -\frac{1}{\sqrt{5}}$$

gilt. Insgesamt haben wir damit die folgende Gleichung für die erzeugende Funktion f(x) gefunden:

$$f(x) = \frac{1}{\sqrt{5}} \cdot \left( \frac{1}{1 - x \cdot \varphi} - \frac{1}{1 - x \cdot \overline{\varphi}} \right) \tag{*}$$

Erinnern wir uns hier an die geometrische Reihe

$$\sum_{n=0}^{\infty}q^n=\frac{1}{1-q}\quad \text{ falls } |q|<1\text{,}$$

und setzen  $q = x \cdot \varphi$  bzw.  $q = x \cdot \overline{\varphi}$ , so können wir die Brüche auf der rechten Seite der Gleichung (\*)

durch geometrische Reihen ersetzen und erhalten

$$f(x) = \frac{1}{\sqrt{5}} \cdot \left( \sum_{n=0}^{\infty} (x \cdot \varphi)^n - \sum_{n=0}^{\infty} (x \cdot \overline{\varphi})^n \right).$$

Setzen wir nun für f(x) die Reihe  $\sum_{n=0}^{\infty} a_n \cdot x^n$  ein und fassen die die beiden Summen auf der rechten Seite zusammen, so erhalten wir die Gleichung

$$\sum_{n=0}^{\infty} a_n \cdot x^n = \sum_{n=0}^{\infty} \frac{1}{\sqrt{5}} \cdot \left( \varphi^n - \overline{\varphi}^n \right) \cdot x^n.$$

Da diese Gleichungen für alle x gelten soll, für die diese Reihen konvergieren, müssen die Koeffizienten der Potenzen von  $x^n$  auf beiden Seiten dieser Gleichung übereinstimmen. Damit haben wir für die Fibonacci-Zahlen die explizite Formel

$$a_n = \frac{1}{\sqrt{5}} \cdot \left(\varphi^n - \overline{\varphi}^n\right) \quad \text{ mit } \varphi = \frac{1}{2} \cdot (1 + \sqrt{5}) \quad \text{ und } \quad \overline{\varphi} = 1 - \varphi = \frac{1}{2} \cdot (1 - \sqrt{5})$$

gefunden.

#### Aufgabe 26:

(a) Lösen Sie die Rekurrenz-Gleichung

$$a_0 = 0$$
,  $a_1 = 1$ ,  $a_{n+2} = 3 \cdot a_{n+1} - 2 \cdot a_n$ 

mit dem in diesem Abschnitt vorgestellten Verfahren.

(b) Lösen Sie die Rekurrenz-Gleichung

$$a_0 = 0$$
,  $a_1 = 1$ ,  $a_{n+2} = 2 \cdot a_{n+1} - 1 \cdot a_n$ 

mit dem in diesem Abschnitt vorgestellten Verfahren.

Hinweis: Stellen Sie das Produkt

$$\left(\sum_{n=0}^{\infty} x^n\right) \cdot \left(\sum_{n=0}^{\infty} x^n\right)$$

als Potenz-Reihe dar.

 $\Diamond$ 

# Kapitel 4

# Stetige Funktionen

# 4.1 Motivation und Definition der Stetigkeit

Wir wollen in diesem Abschnitt präzisieren, wann eine Funktion so beschaffen ist, dass wir sie zeichnen können, ohne dabei den Stift absetzen zu müssen. Für eine solche Funktion soll außerdem der Zwischenwert-Satz gelten. Der Zwischenwert-Satz besagt, dass für eine Funktion

$$f: \mathbb{R} \to \mathbb{R}$$
,

die wir ohne abzusetzen zeichnen können, Folgendes gilt: Falls es  $a,b \in \mathbb{R}$  gibt mit f(a) < 0 und f(b) > 0, dann existiert auch ein  $c \in \mathbb{R}$ , so dass f(c) = 0 ist. Anschaulich ist dieser Satz klar: Ist beispielsweise a < b und zeichne ich die Funktion f in dem Intervall [a,b], so muss der Graph der Funktion an irgendeiner Stelle des Intervalls [a,b] die x-Achse schneiden. Voraussetzung dafür, dass dies tatsächlich so ist, ist aber die Forderung, dass die Funktion f keine Sprünge macht, denn wenn wir beispielsweise die Funktion

$$q: \mathbb{R} \to \mathbb{R}$$

betrachten, die durch

$$g(x) := \left\{ \begin{array}{ll} -1 & \text{falls } x < 0 \\ +1 & \text{falls } x \ge 0 \end{array} \right.$$

definiert ist, so haben wir zwar g(-1)=-1 und g(1)=1, aber es gibt kein  $x\in [-1,1]$ , für das g(x)=0 wäre. Das liegt daran, dass die Funktion an der Stelle x=0 einen Sprung hat. Unser Ziel in diesem Abschnitt ist es, zunächst exakt zu definieren, was wir unter einer Funktion verstehen wollen, die keine Sprünge hat. In der Mathematik bezeichnen wir eine solche Funktion als stetig. Um den Begriff der Stetigkeit einführen zu können, bedarf es einer Reihe von zusätzlichen Definitionen, die nun folgen.

**Definition 56** Es sei  $(x_n)_{n\in\mathbb{N}^*}$  eine Folge und  $D\subseteq\mathbb{R}$ . Wir sagen, dass die Folge  $(x_n)_{n\in\mathbb{N}^*}$  in D liegt, wenn für alle  $n\in\mathbb{N}$  das Folgenglied  $x_n\in D$  ist.

**Definition 57 (Grenzwert einer Funktion)** Es sei  $D \subseteq \mathbb{R}$  und  $f: D \to \mathbb{R}$ . Weiter sei  $\widehat{x} \in \mathbb{R}$  und  $\lambda \in \mathbb{R}$ . Außerdem gebe es mindestens eine Folge  $(x_n)_{n \in \mathbb{N}^*}$ , die gegen  $\widehat{x}$  konvergiert. Dann ist  $\lambda$  der *Grenzwert* der Funktion f im Punkt  $\widehat{x}$ , wenn für jede in D liegende Folge  $(x_n)_{n \in \mathbb{N}^*}$  gilt:

$$\lim_{n \to \infty} x_n = \widehat{x} \implies \lim_{n \to \infty} f(x_n) = \lambda.$$

In diesem Fall schreiben wir

$$\lim_{x \to \widehat{x}} f(x) = \lambda.$$

**Bemerkung**: In der obigen Definition ist nicht gefordert, dass  $\hat{x}$  ein Element des Definitions-Bereichs

D ist. In vielen interessanten Fällen ist dies auch nicht der Fall, beispielsweise werden wir später zeigen, dass

$$\lim_{x \to 0} \frac{\sin(x)}{x} = 1$$

gilt. Die Funktion  $x\mapsto \frac{\sin(x)}{x}$  ist für x=0 nicht definiert, trotzdem existiert der Grenzwert.

**Definition 58 (Stetigkeit)** Es sei  $D \subseteq \mathbb{R}$  und  $f: D \to \mathbb{R}$ . Weiter sei  $\widehat{x} \in D$ . Dann ist die Funktion f stetig im Punkt  $\widehat{x}$ , wenn gilt:

$$\lim_{x \to \widehat{x}} f(x) = f(\widehat{x}).$$

Aus den beiden letzten Definitionen folgt, dass für eine stetige Funktion der Prozess der Grenzwert-Bildung mit der Anwendung der Funktion vertauschbar ist. Für eine konvergente Folge  $(x_n)_{n\in\mathbb{N}^*}$  und eine stetige Funktion f gilt

$$f\left(\lim_{n\to\infty} x_n\right) = \lim_{n\to\infty} f(x_n).$$

#### Beispiele:

1. Es sei  $c \in \mathbb{R}$ . Dann ist die konstante Funktion  $f : \mathbb{R} \to \mathbb{R}$ , die durch f(x) := c definiert ist, in jedem Punkt  $\widehat{x} \in \mathbb{R}$  stetig, denn für jede beliebige Folge  $(x_n)_{n \in \mathbb{N}^*}$  gilt

$$\lim_{n \to \infty} f(x_n) = \lim_{n \to \infty} c = c.$$

2. Die identische Funktion  $id : \mathbb{R} \to \mathbb{R}$ , die durch id(x) = x definiert ist, ist in jedem Punkt  $\widehat{x} \in \mathbb{R}$  stetig, denn wenn  $(x_n)_{n \in \mathbb{N}^*}$  eine Folge ist, so dass

$$\lim_{n \to \infty} x_n = \widehat{x}$$

gilt, dann folgt sofort

$$\lim_{n \to \infty} id(x_n) = \lim_{n \to \infty} x_n = \widehat{x}.$$

3. Die Funktion  $f: \mathbb{R} \to \mathbb{R}$ , die durch  $f(x) = x^2$  definiert ist, ist in jedem Punkt stetig, denn falls  $(x_n)_{n \in \mathbb{N}^*}$  eine Folge ist, so dass

$$\lim_{n \to \infty} x_n = \widehat{x}$$

gilt, dann folgt nach dem Satz über den Grenzwert einer Folge von Produkten

$$\lim_{n \to \infty} f(x_n) = \lim_{n \to \infty} (x_n \cdot x_n) = \left(\lim_{n \to \infty} x_n\right) \cdot \left(\lim_{n \to \infty} x_n\right) = \widehat{x} \cdot \widehat{x} = \widehat{x}^2.$$

4. Das letzte Beispiel lässt sich verallgemeinern: Die Funktionen  $f:\mathbb{R}\to\mathbb{R}$  und  $g:\mathbb{R}\to\mathbb{R}$  seien im Punkt  $\widehat{x}$  stetig. Dann ist auch die Funktion  $h:\mathbb{R}\to\mathbb{R}$  die durch  $h(x):=f(x)\cdot g(x)$  definiert ist, stetig. Denn sei  $\big(x_n\big)_{n\in\mathbb{N}^*}$  eine Folge, die gegen  $\widehat{x}$  konvergiert. Dann gilt

$$\begin{array}{lll} \lim_{n \to \infty} h(x_n) & = & \lim_{n \to \infty} f(x_n) \cdot g(x_n) & \text{ Definition von } h \\ \\ & = & \left(\lim_{n \to \infty} f(x_n)\right) \cdot \left(\lim_{n \to \infty} g(x_n)\right) & \text{ Grenzwert von Produkten} \\ \\ & = & f\left(\lim_{n \to \infty} x_n\right) \cdot g\left(\lim_{n \to \infty} x_n\right) & f \text{ und } g \text{ sind stetig} \\ \\ & = & f(\widehat{x}) \cdot g(\widehat{x}) & \lim_{n \to \infty} x_n = \widehat{x} \\ \\ & = & h(\widehat{x}) & \text{ Definition von } h \end{array}$$

5. Mit einer zum letzten Fall analogen Argumentation können wir leicht einsehen, dass alle Funktionen, die ausgehend von den konstanten Funktionen  $x \mapsto c$  und der identischen Funktion  $x \mapsto x$ 

mit Hilfe der elementaren Rechen-Operationen "+", "-", "·" und "/" gebildet werden können, stetig sind. Solche Funktionen werden als rationale Funktionen bezeichnet. Ein Beispiel für eine solche Funktion ist

$$x \mapsto \frac{x^3 - 2 \cdot x + 1}{x^2 - 1}.$$

Diese Funktion ist für alle  $x \in \mathbb{R} \setminus \{1, -1\}$  definiert und ist nach der obigen Argumentation stetig.

6. Die Funktion  $sign: \mathbb{R} \to \mathbb{R}$  sei durch

$$\mathit{sign}(x) = \left\{ \begin{array}{ll} +1 & \mathsf{falls}\ x > 0, \\ 0 & \mathsf{falls}\ x = 0, \\ -1 & \mathsf{falls}\ x < 0. \end{array} \right.$$

definiert. Diese Funktion ist im Punkt 0 nicht stetig, denn für die Folge  $\left(\frac{1}{n}\right)_{n\in\mathbb{N}^*}$  gilt

$$\lim_{n\to\infty}\frac{1}{n}=0, \quad \text{ aber } \quad \lim_{n\to\infty}\operatorname{sign}\left(\frac{1}{n}\right)=\lim_{n\to\infty}1=1\neq 0=\operatorname{sign}(0).$$

Anschaulich ist die Funktion  $sign : \mathbb{R} \to \mathbb{R}$  im Punkt 0 nicht stetig, weil sie an dieser Stelle einen Sprung hat.

**Definition 59 (Uneigentliche Konvergenz)** Wir sagen, dass eine Folge  $(x_n)_{n\in\mathbb{N}^*}$  gegen Unendlich konvergiert und schreiben

$$\lim_{n \to \infty} x_n = \infty$$

wenn gilt:

$$\forall c \in \mathbb{R} : \exists K \in \mathbb{N} : \forall n \in \mathbb{N} : (n \ge K \to x_n > c).$$

**Beispiel**: Für die Folge  $(n)_{n\in\mathbb{N}^*}$  gilt offenbar

$$\lim_{n \to \infty} n = \infty.$$

**Definition 60** Es sei  $f: \mathbb{R} \to \mathbb{R}$  eine Funktion und  $\lambda \in \mathbb{R}$ . Gilt für jede Folge  $(x_n)_{n \in \mathbb{N}^*}$ 

$$\lim_{n \to \infty} x_n = \infty \implies \lim_{n \to \infty} f(x_n) = \lambda,$$

dann schreiben wir

$$\lim_{x \to \infty} f(x) = \lambda.$$

Beispiel: Es gilt

$$\lim_{x \to \infty} \frac{1}{x} = 0.$$

**Beweis**: Es sei eine Folge  $(x_n)_{n\in\mathbb{N}^*}$  gegeben, so dass

$$\lim_{n \to \infty} x_n = \infty$$

gilt. Nach Definition der uneigentlichen Konvergenz gegen  $\infty$  gilt dann

$$\forall c \in \mathbb{R} : \exists K \in \mathbb{N} : \forall n \in \mathbb{N} : (n \ge K \to x_n > c)$$

$$\tag{4.1}$$

Wir müssen zeigen, dass gilt:

$$\lim_{n \to \infty} \frac{1}{x_n} = 0.$$

Dies ist nach der Definition des Grenzwerts einer Folge äquivalent zu der Formel

$$\forall \varepsilon \in \mathbb{R}_{+}^{*} : \exists K \in \mathbb{R} : \forall n \in \mathbb{N} : \left( n \ge K \to \left| \frac{1}{x_{n}} \right| < \varepsilon \right)$$
(4.2)

 $\Diamond$ 

Um diese Formel nachzuweisen, nehmen wir an, dass eine Zahl  $\varepsilon > 0$  gegeben ist. Wir müssen dann ein K finden, so dass für alle natürlichen Zahlen n, die größer-gleich K sind, die Ungleichung

$$\left|\frac{1}{x_n}\right| < \varepsilon$$

gilt. Dies gelingt uns mit Hilfe der Formel (4.1), denn wenn wir in dieser Formel  $c:=\frac{1}{\varepsilon}$  definieren, dann finden wir eine Zahl K, so dass für alle natürlichen Zahlen n, die größer-gleich K sind, die Ungleichung

$$x_n > c$$
, also  $x_n > \frac{1}{\varepsilon}$ 

gilt. Invertieren wir nun diese Ungleichung, so folgt

$$\frac{1}{x_n} < \varepsilon$$

und da andererseits aus  $x_n>\frac{1}{\varepsilon}$  und  $\varepsilon>0$  auch  $x_n>0$  und damit  $\frac{1}{x_n}>0$  folgt, haben wir insgesamt

$$\left| \frac{1}{x_n} \right| < \varepsilon$$

für alle  $n \geq K$  gezeigt.

Es gibt eine alternative Definition der Stetigkeit, die zu der oben gegebenen Definition äquivalent ist. Diese Definition trägt den Namen  $\varepsilon$ - $\delta$ -Definition der Stetigkeit und Funktionen, die nach dieser Definition stetig sind, heißen  $\varepsilon$ - $\delta$ -stetig.

**Definition 61** ( $\varepsilon$ - $\delta$ -**Stetigkeit**) Eine Funktion  $f:D\to\mathbb{R}$  ist  $\varepsilon$ - $\delta$ -stetig im Punkt  $\widehat{x}$ , wenn gilt:

$$\forall \varepsilon \in \mathbb{R}_{+}^{*} : \exists \delta \in \mathbb{R}_{+}^{*} : \forall x \in D : (|x - \widehat{x}| < \delta \to |f(x) - f(\widehat{x})| < \varepsilon).$$

#### Aufgabe 27:

- (a) Zeigen Sie, dass jede Funktion, die  $\varepsilon$ - $\delta$ -stetig ist, auch stetig ist.
- (b) Zeigen Sie, dass jede stetige Funktion auch  $\varepsilon$ - $\delta$ -stetig ist.

Hinweis: Führen Sie den Beweis von Teil (b) dieser Aufgabe indirekt.

#### **Definition 62 (Allgemeine Stetigkeit)**

Eine Funktion  $f:D\to\mathbb{R}$  heißt stetig genau dann, wenn die Funktion f für alle  $\widehat{x}\in D$  stetig ist.

**Aufgabe 28**: Es sei  $f: \mathbb{R} \to \mathbb{R}$ . Geben Sie eine sinnvolle Definition für

$$\lim_{x \to \infty} f(x) = \infty.$$

**Bemerkung**: Wir haben den Begriff des Grenzwerts einer Funktion mit Hilfe von Folgen definiert. Es gibt eine dazu äquivalente  $\varepsilon$ -δ-Definition des Grenzwerts. Bei dieser Definition sagen wir, dass eine Funktion

$$f:D\to\mathbb{R}$$

an der Stelle  $\bar{x}$  den Grenzwert  $\lambda$  hat, wenn

$$\forall \varepsilon \in \mathbb{R}_{+}^{*} : \exists \delta \in \mathbb{R}_{+}^{*} : \forall x \in D : (|x - \bar{x}| < \delta \rightarrow |f(x) - \lambda| < \varepsilon)$$

gilt. Genau wie die  $\varepsilon$ - $\delta$  Definition der Stetigkeit äquivalent ist zu dem Stetigkeits-Begriff, den wir mit Hilfe von Folgen definiert haben, ist auch die  $\varepsilon$ - $\delta$ -Definition des Grenzwerts äquivalent zu der Definition des Grenzwerts, die wir früher mit Hilfe von Folgen gegeben haben. Der Beweis dieser Behauptung ist Gegenstand der folgenden Aufgabe.

#### Aufgabe 29: Es sei

$$f:D\to\mathbb{R}$$

eine reellwertige Funktion. Beweisen Sie die beiden folgenden Behauptungen:

(a) Falls die Formel

$$\forall \varepsilon \in \mathbb{R}_+^*: \exists \delta \in \mathbb{R}_+^*: \forall x \in D: \left(|x-\bar{x}| < \delta \to |f(x)-\lambda| < \varepsilon\right)$$
 richtig ist, dann gilt  $\lim_{x \to \bar{x}} f(x) = \lambda$ .

(b) Falls  $\lim_{x \to \bar{x}} f(x) = \lambda$  gilt, dann gilt auch

$$\forall \varepsilon \in \mathbb{R}_+^* : \exists \delta \in \mathbb{R}_+^* : \forall x \in D : (|x - \bar{x}| < \delta \to |f(x) - \lambda| < \varepsilon).$$

# 4.2 Bestimmung von Nullstellen

In der Praxis tritt häufig die Frage auf, ob eine Funktion in einem bestimmten Intervall eine Nullstelle hat. Zusätzlich werden Verfahren benötigt, mit denen eine solche Nullstelle gegebenenfalls berechnet werden kann.

## Satz 63 (Zwischenwert-Satz)

Die Funktion  $f:[a,b]\to\mathbb{R}$  sei stetig. Weiter sei  $f(a)\leq 0$  und  $f(b)\geq 0$ . Dann gibt es ein  $x_0\in[a,b]$ , so dass  $f(x_0)=0$  ist.

**Beweis**: Wir geben ein Verfahren an, mit dem eine Nullstelle berechnet werden kann und weisen dann nach, dass der von diesem Verfahren gelieferte Wert tatsächlich eine Nullstelle der Funktion ist. Das Verfahren, dass wir vorstellen werden, wird in der Literatur als *Verfahren der Intervall-Halbierung* oder auch als Bisektions-Verfahren bezeichnet. Das Verfahren folgt dem Paradigma "*Teile und Herrsche*". Im Englischen werden solche Verfahren als "divide and conquer algorithms" bezeichnet. Beim Bisektions-Verfahren definieren wir induktiv zwei Folgen  $(a_n)_{n\in\mathbb{N}^*}$  und  $(b_n)_{n\in\mathbb{N}^*}$  wie folgt:

I.A.: n = 1.

$$a_1 := a, \quad b_1 := b.$$

I.S.:  $n \mapsto n+1$ 

Zunächst definieren wir  $c_n$  als das arithmetische Mittel von  $a_n$  und  $b_n$ :

$$c_n := \frac{1}{2} \cdot (a_n + b_n).$$

Dann definieren wir  $a_{n+1}$  und  $b_{n+1}$  simultan durch Fall-Unterscheidung:

$$\langle a_{n+1},b_{n+1}\rangle := \left\{ \begin{array}{ll} \langle a_n,c_n\rangle & \text{falls} & f(c_n)>0 \\ \langle c_n,b_n\rangle & \text{falls} & f(c_n)\leq 0. \end{array} \right.$$

Aus dieser Definition folgt sofort per Induktion, dass für alle  $n \in \mathbb{N}$  gilt:

- 1.  $f(a_n) \le 0$  und  $f(b_n) \ge 0$ .
- 2.  $a_n \leq a_{n+1}$ , die Folge  $(a_n)_{n \in \mathbb{N}^*}$  ist also monoton steigend.
- 3.  $b_n \geq b_{n+1}$ , die Folge  $(b_n)_{n \in \mathbb{N}^*}$  ist also monoton fallend.
- 4.  $a_n \leq b_n$ .

5. 
$$b_n - a_n = \left(\frac{1}{2}\right)^{n-1} \cdot (b-a).$$

Wir führen hier nur den Nachweis der letzten Behauptung vor, denn diese Behauptung ist am wenigsten offensichtlich.

I.A.: n=1. Es gilt

$$b_1 - a_1 = b - a = \left(\frac{1}{2}\right)^{1-1} \cdot (b - a).$$

I.S.:  $n \mapsto n+1$ .

Es ist  $c_n = \frac{1}{2} \cdot (a_n + b_n)$ . Wir führen eine Fall-Unterscheidung nach dem Vorzeichen von  $f(c_n)$  durch.

$$\begin{array}{lll} \text{(a)} \ \, f(c_n) > 0. \ \, \text{Dann gilt} \ \, a_{n+1} = a_n \ \, \text{und} \ \, b_{n+1} = c_n = \frac{1}{2} \cdot (a_n + b_n). \ \, \text{Also haben wir} \\ & b_{n+1} - a_{n+1} & = & \frac{1}{2} \cdot (a_n + b_n) - a_n \\ & = & \frac{1}{2} \cdot (b_n - a_n) \\ & \stackrel{IV}{=} & \frac{1}{2} \cdot \left(\frac{1}{2}\right)^{n-1} \cdot (b-a) \\ & = & \left(\frac{1}{2}\right)^{(n+1)-1} \cdot (b-a) \ \, \checkmark \\ \\ \text{(b)} \ \, f(c_n) \leq 0. \ \, \text{Jetzt gilt} \ \, a_{n+1} = c_n = \frac{1}{2} \cdot (a_n + b_n) \ \, \text{und} \ \, b_{n+1} = b_n. \ \, \text{Also haben wir} \\ & b_{n+1} - a_{n+1} & = & b_n - \frac{1}{2} \cdot (a_n + b_n) \\ & = & \frac{1}{2} \cdot (b_n - a_n) \\ & \stackrel{IV}{=} & \frac{1}{2} \cdot \left(\frac{1}{2}\right)^{n-1} \cdot (b-a) \\ & = & \left(\frac{1}{2}\right)^{(n+1)-1} \cdot (b-a) \ \, \checkmark \\ \end{array}$$

Damit ist die Behauptung in beiden Fällen bewiesen.

Aus den Behauptungen 3., 4., und 5. folgt, dass die Folge  $(b_n)_{n\in\mathbb{N}^*}$  durch a nach unten beschränkt ist, denn es gilt

$$a = a_1 \le \cdots \le a_{n-1} \le a_n \le b_n$$
, also gilt  $a \le b_n$  für alle  $n \in \mathbb{N}$ .

Da die Folge  $(b_n)_{n\in\mathbb{N}^*}$  monoton fallend und nach unten beschränkt ist, muss diese Folge nach Satz 32 auch konvergent sein. Wir definieren

$$\widehat{b} := \lim_{n \to \infty} b_n.$$

In analoger Weise sehen wir, dass die Folge  $(a_n)_{n\in\mathbb{N}^*}$  monoton steigend und nach oben beschränkt ist. Also ist diese Folge ebenfalls konvergent und wir definieren

$$\widehat{a} := \lim_{n \to \infty} a_n.$$

Als nächstes weisen wir nach, dass  $\widehat{a}=\widehat{b}$  ist. Dazu betrachten wir die Differenz der Grenzwerte:

 $\Diamond$ 

$$\widehat{b} - \widehat{a} = \left(\lim_{n \to \infty} b_n\right) - \left(\lim_{n \to \infty} a_n\right)$$

$$= \lim_{n \to \infty} b_n - a_n$$

$$= \lim_{n \to \infty} \left(\frac{1}{2}\right)^{n-1} \cdot (b - a)$$

$$= (b - a) \cdot \lim_{n \to \infty} \left(\frac{1}{2}\right)^{n-1} = 0,$$

also gilt  $\widehat{b} = \widehat{a}$ . Da die Funktion f stetig ist, gilt

$$\lim_{n \to \infty} f(a_n) = f\left(\lim_{n \to \infty} a_n\right) = f(\widehat{a}).$$

Weil  $f(a_n) \leq 0$  ist für alle  $n \in \mathbb{N}$  folgt dann sofort

$$f(\widehat{a}) \le 0.$$

Genauso folgt aus der Stetigkeit von f, dass

$$\lim_{n \to \infty} f(b_n) = f\left(\lim_{n \to \infty} b_n\right) = f(\widehat{b})$$

gilt. Aus  $\forall n \in \mathbb{N} : f(b_n) \geq 0$  folgt dann sofort

$$f(\widehat{b}) \geq 0.$$

Da  $\widehat{a} = \widehat{b}$  gilt, haben wir natürlich auch  $f(\widehat{a}) = f(\widehat{b})$ . Dann haben wir aber sowohl

$$f(\widehat{a}) \le 0$$
 als auch  $f(\widehat{a}) \ge 0$ 

und das funktioniert nur, wenn  $f(\widehat{a}) = 0$  ist. Damit können wir  $x_0 = \widehat{a}$  definieren und dann ist  $x_0$  eine Nullstelle von f in dem Intervall [a, b].

Bemerkung: In der Literatur finden Sie eine etwas allgemeinere Version des Zwischenwert-Satzes: Falls

$$f:[a,b]\to\mathbb{R}$$

eine stetige Funktion ist, so nimmt die Funktion jeden Wert zwischen den Werten f(a) und f(b) an. Ist beispielsweise f(a) < f(b), so gilt also

$$\forall c \in [f(a), f(b)] : \exists \bar{x} \in [a, b] : f(\bar{x}) = c.$$

Dieser Satz lässt sich beweisen, indem wir die Funktion g als

$$g := (x \mapsto f(x) - c)$$

definieren. Dann haben wir

$$g(a) = f(a) - c \le 0 \quad \text{ und } \quad g(b) = f(b) - c \ge 0$$

und wir können auf die Funktion g den von uns bewiesen Zwischenwert-Satz anwenden. Damit finden eine Zahl  $\bar{x} \in [a,b]$ , für die  $g(\bar{x})=0$  gilt. Also haben wir

$$f(\bar{x}) - c = 0$$

und daraus folgt  $f(\bar{x}) = c$ .

#### Aufgabe 30:

(a) Die Funktion  $f:[0,1]\to [0,1]$  sei stetig. Zeigen Sie, dass die Funktion f dann einen Fixpunkt hat, zeigen Sie also, dass es ein  $x_0\in [0,1]$  gibt, so dass

$$f(x_0) = x_0$$
 gilt.

(b) Zeigen Sie, dass die Funktion  $f: \mathbb{R} \to \mathbb{R}$ , die durch  $f(x) := \cos(x)$  definiert ist, genau einen Fixpunkt hat. Sie dürfen bei Ihrem Beweis voraussetzen, dass die Funktion  $x \mapsto \cos(x)$  stetig ist. Außerdem ist bekannt, dass diese Funktion im Intervall  $[0, \pi]$  streng monoton fallend ist.  $\diamond$ 

**Aufgabe 31**: Es war einmal ein buddhistischer Mönch, der einmal im Jahr zur Meditation auf einen Berg stieg. Er begann seinen Weg um 6:00 Uhr morgens und erreichte den Gipfel um 18:00 Uhr abends. Nachdem er die ganze Nacht meditiert hatte, begann er am nächsten Morgen um 6:00 mit dem Abstieg, der bis 18:00 abends dauerte. Beim Abstieg nahm der Mönch denselben Weg wie beim Aufstieg. Zeigen Sie, dass es eine Tageszeit t gibt, an welcher der Mönch beim Abstieg am selben Ort ist wie beim Aufstieg.

# 4.2.1 Implementierung des Intervall-Halbierungs-Verfahrens

```
findZero := procedure(f, a, b, n) {
          assert(a < b, "a has to be less than b!");
2
          assert(f(a) < 0, "Precondition f(\$a\$) < 0 failed!"); assert(0 < f(b), "Precondition f(\$b\$) > 0 failed!");
          for (k in [1 .. n]) {
5
                c := 1/2 * (a + b);
6
                if (f(c) < 0) {
                     a := c;
                } else {
9
                     b := c;
10
11
          }
12
          return 1/2 * (a + b);
13
     };
14
```

Abbildung 4.1: Implementierung des Bisektions-Verfahrens in Setla.

Das im Beweis des letzten Satzes beschriebene Intervall-Halbierungs-Verfahren lässt sich ohne große Mühe implementieren. Abbildung 4.1 zeigt eine solche Implementierung in der Sprache Setla. Die Funktion findZero erhält vier Argumente:

- 1. f ist die Funktion, deren Nullstelle bestimmt werden soll,
- 2. a ist die linke Intervall-Grenze,
- 3. b ist die rechte Intervall-Grenze und
- 4. n ist die Anzahl der Iterationen, die durchgeführt werden soll.

Zu Beginn testen wir, ob erstens die linke Intervall-Grenze a kleiner als die rechte Intervall-Grenze b ist und zweitens ob sowohl  $\mathbf{f}(\mathbf{a}) < 0$  als auch  $0 < \mathbf{f}(\mathbf{b})$ gilt, denn sonst sind die Voraussetzungen des Zwischenwert-Satzes nicht erfüllt und das Bisektions-Verfahren lässt sich nicht anwenden.

Die Implementierung setzt den oben skizzierten Algorithmus unmittelbar um. Da wir immer nur die beiden letzten Werte der Folgen  $(a_n)_n$  und  $(b_n)_n$  benötigen, ist es nicht notwendig, die Folgen zu speichern. Es reicht, die Werte  $a_n$  und  $b_n$  in den Variablen a und b abzulegen.

Wenn wir dieses Verfahren einsetzen wollen um in einem vorgegeben Intervall nach einer Nullstelle zu suchen, so können wir im Voraus berechnen, wie viele Iterationen zur Erzielung einer geforderten Genauigkeit benötigt werden: Soll die Nullstelle mit einer Genauigkeit von  $\varepsilon$  bestimmt werden, so muss die Zahl n der Iterationen so gewählt werden, dass

$$\left(\frac{1}{2}\right)^{n-1}\cdot (b-a) \le \varepsilon$$

gilt. Um n zu bestimmen, logarithmieren wir diese Ungleichung und erhalten:

$$(n-1) \cdot \ln\left(\frac{1}{2}\right) + \ln(b-a) \le \ln(\varepsilon)$$

$$\Leftrightarrow (n-1) \cdot \ln\left(\frac{1}{2}\right) \le \ln(\varepsilon) - \ln(b-a)$$

$$\Leftrightarrow (n-1) \cdot \ln\left(\frac{1}{2}\right) \le \ln\left(\frac{\varepsilon}{b-a}\right)$$

$$\Leftrightarrow -(n-1) \cdot \ln(2) \le \ln\left(\frac{\varepsilon}{b-a}\right)$$

$$\Leftrightarrow (n-1) \ge -\frac{1}{\ln(2)} \cdot \ln\left(\frac{\varepsilon}{b-a}\right)$$

$$\Leftrightarrow n \ge \frac{1}{\ln(2)} \cdot \ln\left(\frac{b-a}{\varepsilon}\right) + 1$$

Wollen wir beispielsweise die Nullstelle der Funktion  $x\mapsto x-\cos(x)$  im Intervall [0,1] auf eine Genauigkeit von  $\varepsilon=10^{-9}$  bestimmen, so finden wir

$$n \ge \frac{\ln(10^9)}{\ln(2)} + 1 = 9 \cdot \frac{\ln(10)}{\ln(2)} + 1 \approx 30.89735286,$$

Damit ist klar, dass wir 31 Iterationen des Verfahrens benötigen um die geforderte Genauigkeit zu erreichen. Tabelle 4.1 zeigt die Werte, die  $a_n$  und  $b_n$  bei der Lösung der Gleichung  $x-\cos(x)=0$  beim Intervall-Halbierungs-Verfahren annehmen. Nach 30 Iterationen weichen die Intervall-Grenzen  $a_n$  und  $b_n$  um weniger als  $10^{-9}$  voneinander ab.

# 4.2.2 Die Regula Falsi

Beim Bisektions-Verfahren wird das Intervall in jedem Schritt in zwei gleich große Teile zerteilt, denn wir bestimmen den Mittelpunkt des Intervalls [a, b] nach der Formel

$$c = \frac{1}{2} \cdot (a+b).$$

Bei dieser Formel werden die Beträge der Funktionswerte von f an den Stellen a und b überhaupt nicht berücksichtigt. Es liegt nahe, die Beträge der Funktionswerte in die Formel mit einfließen zu lassen, denn wenn beispielsweise |f(a)| wesentlich kleiner |f(b)| ist, dann ist zu vermuten, dass die Nullstelle von f näher an a als an b liegt.

Betrachten wir beispielsweise die Tabelle 4.1, so sehen wir, dass in dem 24-ten Iterations-Schritt die Funktion  $x\mapsto x-\cos(x)$  an der rechten Intervall-Grenze  $b_n$  den Wert  $\approx 7.7\cdot 10^{-9}$  hat, während die Funktion an der linken Intervall-Grenze  $a_n$  den Wert  $-9.2\cdot 10^{-8}$  hat. Der Betrag dieses Wertes ist mehr als 10 mal so groß wie der Wert an der rechten Intervall-Grenze. Folglich liegt es nahe zu vermuten, dass die Nullstelle näher an der rechten Intervall-Grenze liegt als an der linken. Die weitere Berechnung bestätigt diese Vermutung auch, denn die rechte Intervall-Grenze ändert sich bei den nächsten drei Iterationen nicht. Wie können wir diese Beobachtung ausnutzen? Anstatt in der Formel  $c_n=\frac{1}{2}\cdot(a_n+b_n)$  die Punkte a und b unabhängig von den Funktionswerten gleich stark zu gewichten, könnten wir eine Intervall-Grenze dann stärker gewichten, wenn der Funktionswert dort kleiner ist, weil wir dann vermuten würden, dass dieser Punkt schon näher an der Nullstelle liegt. Eine naheliegende Idee ist daher, die Punkte a und b mit den Beträgen der reziproken Funktionswerte zu gewichten, denn die werden umso größer, je kleiner der Funktionswert ist. Dieser Ansatz führt auf die Formel

n	$a_n$	$b_n$	$f(a_n)$	$f(b_n)$
0:	0.000000000	1.000000000	-1.00000000e+00	4.59697694e-01
1:	0.500000000	1.000000000	-3.77582562e-01	4.59697694e-01
2:	0.500000000	0.750000000	-3.77582562e-01	1.83111311e-02
3:	0.625000000	0.750000000	-1.85963120e-01	1.83111311e-02
4:	0.687500000	0.750000000	-8.53349462e-02	1.83111311e-02
5:	0.718750000	0.750000000	-3.38793724e-02	1.83111311e-02
6:	0.734375000	0.750000000	-7.87472546e-03	1.83111311e-02
7:	0.734375000	0.742187500	-7.87472546e-03	5.19571174e-03
8:	0.738281250	0.742187500	-1.34514975e-03	5.19571174e-03
9:	0.738281250	0.740234375	-1.34514975e-03	1.92387278e-03
10:	0.738281250	0.739257813	-1.34514975e-03	2.89009147e-04
11:	0.738769531	0.739257813	-5.28158434e-04	2.89009147e-04
12:	0.739013672	0.739257813	-1.19596671e-04	2.89009147e-04
13:	0.739013672	0.739135742	-1.19596671e-04	8.47007314e-05
14:	0.739074707	0.739135742	-1.74493466e-05	8.47007314e-05
15:	0.739074707	0.739105225	-1.74493466e-05	3.36253482e-05
16:	0.739074707	0.739089966	-1.74493466e-05	8.08791474e-06
17:	0.739082336	0.739089966	-4.68073746e-06	8.08791474e-06
18:	0.739082336	0.739086151	-4.68073746e-06	1.70358327e-06
19:	0.739084244	0.739086151	-1.48857844e-06	1.70358327e-06
20:	0.739084244	0.739085197	-1.48857844e-06	1.07502077e-07
21:	0.739084721	0.739085197	-6.90538266e-07	1.07502077e-07
22:	0.739084959	0.739085197	-2.91518116e-07	1.07502077e-07
23:	0.739085078	0.739085197	-9.20080247e-08	1.07502077e-07
24:	0.739085078	0.739085138	-9.20080247e-08	7.74702466e-09
25:	0.739085108	0.739085138	-4.21305004e-08	7.74702466e-09
26:	0.739085123	0.739085138	-1.71917379e-08	7.74702466e-09
27:	0.739085130	0.739085138	-4.72235666e-09	7.74702466e-09
28:	0.739085130	0.739085134	-4.72235666e-09	1.51233399e-09
29:	0.739085132	0.739085134	-1.60501133e-09	1.51233399e-09
30:	0.739085133	0.739085134	-4.63386709e-11	1.51233399e-09

Tabelle 4.1: Die ersten 30 Schritte des Bisektions-Verfahrens zur Lösung von  $x - \cos(x) = 0$ .

$$c = \frac{\frac{1}{|f(a)|} \cdot a + \frac{1}{|f(b)|} \cdot b}{\frac{1}{|f(a)|} + \frac{1}{|f(b)|}} = \frac{|f(b)| \cdot a + |f(a)| \cdot b}{|f(a)| + |f(b)|}$$

Diese Formel lässt sich auch geometrisch interpretieren, denn wir erhalten dieselbe Formel, wenn wir c dadurch bestimmen, dass wir eine Gerade durch die Punkte  $\langle a, f(a) \rangle$  und  $\langle b, f(b) \rangle$  legen und c als den Schnittpunkt dieser Gerade mit der x-Achse definieren. Die Gleichung für eine Gerade g(x) hat nämlich die Form

$$g(x) = \alpha \cdot x + \beta.$$

Setzen wir hier für x den Wert a und für g(x) den Wert f(a) ein, so erhalten wir die Gleichung

$$f(a) = \alpha \cdot a + \beta. \tag{4.3}$$

Analog erhalten wir die Gleichung

$$f(b) = \alpha \cdot b + \beta \tag{4.4}$$

wenn wir für x den Wert b und für g(x) den Wert f(b) einsetzen. Somit haben wir zwei Gleichungen für die beiden Unbekannten  $\alpha$  und  $\beta$ . Um Diese Unbekannten zu bestimmen, subtrahieren wir die beiden Gleichungen voneinander. Dann verschwindet die Unbekannte  $\beta$  und wir haben

$$f(b) - f(a) = \alpha \cdot (b - a)$$
, also  $\alpha = \frac{f(b) - f(a)}{b - a}$ .

Setzen wir diesen Wert für  $\alpha$  in die Gleichung 4.3 ein, so ergibt sich

$$f(a) = \frac{f(b) - f(a)}{b - a} \cdot a + \beta.$$

Wir lösen diese Gleichung nach  $\beta$  auf und erhalten

$$\beta = \frac{f(a) \cdot (b-a) - (f(b) - f(a)) \cdot a}{b-a} = \frac{f(a) \cdot b - f(b) \cdot a}{b-a}.$$

Wir bestimmen c aus der Forderung, dass g(c) = 0 ist, also

$$0 = \alpha \cdot c + \beta$$

$$\Leftrightarrow c = -\frac{\beta}{\alpha}$$

Setzen wir hier die eben berechneten Werte für  $\alpha$  und  $\beta$  ein, so erhalten wir

$$c = -\frac{\frac{f(a) \cdot b - f(b) \cdot a}{b - a}}{\frac{f(b) - f(a)}{b - a}} = \frac{f(b) \cdot a - f(a) \cdot b}{f(b) - f(a)}$$

Falls nun f(a) < 0 und f(b) > 0 ist, gilt -f(a) = |f(a)| und f(b) = |f(b)|. Setzen wir diese Werte in die obige Gleichung ein, so erhalten wir

$$c = \frac{|f(b)| \cdot a + |f(a)| \cdot b}{|f(a)| + |f(b)|}$$

und das ist die gleiche Formel, die wir auch oben schon abgeleitet hatten. Abbildung 4.2 zeigt die graphische Bestimmung von c als Schnittpunkt der Geraden mit der x-Achse.

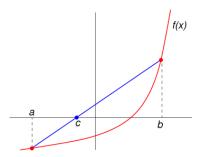


Abbildung 4.2: Die Regula-Falsi zur Nullstellen-Bestimmung.

Das Verfahren, das mit dieser Formel arbeitet, ist unter dem Namen Regula Falsi bekannt und sieht genauso aus wie das Bisektions-Verfahren, nur dass wir für c jetzt die oben abgeleitete Formel verwenden:

I.A.: 
$$n = 1$$
.

$$a_1 := a, \quad b_1 := b.$$

$$\mathsf{I.S.:}\ n\mapsto n+1$$

$$c_n := \frac{|f(b_n)| \cdot a_n + |f(a_n)| \cdot b_n}{|f(a_n)| + |f(b_n)|}.$$

Dann definieren wir  $a_{n+1}$  und  $b_{n+1}$  durch Fall-Unterscheidung:

$$\langle a_{n+1},b_{n+1}\rangle := \left\{ \begin{array}{ll} \langle a_n,c_n\rangle & \text{falls} & f(c_n)>0 \\ \langle c_n,b_n\rangle & \text{falls} & f(c_n)\leq 0. \end{array} \right.$$

Ähnlich wie beim Beweis des Zwischenwert-Satzes lässt sich zeigen, dass die Folge  $(a_n)_{n\in\mathbb{N}^*}$  monoton steigend ist, während die Folge  $(b_n)_{n\in\mathbb{N}^*}$  monoton fallend ist. Da die Folgen überdies beschränkt sind, denn  $a_n$  ist immer kleiner als b und  $b_n$  ist immer größer als a, konvergieren beide Folgen. Allerdings ist nicht garantiert, dass  $a_n$  und  $b_n$  gegen den gleichen Grenzwert konvergieren! Es lässt sich lediglich zeigen, dass entweder  $a_n$  oder  $b_n$  gegen eine Nullstelle der Funktion f konvergiert. Um das Verfahren experimentell untersuchen zu können, implementieren wir es. Abbildung 4.3 zeigt die Implementierung der Methode findZero(). Diese Implementierung ist weitgehend analog zu der Implementierung des Bisektions-Verfahrens. Es gibt eigentlich nur zwei wesentliche Unterschiede:

1. In Zeile 6 berechnen wir C nun nach der Formel

$$c := \frac{f(b) \cdot a - f(a) \cdot b}{f(b) - f(a)}.$$

Beim Bisektions-Verfahren hatten wir hier die Formel

$$c := \frac{1}{2} \cdot (a+b)$$

verwendet.

2. Bei der Rückgabe des berechneten Wertes in Zeile 14 bzw. 16 ist es erforderlich, die Beträge der Funktionswerte an den Intervall-Grenzen a und b zu vergleichen, denn wir wissen nicht, ob die Folge  $(a_n)_n$  oder die Folge  $(b_n)_n$  gegen die Nullstelle von f konvergiert. Wir geben daher als Ergebnis die Intervall-Grenze zurück, für die der Betrag des Funktionswertes am kleinsten ist. Da wir wissen, dass der Funktionswert an der linken Intervall-Grenze immer kleiner als 0 ist, erhalten wir dort den Betrag der Funktion f, indem wir dem Funktionswert das Minuszeichen vorstellen.

```
regulaFalsi := procedure(f, a, b, n) {
        assert(a < b, "Error: !(a < b)");
        assert(f(a) < 0 \&\& f(b) > 0, "Error: !(f(a) < 0 \&\& f(b) > 0)"):
        fa := f(a); fb := f(b);
        for (i in [1 .. n]) {
             c := (fb * a - fa * b) / (fb - fa); fc := f(c);
             if (fc <= 0) {
                 a := c; fa := fc;
             } else {
                 b := c; fb := fc;
10
11
12
        if (-fa < fb) {
13
             return a:
14
        } else {
15
             return b;
16
17
    };
18
```

Abbildung 4.3: Implementierung der Regula Falsi in SetlX.

Tabelle 4.2 zeigt die ersten 12 Iterations-Schritte, wenn die Regula Falsi zur Berechnung der Nullstelle von  $x - \cos(x)$  eingesetzt wird. Wir sehen, dass wir bereits im 9-ten Schritt dieselbe Genauigkeit

erreicht haben, für die wir mit dem Bisektions-Verfahren 30 Schritte benötigt haben. Wir sehen auch, dass die rechte Intervall-Grenze immer konstant bleibt. Es sieht so aus, als ob wir mit der Regula Falsi ein Verfahren gefunden hätten, dass dem Bisektions-Verfahren überlegen wäre. Die nächste Aufgabe zeigt Ihnen jedoch, dass dem Verfahren eine ganz wichtige Eigenschaft fehlt, die das Bisektions-Verfahren besitzt:

Das Verfahren, das die Regula Falsi zur Bestimmung der Nullstelle verwendet, ist nicht robust!

Es gibt nämlich Funktionen, bei denen die Regula Falsi zur Nullstellen-Bestimmung <u>wesentlich mehr</u> Iterationen benötigt als das Bisektions-Verfahren.

n	$a_n$	$b_n$	$f(a_n)$	$f(b_n)$
1:	0.000000000	1.000000000	-1.00000000e+00	4.59697694e-01
2:	0.685073357	1.000000000	-8.92992765e-02	4.59697694e-01
3:	0.736298997	1.000000000	-4.66003904e-03	4.59697694e-01
4:	0.738945356	1.000000000	-2.33925666e-04	4.59697694e-01
5:	0.739078130	1.000000000	-1.17191742e-05	4.59697694e-01
6:	0.739084782	1.000000000	-5.87046549e-07	4.59697694e-01
7:	0.739085115	1.000000000	-2.94066726e-08	4.59697694e-01
8:	0.739085132	1.000000000	-1.47305551e-09	4.59697694e-01
9:	0.739085133	1.000000000	-7.37890543e-11	4.59697694e-01
10:	0.739085133	1.000000000	-3.69623245e-12	4.59697694e-01
11:	0.739085133	1.000000000	-1.85199566e-13	4.59697694e-01
12:	0.739085133	1.000000000	-9.23913723e-15	4.59697694e-01

Tabelle 4.2: Die ersten 12 Schritte der Regula Falsi zur Lösung von  $x - \cos(x) = 0$ .

Aufgabe 32: Verwenden Sie die Regula Falsi zur Lösung der Gleichung

$$x^4 - 1 = 0.$$

Starten Sie mit dem Intervall [0, 10]. Zeigen Sie, dass für alle natürlichen Zahlen n mit  $n \le 1000$  die folgende Ungleichung für die linke Intervall-Grenze  $a_n$  gilt:

$$a_n \leq \frac{n}{1000}$$
.

Die Lösung der Gleichung  $x^4-1=0$  in dem Intervall ist x=1. Aus der zu zeigenden Ungleichung kann beispielsweise gefolgert werden, dass  $a_{100} \leq 0.1$  gilt. Der mit dem obigen Programm ermittelte Wert für  $a_{100}$  ist  $a_{100}=0.0985146583$ . In diesem Fall hat die Regula Falsi also selbst nach 100 Iterationen nicht eine einzige korrekte Stelle im Ergebnis berechnen können!

**Lösung**: Wir zeigen durch vollständige Induktion über n, dass für alle  $n \le 1000$  zum einen die Ungleichung  $a_n \le n \cdot 10^{-3}$  gilt und dass zum anderen  $b_n$  konstant ist, es gilt  $b_n = 10$ .

I.A.: n = 1. Es gilt

$$a_1 = 0 \le 1 \cdot 10^{-3}$$
 und  $b_1 = 10$ .

I.S.:  $n \mapsto n+1$ .

Die Funktion  $f:=(x\mapsto x^4-1)$  ist für nicht-negative Zahlen *monoton steigend*, das heißt aus  $0\le u\le v$  folgt auch  $f(u)\le f(v)$ . Es gilt

$$f(n \cdot 10^{-3}) = n^4 \cdot 10^{-12} - 1$$
 und  $f(10) = 10^4 - 1$ .

Nach Induktions-Voraussetzung können wir  $a_n$  durch  $n \cdot 10^{-3}$  nach oben abschätzen und aufgrund der Monotonie von f können wir dann  $f(a_n)$  durch  $f(n \cdot 10^{-3})$  nach oben abschätzen:

$$f(a_n) \le f(n \cdot 10^{-3}) = n^4 \cdot 10^{-12} - 1$$

Wenden wir daher für  $a_n'=n\cdot 10^{-3}$  und  $b_n=10$  die Regula Falsi an um eine Näherung  $c_n'$  für die Nullstelle von f zu berechnen, so wird  $c_n'$  größer sein als der wahre Wert von  $c_n$ , der in dem Algorithmus tatsächlich auftritt. Es gilt:

$$c'_{n} = \frac{f(b_{n}) \cdot a'_{n} - f(a'_{n}) \cdot b_{n}}{f(b_{n}) - f(a'_{n})}$$

$$= \frac{f(10) \cdot n \cdot 10^{-3} - f(n \cdot 10^{-3}) \cdot 10}{f(10) - f(n \cdot 10^{-3})}$$

$$= \frac{(10^{4} - 1) \cdot n \cdot 10^{-3} - (n^{4} \cdot 10^{-12} - 1) \cdot 10}{10^{4} - 1 - n^{4} \cdot 10^{-12} + 1}$$

$$= 10^{-4} \cdot \frac{10 \cdot n - n \cdot 10^{-3} - n^{4} \cdot 10^{-11} + 10}{1 - n^{4} \cdot 10^{-16}}$$

$$= 10^{-3} \cdot \frac{n + 1 - n \cdot 10^{-4} - n^{4} \cdot 10^{-12}}{1 - n^{4} \cdot 10^{-16}}$$

Wir untersuchen nun, für welche natürlichen Zahlen n die Ungleichung  $c'_n \leq 10^{-3} \cdot (n+1)$  gilt.

$$\begin{aligned} c_n' &\leq 10^{-3} \cdot (n+1) \\ \Leftrightarrow & 10^{-3} \cdot \frac{n+1-n \cdot 10^{-4}-n^4 \cdot 10^{-12}}{1-n^4 \cdot 10^{-16}} \leq 10^{-3} \cdot (n+1) \\ \Leftrightarrow & n+1-n \cdot 10^{-4}-n^4 \cdot 10^{-12} \leq (n+1) \cdot \left(1-n^4 \cdot 10^{-16}\right) \\ \Leftrightarrow & n+1-n \cdot 10^{-4}-n^4 \cdot 10^{-12} \leq (n+1)-(n+1) \cdot n^4 \cdot 10^{-16} \\ \Leftrightarrow & -n \cdot 10^{-4}-n^4 \cdot 10^{-12} \leq -(n+1) \cdot n^4 \cdot 10^{-16} \\ \Leftrightarrow & n \cdot 10^{-4}+n^4 \cdot 10^{-12} \geq (n+1) \cdot n^4 \cdot 10^{-16} \\ \Leftrightarrow & n^4 \cdot 10^{-12} \geq (n+1) \cdot n^4 \cdot 10^{-16} \\ \Leftrightarrow & 1 \geq (n+1) \cdot 10^{-4} \\ \Leftrightarrow & 10^4 \geq n+1 \\ \Leftrightarrow & n < 9999 \end{aligned}$$

Solange n < 1000 ist, gilt also sicher  $c'_n < 1$  und damit ist  $f(c'_n)$  negativ. Daher gilt

$$a_{n+1} \leq a'_{n+1} = c'_n \leq 10^{-3} \cdot n < 10^{-3} \cdot (n+1) \text{ und } b_{n+1} = b_n = 10.$$

#### 4.2.3 Das Sekanten-Verfahren

Ein Problem bei der Regula Falsi scheint darin zu liegen, dass häufig eine Intervall-Grenze während der gesamten Iteration fest bleibt. Dies war schon bei der Bestimmung der Nullstelle der Funktion

$$x \mapsto x - \cos(x)$$

der Fall. Eine Möglichkeit, dieses Problem zu umgehen besteht darin, dass wir anstatt eine Folge von Intervallen  $([a_n,b_n])_{n\in\mathbb{N}^*}$  zu bilden, einfach nur eine Folge von Punkten  $(x_n)_{n\in\mathbb{N}^*}$  konstruieren. Den Punkt  $x_{n+1}$  bestimmen wir, indem wir durch die Punkte  $x_n$  und  $x_{n-1}$  eine Gerade legen und dann  $x_n$  als den Schnittpunkt dieser Geraden mit der x-Achse bestimmen. Das führt auf dieselbe Formel wie bei der Regula-Falsi, wir setzen nämlich

$$x_{n+1} := \frac{f(x_n) \cdot x_{n-1} - f(x_{n-1}) \cdot x_n}{f(x_n) - f(x_{n-1})}.$$

Dann brauchen wir nur noch zwei Startwerte  $x_1$  und  $x_2$  und die Rechnung kann los gehen. Abbildung 4.4 zeigt eine Implementierung des Sekanten-Verfahrens in SETLX. Testen wir dieses Programm mit der Funktion  $x\mapsto x-\cos(x)$ , so erhalten wir die in Tabelle 4.3 gezeigten Werte. Wir sehen, dass jetzt bereits 7 Iterationen ausreichen, um die Lösung der Gleichung mit der geforderten Genauigkeit zu berechnen. Es sieht also so aus, als ob das Sekanten-Verfahren den anderen Verfahren überlegen ist. In der Tat kann gezeigt werden, dass das Sekanten-Verfahren, **wenn** es denn konvergiert, schneller konvergiert als die anderen Verfahren. Wir werden das später präzisieren. Das Problem ist, dass das Sekanten-Verfahren gar nicht immer konvergiert. Betrachten wir beispielsweise die Funktion

$$x \mapsto \frac{2}{x^2 + 1} - 1.$$

Diese Funktion hat bei x=1.0 eine Nullstelle. Mit den Startwerten a=0 und b=5.0 produziert unser Programm die in Tabelle 4.4 gezeigten Werte.

```
secant := procedure(f, a, b, digits) {
    fa := f(a);
    fb := f(b);
    while (abs(b - a) > (1/10)**(digits + 1)) {
        c := (fb * a - fa * b) / (fb - fa);
        a := b; b := c; fa := fb; fb := f(c);
    }
    return b;
}
```

Abbildung 4.4: Implementierung des Sekanten-Verfahrens in Setla.

n	$x_n$	$f(x_n)$
1:	10.000000000000	+1.08390715e+01
2:	0.84466083134	+1.80675899e-01
3:	0.68946400911	-8.21230732e-02
4:	0.73796206792	-1.87910933e-03
5:	0.73909776898	+2.11474296e-05
6:	0.73908513008	-5.24715686e-09
7:	0.73908513322	-1.46275678e-14

Tabelle 4.3: Lösung der Gleichung  $x - \cos(x) = 0$  mit dem Sekanten-Verfahren.

#### 4.2.4 Das Illinois-Verfahren

Von den bisher vorgestellten Verfahren ist nur das Bisektions-Verfahren wirklich robust. Bei der Regula-Falsi ist das Problem, dass eine Intervall-Grenze stehen bleiben kann. Am Beispiel der Funktion

$$x \mapsto x^4 - 1$$

haben wir gesehen, dass dies zu einer sehr langsamen Konvergenz führen kann. Beim Sekanten-Verfahren hatten wir dieses Problem behoben, aber dort kann es in ungünstigen Fällen passieren, dass das Verfahren überhaupt nicht mehr konvergiert. Das *Illinois-Verfahren* [8] versucht die Konvergenz der Regula Falsi auf andere Weise zu beschleunigen. Die Idee des Verfahrens ist eigentlich sehr

n	$x_n$	$f(x_n)$
1:	+5.000000e+00	-0.923076923
2:	+2.600000e+00	-0.742268041
3:	-7.252631e+00	-0.962687030
4:	+3.577905e+01	-0.998438891
5:	-1.165962e+03	-0.999998529
6:	+7.693592e+05	-1.000000000
7:	-5.237534e+11	-1.000000000
8:	+1.550094e+23	-1.000000000
9:	$\infty$	-1.000000000

Tabelle 4.4: Divergenz des Sekanten-Verfahrens bei der Lösung von  $\frac{2}{x^2+1}-1=0.$ 

naheliegend: Wenn bei der Regula Falsi eine der Intervall-Grenzen über zwei oder mehr Schritte konstant bleibt, dann wird der Funktionswert an der betreffenden Intervall-Grenze halbiert, so dass der Einfluss dieses Wertes bei der Berechnung der nächsten Näherung  $c_n$  nach der Formel

$$c_n := \frac{f(b_n) \cdot a_n - f(a_n) \cdot b_n}{f(b_n) - f(a_n)}$$

gemindert wird. Nehmen wir o.B.d.A. an, dass f(a) < 0 und 0 < f(b) ist, so führt das zur folgenden Definition der Folgen  $\left(a_n\right)_{n \in \mathbb{N}^*}$  und  $\left(b_n\right)_{n \in \mathbb{N}^*}$ :

I.A.: n = 1. Wir setzen

$$a_1 := a$$
,  $b_1 := b$ ,  $\alpha_1 := 1$ , und  $\beta_1 := 1$ .

Die Werte  $\alpha_1$  und  $\beta_1$  sind dabei Gewichtungs-Faktoren, die wir später benötigen.

I.S.:  $n \mapsto n+1$ . Wir definieren ähnlich wie bei der Regula Falsi den Wert  $c_n$  als

$$c_n := \frac{\beta_n \cdot f(b_n) \cdot a_n - \alpha_n \cdot f(a_n) \cdot b_n}{\beta_n \cdot f(b_n) - \alpha_n \cdot f(a_n)}.$$

Der Unterschied zur Regula Falsi liegt in den Gewichtungs-Faktoren  $\alpha_n$  und  $\beta_n$ . Die Werte für  $a_{n+1}$  und  $b_{n+1}$  werden durch dieselbe Fall-Unterscheidung wie bei der Regula Falsi festgelegt:

$$\langle a_{n+1}, b_{n+1} \rangle := \left\{ \begin{array}{ll} \langle a_n, c_n \rangle & \text{falls} & f(c_n) > 0 \\ \langle c_n, b_n \rangle & \text{falls} & f(c_n) \leq 0. \end{array} \right.$$

Falls wir nun feststellen, dass  $b_{n+1}=b_{n-1}$  ist, so hat sich der Wert der rechten Intervall-Grenze während der letzten zwei Iterationen nicht geändert. Wir wollen diesen Wert daher beim nächsten Iterations-Schritt schwächer gewichten und setzen deshalb in diesem Fall

$$\beta_{n+1} := \frac{1}{2} \cdot \beta_n$$
 und  $\alpha_{n+1} := 1$ .

Ist umgekehrt  $a_{n+1}=a_{n-1}$ , so hat sich der Wert der linken Intervall-Grenze nicht geändert. Wir gewichten daher die linke Intervall-Grenze beim nächsten Iterations-Schritt schwächer und setzen

$$\beta_{n+1} := 1$$
 und  $\alpha_{n+1} := \frac{1}{2} \cdot \alpha_n$ .

In allen anderen Fällen setzen wir

$$\beta_{n+1} := 1 \quad \text{ und } \quad \alpha_{n+1} := 1.$$

Die Umsetzung dieses Verfahrens sehen Sie in Abbildung 4.5. In den Variablen oldA1 und oldB1 speichern wir die Werte von  $a_{n-1}$  und  $b_{n-1}$ , in den Variablen oldA2 und oldB2 sind die Werte  $a_{n-2}$  und  $b_{n-2}$  gespeichert. Wir initialisieren diese Werte mit om, denn om bezeichnet in Setla den

undefinierten Wert. Falls wir in Zeile 19 feststellen, dass der Wert von  $a_n=a_{n-2}$  ist, dann setzen wir den Wert  $\alpha_{n+1}$  auf  $\alpha_n/2$ . Analog testen wir in Zeile 14, ob  $b_n=b_{n-2}$  ist und setzen gegebenenfalls  $\beta_{n+1}$  auf  $\beta_n/2$ .

```
illinois := procedure(f, a, b, n) {
         assert(a < b, "a has to be less than b");</pre>
         assert(f(a) < 0 \&\& 0 < f(b), "We need f(a) < 0 and 0 < f(b)!");
         [ fa, fb ] := [ f(a), f(b) ];
        oldA1 := om; oldB1 := om;
        oldA2 := om; oldB2 := om;
        alpha := 1; beta := 1;
         for (k in [1 .. n]) {
             c := (beta * fb * a - alpha * fa * b) / (beta * fb - alpha * fa);
             fc := f(c);
10
             if (fc < 0) {
                 a := c; fa := fc; alpha := 1;
12
                 if (oldB2 == b) {
                      beta /= 2;
14
                 }
15
             } else if (fc > 0) {
16
                 b := c; fb := fc; beta := 1;
17
                 if (oldA2 == a) {
18
                      alpha /= 2;
19
20
             } else {
                 return c;
22
23
             oldA2 := oldA1; oldB2 := oldB1;
24
             oldA1 := a;
                              oldB1 := b;
25
26
         return (a + b) / 2;
27
    };
28
```

Abbildung 4.5: Implementierung des Illinois-Verfahrens zur Berechnung von Nullstellen.

# Kapitel 5

# Differenzierbare Funktionen

In diesem Kapitel kommen wir zum Kern der Analysis und führen den Begriff der *Ableitung* einer Funktion ein. Dies ist der wichtigste Begriff in der Analysis. Die folgende formale Definition der Ableitung geht auf Augustin-Louis Cauchy zurück.

# 5.1 Der Begriff der Ableitung

**Definition 64 (Ableitung)** Es sei  $D \subseteq \mathbb{R}$  ein Intervall. Eine Funktion  $f: D \to \mathbb{R}$  ist im Punkt  $\widehat{x} \in D$  differenzierbar, wenn der Grenzwert

$$\lim_{h \to 0} \frac{f(\widehat{x} + h) - f(\widehat{x})}{h}$$

existiert. In diesem Fall definieren wir

$$\frac{\mathrm{d} f}{\mathrm{d} x}(\widehat{x}) = \lim_{h \to 0} \frac{f(\widehat{x} + h) - f(\widehat{x})}{h}.$$

Wir bezeichnen den Wert  $\frac{\mathrm{d}\,f}{\mathrm{d}x}(\widehat{x})$  als die *Ableitung* der Funktion f an der Stelle  $\widehat{x}$ . Gelegentlich werden wir für die Ableitung auch die Schreibweise  $f'(\widehat{x})$  verwenden.

Bemerkung: Beachten Sie, dass wir in der obigen Definition den Ausdruck

$$\frac{f(\widehat{x}+h)-f(\widehat{x})}{h}$$

als Funktion von h auffassen. Dieser Ausdruck wird auch als Differential-Quotient bezeichnet. Er gibt die Steigung einer Sekante an, welche die Funktion  $x\mapsto f(x)$  in den Punkten  $\widehat{x}$  und  $\widehat{x}+h$  schneidet. Definieren wir

$$r(h) := f(\widehat{x} + h) - f(\widehat{x}) - h \cdot \frac{\mathrm{d}f}{\mathrm{d}x}(\widehat{x}),$$

so gilt einerseits

$$\lim_{h\to 0}\frac{r(h)}{h}=\lim_{h\to 0}\frac{f(\widehat{x}+h)-f(\widehat{x})}{h}-\frac{\mathrm{d}f}{\mathrm{d}x}(\widehat{x})=\frac{\mathrm{d}f}{\mathrm{d}x}(\widehat{x})-\frac{\mathrm{d}f}{\mathrm{d}x}(\widehat{x})=0,$$

und andererseits haben wir

$$f(\widehat{x} + h) = f(\widehat{x}) + h \cdot \frac{\mathrm{d}f}{\mathrm{d}r}(\widehat{x}) + r(h).$$

Die Funktion r(h) ist also der Fehler, der entsteht, wenn wir die Funktion f(x) durch ihre Tangente im Punkt  $\langle \widehat{x}, f(\widehat{x}) \rangle$  approximieren.

**Bemerkung**: Falls die Funktion f im Punkt  $\hat{x}$  differenzierbar ist, dann ist die Funktion dort auch stetig, denn es gilt

$$\begin{split} \lim_{h \to 0} f(\widehat{x} + h) &= \lim_{h \to 0} f(\widehat{x} + h) - f(\widehat{x}) + f(\widehat{x}) \\ &= \lim_{h \to 0} \frac{f(\widehat{x} + h) - f(\widehat{x})}{h} \cdot h + f(\widehat{x}) \\ &= \lim_{h \to 0} \frac{f(\widehat{x} + h) - f(\widehat{x})}{h} \cdot \lim_{h \to 0} h + f(\widehat{x}) \\ &= f'(\widehat{x}) \cdot 0 + f(\widehat{x}) \\ &= f(\widehat{x}) \end{split}$$

und  $\lim_{h\to 0}f(\widehat{x}+h)=f(\widehat{x})$  heißt gerade, dass f im Punkt  $\widehat{x}$  stetig ist.

#### Beispiele:

1. Die konstante Funktion  $f := (x \mapsto c)$  hat überall die Ableitung 0, denn es gilt

$$\lim_{h \to 0} \frac{f(\widehat{x} + h) - f(\widehat{x})}{h} = \lim_{h \to 0} \frac{c - c}{h} = \lim_{h \to 0} 0 = 0.$$

2. Die identische Funktion  $id := (x \mapsto x)$  hat überall die Ableitung 1, denn es gilt:

$$\lim_{h\to 0}\frac{id(\widehat{x}+h)-id(\widehat{x})}{h}=\lim_{h\to 0}\frac{\widehat{x}+h-\widehat{x}}{h}=\lim_{h\to 0}\frac{h}{h}=\lim_{h\to 0}1=1.$$

3. Die Funktion  $abs := (x \mapsto |x|)$ , die den Absolutbetrag berechnet, ist im Punkte  $\hat{x} = 0$  nicht differenzierbar. Wir zeigen, dass der Grenzwert

$$\lim_{h\to 0} \frac{\mathit{abs}(h) - \mathit{abs}(0)}{h}$$

nicht existiert. Dazu betrachten wir zunächst die Folge  $\left(\frac{1}{n}\right)_{n\in\mathbb{N}^*}$ . Nehmen wir an, dass dieser Grenzwert existiert und den Wert a hat. Da

$$\lim_{n \to \infty} \frac{1}{n} = 0$$

ist, müsste nach Definition des Grenzwerts dann gelten:

$$a = \lim_{h \to 0} \frac{\mathsf{abs}(h) - \mathsf{abs}(0)}{h} = \lim_{n \to \infty} \frac{\mathsf{abs}(\frac{1}{n})}{\frac{1}{n}} = \lim_{n \to \infty} \frac{\frac{1}{n}}{\frac{1}{n}} = 1.$$

Betrachten wir andererseits die Folge  $\left(-\frac{1}{n}\right)_{n\in\mathbb{N}^*}$  und berücksichtigen, dass diese Folge ebenfalls gegen 0 konvergiert, so erhalten wir

$$a = \lim_{h \to 0} \frac{\mathsf{abs}(h) - \mathsf{abs}(0)}{h} = \lim_{n \to \infty} \frac{\mathsf{abs}(-\frac{1}{n})}{-\frac{1}{n}} = \lim_{n \to \infty} \frac{\frac{1}{n}}{-\frac{1}{n}} = -1.$$

Da a nicht gleichzeitig die Werte +1 und -1 annehmen kann, müssen wir folgern, dass die Funktion abs an der Stelle  $\widehat{x}=0$  nicht differenzierbar ist.

**Satz 65 (Ableitungs-Regeln)** Es seien  $f:D\to\mathbb{R}$  und  $g:D\to\mathbb{R}$  Funktionen, die im Punkt  $\widehat{x}$  differenzierbar sind. Dann gilt:

1. Die Funktion  $f + g := (x \mapsto f(x) + g(x))$  ist im Punkt  $\hat{x}$  differenzierbar und es gilt:

$$(f+g)'(\widehat{x}) = f'(\widehat{x}) + g'(\widehat{x}).$$

2. Die Funktion  $f - g := (x \mapsto f(x) - g(x))$  ist im Punkt  $\widehat{x}$  differenzierbar und es gilt:

$$(f-g)'(\widehat{x}) = f'(\widehat{x}) - g'(\widehat{x}).$$

3. Die Funktion  $f\cdot g:=\left(x\mapsto f(x)\cdot g(x)\right)$  ist im Punkt  $\widehat{x}$  differenzierbar und es gilt die Produkt-Regel:

$$(f \cdot g)'(\widehat{x}) = f'(\widehat{x}) \cdot g(\widehat{x}) + f(\widehat{x}) \cdot g'(\widehat{x}).$$

4. Ist  $g(\widehat{x}) \neq 0$ , dann ist die Funktion  $\frac{f}{g} := \left(x \mapsto \frac{f(x)}{g(x)}\right)$  im Punkt  $\widehat{x}$  differenzierbar und es gilt die Quotienten-Regel:

$$\left(\frac{f}{g}\right)'(\widehat{x}) = \frac{f'(\widehat{x}) \cdot g(\widehat{x}) - f(\widehat{x}) \cdot g'(\widehat{x})}{g(\widehat{x})^2}.$$

Beweis: Wir zeigen nur die Produkt-Regel. Es gilt:

$$\begin{split} &(f \cdot g)'(\widehat{x}) \\ &= \lim_{h \to 0} \frac{(f \cdot g)(\widehat{x} + h) - (f \cdot g)(\widehat{x})}{h} \\ &= \lim_{h \to 0} \frac{f(\widehat{x} + h) \cdot g(\widehat{x} + h) - f(\widehat{x}) \cdot g(\widehat{x})}{h} \\ &= \lim_{h \to 0} \frac{f(\widehat{x} + h) \cdot g(\widehat{x} + h) - f(\widehat{x}) \cdot g(\widehat{x} + h)}{h} + \frac{f(\widehat{x}) \cdot g(\widehat{x} + h) - f(\widehat{x}) \cdot g(\widehat{x})}{h} \\ &= \lim_{h \to 0} \frac{f(\widehat{x} + h) \cdot g(\widehat{x} + h) - f(\widehat{x}) \cdot g(\widehat{x} + h)}{h} + \lim_{h \to 0} \frac{f(\widehat{x}) \cdot g(\widehat{x} + h) - f(\widehat{x}) \cdot g(\widehat{x})}{h} \\ &= \lim_{h \to 0} \frac{f(\widehat{x} + h) - f(\widehat{x})}{h} \cdot \lim_{h \to 0} g(\widehat{x} + h) + f(\widehat{x}) \cdot \lim_{h \to 0} \frac{g(\widehat{x} + h) - g(\widehat{x})}{h} \\ &= f'(\widehat{x}) \cdot g(\widehat{x}) + f(\widehat{x}) \cdot g'(\widehat{x}) \end{split}$$

Dabei haben wir im letzten Schritt ausgenutzt, dass eine differenzierbare Funktion auch stetig ist. Daher gilt

$$\lim_{h \to 0} g(\widehat{x} + h) = g(\widehat{x}).$$

**Aufgabe 33**: Zeigen Sie: Ist die Funktion g im Punkt  $\widehat{x}$  differenzierbar und gilt  $g(\widehat{x}) \neq 0$ , so ist auch die Funktion  $\frac{1}{g} := \left(x \mapsto \frac{1}{g(x)}\right)$  im Punkt  $\widehat{x}$  differenzierbar und es gilt

$$\left(\frac{1}{g}\right)'(\widehat{x}) = -\frac{g'(\widehat{x})}{g(\widehat{x})^2}.$$

Folgern Sie aus diesem Ergebnis die Quotienten-Regel.

**Satz 66 (Ketten-Regel)** Die Funktionen  $f: \mathbb{R} \to \mathbb{R}$  sei differenzierbar im Punkt  $\widehat{x} \in \mathbb{R}$  und die Funktion  $g: \mathbb{R} \to \mathbb{R}$  sei differenzierbar im Punkt  $\widehat{y} = f(\widehat{x})$ . Dann ist auch die Funktion

$$g \circ f := (x \mapsto g(f(x)))$$

im Punkt  $\widehat{x}$  differenzierbar und es gilt

$$(g \circ f)'(\widehat{x}) = g'(f(\widehat{x})) \cdot f'(\widehat{x}).$$

**Beweis**: Aus der Differenzierbarkeit von f und g folgt, dass es Funktionen  $r_1(h)$  und  $r_2(h)$  gibt, so dass gilt:

1. 
$$f(\widehat{x}+h) = f(\widehat{x}) + h \cdot f'(\widehat{x}) + r_1(h)$$
 mit  $\lim_{h \to 0} \frac{r_1(h)}{h} = 0$ ,

2. 
$$g(\hat{y} + h) = g(\hat{y}) + h \cdot g'(\hat{y}) + r_2(h)$$
 mit  $\lim_{h \to 0} \frac{r_2(h)}{h} = 0$ .

Damit finden wir für den Differential-Quotienten der Funktion  $g \circ f$  im Punkt  $\widehat{x}$ :

$$\begin{split} &\frac{(g\circ f)(\widehat{x}+h)-(g\circ f)(\widehat{x})}{h}\\ &= \frac{g\big(f(\widehat{x}+h)\big)-g\big(f(\widehat{x})\big)}{h}\\ &= \frac{g\big(f(\widehat{x})+h\cdot f'(\widehat{x})+r_1(h)\big)-g\big(f(\widehat{x})\big)}{h}\\ &= \frac{g\big(\widehat{y}+h\cdot f'(\widehat{x})+r_1(h)\big)-g\big(\widehat{y}\big)}{h}\\ &= \frac{g(\widehat{y})+\big(h\cdot f'(\widehat{x})+r_1(h)\big)\cdot g'(\widehat{y})+r_2\big(h\cdot f'(\widehat{x})+r_1(h)\big)-g(\widehat{y})}{h}\\ &= f'(\widehat{x})\cdot g'(\widehat{y})+\frac{r_1(h)}{h}\cdot g'(\widehat{y})+\frac{r_2\big(h\cdot f'(\widehat{x})+r_1(h)\big)}{h} \end{split}$$

Wenn wir jetzt den Grenzwert  $h \to 0$  berechnen, dann müssen wir uns den letzten Term genauer ansehen. Es gilt

$$\lim_{h \to 0} \frac{r_2 \left( h \cdot f'(\widehat{x}) + r_1(h) \right)}{h} = \lim_{h \to 0} \frac{r_2 \left( h \cdot f'(\widehat{x}) + r_1(h) \right)}{h \cdot f'(\widehat{x}) + r_1(h)} \cdot \frac{h \cdot f'(\widehat{x}) + r_1(h)}{h}$$

$$= \lim_{h \to 0} \frac{r_2 \left( h \cdot f'(\widehat{x}) + r_1(h) \right)}{h \cdot f'(\widehat{x}) + r_1(h)} \cdot \lim_{h \to 0} \frac{h \cdot f'(\widehat{x}) + r_1(h)}{h}$$

$$= \lim_{h \to 0} \frac{r_2 \left( h \right)}{h} \cdot \left( \lim_{h \to 0} f'(\widehat{x}) + \frac{r_1(h)}{h} \right)$$

$$= 0 \cdot \left( f'(\widehat{x}) + 0 \right)$$

$$= 0$$

Damit sehen wir:

$$\lim_{h \to 0} \frac{(g \circ f)(\widehat{x} + h) - (g \circ f)(\widehat{x})}{h}$$

$$= \lim_{h \to 0} f'(\widehat{x}) \cdot g'(\widehat{y}) + \frac{r_1(h)}{h} \cdot g'(\widehat{y}) + \frac{r_2(h \cdot f'(\widehat{x}) + r_1(h))}{h}$$

$$= f'(\widehat{x}) \cdot g'(\widehat{y}) + \lim_{h \to 0} \frac{r_1(h)}{h} \cdot g'(\widehat{y}) + \lim_{h \to 0} \frac{r_2(h \cdot f'(\widehat{x}) + r_1(h))}{h}$$

$$= f'(\widehat{x}) \cdot g'(\widehat{y}) + 0 + 0$$

$$= f'(\widehat{x}) \cdot g'(\widehat{y}).$$

Der obige exakte Beweis ist recht umständlich. Wir geben daher zusätzlich eine Plausibilitätsbetrachtung. Nach Definition der Ableitung gilt

$$g'(\widehat{y}) = \lim_{h \to 0} \frac{g(\widehat{y} + h) - g(\widehat{y})}{h}$$

Für kleine Werte von h gilt daher ungefähr

$$g(\widehat{y} + h) \approx g(\widehat{y}) + g'(\widehat{y}) \cdot h.$$

Analog finden wir für die Funktion f

$$f(\widehat{x} + h) \approx f(\widehat{x}) + f'(\widehat{x}) \cdot h.$$

Damit finden wir für den Differential-Quotienten der Funktion  $g \circ f$  im Punkt  $\widehat{x}$ :

$$\frac{(g \circ f)(\widehat{x} + h) - (g \circ f)(\widehat{x})}{h} = \frac{g(f(\widehat{x} + h)) - g(f(\widehat{x}))}{h}$$

$$\approx \frac{g(f(\widehat{x}) + f'(\widehat{x}) \cdot h) - g(f(\widehat{x}))}{h}$$

$$\approx \frac{g(f(\widehat{x})) + g'(f(\widehat{x})) \cdot f'(\widehat{x}) \cdot h - g(f(\widehat{x}))}{h}$$

$$= \frac{g'(f(\widehat{x})) \cdot f'(\widehat{x}) \cdot h}{h}$$

$$= g'(f(\widehat{x})) \cdot f'(\widehat{x})$$

Die linke Seite der Gleichung stellt den Differential-Quotienten der Funktion  $g\circ f$  dar und muss daher für  $h\to 0$  gegen die Ableitung  $(g\circ f)(\widehat{x})$  konvergieren.

**Aufgabe 34**: Zeigen Sie, dass für alle natürlichen Zahlen n gilt:

$$\frac{dx^n}{dx} = n \cdot x^{n-1}.$$

Satz 67 (Ableitung von Potenzreihen) Ist die Funktion f als Potenzreihe definiert,

$$\sum_{n=0}^{\infty} a_n \cdot x^n$$

und ist R der Konvergenz-Radius dieser Potenzreihe, so ist f für alle  $x \in \mathbb{R}$  mit |x| < R differenzierbar und es gilt

$$f'(x) = \sum_{n=1}^{\infty} n \cdot a_n \cdot x^{n-1}.$$

**Bemerkung**: Der letzte Satz besagt, dass Potenzreihen innerhalb ihres Konvergenz-Radius gliedweise differenziert werden können. Ein Beweis dieses Satzes ist mit den uns zur Verfügung stehenden Hilfsmitteln nicht möglich, da uns der Begriff der *gleichmäßigen Konvergenz* einer Funktionen-Folge fehlt und wir nicht die Zeit haben, diesen Begriff einzuführen. Um Ihnen zu zeigen, dass es an dieser Stelle durchaus Probleme geben könnte, präsentiere ich ein Beispiel, welches zeigt, dass Grenzwertprozesse im Allgemeinen nicht ohne weitere Voraussetzungen vertauscht werden dürfen. Dazu definieren wir für alle  $n \in \mathbb{N}^*$  die Funktion  $f_n : \mathbb{R} \to \mathbb{R}$  als

$$f_n(x) := \frac{\sin(n \cdot x)}{n}.$$

Aus der Tatsache, dass für alle  $x \in \mathbb{R}$  die Ungleichung  $|\sin(x)| \leq 1$  gilt, folgt

$$f(x) := \lim_{n \to \infty} f_n(x) = \lim_{n \to \infty} \frac{\sin(n \cdot x)}{n} = 0.$$

Wir definieren für alle  $n \in \mathbb{N}^*$  die Funktion  $g_n(x)$  als die Ableitung der Funktion  $f_n(x)$ :

$$g_n(x) := f'_n(x) = \cos(n \cdot x).$$

Weiter definieren wir

$$g(x) := f'(x).$$

Wenn wir den Limes  $n \to \infty$  mit dem Prozess des Differenzieren vertauschen dürften, dann würden wir erwarten, dass

$$g(x) = \frac{\mathrm{d}}{\mathrm{d}x} \lim_{n \to \infty} \frac{\sin(n \cdot x)}{n}$$
$$= \lim_{n \to \infty} \frac{\mathrm{d}}{\mathrm{d}x} \frac{\sin(n \cdot x)}{n}$$
$$= \lim_{n \to \infty} \cos(n \cdot x)$$

gelten würde. Für x = 0 gilt aber

$$\lim_{n \to \infty} \cos(n \cdot 0) = \cos(0) = 1 \neq 0 = g(0).$$

Dieses Beispiel zeigt, dass Grenzwertprozesse im Allgemeinen nicht vertauscht werden dürfen.

Beispiele: Wir berechnen als nächstes die Ableitung einiger wichtiger Funktionen.

1. Die Exponential-Funktion  $\exp(x)$  ist definiert als

$$\exp(x) = \sum_{n=0}^{\infty} \frac{x^n}{n!}.$$

Nach dem letzten Satz gilt für die Ableitung der Exponential-Funktion

$$\frac{\mathrm{d}}{\mathrm{d}x} \exp(x) = \sum_{n=1}^{\infty} \frac{n}{n!} \cdot x^{n-1} = \sum_{n=1}^{\infty} \frac{1}{(n-1)!} \cdot x^{n-1} = \sum_{n=0}^{\infty} \frac{1}{n!} \cdot x^n = \exp(x),$$

die Ableitung der Exponential-Funktion ergibt also wieder die Exponential-Funktion!

2. Um den natürlichen Logarithmus ableiten zu können, betrachten wir die Gleichung

$$\ln(\exp(x)) = x.$$

Differenzieren wir beide Seiten dieser Gleichung nach x, so erhalten wir nach der Ketten-Regel

$$\ln'(\exp(x)) \cdot \exp(x) = 1$$
,

 $\Diamond$ 

denn die Ableitung der Exponential-Funktion ergibt ja wieder die Exponential-Funktion. Setzen wir hier  $y := \exp(x)$ , so haben wir

$$\ln'(y) \cdot y = 1$$
, also  $\frac{\mathrm{d}}{\mathrm{d}y} \ln(y) = \frac{1}{y}$ .

Bemerkung: An dieser Stelle haben wir nicht gezeigt, dass der natürliche Logarithmus differenzierbar ist. Wir haben lediglich gezeigt, dass unter der Annahme, dass der natürliche Logarithmus differenzierbar ist, die Gleichung

$$\frac{\mathrm{d}}{\mathrm{d}x}\ln(x) = \frac{1}{x}$$

gefolgert werden kann.

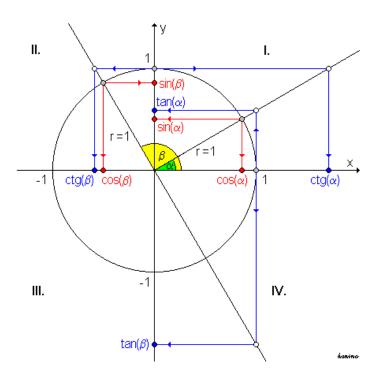


Abbildung 5.1: Die Winkel-Funktionen am Einheitskreis.

3. Um die Ableitung der Funktion  $x\mapsto\sin(x)$  berechnen zu können, betrachten wir in Abbildung 5.1 auf Seite 86 die Definition von Sinus und Tangens am Einheitskreis. Aus der Definition von Sinus und Tangens folgt die Ungleichung

$$\sin(\varphi) \le \varphi \le \tan(\varphi) = \frac{\sin(\varphi)}{\cos(\varphi)}$$

Division dieser Gleichung durch  $\sin(\varphi)$  liefert

$$1 \le \frac{\varphi}{\sin(\varphi)} \le \frac{1}{\cos(\varphi)}$$

Wir bilden den Kehrwert und erhalten

$$1 \ge \frac{\sin(\varphi)}{\varphi} \ge \cos(\varphi)$$

Nun bilden wir den Grenzwert für  $\varphi \to 0$ :

$$1 \ge \lim_{\varphi \to 0} \frac{\sin(\varphi)}{\varphi} \ge \lim_{\varphi \to 0} \cos(\varphi)$$

Wegen  $\lim_{\varphi \to 0} \cos(\varphi) = \cos(0) = 1$  folgt daraus

$$\lim_{\varphi \to 0} \frac{\sin(\varphi)}{\varphi} = 1.$$

Aus dem Geometrie-Unterricht ist das Additionstheorem für den Sinus bekannt:

$$\sin(x+y) = \sin(x) \cdot \cos(y) + \cos(x) \cdot \sin(y).$$

Daraus folgt einerseits

$$\sin(x) = \sin\left(\frac{x+y}{2} + \frac{x-y}{2}\right)$$
$$= \sin\left(\frac{x+y}{2}\right) \cdot \cos\left(\frac{x-y}{2}\right) + \cos\left(\frac{x+y}{2}\right) \cdot \sin\left(\frac{x-y}{2}\right)$$

und andererseits gilt wegen  $\sin(-x) = -\sin(x)$  und  $\cos(-x) = \cos(x)$ 

$$\sin(y) = \sin\left(\frac{x+y}{2} - \frac{x-y}{2}\right)$$
$$= \sin\left(\frac{x+y}{2}\right) \cdot \cos\left(\frac{x-y}{2}\right) - \cos\left(\frac{x+y}{2}\right) \cdot \sin\left(\frac{x-y}{2}\right).$$

Subtrahieren wir diese Gleichungen voneinander, so erhalten wir

$$\sin(x) - \sin(y) = 2 \cdot \cos\left(\frac{x+y}{2}\right) \cdot \sin\left(\frac{x-y}{2}\right).$$

Damit können wir die Ableitung des Sinus ausrechnen:

$$\lim_{h \to 0} \frac{\sin(x+h) - \sin(x)}{h} = \lim_{h \to 0} \frac{2 \cdot \cos\left(\frac{x+h+x}{2}\right) \cdot \sin\left(\frac{x+h-x}{2}\right)}{h}$$

$$= \lim_{h \to 0} \cos\left(x + \frac{h}{2}\right) \cdot \lim_{h \to 0} \frac{\sin\left(\frac{h}{2}\right)}{\frac{h}{2}}$$

$$= \cos(x) \cdot \lim_{h \to 0} \frac{\sin(h)}{h}$$

$$= \cos(x)$$

Damit haben wir gezeigt, dass gilt:

$$\frac{\mathrm{d}}{\mathrm{d}x}\sin(x) = \cos(x).$$

4. Die Ableitung des Kosinus könnte in analoger Weise berechnet werden, es ist aber einfacher, wenn wir von den Gleichungen

$$cos(x) = sin(\frac{\pi}{2} - x)$$
 und  $cos(\frac{\pi}{2} - x) = sin(x)$ 

ausgehen und die Ketten-Regel verwenden. Es ergibt sich

$$\begin{array}{rcl} \frac{\mathrm{d}}{\mathrm{d}x}\cos(x) & = & \frac{\mathrm{d}}{\mathrm{d}x}\sin\left(\frac{\pi}{2}-x\right) \\ & = & \cos\left(\frac{\pi}{2}-x\right)\cdot\frac{\mathrm{d}}{\mathrm{d}x}\left(\frac{\pi}{2}-x\right) \quad \text{nach der Ketten-Regel} \\ & = & \sin(x)\cdot(-1) \\ & = & -\sin(x). \end{array}$$

5. Jetzt kann die Ableitung der Tangens-Funktion über die Quotienten-Regel berechnet werden:

$$\frac{d}{dx}\tan(x) = \frac{d}{dx}\left(\frac{\sin(x)}{\cos(x)}\right)$$

$$= \frac{\left(\frac{d}{dx}\sin(x)\right)\cdot\cos(x) - \sin(x)\cdot\left(\frac{d}{dx}\cos(x)\right)}{\cos^2(x)}$$

$$= \frac{\cos(x)\cdot\cos(x) - \sin(x)\cdot\left(-\sin(x)\right)}{\cos^2(x)}$$

$$= \frac{\cos^2(x) + \sin^2(x)}{\cos^2(x)}$$

$$= \frac{1}{\cos^2(x)} = \sec^2(x)$$

6. Die Ableitung der Arcus-Tangens-Funktion kann nun mit demselben Trick berechnet werden, den wir schon bei der Berechnung der Ableitung des Logarithmus benutzt haben. Wir gehen diesmal von der Gleichungen

$$\arctan(\tan(x)) = x$$

aus und differenzieren beide Seiten dieser Gleichung. Nach der Ketten-Regel erhalten wir

$$\arctan'(\tan(x)) \cdot \frac{\mathrm{d}}{\mathrm{d}x} \tan(x) = 1.$$

Setzen wir hier die Ableitung für die Tangens-Funktion ein, so haben wir

$$\frac{\mathrm{d}}{\mathrm{d}x}\arctan(\tan(x))\cdot\frac{1}{\cos^2(x)}=1.$$

Multiplikation mit  $\cos^2(x)$  ergibt

$$\frac{\mathrm{d}}{\mathrm{d}x}\arctan(\tan(x)) = \cos^2(x).$$

Den in dieser Gleichung auftretenden Term  $\cos^2(x)$  müssen wir durch einen Term ausdrücken, in dem nur  $\tan(x)$  auftritt. Dazu betrachten wir die Definition der Tangens-Funktion:

 $\Diamond$ 

$$\tan^{2}(x) = \frac{\sin^{2}(x)}{\cos^{2}(x)}$$

$$\Leftrightarrow \tan^{2}(x) = \frac{1 - \cos^{2}(x)}{\cos^{2}(x)} \quad \text{wegen } \sin^{2}(x) + \cos^{2}(x) = 1$$

$$\Leftrightarrow \cos^{2}(x) \cdot \tan^{2}(x) = 1 - \cos^{2}(x)$$

$$\Leftrightarrow \cos^{2}(x) \cdot \tan^{2}(x) + \cos^{2}(x) = 1$$

$$\Leftrightarrow \cos^{2}(x) \cdot (\tan^{2}(x) + 1) = 1$$

$$\Leftrightarrow \cos^{2}(x) \cdot (\tan^{2}(x) + 1) = 1$$

$$\Leftrightarrow \cos^{2}(x) \cdot (\tan^{2}(x) + 1) = 1$$

Damit können wir also schreiben

$$\arctan'(\tan(x)) = \frac{1}{\tan^2(x) + 1}.$$

Setzen wir jetzt  $y = \tan(x)$ , so erhalten wir

$$\frac{\mathrm{d}}{\mathrm{d}y}\arctan(y) = \frac{1}{y^2 + 1}.$$

### Aufgabe 35:

(a) Zeigen Sie

$$\frac{\mathrm{d}}{\mathrm{d}x}\arcsin(x) = \frac{1}{\sqrt{1-x^2}}.$$

(b) Zeigen Sie

$$\frac{\mathrm{d}}{\mathrm{d}x}\arccos(x) = -\frac{1}{\sqrt{1-x^2}}.$$

**Aufgabe 36**: Der Sekans eines Winkels  $\varphi$  ist als

$$\sec(\varphi) := \frac{1}{\cos(\varphi)}$$

definiert. Entsprechend ist der Kosekans eines Winkels  $\varphi$  als

$$\csc(\varphi) := \frac{1}{\sin(\varphi)}$$

definiert. Beweisen Sie die Gleichungen

$$\frac{\mathrm{d}}{\mathrm{d}x}\sec(x) = \sec(x)\cdot\tan(x) \quad \text{ und } \quad \frac{\mathrm{d}}{\mathrm{d}x}\csc(x) = -\csc(x)\cdot\cot(x).$$

#### Aufgabe 37:

(a) Berechnen Sie die Ableitung der Funktion  $x \mapsto \sqrt{x}$ .

Hinweis: Verwenden Sie die Produkt-Regel oder die Ketten-Regel.

(b) Es sei  $p \in \mathbb{Z}$  und  $q \in \mathbb{N}^*$ . überlegen Sie, was die Ableitung der Funktion

$$x\mapsto x^{\frac{p}{q}}$$

ist und beweisen Sie Ihre Behauptung.

**Hinweis**: Betrachten Sie zunächst den Fall p = 1.

 $\Diamond$ 

## 5.2 Mittelwert-Sätze

### Definition 68 (lokales Maximum)

Eine Funktion  $f: \mathbb{R} \to \mathbb{R}$  hat im Punkt  $\bar{x} \in \mathbb{R}$  genau dann ein *lokales Maximum*, wenn

$$\exists \varepsilon \in \mathbb{R}_{+}^{*} : \forall x \in \mathbb{R} : (|x - \bar{x}| < \varepsilon \to f(x) \le f(\bar{x}))$$

gilt.

Die in der obigen Definition auftretende Menge von Zahlen, deren Abstand von  $\bar{x}$  kleiner ist als  $\varepsilon$ , bezeichnen wir auch als  $\varepsilon$ -Umgebung des Punktes  $\bar{x}$ , die  $\varepsilon$ -Umgebung des Punktes x ist also die Menge

$$U_{\varepsilon}(\bar{x}) := \{ x \in \mathbb{R} \mid |x - \bar{x}| < \varepsilon \}.$$

Der Begriff des lokalen Maximums steht im Kontrast zu dem Begriff eines *globalen Maximums*. Eine Funktion  $f:D\to\mathbb{R}$  hat in einem Punkt  $\bar{x}\in D$  ein globales Maximum, wenn

$$\forall x \in D : f(x) \le f(\bar{x})$$

gilt. Natürlich ist jedes globale Maximum auch ein lokales Maximum, aber die Umkehrung gilt im allgemeinen nicht. Der nächste Satz liefert ein notwendiges Kriterium für das Auftreten eines lokalen Maximums.

#### Satz 69 (Pierre de Fermat, 160?-1665) Falls

- 1. die Funktion  $f: \mathbb{R} \to \mathbb{R}$  im Punkt  $\bar{x}$  ein lokales Maximum besitzt und
- 2. die Funktion f im Punkt  $\bar{x}$  differenzierbar ist,

so gilt

$$\frac{\mathrm{d}f}{\mathrm{d}x}(\bar{x}) = 0.$$

**Beweis**: Wir betrachten zunächst die Folge  $(\bar{x} + \frac{1}{n})_{n \in \mathbb{N}^*}$ . Da f im Punkt  $\bar{x}$  ein lokales Maximum besitzt, finden wir ein  $\varepsilon$ , so dass

$$\forall x \in \mathbb{R} : (|x - \bar{x}| < \varepsilon \to f(x) \le f(\bar{x}))$$

gilt. Falls n eine natürliche Zahl ist, für die  $n>\frac{1}{\varepsilon}$  gilt, so liegt  $\bar x+\frac{1}{n}$  in der  $\varepsilon$ -Umgebung von  $\bar x$ . Daher gilt für alle  $n>\frac{1}{\varepsilon}$ 

$$f(\bar{x} + \frac{1}{n}) \leq f(\bar{x}).$$

Damit gilt für den Differential-Quotienten

$$\frac{f\left(\bar{x} + \frac{1}{n}\right) - f(\bar{x})}{\bar{x} + \frac{1}{n} - \bar{x}} = n \cdot \left(f\left(\bar{x} + \frac{1}{n}\right) - f(\bar{x})\right) \le 0.$$

Da wir vorausgesetzt haben, dass die Funktion f im Punkt  $\bar{x}$  differenzierbar ist, gilt

$$\frac{\mathrm{d}f}{\mathrm{d}x}(\bar{x}) = \lim_{n \to \infty} \frac{f\left(\bar{x} + \frac{1}{n}\right) - f(\bar{x})}{\bar{x} + \frac{1}{n} - \bar{x}} \le 0.$$

Wir betrachten nun die Folge  $(\bar{x} - \frac{1}{n})_{n \in \mathbb{N}^*}$ . Wieder sei  $\varepsilon$  so gewählt, dass

$$\forall x \in \mathbb{R} : (|x - \bar{x}| < \varepsilon \to f(x) \le f(\bar{x}))$$

gilt. Wenn  $n\in\mathbb{N}^*$  ist und  $n>\frac{1}{\varepsilon}$  gilt, liegt daher  $\bar{x}-\frac{1}{n}$  in der  $\varepsilon$ -Umgebung von  $\bar{x}$ . Daher gilt für alle

 $\Diamond$ 

natürlichen Zahlen n mit  $n > \frac{1}{\varepsilon}$ 

$$f(\bar{x} - \frac{1}{n}) \le f(\bar{x}).$$

Damit gilt für den Differential-Quotienten

$$\frac{f\left(\bar{x} + \frac{1}{n}\right) - f(\bar{x})}{\bar{x} - \frac{1}{n} - \bar{x}} = -n \cdot \left(f\left(\bar{x} - \frac{1}{n}\right) - f(\bar{x})\right) \ge 0.$$

Da wir vorausgesetzt haben, dass die Funktion f im Punkt  $\bar{x}$  differenzierbar ist, gilt

$$\frac{\mathrm{d}f}{\mathrm{d}x}(\bar{x}) = \lim_{n \to \infty} \frac{f(\bar{x} - \frac{1}{n}) - f(\bar{x})}{\bar{x} - \frac{1}{n} - \bar{x}} \ge 0.$$

Wir haben jetzt also die beiden Ungleichungen

$$\frac{\mathrm{d}f}{\mathrm{d}x}(\bar{x}) \le 0$$
 und  $\frac{\mathrm{d}f}{\mathrm{d}x}(\bar{x}) \ge 0$ 

gezeigt. Daraus folgt sofort  $\frac{\mathrm{d}f}{\mathrm{d}x}(\bar{x})=0.$ 

**Bemerkung**: Der Satz bleibt richtig, wenn die Voraussetzung  $f:\mathbb{R}\to\mathbb{R}$  zu  $f:D\to\mathbb{R}$  abgeschwächt wird, wenn also f nicht mehr auf ganz  $\mathbb{R}$  definiert ist. Dann muss allerdings zusätzlich sichergestellt werden, dass es eine  $\varepsilon$ -Umgebung von  $\bar{x}$  gibt, die vollständig in dem Definitions-Bereich D liegt, es muss also ein  $\varepsilon>0$  geben, so dass  $U_{\varepsilon}(\bar{x})\subseteq D$  gilt.

Aufgabe 38: Überlegen Sie, warum diese zusätzliche Bedingung notwendig ist.

**Bemerkung**: Analog zur Definition eines lokalen Maximums kann auch der Begriff eines *lokalen Minimums* definiert werden. Auch in einem lokalen Minimum  $\bar{x}$  einer Funktion f hat die Ableitung den Wert 0. Um dies einzusehen, können wir die Funktion  $g:=\left(x\mapsto -f(x)\right)$  betrachten, denn die Funktion hat genau dann an der Stelle  $\bar{x}$  ein lokales Maximum, wenn die Funktion f dort ein lokales Minimum hat.

**Satz 70** Ist die Funktion  $f:[a,b]\to\mathbb{R}$  stetig, so nimmt f auf dem Intervall [a,b] sowohl das Maximum als auch das Minimum an, es gibt also Punkte  $x_{\textit{min}}$  und  $x_{\textit{max}}$ , so dass gilt

$$\forall x \in [a,b]: f(x) \le f(x_{\max}) \quad \text{ und } \quad \forall x \in [a,b]: f(x) \ge f(x_{\min}).$$

Die wesentliche Idee des Beweises besteht darin zu zeigen, dass die Menge  $\{f(x) \mid x \in [a,b]\}$  ein Supremum hat. Im nächsten Schritt wird dann gezeigt, dass dieses Supremum auch tatsächlich als Funktionswert auftritt. Wir müssen darauf verzichten, den Beweis auszuführen, denn dazu müssten wir zunächst den Begriff einer *Teilfolge* einführen und dann den Satz von Bolzano-Weierstraß beweisen. Das würde uns zu lange aufhalten.

**Satz 71 (Michel Rolle, 1652 – 1719)** Ist die Funktion  $f:[a,b]\to\mathbb{R}$  differenzierbar und gilt außerdem f(a)=f(b), dann gibt es ein  $\bar{x}\in(a,b)$ , so dass gilt

$$\frac{\mathrm{d}f}{\mathrm{d}x}(\bar{x}) = 0.$$

Beweis: Es gibt zwei Fälle:

1. Die Funktion f ist konstant, für alle  $x \in [a,b]$  gilt also f(x) = f(a). Da die Ableitung einer konstanten Funktion den Wert 0 hat, gilt dann offenbar sogar für alle  $x \in [a,b]$ 

— 91/<del>182</del> —

$$\frac{\mathrm{d}f}{\mathrm{d}x}(x) = 0.$$

2. Da die Funktion f differenzierbar ist, ist sie auch stetig und nimmt daher sowohl ein Minimum als auch ein Maximum in dem Intervall [a,b] an. Es gibt also  $x_{min}$  und  $x_{max}$  mit

$$\forall x \in [a,b]: f(x) \le f(x_{\max}) \quad \text{ und } \quad \forall x \in [a,b]: f(x) \ge f(x_{\min}).$$

Da wir jetzt voraussetzen können, dass die Funktion nicht konstant ist, und da weiterhin f(a) = f(b) gilt, muss

$$f(x_{\min}) < f(a)$$
 oder  $f(x_{\max}) > f(a)$ 

gelten. Daraus folgt

$$x_{min} \notin \{a, b\}$$
 oder  $x_{max} \notin \{a, b\}$ .

Damit hat die Funktion dann in  $x_{min}$  ein lokales Minimum oder in  $x_{max}$  ein lokales Maximum (oder beides) und nach dem Satz von Fermat folgt

$$\frac{\mathrm{d}f}{\mathrm{d}x}(x_{\min}) = 0 \quad \text{oder} \quad \frac{\mathrm{d}f}{\mathrm{d}x}(x_{\max}) = 0.$$

Aus dem Satz von Rolle folgern wir später zwei wichtige Mittelwert-Sätze und den Satz von L'Hôpital.

Aufgabe 39: Eine Konservendose ist ein Zylinder, dessen Volumen V durch die Formel

$$V = \pi \cdot r^2 \cdot h$$

gegeben ist. Hier bezeichnet r den Radius des Kreises der Grundfläche der Konservendose, während h die Höhe der Konservendose bezeichnet. Die Oberfläche der Konservendose ist durch die Formel

$$O = 2 \cdot \pi \cdot r^2 + 2 \cdot \pi \cdot r \cdot h$$

gegeben. Nehmen Sie an, dass Sie eine Konservendose so konstruieren sollen, dass die Oberfläche dieser Konservendose bei einem fest vorgegebenem Volumen  $V_0$  minimal wird. Berechnen Sie das Verhältnis  $\frac{h}{r}$  der Höhe h zum Radius r für eine solche Dose.

**Aufgabe 40**: Berechnen Sie das Maximum und das Minimum der Funktion  $x\mapsto x-|x^2+2\cdot x-3|$  in dem Intervall [-4,2].

Satz 72 (Mittelwert-Satz der Differential-Rechnung, Augustin-Louis Cauchy, 1789–1857) Ist die Funktion  $f:[a,b] \to \mathbb{R}$  für alle  $x \in [a,b]$  differenzierbar, so gilt:

$$\exists c \in (a,b) : \frac{\mathrm{d}f}{\mathrm{d}x}(c) = \frac{f(b) - f(a)}{b - a}.$$

**Beweis**: Wir definieren die Funktion  $g:[a,b] \to \mathbb{R}$  durch

$$g(x) := f(x) - f(a) - \frac{f(b) - f(a)}{b - a} \cdot (x - a).$$

Da die Funktion f nach Voraussetzung differenzierbar ist, ist auch die Funktion g differenzierbar und es gilt

$$g(a) = f(a) - f(a) - \frac{f(b) - f(a)}{b - a} \cdot (a - a) = 0.$$

und

$$g(b) = f(b) - f(a) - \frac{f(b) - f(a)}{b - a} \cdot (b - a) = f(b) - f(a) - (f(b) - f(a)) = 0.$$

Damit gilt g(a) = g(b) und folglich erfüllt die Funktion g die Voraussetzung des Satzes von Rolle. Also gibt es ein  $c \in (a,b)$ , so dass

$$\frac{\mathrm{d}g}{\mathrm{d}x}(c) = 0$$

gilt. Setzen wir hier die Definition von g ein, so haben wir

$$\frac{\mathrm{d}g}{\mathrm{d}x}(c) = \frac{\mathrm{d}f}{\mathrm{d}x}(c) - \frac{f(b) - f(a)}{b - a} = 0$$

$$\Rightarrow \frac{\mathrm{d}f}{\mathrm{d}x}(c) = \frac{f(b) - f(a)}{b - a}$$

Abbildung 5.2 zeigt die geometrische Bedeutung des Mittelwert-Satzes: Es gibt einen Punkt c, so dass die Tangente an die Funktion f im Punkt  $\langle c, f(c) \rangle$  die dieselbe Steigung hat wie die Sekante, die durch die Punkte  $\langle a, f(a) \rangle$  und  $\langle b, f(b) \rangle$  geht.

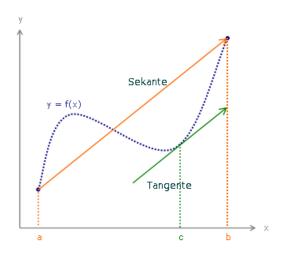


Abbildung 5.2: Geometrische Bedeutung des Mittelwert-Satzes.

**Satz 73 (Erweiterter Mittelwert-Satz)** Sind die Funktion  $f,g:[a,b]\to\mathbb{R}$  für alle  $x\in[a,b]$  differenzierbar und gilt  $g'(x)\neq 0$  für alle  $x\in[a,b]$ , so gilt:

$$\exists c \in (a,b) : \frac{f'(c)}{g'(c)} = \frac{f(b) - f(a)}{g(b) - g(a)}.$$

**Bemerkung**: Auf den ersten Blick mag es verwundern, dass nicht explizit  $g(a) \neq g(b)$  gefordert wird. Dies folgt aber sofort aus der Bedingung  $\forall x \in [a,b] : g'(x) \neq 0$  und dem Satz von Rolle.

Aufgabe 41: Beweisen Sie den erweiterten Mittelwert-Satz. Betrachten Sie dazu die Funktion

$$h(x) := \alpha \cdot f(x) - \beta \cdot g(x)$$

und bestimmen Sie  $\alpha$  und  $\beta$  so, dass Sie auf die Funktion h den Satz von Rolle anwenden können.  $\diamond$ 

Der folgende Satz ist für die praktische Berechnung von Grenzwerten unentbehrlich. Wir haben diesen Satz bereits mehrfach in der Vorlesung "Algorithmen und Komplexität" zur Berechnung von Grenzwerten benutzt.

#### Satz 74 (Guillaume François Antoine, Marquis de L'Hôpital, 1661–1704)

Die Funktionen  $f,g:(a,b)\to\mathbb{R}$  seien differenzierbar, es sei  $c\in(a,b)$  und es gelte

- 1. f(c) = g(c) = 0 und
- 2.  $\forall x \in (a, b) : q'(x) \neq 0$ .

Dann gilt

$$\lim_{x \to c} \frac{f(x)}{g(x)} = \frac{f'(c)}{g'(c)}.$$

**Beweis**: Da die Funktion f und g im Punkt c differenzierbar sind, gibt es Funktionen  $r_1(h)$  und  $r_2(h)$ , so dass gilt:

1. 
$$f(c+h) = f(c) + h \cdot f'(c) + r_1(h)$$
 mit  $\lim_{h \to 0} \frac{r_1(h)}{h} = 0$ .

2. 
$$g(c+h) = g(c) + h \cdot g'(c) + r_2(h)$$
 mit  $\lim_{h \to 0} \frac{r_2(h)}{h} = 0$ .

Wir haben die folgende Kette von Gleichungen:

$$\lim_{h \to 0} \frac{f(c+h)}{g(c+h)} = \lim_{h \to 0} \frac{f(c) + h \cdot f'(c) + r_1(h)}{g(c) + h \cdot g'(c) + r_2(h)} = \lim_{h \to 0} \frac{h \cdot f'(c) + r_1(h)}{h \cdot g'(c) + r_2(h)}$$

$$= \lim_{h \to 0} \frac{f'(c) + \frac{r_1(h)}{h}}{g'(c) + \frac{r_2(h)}{h}} = \frac{f'(c) + \lim_{h \to 0} \frac{r_1(h)}{h}}{g'(c) + \lim_{h \to 0} \frac{r_2(h)}{h}}$$

$$= \frac{f'(c)}{g'(c)}$$

**Beispiel**: Mit dem Satz von L'Hôpital können wir nun den Grenzwert  $\lim_{x\to 0} \frac{\sin(x)}{x}$  noch einmal berechnen:

$$\lim_{x \to 0} \frac{\sin(x)}{x} = \lim_{x \to 0} \frac{\cos(x)}{1} = \cos(0) = 1.$$

Sie sollten allerdings sehen, dass wir bei dieser Berechnung ausgenutzt haben, dass

$$\frac{\mathrm{d}}{\mathrm{d}x}\sin(x) = \cos(x)$$

gilt und diese Gleichung konnten wir nur beweisen, weil wir vorher gezeigt hatten, dass

$$\lim_{x \to 0} \frac{\sin(x)}{x} = 1$$

ist.

**Bemerkung**: Der Satz von L'Hôpital behält seine Gültigkeit, wenn x gegen Unendlich strebt. Sind  $f,g:\mathbb{R}\to\mathbb{R}$  differenzierbare Funktionen, so dass der Grenzwert

$$\lim_{x \to \infty} \frac{f'(x)}{g'(x)}$$

existiert, und gilt entweder

$$\left(\lim_{x\to\infty}f(x)=0 \ \land \ \lim_{x\to\infty}g(x)=0\right) \quad \lor \quad \left(\lim_{x\to\infty}f(x)=\infty \ \land \ \lim_{x\to\infty}g(x)=\infty\right)$$

so folgt

$$\lim_{x \to \infty} \frac{f(x)}{g(x)} = \lim_{x \to \infty} \frac{f'(x)}{g'(x)}.$$

Wir geben ein Beispiel. Es gilt

$$\lim_{x \to \infty} \frac{x}{\exp(x)} = \lim_{x \to \infty} \frac{1}{\exp(x)} = 0.$$

 $\Diamond$ 

 $\Diamond$ 

Wir haben es zwar nicht bewiesen, aber es kann gezeigt werden, dass der Satz von L'Hôpital sich auch iteriert anwenden lässt. Beispielsweise gilt

$$\lim_{x \to \infty} \frac{x^2}{\exp(x)} = \lim_{x \to \infty} \frac{2 \cdot x}{\exp(x)} = \lim_{x \to \infty} \frac{2}{\exp(x)} = 0.$$

**Aufgabe 42**: Berechnen Sie den Grenzwert  $\lim_{x\to 0} \frac{\cos(x)-1}{x^2}$ .

#### **Definition 75 (Schnelleres Wachstum)**

Wir sagen, dass die Funktion  $x \mapsto f(x)$  für  $x \to \infty$  schneller als die Funktion  $x \mapsto g(x)$  wächst, falls

$$\lim_{x \to \infty} \frac{g(x)}{f(x)} = 0 \quad \text{gilt.}$$

**Aufgabe 43**: Zeigen Sie, dass für alle natürlichen Zahlen n gilt:

$$\lim_{x \to \infty} \frac{x^n}{\exp(x)} = 0.$$

Damit sehen wir, dass die Exponential-Funktion schneller wächst als jede Potenz.

#### Aufgabe 44:

- (a) Zeigen Sie, dass die Funktion  $x\mapsto \exp\bigl(\ln(x)\cdot\ln(x)\bigr)$  für alle  $n\in\mathbb{N}$  schneller als die Funktion  $x\mapsto x^n$  wächst.
- (b) Zeigen Sie, dass die Funktion  $x\mapsto \exp(x)$  schneller wächst als die Funktion  $x\mapsto \exp\bigl(\ln(x)\cdot\ln(x)\bigr)$ .

Aufgabe 45: Berechnen Sie die folgenden Grenzwerte:

(a)  $\lim_{x \to 0} x \cdot \ln(x)$ ,

(b) 
$$\lim_{x \to \infty} \sqrt{x + \sqrt{x}} - \sqrt{x}$$
.

## 5.3 Monotonie und Konvexität

Im Folgenden bezeichnet D entweder ein Intervall der Form

ein unbeschränktes Intervall der Form

$$[a, \infty)$$
,  $(a, \infty)$ ,  $(-\infty, b]$ ,  $(-\infty, b)$ 

oder die Menge  $\mathbb{R}$  der reellen Zahlen.

**Definition 76 (monoton)** Eine Funktion  $f: D \to \mathbb{R}$  ist *monoton steigend* g.d.w.

$$\forall x, y \in D : (x < y \to f(x) \le f(y))$$

gilt. Die Funktion f ist streng monoton steigend, wenn die schärfere Bedingung

$$\forall x, y \in D : (x < y \to f(x) < f(y))$$

erfüllt ist. Weiter heißt f monoton fallend, wenn

$$\forall x, y \in D : (x < y \to f(x) \ge f(y))$$

gilt. Analog ist f streng monoton fallend, falls die folgende Bedingung gilt:

$$\forall x, y \in D : (x < y \to f(x) > f(y)).$$

**Satz 77** Eine differenzierbare Funktion  $f:D\to\mathbb{R}$  ist genau dann monoton steigend, wenn gilt:

$$\forall x \in D: f'(x) \ge 0.$$

**Beweis**: Da es sich bei diesem Beweis um eine "genau-dann-wenn"-Aussage handelt, spalten wir den Beweis in zwei Teile auf.

" $\Rightarrow$ ": Wir nehmen zunächst an, dass f monoton steigend ist und zeigen, dass dann  $f'(x) \ge 0$  gilt. Die Ableitung ist definiert als der Grenzwert

$$f'(x) = \lim_{h \to 0} \frac{f(x+h) - f(x)}{h}.$$

Wir zeigen, dass der Differential-Quotient

$$\frac{f(x+h) - f(x)}{h}$$

für alle h>0 größer oder gleich 0 ist. Aus h>0 folgt x+h>x. Aus der Monotonie von f folgt dann, dass  $f(x+h)\geq f(x)$  ist. Also gilt  $f(x+h)-f(x)\geq 0$  und daraus folgt

$$\frac{f(x+h) - f(x)}{h} \ge 0.$$

Da die Ableitung f'(x) als Grenzwert des Differential-Quotienten für h gegen 0 definiert ist, muss  $f'(x) \ge 0$  gelten.

" $\Leftarrow$ ": Wir nehmen nun an, dass für alle  $x \in D$  die Ungleichung  $f'(x) \ge 0$  gilt und zeigen, dass f dann monoton steigend ist. Diesen Beweis führen wir indirekt. Wir nehmen an, es gäbe  $x, y \in D$  mit

$$x < y$$
 aber  $f(x) > f(y)$ .

Nach dem Mittelwert-Satz der Differential-Rechnung gibt es dann ein  $z \in (x, y)$ , so dass

$$f'(z) = \frac{f(y) - f(x)}{y - x}$$

gilt. Aus x < y folgt y - x > 0 und aus f(x) > f(y) folgt f(y) - f(x) < 0. Damit hätten wir dann aber f'(z) < 0 im Widerspruch zur Voraussetzung.

In Analogie zum letzten Satz kann gezeigt werden, dass eine differenzierbare Funktion  $f:D\to\mathbb{R}$  genau dann monoton fallend ist, wenn für alle  $x\in D$  die Ungleichung  $f'(x)\leq 0$  gilt.

**Aufgabe 46**: Die Funktion  $f:D\to\mathbb{R}$  sei differenzierbar und es gelte

$$\forall x \in D : f'(x) > 0.$$

Zeigen Sie, dass die Funktion f dann streng monoton steigend ist.

**Bemerkung:** Die Funktion  $x\mapsto x^3$  ist streng monoton steigend, aber an der Stelle x=0 verschwindet die Ableitung dieser Funktion. Dies zeigt, dass sich die Aussage des letzten Satzes nicht umkehren lässt.

#### **Definition 78 (strenges lokales Minimum)**

Eine Funktion  $f: \mathbb{R} \to \mathbb{R}$  hat im Punkt  $\bar{x} \in \mathbb{R}$  ein strenges lokales Minimum, wenn gilt:

$$\exists \varepsilon \in \mathbb{R}_+^* : \forall x \in \mathbb{R} : (|x - \bar{x}| < \varepsilon \land \ x \neq \bar{x} \to f(x) > f(\bar{x})).$$

Bemerkung: Der Begriff des strengen lokalen Maximum lässt sich analog definieren.

 $\Diamond$ 

**Satz 79** Die Funktion  $f: \mathbb{R} \to \mathbb{R}$  sei zweimal differenzierbar, die zweite Ableitung f''(x) sei stetig und für ein  $x_0 \in \mathbb{R}$  gelte

$$f'(x_0) = 0 \land f''(x_0) > 0.$$

Dann hat die Funktion f im Punkt  $x_0$  ein strenges lokales Minimum.

**Beweis**: Da die zweite Ableitung f''(x) stetig ist, können wir  $\varepsilon := f''(x_0) > 0$  setzen und finden dann ein  $\delta > 0$ , so dass

$$\forall x \in \mathbb{R} : (|x - x_0| < \delta \rightarrow |f''(x) - f''(x_0)| < \varepsilon = f''(x_0)).$$

gilt. Subtrahieren wir  $|f''(x) - f''(x_0)|$  auf beiden Seiten dieser Gleichung, so folgt, dass für alle  $x \in \mathbb{R}$  mit  $|x - x_0| < \delta$  die Ungleichung

$$f''(x_0) - |f''(x) - f''(x_0)| > 0$$

gilt. Wir behaupten, dass dann

$$f''(x) > 0 \quad \text{für alle } x \in \mathbb{R} \text{ mit } |x - x_0| < \delta \tag{5.1}$$

gilt. Zum Nachweis dieser Behauptung führen wir eine Fallunterscheidung bezüglich der relativen Größe von f''(x) und  $f''(x_0)$  durch.

1. Fall:  $f''(x) < f''(x_0)$ . Dann gilt

$$|f''(x) - f''(x_0)| = f''(x_0) - f''(x).$$

Also folgt aus der Ungleichung  $f''(x_0) - |f''(x) - f''(x_0)| > 0$  die Ungleichung

$$f''(x_0) - (f''(x_0) - f''(x)) > 0$$

und wegen  $f''(x_0) - (f''(x_0) - f''(x)) = f''(x)$  haben wir damit die Behauptung f''(x) > 0 gezeigt.

2. Fall:  $f''(x) \ge f''(x_0)$ .

In diesem Fall folgt die Behauptung sofort aus der Voraussetzung  $f''(x_0) > 0$  und der Transitivität der Relation >.

Zusammen mit dem Satz 77 zeigt die Ungleichung (5.1), dass die Funktion  $x \mapsto f'(x)$  in der  $\delta$ -Umgebung von  $x_0$  streng monoton steigend ist. Da außerdem  $f'(x_0) = 0$  gilt, folgt insgesamt

$$f'(x) < 0$$
 für alle  $x \in U_{\delta}(x_0)$  mit  $x < x_0$  und

$$f'(x) > 0$$
 für alle  $x \in U_{\delta}(x_0)$  mit  $x > x_0$ .

Damit ist die Funktion f innerhalb der  $\delta$ -Umgebung  $U_{\delta}(x_0)$  für  $x < x_0$  streng monoton fallend und für  $x > x_0$  streng monoton wachsend. Dann muss f aber ein strenges lokales Minimum im Punkt  $x_0$  haben.

**Bemerkung**: Falls für die Funktion f die Bedingung

$$f'(x_0) = 0 \wedge f''(x_0) < 0.$$

erfüllt ist, dann hat die Funktion an der Stelle  $x_0$  ein strenges lokales Maximum.

**Definition 80 (konvex, konkav)** Eine Funktion  $f: \mathbb{R} \to \mathbb{R}$  heißt *konvex* genau dann, wenn

$$\forall x_1, x_2 \in \mathbb{R} : \forall t \in [0, 1] : \left( f(t \cdot x_1 + (1 - t) \cdot x_2) \le t \cdot f(x_1) + (1 - t) \cdot f(x_2) \right)$$

gilt. Geometrisch bedeutet dies, dass die Funktionswerte der Funktion f unterhalb der Sekante durch die Punkte  $\langle x_1, f(x_1) \rangle$  und  $\langle x_2, f(x_2) \rangle$  liegen. Abbildung 5.3 auf Seite 99 zeigt dies anschaulich: In dem Intervall  $(x_1, x_2)$  liegen die Werte der Funktion f unterhalb der Gerade g, die durch die beiden Punkte  $\langle x_1, f(x_1) \rangle$  und  $\langle x_2, f(x_2) \rangle$  geht. Die Gleichung dieser Geraden ist

 $\Diamond$ 

$$g(x) = \frac{x - x_1}{x_2 - x_1} \cdot f(x_2) + \frac{x - x_2}{x_1 - x_2} \cdot f(x_1).$$

Sie können dies sofort verifizieren, denn offenbar ist der Ausdruck g(x) linear in der Variablen x und andererseits gilt

$$g(x_1) = \frac{x_1 - x_1}{x_2 - x_1} \cdot f(x_2) + \frac{x_1 - x_2}{x_1 - x_2} \cdot f(x_1) = f(x_1)$$

und analog sehen wir, dass auch  $g(x_2) = f(x_2)$  ist. Die Tatsache, dass f(x) für  $x \in [x_1, x_2]$  unterhalb der Geraden g(x) liegt, bedeutet, dass

$$f(x) \le g(x)$$
 für alle  $x \in [x_1, x_2]$ 

gilt. Jedes  $x \in [x_1, x_2]$  lässt sich in der Form

$$x = t \cdot x_1 + (1 - t) \cdot x_2$$

schreiben, wobei  $t \in [0,1]$  gilt. Setzen wir diesen Wert von x in die Ungleichung  $f(x) \leq g(x)$  ein, so erhalten wir

$$f(t \cdot x_{1} + (1 - t) \cdot x_{2}))$$

$$\leq g(t \cdot x_{1} + (1 - t) \cdot x_{2}))$$

$$= \frac{(t \cdot x_{1} + (1 - t) \cdot x_{2}) - x_{1}}{x_{2} - x_{1}} \cdot f(x_{2}) + \frac{(t \cdot x_{1} + (1 - t) \cdot x_{2}) - x_{2}}{x_{1} - x_{2}} \cdot f(x_{1})$$

$$= \frac{(1 - t) \cdot x_{2} - (1 - t) \cdot x_{1}}{x_{2} - x_{1}} \cdot f(x_{2}) + \frac{t \cdot x_{1} - t \cdot x_{2}}{x_{1} - x_{2}} \cdot f(x_{1})$$

$$= (1 - t) \cdot f(x_{2}) + t \cdot f(x_{1})$$

und das ist genau die Definition der Konvexität.

Eine Funktion  $f: \mathbb{R} \to \mathbb{R}$  heißt konkav genau dann, wenn

$$\forall x_1, x_2 \in \mathbb{R} : \forall t \in [0, 1] : \left( f(t \cdot x_1 + (1 - t) \cdot x_2) \ge t \cdot f(x_1) + (1 - t) \cdot f(x_2) \right)$$

gilt. Hier liegen die Funktionswerte der Funktion f also oberhalb der Sekante durch die Punkte  $\langle x_1, f(x_1) \rangle$  und  $\langle x_2, f(x_2) \rangle$ .

Abbildung 5.4 auf Seite 99 zeigt eine konkave Funktion f zusammen mit einer Sekante g.

### Lemma 81 (Invarianz der Konvexität unter linearen Transformationen)

Die Funktion  $f: \mathbb{R} \to \mathbb{R}$  sei konvex und es seien  $\alpha, \beta \in \mathbb{R}$ . Definieren wir die Funktion  $g: \mathbb{R} \to \mathbb{R}$  als

$$g(x) := f(x) + \alpha \cdot x + \beta$$

so ist auch die Funktion g konvex. Eine entsprechende Aussage gilt auch für konkave Funktionen.

Aufgabe 47: Beweisen Sie das vorangehende Lemma.

**Satz 82** Die Funktion  $f: \mathbb{R} \to \mathbb{R}$  sei zweimal differenzierbar und die Funktion  $x \mapsto f''(x)$  sei stetig. Dann gilt

$$f \text{ konvex} \quad \Leftrightarrow \quad \forall x \in \mathbb{R} : f''(x) \ge 0.$$

Beweis: Wir spalten den Beweis in zwei Teile auf.

" $\Rightarrow$ ": Wir führen den Nachweis indirekt und nehmen an, dass es ein  $x_0 \in \mathbb{R}$  gibt, so dass  $f''(x_0) < 0$  ist. Ähnlich wie im Beweis von Satz 79 folgt daraus, dass es eine  $\delta_1$ -Umgebung  $U_{\delta_1}(x_0)$  gibt, so dass

$$f''(x) < 0$$
 für alle  $x \in U_{\delta_1}(x_0)$ 

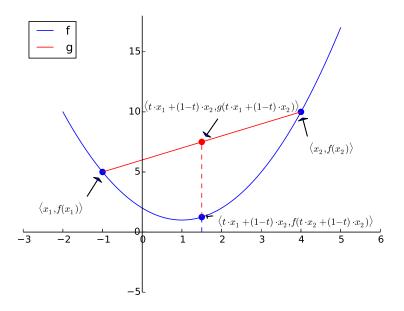


Abbildung 5.3: Eine konvexe Funktion f zusammen mit einer Sekante g.

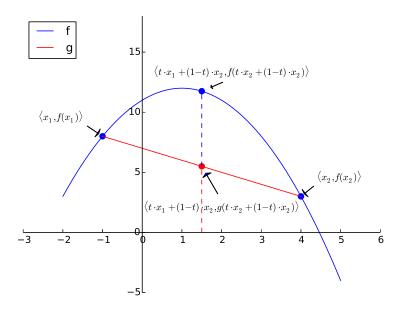


Abbildung 5.4: Eine konkave Funktion f zusammen mit einer Sekante g.

gilt. Wir definieren eine Funktion  $g:\mathbb{R} \to \mathbb{R}$  durch

$$g(x) := f(x) - x \cdot f'(x_0).$$

Dann gilt

$$g'(x) = f'(x) - f'(x_0)$$
 und  $g''(x) = f''(x)$ .

Daraus folgt durch Einsetzen

$$g'(x_0) = 0$$
 und  $g''(x_0) < 0$ .

Damit hat die Funktion g im Punkt  $x_0$  ein strenges lokales Maximum. Also gibt es eine  $\delta_2$ -Umgebung von  $x_0$ , so dass

$$g(x) < g(x_0)$$
 für alle  $x \in U_{\delta_2}(x_0)$ 

gilt. O.B.d.A. können wir voraussetzen, dass  $\delta_2 \leq \delta_1$  gilt. Nach dem Lemma 81 wissen wir, dass die Funktion g ebenfalls konvex ist. Definieren wir

$$x_1 := x_0 - \frac{\delta_2}{2}$$
,  $x_2 := x_0 + \frac{\delta_2}{2}$  und  $t := \frac{1}{2}$ ,

so folgt also

$$t \cdot g(x_1) + (1-t) \cdot g(x_2) \ge g(t \cdot x_1 + (1-t) \cdot x_2). \tag{5.2}$$

Nun gilt

$$t \cdot x_1 + (1 - t) \cdot x_2 = \frac{1}{2} \cdot x_0 - \frac{1}{2} \cdot \frac{\delta_2}{2} + \frac{1}{2} \cdot x_0 + \frac{1}{2} \cdot \frac{\delta_2}{2} = x_0.$$

Damit folgt aus der Ungleichung (5.2) die Ungleichung

$$\frac{1}{2} \cdot g(x_1) + \frac{1}{2} \cdot g(x_2) \ge g(x_0). \tag{5.3}$$

Andererseits folgt aus der Tatsache, dass sowohl  $x_1$  als auch  $x_2$  in der  $\delta_1$ -Umgebung von  $x_0$  liegen, dass

$$g(x_1) < g(x_0)$$
 und  $g(x_2) < g(x_0)$ 

gilt. Multiplizieren wir diese beiden Gleichungen mit  $\frac{1}{2}$  und addieren sie, so ergibt sich

$$\frac{1}{2} \cdot g(x_1) + \frac{1}{2} \cdot g(x_2) < g(x_0)$$
.

Diese Ungleichung steht aber im Widerspruch zur Ungleichung (5.3).

" $\Leftarrow$ ": Es seien  $x_1$ ,  $x_2$  und  $t \in [0,1]$  gegeben. O.B.d.A. sei weiter  $x_1 < x_2$ . Wir definieren zunächst

$$x_0 := t \cdot x_1 + (1-t) \cdot x_2$$

Es lässt sich sofort nachrechnen, dass dann  $x_1 < x_0 < x_2$  gilt. Nach dem Mittelwert-Satz der Differential-Rechnung gibt es jeweils ein  $c_1 \in (x_1, x_0)$  und ein  $c_2 \in (x_0, x_2)$ , so dass

$$f'(c_1) = \frac{f(x_0) - f(x_1)}{x_0 - x_1} \quad \text{ und } \quad f'(c_2) = \frac{f(x_2) - f(x_0)}{x_2 - x_0}$$

gilt. Da  $f''(x) \ge 0$  ist, wissen wir außerdem, dass die Funktion f'(x) monoton steigend ist. Da offenbar  $c_1 \le c_2$  ist, folgt daraus die Ungleichung  $f'(c_1) \le f'(c_2)$  und damit gilt

$$\frac{f(x_0) - f(x_1)}{x_0 - x_1} \le \frac{f(x_2) - f(x_0)}{x_2 - x_0}. (5.4)$$

Es gilt

$$x_0 - x_1 = t \cdot x_1 + (1 - t) \cdot x_2 - x_1 = (1 - t) \cdot (x_2 - x_1)$$

und genauso sehen wir

$$x_2 - x_0 = x_2 - (t \cdot x_1 + (1 - t) \cdot x_2) = t \cdot (x_2 - x_1).$$

Multiplizieren wir daher die Ungleichung (5.4) mit  $t \cdot (1-t) \cdot (x_2-x_1)$ , so erhalten wir die Ungleichung

$$t \cdot (f(x_0) - f(x_1)) \le (1 - t) \cdot (f(x_2) - f(x_0)).$$

Addieren wir auf beiden Seiten der Gleichung  $(1-t)\cdot f(x_0)$  und  $t\cdot f(x_1)$  und setzen dann noch für  $x_0$  den Wert  $t\cdot x_1+(1-t)\cdot x_2$  ein, so erhalten wir die Ungleichung

$$f(t \cdot x_1 + (1-t) \cdot x_2) \le t \cdot f(x_1) + (1-t) \cdot f(x_2).$$

Das ist aber gerade die Konvexität der Funktion f.

# 5.4 Die Exponential-Funktion

Wir haben die Exponential-Funktion als die Potenzreihe

$$\exp(x) := \sum_{n=0}^{\infty} \frac{1}{n!} \cdot x^n$$

definiert und gesehen, dass diese Potenzreihe für alle  $x \in \mathbb{R}$  konvergiert. Wir definieren nun die Eulersche Zahl e (Leonhard Euler, 1707–1783) mit Hilfe der Exponential-Funktion als

$$e := \exp(1) = \sum_{n=0}^{\infty} \frac{1}{n!} = 2.718281828459045235360287471352662497757247093\cdots$$

Wir wollen in diesem Abschnitt zeigen, dass für die Exponential-Funktion die Gleichung

$$\exp(x) = e^x$$

gilt. Zum Nachweis der oben behaupteten Gleichung benötigen wir das folgende Lemma.

**Lemma 83** Ist die Funktion  $f: \mathbb{R} \to \mathbb{R}$  für alle  $x \in \mathbb{R}$  differenzierbar und gilt

$$f'(x) = 0$$
 für alle  $x \in \mathbb{R}$ 

so ist die Funktion f konstant: Es gibt dann ein  $c \in \mathbb{R}$  so dass

$$f(x) = c$$
 für alle  $x \in \mathbb{R}$  ist.

**Beweis**: Wir betrachten zwei beliebige Zahlen  $x_1, x_2 \in \mathbb{R}$ , für die

$$x_1 \neq x_2$$

gilt. O.B.d.A. sei  $x_1 < x_2$ . Wir zeigen, dass dann

$$f(x_1) = f(x_2)$$

gilt. Nach dem Mittelwert-Satz gibt es ein  $c \in [x_1, x_2]$ , so dass

$$f'(c) = \frac{f(x_2) - f(x_1)}{x_2 - x_1}$$

gilt. Nach Voraussetzung wissen wir, dass f'(c) = 0 ist. Also haben wir

$$0 = \frac{f(x_2) - f(x_1)}{x_2 - x_1}.$$

Multiplikation dieser Gleichung mit  $x_2 - x_1$  liefert die Gleichung

$$0 = f(x_2) - f(x_1)$$

und daraus folgt sofort  $f(x_1) = f(x_2)$ . Damit ist gezeigt, dass die Funktion f für alle Argumente den selben Wert liefert und also konstant ist.

**Aufgabe 48**: Zeigen Sie: Ist die Funktion  $f: \mathbb{R} \to \mathbb{R}$  zweimal differenzierbar und gilt f''(x) = 0 für alle  $x \in \mathbb{R}$ , so gibt es Zahlen  $c, d \in \mathbb{R}$ , so dass

$$\forall x \in \mathbb{R} : f(x) = c \cdot x + d$$

gilt. Überlegen Sie, wie Sie diese Aussage so verallgemeinern können, dass die verallgemeinerte Aussage für beliebige n-mal differenzierbare Funktionen  $f: \mathbb{R} \to \mathbb{R}$  gilt, für deren n-te Ableitung

$$f^{(n)}(x) = 0$$
 für alle  $x \in \mathbb{R}$  ist.

**Aufgabe 49**: Zeigen Sie, dass für alle  $x \in \mathbb{R}$ 

$$\exp(x) \cdot \exp(-x) = 1$$

gilt. Bei Ihrem Beweis sollen Sie die Gleichung  $\exp(x+y)=\exp(x)\cdot\exp(y)$  nicht benutzen! Folgern Sie aus der von Ihnen gezeigten Gleichung, dass die Exponential-Funktion keine Nullstelle hat.  $\diamond$ 

Aus dem letzten Lemma folgt eine wichtige Charakterisierung der Exponential-Funktion.

**Lemma 84** Die Funktion  $f: \mathbb{R} \to \mathbb{R}$  sei für alle  $x \in \mathbb{R}$  differenzierbar und es gelte

$$f'(x) = \lambda \cdot f(x)$$
 für ein  $\lambda \in \mathbb{R}$ .

Dann gibt es ein  $c \in \mathbb{R}$ , so dass

$$f(x) = c \cdot \exp(\lambda \cdot x)$$
 für alle  $x \in \mathbb{R}$  ist.

**Beweis**: Wir definieren die Funktion  $g: \mathbb{R} \to \mathbb{R}$  als

$$g(x) := f(x) \cdot \exp(-\lambda \cdot x).$$

Als Produkt differenzierbarer Funktionen ist die Funktion g differenzierbar und es gilt

$$g'(x) = f'(x) \cdot \exp(-\lambda \cdot x) + f(x) \cdot (-\lambda) \cdot \exp(-\lambda \cdot x)$$
$$= \lambda \cdot f(x) \cdot \exp(-\lambda \cdot x) - \lambda \cdot f(x) \cdot \exp(-\lambda \cdot x)$$
$$= 0$$

Nach dem letzten Lemma (Lemma 83) muss die Funktion g konstant sein. Damit gilt

$$g(x) = g(0) = f(0) \cdot \exp(0) = f(0) \cdot 1 = f(0).$$

Wir definieren c:=f(0). Setzen wir in der letzten Gleichung die Definition der Funktion g ein, so haben wir

$$f(x) \cdot \exp(-\lambda \cdot x) = c.$$

Multiplizieren wir diese Gleichung mit  $\exp(\lambda \cdot x)$  und berücksichtigen, dass wir in der letzten Aufgabe gezeigt haben, dass  $\exp(\lambda \cdot x) \cdot \exp(-\lambda \cdot x) = 1$  ist, dann erhalten wir die Gleichung

$$f(x) = c \cdot \exp(\lambda \cdot x).$$

Aus dem letzten Satz können wir nun die Funktional-Gleichung der Exponential-Funktion folgern.

### Satz 85 (Funktional-Gleichung der Exponential-Funktion) Für alle $x,y\in\mathbb{R}$ gilt

$$\exp(x+y) = \exp(x) \cdot \exp(y).$$

**Beweis**: Für ein gegebenes, festes  $y \in \mathbb{R}$  definieren wir die Funktion  $f : \mathbb{R} \to \mathbb{R}$  durch

$$f_y(x) := \exp(x + y).$$

Dann gilt

$$f_y'(x) = 1 \cdot \exp(x + y) = f_y(x).$$

Nach dem letzten Lemma gilt also

$$f_y(x) = c \cdot \exp(x). \tag{5.5}$$

Da diese Gleichung auch für x=0 gilt und da  $\exp(0)=1$  ist, haben wir

$$f_u(0) = c.$$

Setzen wir hier die Definition von  $f_u(x)$  ein, so folgt

$$\exp(0+y) = c$$
, also  $c = \exp(y)$ .

Setzen wir dies zusammen mit der Definition von  $f_y$  in Gleichung (5.5) ein, so erhalten wir

$$\exp(x+y) = \exp(y) \cdot \exp(x).$$

**Bemerkung**: Mit Hilfe der Funktional-Gleichung der Exponential-Funktion können wir nun für beliebige  $\lambda \in \mathbb{R}_0^*$  und  $x \in \mathbb{R}$  den Ausdruck  $\lambda^x$  definieren. Wir betrachten zunächst den Spezialfall  $\lambda = \mathrm{e}$ : Ist  $n \in \mathbb{N}$ , so können wir mit Hilfe der Funktional-Gleichung durch eine leichte Induktion nach n zeigen, dass

$$\exp(n) = e^n$$

ist. Aufgrund der Gleichung

$$\exp(x) \cdot \exp(-x) = 1$$

folgt daraus, dass auch für negative ganze Zahlen  $m \in \mathbb{Z}$ 

$$\exp(m) = e^m$$

gilt, denn wenn m=-n mit  $n\in\mathbb{N}^*$  ist, haben wir

$$e^m = e^{-n} = \frac{1}{e^n} = \frac{1}{\exp(n)} = \exp(-n) = \exp(m).$$

Ist nun  $\frac{p}{q}\in\mathbb{Q}$ , wobei  $p\in\mathbb{Z}$  und  $q\in\mathbb{N}^*$  gilt, so haben wir nach dem bisher gezeigten

$$e^p = \exp(p)$$
.

Ziehen wir hier die q-te Wurzel, so haben wir

$$e^{\frac{p}{q}} = \sqrt[q]{\exp(p)} = \exp\left(\frac{p}{q}\right),$$

gezeigt, denn es gilt

$$\left(\exp\left(\frac{p}{q}\right)\right)^q = \exp\left(q \cdot \frac{p}{q}\right) = \exp(p) = e^p.$$

Damit haben wir also nun für alle rationalen Zahlen  $r \in \mathbb{Q}$  die Gleichung

$$e^r = \exp(r)$$

gezeigt. Es stellt sich die Frage, wie wir am sinnvollsten den Wert von Ausdrücken wie  $e^x$  in den Fällen definieren können, in denen x keine rationale Zahl ist. Es ist naheliegend, für beliebige reelle Zahlen  $x \in \mathbb{R}$  den Wert  $e^x$  als

$$e^x := \exp(x)$$

zu definieren. Für beliebige  $\lambda \in \mathbb{R}_+^*$  setzen wir dann

$$\lambda^x := \exp(x \cdot \ln(\lambda)).$$

Mit Hilfe der Funktional-Gleichung der Exponential-Funktion können Sie nun leicht nachweisen, dass für die so definierte Potenz die aus der Schule bekannten Potenz-Gesetze gelten.

Aufgabe 50: Berechnen Sie den Grenzwert

$$\lim_{n \to \infty} \left( 1 + \frac{1}{n} \right)^n.$$

R

# Kapitel 6

# Anwendungen

In diesem Kapitel stellen wir verschiedene Anwendungen der bisher entwickelten Theorie vor. Zunächst zeigen wir, wie sich bestimmte transzendente Funktionen wie der natürliche Logarithmus und die trigonometrischen Funktionen effektiv mit Hilfe von Reihen berechnen lassen. Anschließend diskutieren wir, wann eine Funktion sich durch ein Polynom interpolieren lässt. Danach besprechen wir das Newton'sche Verfahren zur Bestimmung von Nullstellen, welches dann anwendbar ist, wenn die Funktion, deren Nullstelle bestimmt werden soll, differenzierbar ist. Außerdem untersuchen wir die Konvergenz von Fixpunkt-Verfahren und zeigen, wie sich lineare Gleichungs-Systeme mit Hilfe von Fixpunkt-Verfahren approximativ lösen lassen.

# 6.1 Taylor-Reihen

Es sei  $f:\mathbb{R}\to\mathbb{R}$  eine Funktion, die beliebig oft differenzierbar ist. Wir stellen uns die Frage, ob es möglich ist, eine solche Funktion als Potenzreihe darzustellen, wir fragen also, ob es eine Folge  $(a_n)_{n\in\mathbb{N}^*}$  gibt, so dass

$$f(x) = \sum_{n=0}^{\infty} a_n \cdot x^n \tag{6.1}$$

gilt. Falls eine solche Folge  $(a_n)_{n\in\mathbb{N}^*}$  existiert, dann möchten wir diese Folge berechnen können. Wenn die Gleichung (6.1) gültig ist, dann können wir den Koeffizienten  $a_0$  dadurch berechnen, dass wir in dieser Gleichung x=0 setzen. Wir erhalten dann

$$f(0) = a_0 + \sum_{n=1}^{\infty} a_n \cdot 0^n = a_0.$$
(6.2)

Um den Koeffizienten  $a_1$  zu berechnen, differenzieren wir Gleichung (6.1):

$$\frac{\mathrm{d}f}{\mathrm{d}x}(x) = a_1 \cdot 1 \cdot x^0 + \sum_{n=2}^{\infty} a_n \cdot n \cdot x^{n-1}.$$
(6.3)

Setzen wir in dieser Gleichung x=0, so finden wir

$$\frac{\mathrm{d}f}{\mathrm{d}x}(0) = a_1 + \sum_{n=2}^{\infty} a_n \cdot n \cdot 0^{n-1} = a_1.$$
(6.4)

Allgemein können wir den Koeffizienten  $a_k$  dadurch bestimmen, dass wir Gleichung (6.1) k-mal nach x differenzieren und anschließend x=0 setzen. Wir beweisen zunächst durch Induktion über k, dass

für alle  $k \in \mathbb{N}_0$ 

$$f^{(k)}(x) = \sum_{n=k}^{\infty} a_n \cdot n \cdot (n-1) \cdot \dots \cdot (n-(k-1)) \cdot x^{n-k}$$

$$= \sum_{n=k}^{\infty} a_n \cdot \left( \prod_{i=0}^{k-1} (n-i) \right) \cdot x^{n-k}$$

$$= \sum_{n=k}^{\infty} \frac{n!}{(n-k)!} \cdot a_n \cdot x^{n-k}$$
(6.5)

gilt. Hierbei bezeichnet  $f^{(k)}(x)$  die k-te Ableitung der Funktion f an der Stelle x.

I.A.: k = 0. Es gilt

$$f^{(0)}(x) = f(x)$$

$$= \sum_{n=0}^{\infty} a_n \cdot x^n$$

$$= \sum_{n=0}^{\infty} \frac{n!}{(n-0)!} \cdot a_n \cdot x^{n-k}.$$

I.S.:  $k \mapsto k+1$ . Es gilt

$$f^{(k+1)}(x) = \frac{\mathrm{d}f}{\mathrm{d}x}^{(k)}(x)$$

$$\stackrel{IV}{=} \frac{\mathrm{d}}{\mathrm{d}x} \sum_{n=k}^{\infty} \frac{n!}{(n-k)!} \cdot a_n \cdot x^{n-k}$$

$$= \sum_{n=k+1}^{\infty} \frac{n!}{(n-k)!} \cdot (n-k) \cdot a_n \cdot x^{n-k-1}$$

$$= \sum_{n=k+1}^{\infty} \frac{n!}{(n-k-1)!} \cdot a_n \cdot x^{n-(k+1)}$$

$$= \sum_{n=k+1}^{\infty} \frac{n!}{(n-(k+1))!} \cdot a_n \cdot x^{n-(k+1)}$$

Damit ist der Beweis von Gleichung (6.5) abgeschlossen. Setzen wir in dieser Gleichung für x den Wert 0 ein, so erhalten wir

$$f^{(k)}(0) = \frac{k!}{(k-k)!} \cdot a_k + \sum_{n=k+1}^{\infty} \frac{n!}{(n-k)!} \cdot a_n \cdot 0^{n-k}$$
$$= k! \cdot a_k$$

Dividieren wir diese Gleichung durch k!, so haben wir für die Koeffizienten der Taylor-Reihe die Formel  $a_k = \frac{f^{(k)}(0)}{k!}$ 

gefunden. Also definieren wir für eine Funktion  $f: \mathbb{R} \to \mathbb{R}$ , die im Punkt x=0 beliebig oft differenzierbar ist, die der Funktion f zugeordnete Taylor-Reihe als

$$taylor(f,x) := \sum_{n=0}^{\infty} \frac{f^{(n)}(0)}{n!} \cdot x^{n}.$$
 (6.6)

**Bemerkung**: Im Allgemeinen wissen wir nicht, ob die Reihe taylor(f,x) konvergiert. Selbst wenn die Reihe konvergiert folgt daraus noch nicht, dass f(x) = taylor(f,x) ist. Als Beispiel dazu betrachten wir die Funktion  $f: \mathbb{R} \to \mathbb{R}$ , die durch

$$f(x) := \left\{ \begin{array}{ll} \exp\left(-\frac{1}{x^2}\right) & \text{falls } x \neq 0 \\ 0 & \text{falls } x = 0 \end{array} \right.$$

definiert ist. Im Buch von Otto Forster [1] wird gezeigt, dass für diese Funktion die Werte sämtlicher Ableitungen an der Stelle x=0 verschwinden. Damit gilt dann taylor(f,x)=0.

## 6.1.1 Der Abbruch-Fehler bei der Taylor-Reihe

Um zu untersuchen, wann die Taylor-Reihe taylor(f,x) gegen f(x) konvergiert, definieren wir zu einer gegebenen Funktion f und einer natürlichen Zahl  $n \in \mathbb{N}_0$  den Abbruch-Fehler vom Grad n als

$$error_n(x) := f(x) - \sum_{i=0}^n \frac{f^{(i)}(0)}{i!} \cdot x^i.$$

Der Abbruch-Fehler gibt also an, wie groß der Fehler ist, wenn wir die Berechnung der Summe einer Taylor-Reihe nach dem n-ten Glied abbrechen. Wir berechnen eine Abschätzung für den Abbruch-Fehler  $error_n(x)$ . Dazu benutzen wir den erweiterten Mittelwert-Satz. Zunächst bemerken wir, dass für alle  $k=0,\cdots,n$  die k-te Ableitung des Abbruch-Fehlers vom Grad n den Wert 0 hat:

$$error_n^{(k)}(0) = 0$$

Dies folgt aus der Definition des Abbruch-Fehlers, denn wir hatten die Taylor-Reihe ja gerade so definiert, dass Sie mit der Funktion f an der Stelle 0 in allen Ableitungen übereinstimmt. Jetzt wenden wir auf die Funktionen  $error_n(x)$  und  $g_0(x):=x^{n+1}$  in dem Intervall [0,x] den erweiterten Mittelwert-Satz an. Dann gibt es ein  $\chi_1\in[0,x]$ , so dass

$$\frac{\frac{\mathrm{d}}{\mathrm{d}x}\operatorname{error}_n(\chi_1)}{\frac{\mathrm{d}}{\mathrm{d}x}g_0(\chi_1)} = \frac{\operatorname{error}_n(x) - \operatorname{error}_n(0)}{g_0(x) - g_0(0)}$$
(6.7)

gilt. Für die Ableitung der Funktion  $g_0(x)=x^{n+1}$  finden wir  $\frac{\mathrm{d}}{\mathrm{d}x}g_0(x)=(n+1)\cdot x^n$ . Wegen  $error_n(0)=0$  und  $g_0(0)=0$  vereinfacht sich Gleichung (6.7) zu

$$\frac{\operatorname{error}_{n}^{(1)}(\chi_{1})}{(n+1)\cdot\chi_{1}^{n}} = \frac{\operatorname{error}_{n}(x)}{x^{n+1}}.$$
(6.8)

Nun wenden wir in dem Intervall  $[0, \chi_1]$  den erweiterten Mittelwert-Satz auf die beiden Funktionen  $error_n^{(1)}(x)$  und  $g_1(x) := (n+1) \cdot x^n$  an. Dann gibt es ein  $\chi_2 \in [0, \chi_1]$ , so dass

$$\frac{\frac{\mathrm{d}}{\mathrm{d}x}\operatorname{error}_{n}^{(1)}(\chi_{2})}{\frac{\mathrm{d}}{\mathrm{d}x}g_{1}(\chi_{2})} = \frac{\operatorname{error}_{n}^{(1)}(\chi_{1}) - \operatorname{error}_{n}^{(1)}(0)}{g_{1}(\chi_{1}) - g_{1}(0)} \tag{6.9}$$

gilt. Für die Ableitung der Funktion  $g_1(x)=(n+1)\cdot x^n$  finden wir  $\frac{\mathrm{d}}{\mathrm{d}x}g_1(x)=(n+1)\cdot n\cdot x^{n-1}$ . Wegen  $\operatorname{\textit{error}}_n^{(1)}(0)=0$  und  $g_1(0)=0$  vereinfacht sich Gleichung (6.9) unter Berücksichtigung von Gleichung (6.8) zu

$$\frac{\textit{error}_n^{(2)}(\chi_2)}{(n+1) \cdot n \cdot \chi_2^{n-1}} = \frac{\textit{error}_n^{(1)}(\chi_1)}{(n+1) \cdot \chi_1^n} = \frac{\textit{error}_n(x)}{x^{n+1}}.$$

Dieses Spiel können wir fortsetzen. Wenn wir k-mal den erweiterten Mittelwert-Satz anwenden und  $k \le n$  ist, erhalten wir ein  $\chi_k \in [0, \chi_{k-1}]$ , so dass gilt:

$$\frac{error_n^{(k)}(\chi_k)}{\frac{(n+1)!}{(n+1-k)!} \cdot \chi_k^{n+1-k}} = \frac{error_n(x)}{x^{n+1}}$$
(6.10)

Um diese Behauptung per Induktion nach k zu beweisen, bemerken wir, dass der Induktions-Anfang k=1 bereits bewiesen wurde. Im Induktions-Schritt wenden wir in dem Intervall  $[0,\chi_k]$  auf die beiden Funktionen  $\operatorname{error}_n^{(k)}(\chi_k)$  und  $g_k(x):=\frac{(n+1)!}{(n+1-k)!}\cdot x^{n+1-k}$  den erweiterten Mittelwert-Satz an. Wir finden dann ein  $\chi_{k+1}\in[0,\chi_k]$ , so dass

$$\frac{\frac{\mathrm{d}}{\mathrm{d}x}\operatorname{error}_{n}^{(k)}(\chi_{k+1})}{\frac{\mathrm{d}}{\mathrm{d}x}g_{k}(\chi_{k+1})} = \frac{\operatorname{error}_{n}^{(k)}(\chi_{k}) - \operatorname{error}_{n}^{(k)}(0)}{g_{k}(\chi_{k}) - g_{k}(0)}$$

$$(6.11)$$

gilt. Für die Ableitung der Funktion  $g_k(x)$  finden wir

$$\frac{\mathrm{d}}{\mathrm{d}x}g_k(x) = \frac{(n+1)!}{(n+1-k)!} \cdot (n+1-k) \cdot x^{n+1-k-1}$$

$$= \frac{(n+1)!}{(n+1-(k+1))!} \cdot x^{n+1-(k+1)}$$

$$= g_{k+1}(x)$$

Wegen  $error_n^{(k)}(0) = 0$  und  $g_k(0) = 0$  vereinfacht sich Gleichung (6.11) zu

$$\frac{\operatorname{error}_n^{(k+1)}(\chi_{k+1})}{g_{k+1}(\chi_{k+1})} = \frac{\operatorname{error}_n^{(k)}(\chi_k)}{g_{k+1}(\chi_k)}$$

Berücksichtigen wir hier noch die Induktions-Voraussetzung (6.10), so haben wir

$$\frac{error_n^{(k+1)}(\chi_{k+1})}{g_{k+1}(\chi_{k+1})} = \frac{error_n(x)}{x^{n+1}}$$
(6.12)

gefunden und dadurch die Formel (6.10) per Induktion nachgewiesen. Setzen wir in der Gleichung (6.10) für k den Wert n ein, so haben wir

$$\frac{\operatorname{error}_{n}^{(n)}(\chi_{n})}{(n+1)! \cdot \chi_{n}} = \frac{\operatorname{error}_{n}(x)}{x^{n+1}} \tag{6.13}$$

gezeigt. Wir wenden den erweiterten Mittelwert-Satz auf die Funktionen  $error_n^{(n)}(x)$  und  $x\mapsto (n+1)!\cdot x$  an. Dann erhalten wir ein  $\chi\in[0,\chi_n]\subseteq[0,x]$ , so dass

$$\frac{\frac{\mathrm{d}}{\mathrm{d}x}\operatorname{error}_{n}^{(n)}(\chi)}{\frac{\mathrm{d}}{\mathrm{d}x}(n+1)! \cdot x(\chi)} = \frac{\operatorname{error}_{n}^{(n)}(\chi_{n}) - \operatorname{error}_{n}^{(n)}(0)}{(n+1)! \cdot \chi_{n} - (n+1)! \cdot 0}$$

$$(6.14)$$

gilt. Wegen  $error_n^{(n)}(0) = 0$  haben wir also

$$\frac{\operatorname{error}_{n}^{(n+1)}(\chi)}{(n+1)!} = \frac{\operatorname{error}_{n}^{(n)}(\chi_{n})}{(n+1)! \cdot \chi_{n}}.$$
(6.15)

Um diese Gleichung zu vereinfachen, erinnern wir daran, dass  $\mathit{error}_n(x)$  als

$$error_n(x) = f(x) - \sum_{k=0}^n \frac{f^{(k)}(0)}{k!} \cdot x^k$$

definiert ist. Wenn wir die (n+1)-te Ableitung der Funktion  $error_n(x)$  bilden, dann bleibt von der Summe nichts über, es gilt also

$$error_n^{(n+1)}(x) = f^{(n+1)}(x).$$

Setzen wir dieses Ergebnis in Gleichung (6.15) ein und berücksichtigen Gleichung (6.13), so finden wir

$$\frac{f^{(n+1)}(\chi)}{(n+1)!} = \frac{error_n(x)}{x^{n+1}}.$$
(6.16)

Setzen wir hier die Definition von  $error_n(x)$  ein und multiplizieren die Gleichung mit  $x^{n+1}$ , so haben wir gezeigt, dass es ein  $\chi \in [0, x]$  gibt, so dass

$$f(x) = \sum_{k=0}^{n} \frac{f^{(k)}(0)}{k!} \cdot x^k + f^{(n+1)}(\chi) \cdot \frac{x^{n+1}}{(n+1)!}$$
 (6.17)

gilt. Diese Formel bezeichnen wir als die *Taylor-Entwicklung* (Brook Taylor, 1685 - 1731) der Funktion f mit *Lagrange'schem Restglied* (Joseph Louis Lagrange, 1736 - 1813).

## 6.2 Beispiele von Taylor-Entwicklungen

Wir zeigen nun, wie wir transzendente Funktionen mit Hilfe der Taylor-Entwicklungen approximieren können. Dadurch werden diese Funktionen einer numerischen Behandlung zugänglich.

## 6.2.1 Berechnung des natürlichen Logarithmus

Wir beginnen mit dem natürlichen Logarithmus  $x \mapsto \ln(x)$ . Dieser ist als die Umkehrfunktion der Exponential-Funktion definiert, es gilt also

$$\ln(\exp(x)) = x.$$

Da die Exponential-Funktion immer positiv ist, ist der natürliche Logarithmus für  $x \leq 0$  nicht definiert. Damit macht eine Taylor-Entwicklung der Funktion  $f(x) := \ln(x)$  keinen Sinn, denn in der Taylor-Reihe ist schon der konstante Koeffizient

$$\frac{f^{(0)}(0)}{0!} = f(0)$$

undefiniert. Alle weiteren Koeffizienten sind natürlich ebenfalls undefiniert. Wir betrachten daher die Funktion  $f(x) := \ln(1+x)$ , denn diese Funktion ist für x=0 definiert. Zunächst berechnen wir die Ableitungen dieser Funktion. Wir beweisen durch Induktion, dass für alle  $n \in \mathbb{N}$  die n-te Ableitung der Funktion f die folgende Form hat:

$$f^{(n)}(x) = (-1)^{n+1} \cdot \frac{(n-1)!}{(1+x)^n}$$

I.A.: n = 1. Es gilt

$$\frac{\mathrm{d}}{\mathrm{d}x}f(x) = \frac{\mathrm{d}}{\mathrm{d}x}\ln(1+x) = \frac{1}{1+x} = (-1)^{1+1} \cdot \frac{(1-1)!}{(1+x)^1},$$

denn n! ist für  $n \in \mathbb{N}_0$  so definiert, dass 0! = 1 gilt.

I.S.:  $n \mapsto n+1$ . Wir haben

$$f^{(n+1)}(x) = \frac{\mathrm{d}}{\mathrm{d}x} f^{(n)}(x)$$

$$\stackrel{\text{IV}}{=} \frac{\mathrm{d}}{\mathrm{d}x} \left( (-1)^{n+1} \cdot \frac{(n-1)!}{(1+x)^n} \right)$$

$$= (-1)^{n+1} \cdot (n-1)! \cdot \frac{(-n)}{(1+x)^{n+1}}$$

$$= (-1)^{(n+1)+1} \cdot \frac{n!}{(1+x)^{n+1}}$$

Setzen wir hier x = 0, so sehen wir, dass

$$f^{(n)}(0) = (-1)^{n+1} \cdot \frac{(n-1)!}{(1+0)^n} = (-1)^{n+1} \cdot (n-1)!$$

gilt. Wegen  $f(0) = \ln(1) = 0$  erhalten wir für die Taylor-Entwicklungen der Funktion  $\ln(1+x)$  das Ergebnis

$$taylor(x \mapsto \ln(1+x), x) = \sum_{n=1}^{\infty} (-1)^{n+1} \cdot \frac{(n-1)! \cdot x^n}{n!} = \sum_{n=1}^{\infty} (-1)^{n+1} \cdot \frac{x^n}{n}.$$
 (6.18)

Wir wollen nun zeigen, dass diese Taylor-Reihe tatsächlich gegen  $\ln(1+x)$  konvergiert, wir wollen also zeigen, dass

$$taylor(x \mapsto ln(1+x), x) = ln(1+x)$$

gilt. Dazu betrachten wir die Taylor-Entwicklung mit dem Lagrange'schen Restglied:

$$\ln(1+x) = \sum_{k=1}^{n} (-1)^{k+1} \cdot \frac{x^k}{k} + (-1)^n \cdot \frac{1}{(1+\chi)^{n+1}} \cdot \frac{x^{n+1}}{n+1}$$
(6.19)

Für den Abbruch-Fehler haben wir also

$$error_n(x) = (-1)^n \cdot \frac{1}{(1+\chi)^{n+1}} \cdot \frac{x^{n+1}}{n+1}$$

mit  $\chi \in [0,x]$  und für  $x \in [0,1]$  geht dieser Wert für  $n \to \infty$  gegen 0. Damit haben wir insgesamt  $taylor(x \mapsto \ln(1+x),x) = \ln(1+x)$  für  $x \in [0,1]$  gezeigt und folglich können wir

$$\ln(1+x) = \sum_{k=1}^{\infty} (-1)^{k+1} \cdot \frac{x^k}{k} \quad \text{ für } x \in (-1,1]$$

schreiben. Setzen wir hier für x den Wert 1 ein, so haben wir die Formel

$$\ln(2) = \sum_{k=1}^{\infty} \frac{(-1)^{k+1}}{k} = 1 - \frac{1}{2} + \frac{1}{3} - \frac{1}{4} + \frac{1}{5} \pm \cdots$$

gefunden. Um den Abbruch-Fehler abzuschätzen, setzen wir in  $\mathit{error}_n(x)$  für x den Wert 1 ein und finden

$$|error_n(1)| \leq \frac{1}{n+1}$$
.

Um  $\ln(2)$  also nach der obigen Formel auf eine Genauigkeit von  $10^{-9}$  berechnen zu können, müssten

 $<sup>^{1}</sup>$  Die Formel gilt auch für für negative x, deren Betrag kleiner als 1 ist, aber das ist etwas schwieriger zu beweisen.

wir  $1\,000\,000\,000$  Terme aufsummieren! Erfreulicherweise geht es auch effizienter. Dazu ersetzen wir in Gleichung (6.18) x durch -x und erhalten

$$\ln(1-x) = \sum_{k=1}^{\infty} (-1)^{k+1} \cdot \frac{(-x)^k}{k} = \sum_{k=1}^{\infty} (-1)^{k+1} \cdot \frac{(-1)^k \cdot x^k}{k} = -\sum_{k=1}^n \frac{x^k}{k}$$
 (6.20)

Subtrahieren wir diese Gleichung von der Gleichung (6.19), so erhalten wir

$$\ln\left(\frac{1+x}{1-x}\right) = \ln(1+x) - \ln(1-x)$$

$$= \sum_{k=1}^{\infty} (-1)^{k+1} \cdot \frac{x^k}{k} + \sum_{k=1}^{n} \frac{x^k}{k}$$

$$= \sum_{k=1}^{\infty} ((-1)^{k+1} + 1) \cdot \frac{x^k}{k}$$

$$= 2 \cdot \sum_{k=0}^{\infty} \frac{x^{2 \cdot n+1}}{2 \cdot n+1},$$
(6.21)

denn  $(-1)^k + 1 + 1$  hat für gerade Werte von k den Wert 0 und für ungerade Werte hat dieser Term den Wert 2. Setzen wir hier für x den Wert  $\frac{1}{3}$  ein, so erhalten wir

$$\ln\left(\frac{1+\frac{1}{3}}{1-\frac{1}{3}}\right) = \ln\left(\frac{\frac{4}{3}}{\frac{2}{3}}\right) = \ln(2) = 2 \cdot \sum_{n=0}^{\infty} \frac{1}{2 \cdot n + 1} \cdot \left(\frac{1}{3}\right)^{2 \cdot n + 1}$$

Um den Fehler e abzuschätzen, den wir erhalten, wenn wir diese Reihe nach dem Glied  $2 \cdot n + 1$  abbrechen, schätzen wir den Abbruch-Fehler wie folgt ab:

$$\left| \ln \left( \frac{1+\frac{1}{3}}{1-\frac{1}{3}} \right) - 2 \cdot \sum_{k=0}^{n} \frac{1}{2 \cdot k + 1} \cdot \left( \frac{1}{3} \right)^{2 \cdot k + 1} \right|$$

$$= 2 \cdot \left| \sum_{k=n+1}^{\infty} \frac{1}{2 \cdot k + 1} \cdot \left( \frac{1}{3} \right)^{2 \cdot k + 1} \right|$$

$$\leq 2 \cdot \sum_{k=n+1}^{\infty} \left( \frac{1}{3} \right)^{2 \cdot k + 1} = 2 \cdot \sum_{k=0}^{\infty} \left( \frac{1}{3} \right)^{2 \cdot n + 2 \cdot k + 3}$$

$$= 2 \cdot \left( \frac{1}{3} \right)^{2 \cdot n + 3} \sum_{k=0}^{\infty} \left( \frac{1}{3} \right)^{2 \cdot k} = 2 \cdot \left( \frac{1}{3} \right)^{2 \cdot n + 3} \sum_{k=0}^{\infty} \left( \frac{1}{9} \right)^{k}$$

$$= 2 \cdot \left( \frac{1}{3} \right)^{2 \cdot n + 3} \frac{1}{1 - \frac{1}{9}} = 2 \cdot \left( \frac{1}{3} \right)^{2 \cdot n + 3} \frac{9}{8}$$

$$= \frac{1}{4} \cdot \left( \frac{1}{3} \right)^{2 \cdot n + 1}$$

Wir wollen ln(2) auf eine Genauigkeit von  $10^{-9}$  berechnen. Also wählen wir n so, dass gilt:

$$\frac{1}{4} \cdot \left(\frac{1}{3}\right)^{2 \cdot n + 1} \leq 10^{-9}$$

$$\Leftrightarrow \left(\frac{1}{3}\right)^{2 \cdot n + 1} \leq 4 \cdot 10^{-9}$$

$$\Leftrightarrow -\ln(3) \cdot (2 \cdot n + 1) \leq \ln(4) - 9 \cdot \ln(10)$$

$$\Leftrightarrow (2 \cdot n + 1) \geq \frac{9 \cdot \ln(10) - \ln(4)}{\ln(3)}$$

$$\Leftrightarrow n \geq 0.5 \cdot \left(\frac{9 \cdot \ln(10) - \ln(4)}{\ln(3)} - 1\right) \approx 8.3$$

$$\Leftrightarrow n \geq 9$$

Um  $\ln(2)$  auf eine Genauigkeit von  $10^{-9}$  zu berechnen reicht es also aus, wenn wir in der Formel (6.21) die ersten 9 Glieder der Summe berücksichtigen. Wir erhalten

$$\ln(2) \approx 2 \cdot \sum_{n=0}^{9} \frac{1}{2 \cdot n + 1} \left(\frac{1}{3}\right)^{2 \cdot n + 1} \approx 0.69314718054981171974$$

Der wirkliche Fehler ist sogar noch kleiner, er beträgt etwa  $10^{-11}$ . Das liegt daran, dass wir bei der Abschätzung der Summe durch die geometrische Reihe den Faktor  $\frac{1}{2 \cdot k + 1}$  vernachlässigt haben.

Das Verfahren, das wir oben benutzt haben um  $\ln(2)$  zu berechnen, lässt sich verallgemeinern. Ist die Aufgabe gegeben, für eine gegebene reelle Zahl r den natürlichen Logarithmus  $\ln(r)$  zu berechnen, so setzen wir

$$r = \frac{1+x}{1-x}$$

$$\Leftrightarrow (1-x) \cdot r = 1+x$$

$$\Leftrightarrow r - x \cdot r = 1+x$$

$$\Leftrightarrow r - 1 = x + x \cdot r$$

$$\Leftrightarrow r - 1 = x \cdot (1+r)$$

$$\Leftrightarrow \frac{r-1}{r+1} = x$$

Bei gegebenem r bestimmen wir also x nach der Formel  $x=\frac{r-1}{r+1}$ . Für das so bestimmte x gilt dann

$$\ln(r) = \ln\left(\frac{1+x}{1-x}\right) = 2 \cdot \sum_{n=0}^{\infty} \frac{x^{2\cdot n+1}}{2\cdot n+1} \quad \text{mit } x = \frac{r-1}{r+1}.$$
 (6.22)

Aufgabe 51: Zeigen Sie, dass

$$0 \le \frac{r-1}{r+1} \le \frac{1}{3}$$

gilt, falls  $r \in [1, 2]$  ist.

Die letzte Aufgabe zeigt, dass aus  $r\in[1,2]$  die Ungleichung  $0\le x\le \frac{1}{3}$  folgt und dann konvergiert die in Gleichung (6.22) gegebene Reihe sehr gut. In modernen Rechnern werden reelle Zahlen y in der Form

$$y=s\cdot r\cdot 2^n \quad \text{ mit } s\in \{-1,+1\}, \quad r\in [1,2) \quad \text{ und } n\in \mathbb{Z}$$

 $\Diamond$ 

dargestellt. Ist y positiv, so lässt sich der natürliche Logarithmus nach der Formel

$$\ln(y) = \ln(r) + n \cdot \ln(2)$$

berechnen, wobei ln(r) mit Hilfe der Formel (6.22) gefunden wird.

**Aufgabe 52**: Berechnen Sie die Taylor-Reihen für die Funktionen  $x \mapsto \sin(x)$  und  $x \mapsto \cos(x)$  und geben Sie eine Abschätzung für den Abbruch-Fehler an. Folgern Sie außerdem die Eulersche Formel

$$e^{i \cdot x} = \cos(x) + i \cdot \sin(x),$$

die auf Leonard Euler (1707 — 1783) zurück geht.

## 6.2.2 Berechnung des Arcus-Tangens

Die direkte Berechnung der Taylor-Reihe einer Funktion mit Hilfe der Formel (6.6) ist unter Umständen sehr mühsam. Wollen wir beispielsweise die Funktion  $x \mapsto \arctan(x)$  in einer Taylor-Reihe entwickeln, so berechnen wir mit WolframAlpha® die ersten fünf Ableitungen wie folgt:

1. 
$$\arctan^{(1)}(x) = \frac{1}{1+x^2}$$
.

2. 
$$\arctan^{(2)}(x) = -2 \cdot \frac{x}{(1+x^2)^2}$$
.

3. 
$$\arctan^{(3)}(x) = 2 \cdot \frac{3 \cdot x^2 - 1}{(1 + x^2)^3}$$
.

4. 
$$\arctan^{(4)}(x) = -24 \cdot \frac{x \cdot (x^2 - 1)}{(1 + x^2)^4}$$
.

5. 
$$\arctan^{(5)}(x) = 24 \cdot \frac{1 + 5 \cdot x^4 - 10 \cdot x^2}{(1 + x^2)^5}$$
.

Offenbar ist es schwierig, hier eine Struktur zu erkennen.

**Aufgabe 53**: Versuchen Sie, eine allgemeine Formel für die n-te Ableitung der Funktion  $x \mapsto \arctan(x)$  zu finden. Beweisen Sie die Richtigkeit Ihrer Formel.

Hinweis: Es gilt

$$\frac{1}{1+x^2} = \frac{1}{2} \cdot \left( \frac{1}{1+i \cdot x} + \frac{1}{1-i \cdot x} \right).$$

Wir gehen in der Vorlesung einen anderen Weg um die Taylor-Reihe der Arkustangens-Funktion zu berechnen. Dazu stellen wir die Ableitung der Funktion  $x \mapsto \arctan(x)$  durch eine geometrische Reihe dar:

$$\frac{d}{dx}\arctan(x) = \frac{1}{1+x^2} = \sum_{n=0}^{\infty} (-x^2)^n = \sum_{n=0}^{\infty} (-1)^n \cdot x^{2 \cdot n}.$$

Die Ableitung der Taylor-Reihe muss diese Reihe ergeben und außerdem muss die Reihe an der Stelle 0 den Wert 0 haben, denn es gilt  $\arctan(0) = 0$ . Damit finden wir

$$\arctan(x) = \sum_{n=0}^{\infty} (-1)^n \cdot \frac{x^{2 \cdot n + 1}}{2 \cdot n + 1}$$
 (6.23)

Da  $\tan\left(\frac{\pi}{4}\right)=1$ , also  $\arctan(1)=\frac{\pi}{4}$  ist, haben wir die Formel

$$\frac{\pi}{4} = \sum_{n=0}^{\infty} (-1)^n \cdot \frac{1}{2 \cdot n + 1} = 1 - \frac{1}{3} + \frac{1}{5} - \frac{1}{7} + \frac{1}{9} \pm \cdots$$
 (6.24)

gefunden. Für einen vollständigen Beweis dieser Formel müssten wir den Abbruch-Fehler nach der Lagrange'schen Formel berechnen. Das würde uns jetzt allerdings zu viel Zeit kosten.

## 6.2.3 Berechnung von $\pi^*$

Zur effizienten Berechnung von  $\pi$  ist die Formel (6.24) nicht geeignet. Aus dem Beweis des Kriteriums von Leibniz für die Konvergenz alternierender Summen folgt, dass der Abbruch-Fehler durch das erste weggelassene Glied abgeschätzt werden kann. Für die obige Formel heißt das, dass der Abbruch-Fehler wie folgt abgeschätzt werden kann:

$$\left| \arctan(x) - \sum_{k=0}^{n} (-1)^k \cdot \frac{1}{2 \cdot k + 1} \right| \le \frac{1}{2 \cdot (n+1) + 1}$$

Überlegen wir, wie viele Glieder der Summe benötigt werden, um  $\frac{\pi}{4}$  auf eine Genauigkeit von  $10^{-9}$  zu berechnen. Dann muss n die folgende Ungleichung erfüllen:

$$\frac{1}{2 \cdot n + 3} \leq 10^{-9}$$

$$\Leftrightarrow 2 \cdot n + 3 \geq 10^{9}$$

$$\Leftrightarrow n \geq 0.5 \cdot (10^{9} - 3)$$

$$\Leftrightarrow n \geq 499 999 998.5$$

$$\Leftarrow n \geq 499 999 999$$

Wir müssten wir also etwa 500 Millionen Terme aufsummieren um die geforderte Genauigkeit zu erreichen. Um eine Formel zu erhalten, die schneller konvergiert, gehen wir von den Additions-Theoremen von Sinus und Cosinus aus. Diese lauten:

$$\begin{split} \sin(\alpha+\beta) &= \sin(\alpha) \cdot \cos(\beta) + \cos(\alpha) \cdot \sin(\beta) \quad \text{ und} \\ \cos(\alpha+\beta) &= \cos(\alpha) \cdot \cos(\beta) - \sin(\alpha) \cdot \sin(\beta). \end{split}$$

Teilen wir die erste Gleichung durch die zweite Gleichung, so folgt

$$\frac{\sin(\alpha+\beta)}{\cos(\alpha+\beta)} = \frac{\sin(\alpha)\cdot\cos(\beta) + \cos(\alpha)\cdot\sin(\beta)}{\cos(\alpha)\cdot\cos(\beta) - \sin(\alpha)\cdot\sin(\beta)}.$$

Da  $\tan(x) = \frac{\sin(x)}{\cos(x)}$  ist, können wir die linke Seite dieser Gleichung durch  $\tan(\alpha + \beta)$  ersetzen. Auf der rechten Seite der Gleichung kürzen wir durch  $\cos(\alpha) \cdot \cos(\beta)$ . Dann erhalten wir

$$\tan(\alpha + \beta) = \frac{\frac{\sin(\alpha)}{\cos(\alpha)} + \frac{\sin(\beta)}{\cos(\beta)}}{1 - \frac{\sin(\alpha)}{\cos(\alpha)} \cdot \frac{\sin(\beta)}{\cos(\beta)}}.$$

Ersetzen wir hier noch die Brüche der Form  $\frac{\sin(x)}{\cos(x)}$  durch  $\tan(x)$ , so haben wir das Additions-Theorem für den Tangens gefunden:

$$\tan(\alpha + \beta) = \frac{\tan(\alpha) + \tan(\beta)}{1 - \tan(\alpha) \cdot \tan(\beta)}$$
(6.25)

In dieser Formel setzen wir  $\alpha = \arctan(x)$  und  $\beta = \arctan(y)$  ein und erhalten

$$\tan(\arctan(x) + \arctan(y)) = \frac{\tan(\arctan(x)) + \tan(\arctan(y))}{1 - \tan(\arctan(x)) \cdot \tan(\arctan(y))}$$

Nehmen wir nun von beiden Seiten dieser Gleichung den Arkustangens und berücksichtigen, dass  $\tan(\arctan(x)) = x$  und  $\tan(\arctan(y)) = y$  gilt, so erhalten wir das Additions-Theorem für den

Arkustangens:

$$\arctan(x) + \arctan(y) = \arctan\left(\frac{x+y}{1-x\cdot y}\right)$$
 (6.26)

Hier setzen wir nun y := x. Das liefert

$$2 \cdot \arctan(x) = \arctan\left(\frac{2 \cdot x}{1 - x^2}\right)$$

Wir wollen  $\arctan(1)$  berechnen. Daher wählen wir x so, dass Folgendes gilt:

$$\frac{2 \cdot x}{1 - x^2} = 1$$

$$\Leftrightarrow 2 \cdot x = 1 - x^2$$

$$\Leftrightarrow x^2 + 2 \cdot x + 1 = 2$$

$$\Leftarrow x = \sqrt{2} - 1$$

Wir können also  $x=\sqrt{2}-1$  wählen und dann  $\pi$  nach der Formel

$$\pi = 4 \cdot \arctan(1) = 8 \cdot \arctan(\sqrt{2} - 1) = 8 \cdot \sum_{n=0}^{\infty} (-1)^n \cdot \frac{(\sqrt{2} - 1)^{2 \cdot n + 1}}{2 \cdot n + 1}$$
(6.27)

berechnen. Wegen  $\sqrt{2}-1\approx 0.4142$  konvergiert diese Reihe recht gut. Um auszurechnen, wie viele Glieder benötigt werden um  $\pi$  auf eine Genauigkeit von  $10^{-9}$  zu berechnen, schätzen wir den Abbruch-Fehler mit dem Leibniz-Kriterium ab, wobei wir zur Vereinfachung den Nenner  $2\cdot n+1$  durch 1 abschätzen:

$$8 \cdot \left(\sqrt{2} - 1\right)^{2 \cdot (n+1)+1} \leq 10^{-9}$$

$$\Leftrightarrow \ln(8) + (2 \cdot n + 3) \cdot \ln(\sqrt{2} - 1) \leq -9 \cdot \ln(10)$$

$$\Leftrightarrow (2 \cdot n + 3) \cdot \ln(\sqrt{2} - 1) \leq -9 \cdot \ln(10) - \ln(8)$$

$$\Leftrightarrow 2 \cdot n + 3 \geq -\frac{9 \cdot \ln(10) + \ln(8)}{\ln(\sqrt{2} - 1)}$$

$$\Leftrightarrow n \geq -0.5 \cdot \left(\frac{9 \cdot \ln(10) + \ln(8)}{\ln(\sqrt{2} - 1)} + 3\right) \approx 11.4$$

Also reicht es sicher aus, die ersten 12 Glieder der Summe zu berücksichtigen um  $\pi$  auf eine Genauigkeit von  $10^{-9}$  zu berechnen. Führen wir die Rechnung durch, so finden wir

$$\pi \approx \sum_{k=0}^{12} (-1)^k \cdot \frac{(\sqrt{2}-1)^{2 \cdot k+1}}{2 \cdot k+1} \approx 3.141592653601609.$$

Der tatsächliche Fehler ist hier kleiner als  $2 \cdot 10^{-11}$ .

#### Die Machin'sche Formel\*

Es gibt noch eine elegantere Möglichkeit, die Kreiszahl  $\pi$  mit Hilfe des Arkustangens zu berechnen. Es gilt nämlich die Machin'sche Formel (John Machin, 1686 – 1751):

$$\boxed{\frac{\pi}{4} = 4 \cdot \arctan\left(\frac{1}{5}\right) - \arctan\left(\frac{1}{239}\right)}$$

**Beweis**: Wegen  $\frac{\pi}{4} = \arctan(1)$  ist die Machin'sche Formel äquivalent zu

$$\arctan(1) = 4 \cdot \arctan\left(\frac{1}{5}\right) - \arctan\left(\frac{1}{239}\right).$$

Wir addieren auf beiden Seiten dieser Gleichung den Wert  $\arctan(\frac{1}{239})$  und sehen dann, dass die Machin'sche Gleichung zu der Gleichung

$$\arctan(1) + \arctan\left(\frac{1}{239}\right) = 4 \cdot \arctan\left(\frac{1}{5}\right).$$

äquivalent ist. Wir wenden nun auf beiden Seiten dieser Gleichung das Additions-Theorem des Arkustangens an und finden

$$\arctan\left(\frac{1+\frac{1}{239}}{1-\frac{1}{239}}\right) = 2 \cdot \arctan\left(\frac{\frac{2}{5}}{1-\frac{1}{25}}\right)$$

Dies vereinfachen wir zu

$$\arctan\left(\frac{240}{238}\right) = 2 \cdot \arctan\left(\frac{10}{24}\right)$$

Kürzen liefert

$$\arctan\left(\frac{120}{119}\right) = 2 \cdot \arctan\left(\frac{5}{12}\right)$$

Hier können wir auf der rechten Seite das Additions-Theorem des Arkustangens ein zweites Mal anwenden und finden

$$\arctan\left(\frac{120}{119}\right) = \arctan\left(\frac{\frac{10}{12}}{1 - \frac{25}{12} \cdot \frac{25}{12}}\right)$$

Elementare Bruchrechnung zeigt die Gültigkeit der Gleichung

$$\frac{\frac{10}{12}}{1 - \frac{25}{12} \cdot \frac{25}{12}} = \frac{120}{119}.$$

Damit haben wir die Machin'sche Formel bewiesen.

**Aufgabe 54**\*: Leiten Sie die folgende Formel aus dem Additions-Theorem des Arcus-Tangens her und berechnen Sie damit  $\pi$  auf eine Genauigkeit von  $10^{-9}$ :

$$\frac{\pi}{4} = 2 \cdot \arctan\left(\frac{1}{2}\right) - \arctan\left(\frac{1}{7}\right).$$

# 6.3 Polynom-Interpolation

Nach dem wir uns im letzten Abschnitt damit beschäftigt haben für eine gegebene Funktion f eine Folge von Polynomen zu konstruieren, deren Ableitungen im Punkt 0 mit der Funktion f übereinstimmen, zeigen wir jetzt, wie sich Polynome konstruieren lassen, die mit einer Funktion f an vorgegebenen Punkten übereinstimmen. Sind n+1 Paare der Form

$$\langle x_0, y_0 \rangle$$
,  $\langle x_1, y_1 \rangle$ ,  $\cdots$ ,  $\langle x_n, y_n \rangle$ 

gegeben, so besteht die Aufgabe der Polynom-Interpolation darin, ein Polynom p(x) vom Grad n zu finden, so dass

$$\forall i \in \{0, 1, \cdots, n\} : p(x_i) = y_i$$

gilt. Wir zeigen nun, dass diese Aufgabe lösbar ist: Zu einer gegebenen Liste von n+1 verschiedenen  $St \ddot{u}tzstellen$ 

$$[x_0,x_1,\cdots,x_n]$$

definieren wir das k-te Lagrange'sche Polynom (Joseph-Louis Lagrange, 1736 – 1813) vom Grad n für alle  $k \in \{0, 1, \dots, n\}$  wie folgt:

$$L_k([x_0, \cdots, x_n]; x) := \prod_{\substack{i=0 \ i \neq k}}^n \frac{x - x_i}{x_k - x_i}$$
(6.28)

Für die Folge der Stützstellen [-1,0,1] lauten die Lagrange'schen Polynome beispielsweise

1. 
$$L_0([-1,0,1];x) := \frac{(x-0)\cdot(x-1)}{(-1-0)\cdot(-1-1)} = \frac{1}{2}\cdot x^2 - \frac{1}{2}\cdot x$$

2. 
$$L_1([-1,0,1];x) := \frac{(x-(-1))\cdot(x-1)}{(0-(-1))\cdot(0-1)} = -x^2+1$$

3. 
$$L_2([-1,0,1];x) := \frac{(x-(-1))\cdot(x-0)}{(1-(-1))\cdot(1-0)} = \frac{1}{2}\cdot x^2 + \frac{1}{2}\cdot x$$

Ist eine Liste  $[x_0,x_1,\cdots,x_n]$  von n+1 verschiedenen Stützstellen gegeben, so haben die Lagrange'schen Polynome eine sehr nützliche Eigenschaft. Um diese Eigenschaft einfacher schreiben zu können, definieren wir für natürliche Zahlen j und k das Kronecker-Delta (Leopold Kronecker, 1823 – 1891) wie folgt:

$$\delta_{k,j} = \begin{cases} 1 & \text{falls} \quad j = k; \\ 0 & \text{falls} \quad j \neq k. \end{cases}$$
 (6.29)

Damit gilt nun

$$L_k([x_0, x_1, \cdots, x_n]; x_j) = \delta_{k,j}.$$
 (6.30)

Diese Eigenschaft werden wir durch einfaches Nachrechnen bestätigen. Wir betrachten die Fälle j=k und  $j\neq k$  getrennt:

1. Fall: j = k. Dann haben wir

$$L_k([x_0, \dots, x_n]; x_k) = \prod_{\substack{i=0\\i\neq k}}^n \frac{x_k - x_i}{x_k - x_i} = 1 = \delta_{k,k}$$

2. Fall:  $j \neq k$ . Dann haben wir

$$L_{k}([x_{0}, \cdots, x_{n}]; x_{j}) = \prod_{\substack{i=0\\i\neq k}}^{n} \frac{x_{j} - x_{i}}{x_{k} - x_{i}}$$

$$= \frac{(x_{j} - x_{0}) \cdot \dots \cdot (x_{j} - x_{j}) \cdot \dots \cdot (x_{j} - x_{n})}{(x_{k} - x_{0}) \cdot \dots \cdot (x_{k} - x_{j}) \cdot \dots \cdot (x_{k} - x_{n})} = 0 = \delta_{j,k},$$

denn für  $j \neq k$  enthält das Produkt

$$\prod_{\substack{i=0\\i\neq k}}^n x_j - x_i$$

den Faktor  $x_j - x_j$  und ist damit gleich 0. Die Eigenschaft (6.30) macht es jetzt einfach, Polynome zu konstruieren, die an den Stützstellen  $x_0, x_1, \dots, x_n$  die vorgegebenen Werte  $y_0, y_1, \dots, y_n$  annehmen.

Wir definieren

$$p(x) := \sum_{k=0}^{n} y_k \cdot L_k(x).$$

Dann gilt  $p(x_j) = y_j$  für alle  $j = 0, 1, \dots, n$ , denn wir haben

$$p(x_j) = \sum_{k=0}^{n} y_k \cdot L_k(x_j) = \sum_{k=0}^{n} y_j \cdot \delta_{j,k} = y_j \cdot \delta_{j,j} = y_j.$$

Also löst das oben definierte Polynom p(x) das Interpolations-Problem

$$\langle x_0, y_0 \rangle$$
,  $\langle x_1, y_1 \rangle$ ,  $\cdots$ ,  $\langle x_n, y_n \rangle$ .

**Beispiel**: Wollen wir ein Polynom p(x) konstruieren, welches das Interpolations-Problem

$$\langle -1, 1 \rangle$$
,  $\langle 0, 0 \rangle$  und  $\langle 1, 1 \rangle$ 

löst, so können wir mit den oben gefundenen Lagrange'schen Polynomen das Polynom p(x) wie folgt definieren:

$$p(x) = 1 \cdot L_0([-1,0,1];x) + 0 \cdot L_1([-1,0,1];x) + 1 \cdot L_2([-1,0,1];x)$$

$$= (\frac{1}{2} \cdot x^2 - \frac{1}{2} \cdot x) + (\frac{1}{2} \cdot x^2 + \frac{1}{2} \cdot x)$$

$$= x^2$$

**Aufgabe 55**: Bei einer Klausur können insgesamt n Punkte erreicht werden. Bestimmen Sie ein Polynom p(x) vom Grade 1, so dass

$$p(n) = 1.0 \quad \text{und} \quad p\left(\frac{n}{2}\right) = 4.0$$

gilt. Hat ein Teilnehmer einer Klausur k von n Punkten erreicht, so ist p(k) die Note, mit der die Leistung bewertet wird. Falls p(k) > 5, 0 ist, wird die Leistung mit der Note 5, 0 bewertet.

### 6.3.1 Interpolation nach Newton\*

Bei der Rechnung mit den oben definierten Lagrange'schen Polynomen tritt in der Praxis ein Problem auf. Hat man für eine gegebene Zahl von Stützstellen das Interpolations-Problem gelöst und erhält man nun eine zusätzliche Stützstelle, so ist es erforderlich, alle Lagrange'schen Polynome noch einmal zu berechnen, denn die Lagrange'schen Polynome vom Grad n+1 haben mit den Lagrange'schen Polynomen vom Grad n nur wenig zu tun. Hier ist der Ansatz von Newton besser geeignet. Bei dem Newton'schen Ansatz schreibt sich ein Interpolations-Polynom vom Grad n in der Form

$$p_n(x) = \sum_{k=0}^{n} c_k \cdot \prod_{i=0}^{k-1} (x - x_i)$$

$$= c_0 + c_1 \cdot (x - x_0) + c_2 \cdot (x - x_0) \cdot (x - x_1) + \dots + c_n \cdot \prod_{i=0}^{n-1} (x - x_i)$$
(6.31)

Der Vorteil dieses Ansatzes besteht darin, dass das Newton'sche Interpolations-Polynom vom Grad n+1 unmittelbar aus dem Newton'schen Interpolations-Polynom vom Grad n wie folgt hervorgeht:

$$p_{n+1}(x) = p_n(x) + c_{n+1} \cdot \prod_{i=0}^{n} (x - x_i).$$

Ist eine Interpolations-Aufgabe

$$\langle x_0, y_0 \rangle$$
,  $\langle x_1, y_1 \rangle$ ,  $\cdots$ ,  $\langle x_n, y_n \rangle$ ,

gegeben, so können die Koeffizienten  $c_k$  für  $k=0,1,\cdots,n$  der Reihe nach wie folgt berechnet werden.

1. Um  $c_0$  zu bestimmen, setzen wir in Gleichung (6.31) für x den Wert  $x_0$  ein. Dann fallen alle Terme bis auf den ersten Term weg und wir erhalten

$$y_0 = c_0$$
.

2. Um  $c_1$  zu bestimmen, setzen wir in Gleichung (6.31) für x den Wert  $x_1$  ein. Dann fallen alle Terme bis auf die ersten beiden Term weg und wir erhalten

$$y_1 = c_0 + c_1 \cdot (x_1 - x_0).$$

Setzen wir hier für  $c_0$  den im letzten Schritt gefundenen Wert  $y_0$  ein, so finden wir

$$c_1 = \frac{y_1 - y_0}{x_1 - x_0}.$$

3. Um  $c_2$  zu bestimmen, setzen wir in Gleichung (6.31) für x den Wert  $x_2$  ein. Dann fallen alle Terme bis auf die ersten drei Terme weg und wir erhalten

$$y_2 = c_0 + c_1 \cdot (x_2 - x_0) + c_2 \cdot (x_2 - x_0) \cdot (x_2 - x_1).$$

Hier setzen wir für  $c_0$  und  $c_1$  die in den letzten Schritten gefundenen Werte ein und haben dann

$$y_{2} = y_{0} + \frac{y_{1} - y_{0}}{x_{2} - x_{0}} \cdot (x_{2} - x_{0}) + c_{2} \cdot (x_{2} - x_{0}) \cdot (x_{2} - x_{1})$$

$$y_{2} - y_{0} = \frac{y_{1} - y_{0}}{x_{2} - x_{0}} \cdot (x_{2} - x_{0}) + c_{2} \cdot (x_{2} - x_{0}) \cdot (x_{2} - x_{1})$$

$$\frac{y_{2} - y_{0}}{x_{2} - x_{0}} = \frac{y_{1} - y_{0}}{x_{2} - x_{0}} + c_{2} \cdot (x_{2} - x_{1})$$

$$\frac{y_{2} - y_{0}}{x_{2} - x_{0}} - \frac{y_{1} - y_{0}}{x_{2} - x_{0}} = c_{2} \cdot (x_{2} - x_{1})$$

$$\frac{y_{2} - y_{0}}{x_{2} - x_{1}} - \frac{y_{1} - y_{0}}{x_{2} - x_{0}} = c_{2}$$

Die obige Rechnung gibt Anlass zur Definition der sogenannten dividierten Differenzen vom Rang k, die wir jetzt für alle  $k=1,\cdots,n$  durch Induktion über k definieren.

I.A.: k = 1. Für alle  $i = 0, \dots, n$  setzen wir

$$[x_k]_{\mathrm{dd}} := y_k.$$

I.S.:  $k \mapsto k+1$ . Für  $i=0,\cdots,n-k$  setzen wir

$$[x_i, x_{i+1}, \cdots, x_{i+k}]_{\mathrm{dd}} := \frac{[x_{i+1}, \cdots, x_{i+k}]_{\mathrm{dd}} - [x_i, \cdots, x_{i+k-1}]_{\mathrm{dd}}}{x_{i+k} - x_i}.$$

Die dividierten Differenzen der Ordnung k+1 berechnen sich also aus den dividierten Differenzen der Ordnung k durch Bildung einer Differenz und einer anschließenden Division. Dieser Umstand erklärt ihren Namen. Für die Koeffizienten  $c_k$  in dem Newton'schen Ansatz (6.31) gilt nun

$$c_k = [x_0, x_1, \dots, x_k]_{dd},$$
(6.32)

das Interpolations-Problem ein Polynom p(x) zu finden, für das

$$p(x_0) = y_0$$
,  $p(x_1) = y_1$ ,  $\cdots$  und  $p(x_n) = y_n$ 

gilt, wird also durch das Polynom

$$p(x) = \sum_{k=0}^{n} [x_0, x_1, \dots, x_k]_{dd} \cdot \prod_{i=0}^{k-1} (x - x_i)$$
(6.33)

gelöst.

## 6.3.2 Der Interpolations-Fehler

Wir untersuchen als nächstes, wie groß der Fehler bei der Polynom-Interpolation werden kann. Dazu beweisen wir zunächst den folgenden Hilfs-Satz. Dieser Satz ist eine Verallgemeinerung des Satzes von Rolle (Satz 71).

**Satz 86** Ist  $f: \mathbb{R} \to \mathbb{R}$  eine Funktion, die n-mal differenzierbar ist und die außerdem n+1 verschiedene Null-Stellen

$$x_0 < x_1 < \cdots < x_n$$

hat, so gibt es ein  $\xi \in [x_0, x_n]$  mit  $f^{(n)}(\xi) = 0$ .

**Beweis**: Wir zeigen, dass für alle  $k=0,1,\cdots,n$  die k-te Ableitung  $f^{(k)}(x)$  in dem Intervall  $[x_0,x_n]$  mindestens n+1-k verschiedene Nullstellen hat. Diesen Nachweis führen wir durch Induktion über k.

I.A.: k=0. Es gilt  $f^{(0)}(x)=f(x)$  und da die Funktion f nach Voraussetzung n+1 verschiedene Nullstellen hat, folgt die Behauptung.

I.S.:  $k \mapsto k+1$ . Nach Induktions-Voraussetzung hat die Funktion  $f^{(k)}(x)$  mindestens n+1-k verschiedene Nullstellen. Nehmen wir an, diese Nullstellen seien der Größe nach geordnet als

$$y_1 < y_2 < \cdots y_{n+1-k}.$$

Wegen  $k+1 \leq n$  ist die Funktion  $f^{(k)}(x)$  nach Voraussetzung differenzierbar und nach dem Satz von Rolle hat die Ableitung dieser Funktion jeweils zwischen zwei Nullstellen  $y_i$  und  $y_{i+1}$  eine Nullstelle, für  $i=1,\cdots,n-k-1$  gibt es also  $z_i\in (y_i,y_{i+1})\subseteq [x_0,x_n]$  mit

$$\frac{\mathrm{d}}{\mathrm{d}x}f^{(k)}(z_i) = f^{(k+1)}(z_i) = 0.$$

Setzen wir in der gerade bewiesenen Behauptung für k den Wert n ein, so sehen wir, dass die Funktion  $f^{(n)}(x)$  in dem Interval  $[x_0,x_n]$  mindestens n+1-n=1 Nullstelle hat, also gibt es das gesuchte  $\xi\in[x_0,x_n]$ .

**Aufgabe 56**: Es sei p(x) ein Polynom vom Grad  $n \ge 1$ . Zeigen Sie, dass p(x) höchstens n verschiedene Nullstellen hat. Folgern Sie daraus, dass es zu n gegebenen Paaren

$$\langle x_0, y_0 \rangle$$
,  $\langle x_1, y_1 \rangle$ ,  $\cdots$ ,  $\langle x_n, y_n \rangle$ ,

genau ein Polynom p(x) vom Grad  $\leq n$  gibt, so dass  $p(x_i) = y_i$  für alle  $i = 0, 1, \dots, n$  gilt.

**Satz 87** Ist die Funktion  $f: \mathbb{R} \to \mathbb{R}$  mindestens (n+1)-mal differenzierbar, ist p(x) eine Polynom vom Grad kleiner gleich n, sind  $x_0 < x_1 < \cdots < x_n$  Punkte mit

$$f(x_i) = p(x_i)$$
 für alle  $i = 0, 1, \dots, n$ ,

und ist  $\bar{x} \in [x_0, x_n]$ , so gibt es ein  $\zeta \in [x_0, x_n]$ , so dass für den Interpolations-Fehler  $f(\bar{x}) - p(\bar{x})$  gilt:

$$f(\bar{x}) - p(\bar{x}) = \frac{f^{(n+1)}(\zeta)}{(n+1)!} \cdot \prod_{i=0}^{n} (\bar{x} - x_i).$$

**Beweis**: Falls  $\bar{x} \in \{x_0, x_1, \cdots, x_n\}$  ist, dann folgt sofort  $f(\bar{x}) - p(\bar{x}) = 0$  und da dann auch

$$\prod_{i=0}^{n} (\bar{x} - x_i) = 0$$

gilt, ist die Behauptung in diesem Fall offensichtlich. Andernfalls definieren wir die Funktion

$$g(x) := f(x) - p(x) - \left(\prod_{i=0}^{n} \frac{x - x_i}{\bar{x} - x_i}\right) \cdot \left(f(\bar{x}) - p(\bar{x})\right).$$

Mit f ist auch die Funktion g mindestens (n+1)-mal differenzierbar. Außerdem gilt wegen  $p(x_k) = f(x_k)$  für alle  $k = 0, 1, \dots, n$ 

$$g(x_k) = f(x_k) - p(x_k) - \left(\prod_{i=0}^n \frac{x_k - x_i}{\bar{x} - x_i}\right) \cdot (f(\bar{x}) - p(\bar{x})) = 0,$$

denn der Faktor  $x_k - x_i$  verschwindet im Falle i = k. Außerdem haben wir

$$g(\bar{x}) = f(\bar{x}) - p(\bar{x}) - \left(\prod_{i=0}^{n} \frac{\bar{x} - x_i}{\bar{x} - x_i}\right) \cdot \left(f(\bar{x}) - p(\bar{x})\right)$$

$$= f(\bar{x}) - p(\bar{x}) - 1 \cdot \left(f(\bar{x}) - p(\bar{x})\right)$$

$$= 0.$$

Damit hat die Funktion insgesamt n+2 verschiedene Nullstellen. Wenden wir jetzt auf die Funktion g den eben gezeigten Hilfs-Satz an, so finden wir ein  $\zeta \in [x_0, x_n]$  mit

$$q^{(n+1)}(\zeta) = 0.$$

Wir bilden die (n+1)-te Ableitung von g und finden

$$g^{(n+1)}(x) = f^{(n+1)}(x) - 0 - (n+1)! \cdot \left(\prod_{i=0}^{n} \frac{1}{\bar{x} - x_i}\right) \cdot \left(f(\bar{x}) - p(\bar{x})\right),\tag{6.34}$$

denn die (n+1)-te Ableitung eines Polynoms vom Grad n ist 0 und die (n+1)-te Ableitung des Polynoms

$$\prod_{i=0}^{n} \frac{x - x_i}{\bar{x} - x_i}$$

ist (n+1)! mal der Koeffizient der Potenz  $x^{n+1}$ . Setzen wir in Gleichung (6.34) die Nullstelle  $\zeta$  ein, so finden wir

$$0 = f^{(n+1)}(\zeta) - (n+1)! \cdot \left( \prod_{i=0}^{n} \frac{1}{\bar{x} - x_i} \right) \cdot \left( f(\bar{x}) - p(\bar{x}) \right)$$

$$\Leftrightarrow (n+1)! \cdot \left( \prod_{i=0}^{n} \frac{1}{\bar{x} - x_i} \right) \cdot \left( f(\bar{x}) - p(\bar{x}) \right) = f^{(n+1)}(\zeta)$$

$$\Leftrightarrow f(\bar{x}) - p(\bar{x}) = \frac{f^{(n+1)}(\zeta)}{(n+1)!} \cdot \prod_{i=0}^{n} (\bar{x} - x_i).$$

**Aufgabe 57**: Für die Funktion  $x\mapsto\sin(x)$  soll im Intervall  $\left[0,\frac{\pi}{2}\right]$  ein Tabelle erstellt werden, so dass der bei linearer Interpolation entstehende Interpolations-Fehler kleiner als  $10^{-5}$  ist. Das Intervall  $\left[0,\frac{\pi}{2}\right]$  soll zu diesem Zweck in gleich große Intervalle aufgeteilt werden. Berechnen Sie die Anzahl der Einträge, die für die Erstellung der Tabelle notwendig ist.

# 6.4 Der Banach'sche Fixpunkt-Satz

Der Banach'sche Fixpunkt-Satz, der 1922 von Stefan Banach (1892 – 1945) bewiesen wurde, ist ein wichtiges Hilfsmittel zur Lösung von Gleichungen. Wir werden den Banach'schen Fixpunkt-Satz nur für den Spezialfall der reellen Zahlen formulieren und beweisen. In der Mathematik wird dieser Satz in einem abstrakteren Rahmen verwendet, die Menge der reellen Zahlen wird dann durch einen *vollständigen metrischen Raum* ersetzt.

Bevor wir den Banach'schen Fixpunkt-Satz formulieren und beweisen, wollen wir das damit verbundene Fixpunkt-Verfahren motivieren. Wir haben bereits einmal ein solches Verfahren angewendet: In dem Kapitel 3 über Folgen und Reihen hatten wir die Gleichung

$$x = \cos(x)$$

mit Hilfe eines Fixpunkt-Verfahrens gelöst. Wir hatten damals induktiv eine Folge  $(x_n)_{n\in\mathbb{N}^*}$  definiert, indem wir  $x_1:=0$  und  $x_{n+1}:=\cos(x_n)$  definiert hatten. Das in Abbildung 3.1 auf Seite 25 gezeigte Programm berechnet die Folge  $(x_n)_{n\in\mathbb{N}^*}$  und wir hatten gesehen, dass diese Folge gegen einen Grenzwert

$$\bar{x} := \lim_{n \to \infty} x_n$$

konvergiert, der wegen

$$\cos(\bar{x}) = \cos\left(\lim_{n \to \infty} x_n\right) = \lim_{n \to \infty} \cos(x_n) = \lim_{n \to \infty} x_{n+1} = \bar{x}$$

auch eine Lösung der Fixpunkt-Gleichung  $x=\cos(x)$  ist. Wir wollen dieses Verfahren nun verallgemeinern. Wir nehmen dazu an, dass eine stetige Funktion f gegeben ist und wir eine Lösung der Fixpunkt-Gleichung

$$x = f(x)$$

iterativ bestimmen wollen, indem wir induktiv eine Folge  $(x_n)_{n\in\mathbb{N}^*}$  definieren, wobei wir ausgehend von einem weitgehend beliebig gewählten Startwert  $x_1$  die übrigen Folgenglieder  $x_n$  induktiv durch die Festlegung

$$x_{n+1} = f(x_n)$$

definieren. Sollte die Folge  $(x_n)_{n\in\mathbb{N}^*}$  gegen einen Grenzwert  $\bar{x}$  konvergieren, so ist dieser Grenzwert eine Lösung der Fixpunkt-Gleichung x=f(x), denn es gilt

$$f(\bar{x}) = f\left(\lim_{n \to \infty} x_n\right) = \lim_{n \to \infty} f(x_n) = \lim_{n \to \infty} x_{n+1} = \bar{x}.$$

Dabei haben wir bei der Gleichung

$$f\left(\lim_{n\to\infty} x_n\right) = \lim_{n\to\infty} f(x_n)$$

die Stetigkeit von f ausgenutzt. Weniger klar ist die Antwort auf die Frage, wann diese Folge  $\left(x_n\right)_{n\in\mathbb{N}^*}$  konvergiert. Die entscheidende Antwort auf diese Frage hat Stefan Banach gegeben: Wenn die Funktionswerte von f näher beieinander liegen als die Argumente, dann konvergiert die Folge. Bevor wir das im Detail formal untersuchen, wollen wir die dahinter liegende Anschauung verstehen. Nehmen wir an, dass die Fixpunkt-Gleichung f(x)=x eine Lösung  $\bar{x}$  hat und nehmen wir weiter an, dass eine Näherung  $x_1$  für  $\bar{x}$  gegeben ist. Wenn nun die Funktionswerte von f näher beieinander liegen als die Argumente, dann können wir die Näherung  $x_1$  zu einer Näherung  $x_2$  verbessern, indem wir

$$x_2 := f(x)$$

definieren. Warum ist  $x_2$  besser als  $x_1$ ? Um diese Frage zu beantworten, betrachten wir den Abstand von  $x_2$  und  $\bar{x}$ . Es gilt

$$\begin{split} &|x_2-\bar{x}|\\ &=&|f(x_1)-f(\bar{x})|\quad \text{denn } x_2=f(x_1) \text{ und } \bar{x}=f(\bar{x})\\ &<&|x_1-\bar{x}|, \end{split}$$

wobei wir bei der letzten Ungleichung benutzt haben, dass die Funktionswerte von f näher beieinander liegen als die Argumente. Um diese Argumentation wasserdicht zu machen, definieren wir zunächst formal unter welchen Umständen die Funktionswerte einer Funktion näher beieinander liegen als die Argumente. Die nun folgende Definition ist etwas schärfer, als Sie es vielleicht im ersten Moment vermuten würden. Das werden wir später noch diskutieren.

 $\Diamond$ 

#### Definition 88 (kontrahierend)

Eine Funktion  $f:[a,b] \to [a,b]$  ist eine kontrahierende Abbildung wenn es eine reelle Zahl q mit q < 1 gibt, so dass

$$\forall x, y \in [a, b] : |f(x) - f(y)| \le q \cdot |x - y|$$

gilt. Wir bezeichnen die Zahl q als den Kontraktions-Koeffizienten.

Beispiel: Die Funktion

$$\cos: [0,1] \to [0,1]$$

ist eine kontrahierende Abbildung. Zunächst müssen wir uns davon überzeugen, dass diese Funktion wohldefiniert ist. Dazu muss aus  $x \in [0,1]$  folgen, dass auch  $\cos(x) \in [0,1]$  gilt. Dies folgt aus den Gleichungen

$$\cos(0) = 1$$
 und  $\cos(1) \approx 0.54$ 

zusammen mit der Tatsache, dass die Kosinus-Funktion in dem Intervall  $\left[0,1\right]$  monoton fallend ist, denn es gilt

$$\frac{\mathrm{d}}{\mathrm{d}x}\cos(x) = -\sin(x) \quad \text{ und für alle } x \in [0,\pi] \text{ gilt } \sin(x) \ge 0.$$

Seien nun Zahlen  $x,y\in[0,1]$  gegeben. Nach dem Mittelwert-Satz der Differenzial-Rechnung gibt es dann ein  $\zeta\in[x,y]$  mit

$$\frac{\cos(x) - \cos(y)}{x - y} = \cos'(\zeta) = -\sin(\zeta).$$

Die Sinus-Funktion nimmt in dem Intervall [0,1] ihr Maximum in dem Punkt 1 an, es gilt

$$\forall t \in [0, 1] : \sin(t) \le \sin(1) \approx 0.8414709848 \dots \le 0.85.$$

Also haben wir folgende Abschätzung

$$|\cos(x) - \cos(y)| = \sin(\zeta) \cdot |x - y| \le 0.85 \cdot |x - y|$$
 für alle  $x, y \in [0, 1]$ .

Das letzte Beispiel verallgemeinern wir zu einem Satz.

**Satz 89** Ist die Funktion  $f:[a,b] \to [a,b]$  in dem Intervall [a,b] differenzierbar und gibt es eine Zahl q < 1, so dass

$$\forall t \in [a,b] : |f'(t)| \leq q$$

gilt, dann ist die Abbildung f kontrahierend mit dem Kontraktions-Koeffizienten q.

**Beweis**: Es seien  $x,y\in[a,b]$ . Nach dem Mittelwert-Satz der Differenzial-Rechnung gibt es dann ein  $\zeta\in[x,y]$  mit

$$\frac{f(x) - f(y)}{x - y} = f'(\zeta).$$

Nehmen wir auf beiden Seiten dieser Ungleichung den Betrag, so erhalten wir

$$\frac{|f(x) - f(y)|}{|x - y|} = |f'(\zeta)| \le q,$$

denn wir hatten ja vorausgesetzt, dass die Ungleichung |f'(t)| < q für alle  $t \in [a, b]$  gilt. Multiplizieren wir diese Ungleichung mit |x - y|, so erhalten wir

$$|f(x) - f(y)| \le q \cdot |x - y|$$

und nach Definition einer kontrahierenden Abbildung ist das die Behauptung.

 $\Diamond$ 

**Satz 90** Ist  $f:[a,b] \to [a,b]$  eine kontrahierende Abbildung, so ist f auch stetig.

Aufgabe 58: Beweisen Sie den letzten Satz.

**Hinweis**: Verwenden Sie die  $\varepsilon$ - $\delta$ -Definition der Stetigkeit.

#### Satz 91 (Banach'scher Fixpunkt-Satz)

Es sei  $f:[a,b] \to [a,b]$  eine kontrahierende Abbildung mit dem Kontraktions-Koeffizienten q und  $x_0$  sei eine Zahl aus dem Intervall [a,b]. Definieren wir die Folge  $(x_n)_{n\in\mathbb{N}^*}$  induktiv durch

$$x_{n+1} := f(x_n),$$

so konvergiert diese Folge. Setzen wir

$$\bar{x} := \lim_{n \to \infty} x_n$$

so gilt  $f(\bar{x}) = \bar{x}$  und darüber hinaus gilt die Abschätzung

$$\boxed{|x_n - \bar{x}| \le \frac{q^n}{1 - q} \cdot |x_1 - x_0|.}$$

Beweis: Wir starten den Beweis mit einer im ersten Moment skurril anmutenden Formel:

$$x_n - x_0 = (x_n - x_{n-1}) + (x_{n-1} - x_{n-2}) + \dots + (x_2 - x_1) + (x_1 - x_0) = \sum_{i=1}^{n} (x_i - x_{i-1}).$$

Diese Summe wird als *Teleskop-Summe* bezeichnet. Daraus folgt sofort

$$x_n = x_0 + \sum_{i=1}^{n} (x_i - x_{i-1}).$$

Damit gilt dann aber

$$\lim_{n \to \infty} x_n = x_0 + \sum_{i=1}^{\infty} (x_i - x_{i-1}),$$

wenn wir noch zeigen können, dass die auf der rechten Seite dieser Formel auftretende Reihe konvergiert. Dazu zeigen wir, dass die geometrische Reihe eine Majorante dieser Reihe ist. Konkret zeigen wir durch vollständige Induktion, dass für alle  $i \in \mathbb{N}_0$  die Ungleichung

$$|x_{i+1} - x_i| \le q^i \cdot |x_1 - x_0|$$

gilt. Der Induktions-Anfang i=0 ist trivial. Im Induktions-Schritt haben wir

$$|x_{i+2} - x_{i+1}| = |f(x_{i+1}) - f(x_i)| \le q \cdot |x_{i+1} - x_i| \le q \cdot q^i \cdot |x_1 - x_0| = q^{i+1} \cdot |x_1 - x_0|.$$

Nachdem wir jetzt wissen, dass die Folge  $(x_n)_{n\in\mathbb{N}^*}$  konvergiert, zeigen wir, dass der Grenzwert  $\bar{x}$  dieser Folge ein Fixpunkt der Funktion f ist. Da f als kontrahierende Abbildung auch stetig ist, können wir die Anwendung der Funktion f mit der Grenzwert-Bildung vertauschen. Also haben wir

$$f(\bar{x}) = f\left(\lim_{n \to \infty} x_n\right) = \lim_{n \to \infty} f(x_n) = \lim_{n \to \infty} x_{n+1} = \lim_{n \to \infty} x_n = \bar{x}$$

und dies zeigt, dass  $\bar{x}$  ein Fixpunkt der Funktion f ist. Den Abstand zwischen  $\bar{x}$  und  $x_n$  können wir abschätzen, wenn wir  $\bar{x}$  als unendliche Reihe schreiben und gleichzeitig  $x_n$  als Teleskop-Summe darstellen:

$$|\bar{x} - x_n| = \left| x_0 + \sum_{i=1}^{\infty} (x_i - x_{i-1}) - \left( x_0 + \sum_{i=1}^{n} (x_i - x_{i-1}) \right) \right|$$

$$= \left| \sum_{i=n+1}^{\infty} (x_i - x_{i-1}) \right| \leq \sum_{i=n+1}^{\infty} |x_i - x_{i-1}|$$

$$= \sum_{i=n}^{\infty} |x_{i+1} - x_i| \leq \sum_{i=n}^{\infty} q^i \cdot |x_1 - x_0|$$

$$= |x_1 - x_0| \cdot \sum_{i=n}^{\infty} q^i = |x_1 - x_0| \cdot \sum_{i=0}^{\infty} q^{n+i}$$

$$= |x_1 - x_0| \cdot q^n \cdot \sum_{i=0}^{\infty} q^i = |x_1 - x_0| \cdot q^n \cdot \frac{1}{1 - q}$$

Die obige Ungleichungskette zeigt insgesamt die Gültigkeit der Abschätzung

$$|\bar{x} - x_n| \le \frac{q^n}{1 - q} \cdot |x_1 - x_0|$$

und damit ist der Beweis ist abgeschlossen.

Setzen wir in der eben gezeigten Abschätzung für n den Wert 1 ein, so erhalten wir

$$|\bar{x} - x_1| \le \frac{q}{1-q} \cdot |x_1 - x_0|.$$

Wenn wir in dieser Ungleichung  $x_1$  durch  $x_m$  und  $x_0$  durch  $x_{m-1}$  ersetzen, behält die Ungleichung ihre Gültigkeit, denn wir können  $x_{m-1}$  ja als den Startwert einer neuen Folge  $\left(y_n\right)_{n\in\mathbb{N}^*}$  ansehen, für die wir  $y_0=x_{m-1}$  und  $y_1=f(y_0)=f(x_{m-1})=x_m$  setzen. Wir haben dann also

$$||\bar{x} - x_m| \le \frac{q}{1 - q} \cdot |x_m - x_{m-1}|.$$

Wenn wir q kennen, können wir damit die Güte der bisher erreichten Approximation abschätzen.

**Beispiel**: Wir haben oben gesehen, dass die Abbildung  $\cos:[0,1]\to[0,1]$  kontrahierend ist mit einem Kontraktions-Koeffizienten  $q\le 0.85$ . Wollen wir den Fixpunkt dieser Abbildung auf eine Genauigkeit von  $\varepsilon$  berechnen, so müssen wir folglich solange iterieren, bis

$$\frac{q}{1-q} \cdot |x_m - x_{m-1}| \le \varepsilon,$$

und das ist äquivalent zu

$$|x_m - x_{m-1}| \le \frac{1-q}{q} \cdot \varepsilon$$
,

Setzen wir hier q=0.85 und  $\varepsilon=10^{-6}$ , so ist die Abbruchbedingung also

$$|x_m - x_{m-1}| \le \frac{1 - 0.85}{0.85} \cdot 10^{-6} \approx 1.77 \cdot 10^{-7}.$$

Wir können auch die Zahl der Iterationen abschätzen, die notwendig sind um den Fixpunkt mit einer Genauigkeit von  $\varepsilon$  zu berechnen. Wir gehen dazu von der Ungleichung

$$|x_n - \bar{x}| \le \frac{q^n}{1 - q} \cdot |x_1 - x_0|.$$

aus. Starten wir die Fixpunkt-Iteration mit  $x_0 = 0$ , so erhalten wir  $x_1 = \cos(0) = 1$  und damit können wir die Anzahl der Iterationen n abschätzen:

$$|x_n - \bar{x}| \le \varepsilon$$

$$\Leftrightarrow \frac{q^n}{1 - q} \cdot |x_1 - x_0| \le \varepsilon$$

$$\Leftrightarrow \frac{q^n}{1 - q} \cdot |1 - 0| \le \varepsilon$$

$$\Leftrightarrow \frac{q^n}{1 - q} \le \varepsilon$$

$$\Leftrightarrow n \cdot \ln(q) - \ln(1 - q) \le \ln(\varepsilon)$$

$$\Leftrightarrow n \cdot \ln(q) \le \ln(\varepsilon) + \ln(1 - q)$$

$$\Leftrightarrow n \ge \frac{\ln(\varepsilon) + \ln(1 - q)}{\ln(q)}$$

$$\Leftrightarrow n \ge \frac{\ln(10^{-6}) + \ln(1 - 0.85)}{\ln(0.85)}$$

$$\Leftrightarrow n \ge \frac{-6 \cdot \ln(10) + \ln(1 - 0.85)}{\ln(0.85)}$$

$$\Leftrightarrow n \ge \frac{n > 96.7}{n \ge 10}$$

Damit benötigen wir also höchstens 97 Iterationen um die gewünschte Genauigkeit zu erzielen. Wir haben die einzelnen Werte der Folge, die sich bei der iterativen Lösung der Gleichung  $x=\cos(x)$  ergibt, in Tabelle 3.1 auf Seite 25 angegeben. Diese Tabelle zeigt, dass bereits nach 36 Iterationen eine Genauigkeit von  $10^{-6}$  erreicht ist. Der Grund dafür, dass es deutlich schneller ging, als wir mit der obigen Abschätzung berechnet haben, liegt darin, dass der Kontraktions-Koeffizient q den Wert von  $\sin(x)$  in dem Intervall [0,1] abschätzen muss. Da die Sinus-Funktion in diesem Intervall monoton wächst, haben wir den Kontraktions-Koeffizient als  $\sin(1) \approx 0.85$  berechnet. Für die Lösung  $\bar{x}$  der Fixpunkt-Gleichung gilt aber  $\sin(\bar{x}) \approx 0.67$ , so dass der Kontraktions-Koeffizient kleiner wird, je mehr wir uns der Lösung annähern.

**Aufgabe 59**: Lösen Sie für  $y=10^6$  und  $y=10^{-6}$  die Gleichung  $x\cdot \exp(x)=y$  durch eine einfache Fixpunkt-Iteration.

**Hinweis**: Diese Aufgabe ist in erster Linie als Programmier-Aufgabe gedacht. Es ist nicht gefordert, dass Sie den Abbruchfehler untersuchen.

Bemerkung: Bei der Definition einer kontrahierenden Abbildung haben Sie sich vielleicht gewundert, warum es nicht reicht zu fordern, dass

$$|f(x) - f(y)| < |x - y|$$

gilt. Eine Funktion, die nur diese schwächere Bedingung erfüllt, wollen wir als eine

#### schwach kontrahierende Abbildung

bezeichnen. In der Tat kann gezeigt werden, dass auch für eine schwach kontrahierende Abbildung f die Folge  $x_{n+1}:=f(x_n)$  für beliebige Startwerte gegen eine Lösung der Fixpunkt-Gleichung x=f(x) konvergiert. Allerdings ist die Konvergenz unter Umständen nur sehr langsam. Als Beispiel betrachten wir die Funktion  $x\mapsto\sin(x)$ . Offenbar hat die Gleichung  $x=\sin(x)$  bei  $\bar x=0$  einen Fixpunkt. Setzen wir  $x_1:=1$  und berechnen wir die Folge  $x_n$  numerisch, so erhalten wir die in Tabelle 6.1 gezeigten Ergebnisse. Selbst nach  $10^8$  Iterationen haben wir die Lösung der Gleichung  $x=\sin(x)$  erst auf drei Stellen genau berechnet. Der Grund dafür ist, dass die Ableitung der Sinus-Funktion der Cosinus ist, und dieser hat an der Stelle x=0 den Betrag 1. Es ist zwar so, dass die Funktion  $x\mapsto\sin(x)$  schwach kontrahierend ist, aber es gibt kein q<1, so dass für alle  $x,y\in\mathbb{R}$  die Ungleichung

$$|\sin(x) - \sin(y)| \le q \cdot |x - y|$$

 $\Diamond$ 

n	$x_n$
1	0.8414709848078965
10	0.48132935526234627
100	0.1696653247073242
1000	0.05462012602579727
10000	0.017314486231827124
100000	0.005476997236720512
1000000	0.0017320423900648602
10000000	5.477222534834344E-4
100000000	1.7320506994644328E-4

Tabelle 6.1: Werte der durch  $x_{n+1} = \sin(x_n)$  definierten Folge  $(x_n)_{n \in \mathbb{N}^*}$ .

erfüllt ist. Das ist der Grund für die äußerst langsame Konvergenz der Folge  $(x_n)_{n\in\mathbb{N}^*}$ .

## 6.4.1 Beschleunigung der Fixpunkt-Iteration

Auch mit 36 Iterationen ist die Fixpunkt-Iteration bei der Lösung der Gleichung  $x=\cos(x)$  dem Bisektions-Verfahren unterlegen. Wir stellen uns daher die Frage, ob wir die Konvergenz der Fixpunkt-Iteration beschleunigen können. Falls die kontrahierende Abbildung f differenzierbar ist, so ist der Kontraktions-Koeffizient durch den Betrag der Ableitung von f gegeben. Wir überlegen uns daher, wie wir die Abbildung so verändern können, dass sich einerseits der Fixpunkt nicht ändert, aber andererseits der Betrag der Ableitung kleiner wird. Dazu formen wir die Fixpunkt-Gleichung x=f(x) wie folgt um:

$$\begin{array}{rcl} x & = & f(x) & | & + \alpha \cdot x \\ \Leftrightarrow & (1+\alpha) \cdot x & = & f(x) + \alpha \cdot x & | & \cdot \frac{1}{1+\alpha} \\ \Leftrightarrow & x & = & \frac{f(x) + \alpha \cdot x}{1+\alpha} \end{array}$$

Damit haben wir also die Funktion

$$g(x) = \frac{f(x) + \alpha \cdot x}{1 + \alpha}$$

gefunden, welche dieselben Fixpunkte hat wie die ursprüngliche Funktion f. Für die Ableitung gilt

$$g'(x) = \frac{f'(x) + \alpha}{1 + \alpha}$$

Der Betrag diese Ableitung wird für den Fixpunkt  $\bar{x}$  dann am kleinsten, wenn wir

$$\alpha = -f'(\bar{x})$$

wählen. Wählen wir beispielsweise  $\alpha=0.7$ , so finden wir die Lösung der Fixpunkt-Gleichung  $x=\cos(x)$  mit dem Programm in Abbildung 6.1 die in Tabelle 6.2 gezeigten Werte. Wir sehen, dass bereits nach fünf Iterations-Schritten eine Genauigkeit von mehr als  $10^{-6}$  erreicht ist.

Das oben skizzierte Verfahren der Konvergenz-Beschleunigung hat einen Schönheitsfehler: Wir haben  $\alpha$  so gewählt, dass  $f'(\bar{x}) + \alpha$  möglichst klein wird. Das Problem dabei ist, dass wir  $\bar{x}$  gar nicht kennen und daher auch  $f'(\bar{x})$  unbekannt ist. Eine mögliche Lösung besteht darin, dass wir für  $\alpha$  in jedem Schritt  $-f'(x_n)$  einsetzen. Das führt auf folgende Definition für die Folge  $(x_n)_{n\in\mathbb{N}^*}$ :

$$x_{n+1} = \frac{f(x_n) - f'(x_n) \cdot x_n}{1 - f'(x_n)} \tag{6.35}$$

Abbildung 6.2 zeigt ein Programm zur Umsetzung dieser Idee. Hier haben wir die ersten 7 Werte mit Gleichung (6.35) berechnet, die für den Fall  $f(x) = \cos(x)$  die Form

Abbildung 6.1: Berechnung der durch  $x_{n+1} = \frac{\cos(x) + \alpha \cdot x_n}{1 + \alpha}$  definierten Folge.

n	$x_n$	n	$x_n$
1	0.588235294117647	7	0.739085133207671
2	0.731579943641669	8	0.739085133215044
3	0.738956362842702	9	0.739085133215159
4	0.739083130793540	10	0.739085133215161
5	0.739085102132028	11	0.739085133215161
6	0.739085132732678	12	0.739085133215161

Tabelle 6.2: Die ersten 12 Glieder der durch  $x_{n+1} = \frac{\cos(x) + \alpha \cdot x_n}{1+\alpha}$  definierten Folge für  $\alpha = 0.7$ .

$$x_{n+1} := \frac{\cos(x) + \sin(x) \cdot x}{1 + \sin(x)}$$

annimmt. Da diese Gleichung aber komplexer als die ursprüngliche Gleichung  $x_{n+1}=\cos(x_n)$  ist, müssen wir damit rechnen, dass die Rundungsfehler höher sind als bei der Iteration. Zur Eliminierung dieser Rundungsfehler führen wir daher in Zeile 8 noch eine Nach-Iteration mit der Gleichung  $x_{n+1}=\cos(x_n)$  durch. Tabelle 6.3 zeigt die von diesem Programm berechneten Werte. Diesmal ist die Genauigkeit von  $10^{-6}$  bereits nach 4 Schritten erreicht, de facto ist der im vierten Schritt berechnete Wert sogar auf 9 Stellen hinter dem Komma genau.

Abbildung 6.2: Berechnung der durch  $x_{n+1} = \frac{\cos(x_n) + \sin(x_n) \cdot x}{1 + \sin(x_n)}$  definierten Folge.

## 6.4.2 Das Newton'sche Verfahren zur Berechnung von Nullstellen

Oft besteht die Aufgabe darin, eine Nullstelle einer Funktion g(x) zu finden. Dieses Problem ist dazu äquivalent, eine Fixpunkt-Gleichung zu lösen, denn es gilt

$$g(x) = 0 \Leftrightarrow x + g(x) = x.$$

Eine Nullstelle der Funktion g(x) ist also ein Fixpunkt der Funktion f(x) = x + g(x). Setzen wir in Gleichung (6.35) für f(x) die Funktion x + g(x) ein, so erhalten wir wegen

**\rightarrow** 

n	$x_n$
1	1.0
2	0.7503638678402439
3	0.7391128909113617
4	0.7390851333852839
5	0.7390851332151607
6	0.7390851332151607

Tabelle 6.3: Ausgabe des in Abbildung 6.2 gezeigten Programms.

$$\frac{\mathrm{d}}{\mathrm{d}x}(x+g(x)) = 1 + g'(x)$$

die Gleichung

$$x_{n+1} = \frac{x_n + g(x_n) - (1 + g'(x_n)) \cdot x_n}{1 - (1 + g'(x_n))}$$

$$= \frac{x_n + g(x_n) - x_n - g'(x_n) \cdot x_n}{-g'(x_n)}$$

$$= \frac{-g(x_n) + g'(x_n) \cdot x_n}{g'(x_n)}$$

$$= x_n - \frac{g(x_n)}{g'(x_n)}$$

Wir haben also die Iterations-Vorschrift

$$x_{n+1} = x_n - \frac{g(x_n)}{g'(x_n)} \tag{6.36}$$

gefunden. Dieses Verfahren wird als Newton'sches Verfahren (Sir Isaac Newton, 1642 – 1726) bezeichnet. Die Gleichung (6.36) lässt sich geometrisch interpretieren: Legen wir im Punkt  $\langle x_n, g(x_n) \rangle$  eine Tangente an die Funktion g, so schneidet diese Tangente die x-Achse im Punkt

$$x_n - \frac{g(x_n)}{g'(x_n)}$$
.

Der neue Wert  $x_{n+1}$  ist also die Näherung, die wir erhalten, wenn wir die Funktion g durch die Tangente im Punkt  $\langle x_n, g(x_n) \rangle$  ersetzen und dann die Nullstelle dieser Tangente berechnen.

Aufgabe 60: Beweisen Sie diese Behauptung.

**Beispiel**: Als Anwendung des Newton'schen Verfahrens betrachten wir die Berechnung der k-ten Wurzel ( $k \in \mathbb{N}$  mit  $k \ge 2$ ) einer gegebenen Zahl a > 0. Wegen

$$x = \sqrt[k]{a} \Leftrightarrow x^k - a = 0$$

setzen wir  $g(x):=x^k-a$  und bestimmen die Nullstellen der Funktion g(x) mit dem Newton'schen Verfahren. Für die Ableitung der Funktion g(x) finden wir

$$q'(x) = k \cdot x^{k-1}.$$

Damit lautet die Iterations-Vorschrift

$$x_{n+1} = x_n - \frac{x_n^k - a}{k \cdot x_n^{k-1}} = \frac{1}{k} \left( (k-1) \cdot x_n + \frac{a}{x_n^{k-1}} \right).$$

Berechnen wir mit diesem Verfahren die dritte Wurzel aus 2, so lautet die Iterations-Vorschrift

$$x_{n+1} = \frac{1}{3} \cdot \left( 2 \cdot x_n + \frac{2}{x_n^2} \right)$$

Lassen wir die Folge mit 1 starten so finden wir die Werte

und der letzte Wert stimmt im Rahmen der Rechengenauigkeit mit  $\sqrt[3]{2}$  überein.

Das Newton'sche Verfahren ist <u>nicht</u> robust, denn im Allgemeinen konvergiert das Verfahren nicht. Als Beispiel betrachten wir die Funktion

$$g(x) = x^3 - 2 \cdot x + 2.$$

Es gilt  $g(-2)=-8-2\cdot(-2)+2=-2<0$  und  $g(2)=8-2\cdot2+2=6>0$ . Nach dem Zwischenwert-Satz über stetige Funktionen muss die Funktion g daher in dem Intervall [-2,2] eine Nullstelle haben. Das Newton'sche Verfahren ergibt die Formel

$$x_{n+1} = x_n - \frac{x_n^3 - 2 \cdot x_n + 2}{3 \cdot x_n^2 - 2}.$$

Wählen wir als Start-Wert  $x_0 := 0$ , so erhalten wir

$$x_1 = 0 - \frac{2}{-2} = 1.$$

Für  $x_2$  finden wir

$$x_2 = 1 - \frac{1 - 2 + 2}{3 - 2} = 1 - 1 = 0 = x_0.$$

Wir sind also wieder bei unserem Start-Wert angekommen! Damit gilt allgemein

$$x_n = \left\{ \begin{array}{ll} 0 & \text{falls } n \% \, 2 = 0, \\ \\ 1 & \text{falls } n \% \, 2 = 1. \end{array} \right.$$

Folglich konvergiert das Verfahren in diesem Fall nicht. Wählen wir den Startwert  $x_0=-0.5$ , so oszilliert die Folge  $(x_n)_{n\in\mathbb{N}^*}$  für große n ebenfalls zwischen den Werten 0 und 1. Wählen wir den Startwert nahe genug zur gesuchten Lösung, beispielsweise  $x_0=-1.5$ , so konvergiert das Verfahren gegen die Lösung  $-1.769292354238631\cdots$ . Diese Beispiele zeigen, dass das Newton'sche Verfahren ohne weitere Einschränkungen nicht zuverlässig ist.

## 6.4.3 Analyse des Newton'schen Verfahrens

Wir wollen in diesem Abschnitt herausfinden, unter welchen Umständen das Newton'sche Verfahren konvergiert und wollen außerdem die Geschwindigkeit der Konvergenz des Verfahrens untersuchen. Als erstes benötigen wir einen Hilfssatz über konvexe Funktionen.

**Lemma 92** Die Funktion  $f:[a,b]\to\mathbb{R}$  sei zweimal differenzierbar und konvex. Ist  $x_0\in[a,b]$  und definieren wir die lineare Funktion  $g:[a,b]\to\mathbb{R}$  als

$$g(x) := f(x_0) + f'(x_0) \cdot (x - x_0),$$

so ist die Funktion g die Tangente an f im Punkt  $\langle x_0, f(x_0) \rangle$  und es gilt

$$g(x) \le f(x)$$
 für alle  $x \in [a, b]$ .

Anschaulich bedeutet dies, dass die Tangente immer unterhalb einer konvexen Funktion liegt.

Beweis: Zunächst gilt offenbar

$$g(x_0) = f(x_0) + f'(x_0) \cdot (x_0 - x_0) = f(x_0),$$

so dass die Werte der Funktionen f und g im Punkt  $x_0$  übereinstimmen. Für die Ableitung von g(x)

finden wir

$$g'(x) = f'(x_0),$$

so dass die Gerade g dieselbe Steigung hat wie die Funktion f an der Stelle  $x_0$ . Damit ist g aber die Tangente an die Funktion f an der Stelle  $x_0$ . Zum Beweis der Ungleichung  $g(x) \leq f(x)$  definieren wir die Funktion  $h: [a-x_0,b-x_0] \to \mathbb{R}$  als

$$h(x) := f(x + x_0).$$

Brechen wir die Taylor-Entwicklung der Funktion h nach dem linearen Glied ab, so erhalten wir nach der Formel (6.17) die Gleichung

$$h(x) = h(0) + h'(0) \cdot x + \frac{1}{2} \cdot h^{(2)}(\chi) \cdot x^2$$
,

wobei  $\chi$  ein Element des Intervalls  $[a-x_0,b-x_0]$  ist, über das wir sonst nichts wissen. Aufgrund der Gleichungen

$$f(x) = h(x - x_0), \quad h(0) = f(x_0), \quad h'(0) = f'(x_0) \quad \text{und} \quad h^{(2)}(\chi) = f^{(2)}(\chi + x_0),$$

folgt daraus für die Funktion f die Gleichung

$$f(x) = f(x_0) + f'(x_0) \cdot (x - x_0) + \frac{1}{2} \cdot f^{(2)}(\chi + x_0) \cdot (x - x_0)^2.$$

Definieren wir  $\varphi := \chi + x_0$ , so gilt  $\varphi \in [a,b]$  und wir haben

$$f(x) = f(x_0) + f'(x_0) \cdot (x - x_0) + \frac{1}{2} \cdot f^{(2)}(\varphi) \cdot (x - x_0)^2$$
  
=  $g(x) + \frac{1}{2} \cdot f^{(2)}(\varphi) \cdot (x - x_0)^2$   
 $\geq g(x),$ 

denn da wir angenommen hatten, dass die Funktion f zweimal differenzierbar und konvex ist, gilt

$$f^{(2)}(\varphi) > 0$$

und das Quadrat  $(x-x_0)^2$  ist sicher immer größer oder gleich 0.

Satz 93 (Konvergenz des Newtonschen Verfahrens für monotone und konvexe Funktionen)

Die Funktion  $f:[a,b]\to\mathbb{R}$  sei zweimal differenzierbar und konvex, es gelte f(a)<0, f(b)>0 und

$$\forall x \in [a, b] : f'(x) > 0.$$

Falls der Startwert  $x_0 \in [a,b]$  so gewählt wird, dass  $f(x_0)>0$  ist, dann ist die durch das Newton'sche Verfahren definierte Folge  $(x_n)_{n\in\mathbb{N}^*}$  monoton fallend und beschränkt und damit konvergent. Für den Grenzwert  $\bar{x}:=\lim_{n\to\infty}x_n$  gilt  $f(\bar{x})=0$ .

**Beweis**: Nach dem Zwischenwert-Satz hat die Funktion eine Nullstelle  $\xi$  in dem Intervall [a,b]. Da f'(x) für alle  $x \in [a,b]$  echt größer als Null ist, kann f keine zweite Nullstelle haben, denn sonst hätten wir einen Widerspruch zum Satz von Rolle. Also gilt

$$\forall x \in [a, \xi) : f(x) < 0 \quad \text{und} \quad \forall x \in (\xi, b] : f(x) > 0.$$

Wir zeigen zunächst durch Induktion über n, dass

$$f(x_n) \geq 0$$
 für alle  $n \in \mathbb{N}_0$  gilt.

I.A. n = 0.

Die Ungleichung  $f(x_0) > 0$  gilt nach Voraussetzung.  $\sqrt{\phantom{a}}$ 

I.S.  $n \mapsto n+1$ .

Nach der Definition ist  $x_{n+1}$  die Nullstelle der Tangente g an die Funktion f im Punkt  $x_n$ , es gilt also  $g(x_{n+1})=0$ . Nach dem letzten Lemma gilt  $g(x)\leq f(x)$ . Durch Einsetzen von  $x_{n+1}$ 

folgt daraus die Ungleichung

$$0 \le f(x_{n+1}).$$

Damit ist die Induktion abgeschlossen.  $\sqrt{\phantom{a}}$ 

Nach Definition von  $x_{n+1}$  gilt

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}.$$

Einerseits haben wir gerade gezeigt, dass  $f(x_n) \ge 0$  ist, andererseits ist die Voraussetzung, dass für alle  $x \in [a,b]$  die Ungleichung f'(x) > 0 gilt. Daraus folgt aber

$$\frac{f(x_n)}{f'(x_n)} \ge 0$$

und damit gilt

$$x_{n+1} \le x_n$$

Dies zeigt, dass die Folge  $(x_n)_{n\in\mathbb{N}^*}$  monoton fallend ist. Da wir andererseits wissen, dass  $f(x_n)\geq 0$  ist, muss  $x_n\geq \xi$  gelten. Also ist die Folge  $x_n$  durch  $\xi$  nach unten beschränkt. Als monoton fallend und beschränkte Folge hat  $(x_n)_{n\in\mathbb{N}^*}$  damit einen Grenzwert  $\bar{x}$ . Für diesen Grenzwert gilt

$$\bar{x} = \lim_{n \to \infty} x_n$$

$$= \lim_{n \to \infty} x_{n+1}$$

$$= \lim_{n \to \infty} x_n - \frac{f(x_n)}{f'(x_n)}$$

$$= \bar{x} - \frac{f(\bar{x})}{f'(\bar{x})}.$$

Aus der Gleichung

$$\bar{x} = \bar{x} - \frac{f(\bar{x})}{f'(\bar{x})} \quad \text{ folgt sofort } \quad 0 = -\frac{f(\bar{x})}{f'(\bar{x})}$$

und daraus folgt durch Multiplikation mit  $-f'(\bar{x})$  die gesuchte Gleichung  $f(\bar{x})=0$ .

#### Analyse der Konvergenz-Geschwindigkeit

Benutzen wir das Newton'sche Verfahren zur Berechnung von  $\sqrt{2}$ , so erhalten wir die folgenden Ergebnisse:

Wir sehen, dass  $x_2$  auf 2 Stellen hinter dem Komma mit  $\sqrt{2}$  übereinstimmt, bei  $x_3$  sind bereits 5 Stellen richtig,  $x_4$  hat eine Genauigkeit von 11 Stellen,  $x_5$  stimmt auf 24 Stellen mit  $\sqrt{2}$  überein, bei  $x_6$  sind es 48 Stellen und  $x_7$  hat bereits eine Genauigkeit von 100 Stellen. Wir beobachten, dass sich die Zahl der korrekten Stellen mit jeder Operation etwa verdoppelt. Diese Phänomen wollen wir nun genauer untersuchen. Dazu entwickeln wir die Funktion f(x) an der Stelle  $x_n$  in einer Taylor-Reihe, die wir nach dem linearen Glied abbrechen. Wir erhalten

$$f(x) = f(x_n) + f'(x_n) \cdot (x - x_n) + \frac{1}{2} \cdot f^{(2)}(\varphi) \cdot (x - x_n)^2$$

Hier setzen wir für x den Wert  $\bar{x}$ , also die Nullstelle von f ein und erhalten

$$0 = f(x_n) + f'(x_n) \cdot (\bar{x} - x_n) + \frac{1}{2} \cdot f^{(2)}(\varphi) \cdot (\bar{x} - x_n)^2$$

Wir subtrahieren  $f(x_n)$  und teilen anschließend durch  $f'(x_n)$ . Das liefert die Gleichung

$$-\frac{f(x_n)}{f'(x_n)} = \bar{x} - x_n + \frac{1}{2} \cdot \frac{f^{(2)}(\varphi)}{f'(x_n)} \cdot (\bar{x} - x_n)^2$$

Jetzt addieren wir  $x_n$  und subtrahieren  $\bar{x}$ . Das liefert

$$x_n - \frac{f(x_n)}{f'(x_n)} - \bar{x} = \frac{1}{2} \cdot \frac{f^{(2)}(\varphi)}{f'(x_n)} \cdot (\bar{x} - x_n)^2.$$

An dieser Stelle bemerken wir, dass  $x_n - \frac{f(x_n)}{f'(x_n)} = x_{n+1}$  ist und haben damit

$$x_{n+1} - \bar{x} = \frac{1}{2} \cdot \frac{f^{(2)}(\varphi)}{f'(x_n)} \cdot (\bar{x} - x_n)^2.$$

Wir definieren nun  $\varepsilon_n:=|x_n-\bar{x}|$ . Der Wert  $\varepsilon_n$  gibt also den Betrag des Approximations-Fehler an, den wir nach der n-ten Iteration des Newton'schen Verfahrens haben. Damit schreibt sich die letzte Gleichung als

$$\varepsilon_{n+1} = \frac{1}{2} \cdot \left| \frac{f^{(2)}(\varphi)}{f'(x_n)} \right| \cdot \varepsilon_n^2.$$

In den Fällen, in denen wir den Ausdruck  $\frac{1}{2}\cdot\left|\frac{f^{(2)}(\varphi)}{f'(x_n)}\right|$  durch eine Konstante K abschätzen können, haben wir dann

$$\varepsilon_{n+1} \le K \cdot \varepsilon_n^2$$
.

Die Zahl der korrekten Stellen nach der n-ten Iteration ist in etwa durch

$$\lambda_n \approx -\log_{10}(\varepsilon_n)$$

gegeben. Logarithmieren wir die obige Gleichung zur Basis 10 und multiplizieren mit -1, so erhalten wir

$$\lambda_{n+1} \ge 2 \cdot \lambda_n - \log_{10}(K).$$

Zur Konkretisierung unserer Überlegungen betrachten wir wieder die Funktion  $f(x) = x^2 - 2$ . Hier gilt

$$f'(x) = 2 \cdot x \ge 2$$
 falls  $x \ge 1$  ist

und weiter gilt  $f^{(2)}(x) = 2$ . Damit gilt

$$\frac{1}{2} \cdot \left| \frac{f^{(2)}(\varphi)}{f'(x_n)} \right| \le \frac{1}{2}$$

und wegen  $\log_{10}\!\left(\frac{1}{2}\right)\approx-0.3$  haben wir die Abschätzung

$$\lambda_{n+1} = 2 \cdot \lambda_n + 0.3$$

gefunden, die in der Tat zeigt, dass sich die Anzahl der korrekten Stellen bei jedem Schritt mehr als verdoppelt.

**Aufgabe 61**: Analysieren Sie das Newton'sche Verfahren zur Berechnung der dritten Wurzel aus 2 und berechnen Sie, wie viele Iterationen höchstens notwendig sind um den Wert von  $\sqrt[3]{2}$  auf eine Genauigkeit von  $10^{-101}$  zu berechnen.

# 6.5 Iterative Lösung linearer Gleichungs-Systeme\*

Es sei eine  $n \times n$  Matrix  $\mathbf{A} \in \mathbb{R}^{n \times n}$  und ein Vektor  $\vec{b} \in \mathbb{R}^n$  gegeben. Eine Möglichkeit, das Gleichungs-System

$$\mathbf{A}\vec{x} = \vec{b}$$

zu lösen, haben Sie im ersten Semester kennengelernt: Es ist das Gauß'sche Eliminations-Verfahren (Carl Friedrich Gauß, 1777 – 1855). Es gibt allerdings Situationen, in denen dieses Verfahren zu aufwendig ist. Dies ist beispielsweise dann der Fall, wenn einerseits n groß ist und wenn andererseits die meisten Komponenten der Matrix A den Wert 0 haben. Solche Matrizen heißen dünn besetzte Matrizen. Diese Art von Matrizen tritt beispielsweise bei der numerischen Lösung von partiellen Differential-Gleichungen auf. Das Gauß'sche Eliminations-Verfahren besitzt eine Komplexität von  $O(n^3)$  und ist damit für große dünn besetzte Matrizen ungeeignet. Hier ist der Rechenaufwand bei iterative Verfahren geringer. Ein weiteres Problem ist, dass die Rundungsfehler beim Gauß'schen Eliminations-Verfahren sehr groß werden können. Demgegenüber sind iterative Verfahren selbstkorrigierend.

Ist A gegeben, so lautet die Gleichung A  $\vec{x} = \vec{b}$  in Komponenten-Schreibweise

$$\sum_{i=1}^{n} a_{ij} \cdot x_j = b_i \quad \text{ für alle } i = 1, \cdots, n.$$

Die Idee besteht darin, diese Gleichung in eine Fixpunkt-Gleichung zu transformieren. Dazu formen wir die Gleichung wie folgt um:

$$\sum_{j=1}^{n} a_{ij} \cdot x_{j} = b_{i}$$

$$\Leftrightarrow a_{ii} \cdot x_{i} + \sum_{\substack{j=1 \ j \neq i}}^{n} a_{ij} \cdot x_{j} = b_{i}$$

$$\Leftrightarrow a_{ii} \cdot x_{i} = b_{i} - \sum_{\substack{j=1 \ j \neq i}}^{n} a_{ij} \cdot x_{j}$$

$$\Leftrightarrow x_{i} = \frac{1}{a_{ii}} \cdot \left(b_{i} - \sum_{\substack{j=1 \ i \neq i}}^{n} a_{ij} \cdot x_{j}\right).$$

Diese Umformung liefert uns die Iterations-Vorschrift

$$x_i^{(n+1)} = \frac{1}{a_{ii}} \cdot \left( b_i - \sum_{\substack{j=1\\j \neq i}}^{n} a_{ij} \cdot x_j^{(n)} \right)$$

mit der wir versuchen können, eine Lösung der Fixpunkt-Gleichung zu finden. Das Verfahren, das wir auf diese Weise erhalten, wird als *Gesamtschritt-Verfahren* oder auch als *Jacobi-Verfahren* (Carl Gustav Jacob Jacobi, 1804 – 1851) bezeichnet. Die Frage lautet jetzt, wann die durch dieses Verfahren definierte Iteration konvergiert. Um eine positive Antwort auf diese Frage geben zu können, benötigen wir die folgenden Definitionen.

**Definition 94 (Starkes Zeilen-Summen-Kriterium)** Eine  $n \times n$  Matrix  $A \in \mathbb{R}^{n \times n}$  erfüllt das *starke Zeilen-Summen-Kriterium* falls es eine Zahl q < 1 gibt, so dass gilt

$$\sum_{\substack{j=1\\i\neq i}}^{n} \left| a_{ij} \right| \le q \cdot \left| a_{ii} \right| \quad \text{ für alle } i=1,\cdots,n.$$

Falls  $a_{ii} \neq 0$  ist, ist die in der obigen Definition gegebene Ungleichung äquivalent zu der Ungleichung

$$\frac{1}{|a_{ii}|} \cdot \sum_{\substack{j=1\\j \neq i}}^{n} |a_{ij}| \le q.$$

Als nächstes führen wir ein Konzept ein, das den Begriff des Betrags auf Vektoren aus dem  $\mathbb{R}^n$  verallgemeinert.

**Definition 95 (Maximums-Norm)** Ist  $\vec{x} \in \mathbb{R}^n$ , so definieren wir die Maximums-Norm von  $\vec{x}$  als

$$\|\vec{x}\|_{\infty} := \max\{ |x_i| \mid i \in \{1, \dots, n\} \}.$$

Mit der so definierten Norm können wir so rechnen, wie wir das von Beträgen bei reellen Zahlen gewöhnt sind, insbesondere gilt auch die *Dreiecks-Ungleichung*, wir haben also für beliebige Vektoren  $\vec{x}, \vec{y} \in \mathbb{R}^n$ 

$$\|\vec{x} + \vec{y}\|_{\infty} \le \|\vec{x}\|_{\infty} + \|\vec{y}\|_{\infty}.$$

Außerdem haben wir für reelle Zahlen  $\alpha \in \mathbb{R}$  und Vektoren  $\vec{x} \in \mathbb{R}^n$  die Gleichung

$$\|\alpha \vec{x}\|_{\infty} = |\alpha| \cdot \|\vec{x}\|_{\infty}$$

Hierbei bezeichnet  $\alpha \, \vec{x}$  die komponentenweise Multiplikation des Vektors  $\vec{x}$  mit der Zahl  $\alpha$ . Schließlich gilt für alle  $\vec{x} \in \mathbb{R}^n$  die Ungleichung  $0 \le \left\| \vec{x} \right\|_{\infty}$  wobei Gleichheit nur im Fall  $\vec{x} = \vec{0}$  auftritt:

$$\|\vec{x}\|_{\infty} = 0 \implies \vec{x} = \vec{0}$$
 für alle  $\vec{x} \in \mathbb{R}$ .

Der folgende Satz beantwortet nun die oben gestellte Frage nach der Konvergenz des Gesamtschritt-Verfahrens in einem für Anwendungen wichtigen Spezial-Fall.

**Satz 96** Wenn die Matrix  $A \in \mathbb{R}^{n \times n}$  das starke Zeilen-Summen-Kriterium erfüllt, dann konvergiert das Gesamtschritt-Verfahren für jeden Start-Vektor. Bezeichnen wir die Vektoren der Iteration mit  $\vec{x}^{(n)}$  und definieren wir

$$\vec{x}^{(\infty)} := \lim_{n \to \infty} \vec{x}^{(n)}$$

und ist weiter q die Zahl aus dem starken Zeilen-Summen-Kriterium, dann gilt außerdem die Abschätzung

$$\|\vec{x}^{(\infty)} - \vec{x}^{(n)}\|_{\infty} \le \frac{q^n}{1-q} \cdot \|\vec{x}^{(0)} - \vec{x}^{(1)}\|_{\infty}$$

**Beweis**: Wir definieren eine Funktion  $f: \mathbb{R}^n \to \mathbb{R}^n$  komponentenweise:

$$f_i(\vec{x}) = \frac{1}{a_{ii}} \cdot \left( b_i - \sum_{\substack{j=1\\j\neq i}}^n a_{ij} \cdot x_j \right).$$

Die i-te Komponente der Funktion f berechnet also gerade die i-te Komponente des Vektors  $\vec{x}^{(n+1)}$ . Wir zeigen nun, dass für beliebige Vektoren  $\vec{x}, \vec{y} \in \mathbb{R}^n$ 

$$||f(\vec{x}) - f(\vec{y})||_{\infty} \le q \cdot ||\vec{x} - \vec{y}||_{\infty}$$

gilt, denn dann ist f eine kontrahierende Abbildung, und die Behauptung des Satzes folgt aus dem Banach'schen Fixpunkt-Satz, den wir zwar nur für Funktionen  $f:\mathbb{R}\to\mathbb{R}$  bewiesen haben, der aber auch für vektorwertige Funktionen im  $\mathbb{R}^n$  gilt, wenn wir den Betrag durch die Maximums-Norm ersetzen. Wir schätzen die Differenz  $|f_i(\vec{x}) - f_i(\vec{y})|$  wie folgt ab:

$$|f_{i}(\vec{x}) - f_{i}(\vec{y})| = \left| \frac{1}{a_{ii}} \cdot \left( b_{i} - \sum_{\substack{j=1\\j \neq i}}^{n} a_{ij} \cdot x_{j} \right) - \frac{1}{a_{ii}} \cdot \left( b_{i} - \sum_{\substack{j=1\\j \neq i}}^{n} a_{ij} \cdot y_{j} \right) \right|$$

$$= \left| \frac{1}{a_{ii}} \cdot \sum_{\substack{j=1\\j \neq i}}^{n} a_{ij} \cdot \left( y_{j} - x_{j} \right) \right| \leq \frac{1}{|a_{ii}|} \cdot \sum_{\substack{j=1\\j \neq i}}^{n} |a_{ij}| \cdot |x_{j} - y_{j}|$$

$$\leq \frac{1}{|a_{ii}|} \cdot \sum_{\substack{j=1\\j \neq i}}^{n} |a_{ij}| \cdot ||\vec{x} - \vec{y}||_{\infty} \leq \left( \frac{1}{|a_{ii}|} \cdot \sum_{\substack{j=1\\j \neq i}}^{n} |a_{ij}| \right) \cdot ||\vec{x} - \vec{y}||_{\infty}$$

$$\leq q \cdot ||\vec{x} - \vec{y}||_{\infty}$$

Da diese Ungleichung für alle  $i=1,\cdots,n$  gilt, haben wir insgesamt die Abschätzung

$$||f(\vec{x}) - f(\vec{y})||_{\infty} \le q \cdot ||\vec{x} - \vec{y}||_{\infty}$$

gezeigt und die Behauptung folgt nun aus dem Banach'schen Fixpunkt-Satz.

Abbildung 6.3 auf Seite 136 zeigt eine einfache Implementierung des Jacobi-Verfahrens. Die Funktion jakobi() bekommt drei Argumente:

- 1. a ist eine  $n \times n$  Matrix, die durch eine Liste dargestellt wird, deren Elemente selbst wieder Listen der Länge n sind. Auf das Matrix-Element  $a_{ij}$  wird in  $\operatorname{Setl}X$  dann durch den Ausdruck a[i][j] zugegriffen.
- 2. b ist eine n-dimensionaler Vektor, der durch eine Liste der Länge n dargestellt wird.
- 3. k ist die Anzahl der durchzuführenden Iterationen.

Die Funktion jacobi(a,b,x) versucht, mit Hilfe des Jacobi-Verfahrens das lineare Gleichungs-System

$$\mathbf{a}\,\vec{x}=\vec{b}$$

zu lösen und arbeitet im Detail wie folgt:

- 1. In Zeile 5 wid der Start-Vektor  $\vec{x}^{(0)}$  als Null-Vektor definiert. Die Variable xNew speichert den Wert  $\vec{x}^{(n+1)}$ .
- 2. Die Schleife, die in Zeile 6 beginnt, führt insgesamt k Iterationen des Jacobi-Verfahrens aus.
- 3. Die Schleife, die in Zeile 7 beginnt, berechnet den nächsten Wert  $ec{x}^{(n+1)}$  gemäß der Formel

$$x_i^{(n+1)} = \frac{1}{a_{ii}} \cdot \left( b_i - \sum_{\substack{j=1\\j \neq i}}^n a_{i,j} \cdot x_j \right).$$

Der Index i läuft dabei über die Komponenten des Vektors  $\vec{x}^{(n+1)}$ .

Die Funktion demo() ruft die Funktion so auf, dass anschließend das Gleichungs-System

$$\left(\begin{array}{ccc}
4.0 & 1.0 & 0.0 \\
1.0 & 4.0 & 1.0 \\
0.0 & 1.0 & 4.0
\end{array}\right) \vec{x} = \left(\begin{array}{c}
5.0 \\
6.0 \\
5.0
\end{array}\right)$$

gelöst werden kann. Die Lösung dieses Systems ist

$$\vec{x} = \left(\begin{array}{c} 1.0\\1.0\\1.0\end{array}\right).$$

Diese Lösung wird nach 35 Iterationen gefunden. Tabelle 6.4 auf Seite 137 zeigt den Verlauf der Rechnung. Die Matrix A erfüllt das starke Zeilen-Summen-Kriterium mit  $q=\frac{1}{2}$ . Die exakte Lösung wird nach 35 Schritten gefunden.

```
jacobi := procedure(a, b, k) {
        n := \#b;
                      == n, "wrong number of equations");
        assert(#a
        assert(#a[1] == n, "wrong number of variables");
        x := xNew := [ 0 : i in [ 1 .. n ] ];
        for (l in [1 .. k]) {
             for (i in [1 .. n]) {
                 xNew[i] := b[i];
                 for (j in [ 1 .. n ]) {
                     if (i != j) {
                          xNew[i] -= a[i][j] * x[j];
11
12
                 xNew[i] /= a[i][i];
             x := xNew;
             print("$1$: $x$");
17
18
        return x;
19
    };
20
21
    demo := procedure() {
22
        a := [ [ 4.0, 1.0, 0.0 ],
23
                [ 1.0, 4.0, 1.0 ],
24
                [ 0.0, 1.0, 4.0 ] ];
        b := [5.0, 6.0, 5.0];
26
        k := 35;
        x := jacobi(a, b, k);
        print("x = $x$");
    };
30
```

Abbildung 6.3: Implementierung des Jacobi-Verfahrens.

#### Das Gauß-Seidel-Verfahren

Betrachten wir die Implementierung des Gesamtschritt-Verfahrens, so liegt die folgende Optimierung auf der Hand. Wenn wir mit der Formel

$$x_i^{(n+1)} = \frac{1}{a_{ii}} \cdot \left( b_i - \sum_{\substack{j=1\\i \neq i}}^n a_{ij} \cdot x_j^{(n)} \right)$$

die i-te Komponente von  $\vec{x}^{(n+1)}$  berechnen, dann kennen wir bereits die neuen Komponenten  $x_1^{(n+1)}, \cdots, x_{i-1}^{(n+1)}$ . Da diese Komponenten (hoffentlich) näher an der Lösung liegen als die Komponenten  $x_1^{(n)}, \cdots, x_{i-1}^{(n)}$  des alten Vektors  $\vec{x}^{(n)}$ , liegt es nahe, für j < i die neuen Komponenten  $x_j^{(n+1)}$  an Stelle der alten Komponenten  $x_j^{(n)}$  zu benutzen. Damit kommen wir zu der zunächst kompliziert aussehenden Iterations-Formel

$$x_i^{(n+1)} = \frac{1}{a_{ii}} \cdot \left( b_i - \sum_{j=1}^{i-1} a_{ij} \cdot x_j^{(n+1)} - \sum_{j=i+1}^n a_{ij} \cdot x_j^{(n)} \right).$$

Das Verfahren, das auf dieser Formel basiert, wird als *Einzelschritt-Verfahren* oder auch *Gauß-Seidel-Verfahren* (Philipp Ludwig von Seidel, 1821 – 1896) bezeichnet.

	()		
n	$x_1^{(n)}$	$x_2^{(n)}$	$x_3^{(n)}$
1	1.25	1.5	1.25
2	0.875	0.875	0.875
3	1.03125	1.0625	1.03125
4	0.984375	0.984375	0.984375
5	1.00390625	1.0078125	1.00390625
6	0.998046875	0.998046875	0.998046875
7	1.00048828125	1.0009765625	1.00048828125
8	0.999755859375	0.999755859375	0.999755859375
9	1.00006103515625	1.0001220703125	1.00006103515625
10	0.999969482421875	0.999969482421875	0.999969482421875
11	1.0000076293945312	1.0000152587890625	1.0000076293945312
12	0.9999961853027344	0.9999961853027344	0.9999961853027344
13	1.0000009536743164	1.0000019073486328	1.0000009536743164
14	0.9999995231628418	0.9999995231628418	0.9999995231628418
15	1.0000001192092896	1.000000238418579	1.0000001192092896
16	0.9999999403953552	0.9999999403953552	0.9999999403953552
17	1.0000000149011612	1.0000000298023224	1.0000000149011612
18	0.9999999925494194	0.9999999925494194	0.9999999925494194
19	1.0000000018626451	1.0000000037252903	1.0000000018626451
20	0.9999999990686774	0.9999999990686774	0.9999999990686774
21	1.0000000002328306	1.0000000004656613	1.0000000002328306
22	0.9999999998835847	0.9999999998835847	0.9999999998835847
23	1.0000000000291038	1.0000000000582077	1.0000000000291038
24	0.9999999999854481	0.9999999999854481	0.9999999999854481
25	1.00000000003638	1.000000000007276	1.00000000003638
26	0.99999999998181	0.99999999998181	0.99999999998181
27	1.0000000000004547	1.0000000000009095	1.0000000000004547
28	0.999999999997726	0.999999999997726	0.999999999997726
29	1.0000000000000568	1.0000000000001137	1.0000000000000568
30	0.999999999999716	0.999999999999716	0.999999999999716
31	1.000000000000007	1.000000000000142	1.000000000000007
32	0.999999999999964	0.999999999999964	0.999999999999964
33	1.0000000000000000	1.0000000000000018	1.00000000000000000
34	0.999999999999996	0.999999999999996	0.99999999999999
35	1.0	1.0	1.0
	I	ı	I.

Tabelle 6.4: Konvergenz des Jacobi-Verfahrens.

Abbildung 6.4 zeigt, wie wir die Implementierung ändern müssen, wenn wir das Gauß-Seidel-Verfahren anwenden wollen. Die Implementierung des Gauß-Seidel-Verfahrens ist einfacher als die Implementierung des Jacobi-Verfahrens, denn wir benötigen keine Hilfsvariable xNew mehr. Tabelle 6.5 zeigt, dass das Gauß-Seidel-Verfahren für unser Beispiel etwa doppelt so schnell konvergiert wie das Jacobi-Verfahren. Es lässt sich zeigen, dass das Gauß-Seidel-Verfahren zur Lösung immer dann konvergiert, wenn die Matrix  $\bf A$  des linearen Gleichungs-Systems

$$\mathbf{A}\vec{x} = \vec{b}$$

das starke Zeilen-Summen-Kriterium erfüllt. Allerdings ist die theoretische Analyse des Gauß-Seidel-Verfahren schwieriger als die Untersuchung des Jacobi-Verfahrens, so dass wir von einer detaillierteren Diskussion aus Zeitgründen absehen müssen.

```
gaussSeidel := procedure(a, b, k) {
         n := \#b;
         assert(#a == n, "wrong number of equations");
assert(#a[1] == n, "wrong number of variables");
         x := [0 : i in [1 .. n]];
          for (l in [1 .. k]) {
              for (i in [1 .. n]) {
                   x[i] := b[i];
                   for (j in [ 1 .. n ]) {
                        if (i != j) {
10
                             x[i] -= a[i][j] * x[j];
11
                        }
13
                   x[i] /= a[i][i];
15
              print("$1$: $x$");
         }
17
         return x;
     };
19
```

Abbildung 6.4: Implementierung des Gauß-Seidel-Verfahrens.

n	$x_1^{(n)}$	$x_{2}^{(n)}$	$x_3^{(n)}$
1	1.25	1.1875	0.953125
2	0.953125	1.0234375	0.994140625
3	0.994140625	1.0029296875	0.999267578125
4	0.999267578125	1.0003662109375	0.999908447265625
5	0.999908447265625	1.0000457763671875	0.9999885559082031
6	0.9999885559082031	1.0000057220458984	0.9999985694885254
7	0.9999985694885254	1.0000007152557373	0.9999998211860657
8	0.9999998211860657	1.0000000894069672	0.9999999776482582
9	0.9999999776482582	1.000000011175871	0.9999999972060323
10	0.9999999972060323	1.0000000013969839	0.999999999650754
11	0.999999999650754	1.00000000174623	0.999999999563443
12	0.999999999563443	1.0000000000218279	0.99999999994543
13	0.99999999994543	1.0000000000027285	0.99999999993179
14	0.999999999993179	1.00000000000341	0.999999999999147
15	0.999999999999147	1.0000000000000426	0.999999999999893
16	0.9999999999999893	1.0000000000000053	0.99999999999987
17	0.999999999999987	1.0000000000000000	0.99999999999998
18	0.99999999999998	1.0	1.0
19	1.0	1.0	1.0

Tabelle 6.5: Konvergenz des Gauß-Seidel-Verfahrens.

# Kapitel 7

# Integral-Rechnung

# 7.1 Einführung des Integral-Begriffs

In diesem Kapitel beschäftigen wir uns mit der Frage, wie die Fläche zwischen einer Kurve und der x-Achse berechnet werden kann. Dabei gehen wir davon aus, dass die Kurve durch eine Funktion der Form  $x\mapsto f(x)$  definiert wird. Um die Dinge konkret zu machen betrachten wir die Funktion  $x\mapsto x^2$  und fragen, welche Fläche von dieser Kurve und der x-Achse im Intervall [0,1] eingeschlossen wird. Diese Fläche ist in Abbildung 7.1 grau dargestellt.



Abbildung 7.1: Die Fläche unter der Parabel  $x \mapsto x^2$  im Intervall [0,1].

Wir können versuchen, diese Fläche durch sogenannte *Treppen-Funktionen* zu approximieren. Eine Treppen-Funktion ist eine Funktion, die stückweise konstant ist. Abbildung 7.2 auf Seite 140 zeigt eine Approximation der Funktion  $x\mapsto x^2$  durch eine Treppen-Funktion. In dieser Abbildung haben wir das Intervall [0,1] in 10 gleich große Teilintervalle aufgeteilt. Wollen wir im allgemeinen Fall die Fläche unter eine Funktion f in einem vorgegebenen Intervall [a,b] berechnen, so unterteilen wir das Intervall [a,b] in n Teilintervalle der Form

$$\left[a+(i-1)\cdot h, a+i\cdot h\right] \quad \text{ mit } h:=\frac{b-a}{n} \text{ und } i=1,\cdots,n.$$

Um dann die Fläche berechnen zu können, approximieren wir diese Fläche zum einen durch eine Treppen-Funktion, die oberhalb der zu integrierenden Funktion liegt und zum anderen durch eine Treppen-Funktion, die unterhalb der zu integrierenden Funktion liegt. Wir nehmen zur Vereinfachung zunächst an, dass die Funktion f monoton steigend ist. In diesem Fall definieren wir zu einer vorgege-



Abbildung 7.2: Die Fläche unter der Parabel  $x \mapsto x^2$  im Intervall [0,1].

benen Zahl n von Intervallen die obere Treppen-Funktion  $f_n^{\downarrow}(x)$  wie folgt:

$$f_n^{\downarrow}(x) := f(a+i \cdot h) \quad \text{falls } x \in \left(a+(i-1) \cdot h, \ a+i \cdot h\right) \text{ und } i=1,\cdots,n. \tag{7.1}$$

Da wir f als monoton steigend vorausgesetzt haben, gilt

$$\forall x \in (a + (i-1) \cdot h, a + i \cdot h) : f(x) \leq f(a + i \cdot h) = f^{\downarrow}(x),$$

die Funktion f liegt also unterhalb der Treppen-Funktion  $f^{\downarrow}$ . Wie die Treppen-Funktion an den Randpunkten der Intervalle  $[a+(i-1)\cdot h,a+i\cdot h]$  definiert wird, ist unwichtig. Abbildung 7.2 zeigt die Funktion  $f(x)=x^2$  und die zugehörige Treppen-Funktion  $f_{10}^{\downarrow}(x)$ . Die Fläche unter einer solchen Treppen-Funktion kann leicht berechnet werden: Schreiben wir

$$\int_{a}^{b} f(x) \, \mathrm{d}x$$

für die Fläche unter einer Funktion f in dem Intervall [a,b], so gilt für die Treppen-Funktion  $f_n^{\downarrow}$  offenbar

$$\int_{a}^{b} f_{n}^{\downarrow}(x) \, \mathrm{d}x = \sum_{i=1}^{n} f(a+i \cdot h) \cdot h \tag{7.2}$$

denn die Fläche eines Rechtecks berechnet sich als das Produkt von Breite und Höhe. Die Höhe des Rechtecks im i-ten Teilintervall hat den Wert  $f(a+i\cdot h)$  und die Breite des Teilintervalls ist h.

Genau wie wir die Fläche unter der Funktion f von oben approximieren können, können wir diese Fläche auch von unten approximieren. Die dazu notwendige Treppen-Funktion  $f_n^\uparrow(x)$  definieren wir analog zu Gleichung (7.1)

$$f_n^{\uparrow}(x) = f(a + (i-1) \cdot h) \quad \text{falls } x \in (a + (i-1) \cdot h, a + i \cdot h), \tag{7.3}$$

wir werten also diesmal in jedem Intervall die Funktion f am linken Eckpunkt aus, denn dort ist die Funktion f am kleinsten, da wir vorausgesetzt haben, dass die Funktion f monoton steigend ist. Für diese Treppen-Funktion berechnet sich die Fläche nach der Formel

$$\int_{a}^{b} f_{n}^{\uparrow}(x) \, \mathrm{d}x = \sum_{i=1}^{n} f(a + (i-1) \cdot h) \cdot h = \sum_{i=0}^{n-1} f(a + i \cdot h) \cdot h. \tag{7.4}$$

Für die Fläche, die zwischen der Funktion f und der x-Achse liegt, haben wir insgesamt die Abschätzung

$$\sum_{i=0}^{n-1} f(a+i \cdot h) \cdot h \le \int_a^b f(x) \, \mathrm{d}x \le \sum_{i=1}^n f(a+i \cdot h) \cdot h$$

gefunden. Die linke Summe bezeichnen wir als *Unter-Summe*, die Summe auf der rechten Seite der Ungleichungskette nennen wir *Ober-Summe*. Wir können hoffen, dass für wachsende Werte von n die Werte von Ober-Summe und Unter-Summe gegen den selben Grenzwert konvergieren. Dazu berechnen wir zunächst die Differenz dieser beiden Summen:

$$\sum_{i=1}^{n} f(a+i \cdot h) \cdot h - \sum_{i=0}^{n-1} f(a+i \cdot h) \cdot h$$

$$= f(a+n \cdot h) \cdot h - f(a) \cdot h$$

$$= \left( f\left(a+n \cdot \frac{b-a}{n}\right) - f(a) \right) \cdot \frac{b-a}{n}$$

$$= \left( f(a+b-a) - f(a) \right) \cdot \frac{b-a}{n}$$

$$= \left( f(b) - f(a) \right) \cdot \frac{b-a}{n}$$

$$\xrightarrow{b \to \infty} 0$$

Damit ist klar, dass bei einer monoton steigenden Funktion die Ober-Summe für eine wachsende Zahl n von Intervallen gegen den selben Wert konvergiert wie die Unter-Summe. Daher definieren wir

$$\int_{a}^{b} f(x) \, \mathrm{d}x := \lim_{n \to \infty} \sum_{i=1}^{n} f\left(a + i \cdot \frac{b - a}{n}\right) \cdot \frac{b - a}{n} \tag{7.5}$$

Diesen Grenzwert nennen wir auch das Integral von f in dem Intervall [a,b]. Die so gegebene Definition ist zunächst nur für monoton wachsende Funktionen schlüssig, aber es ist offensichtlich, dass das Integral für monoton fallende Funktionen auf die selbe Weise berechnet werden kann. Ist nun eine Funktion f in dem Intervall f weder monoton fallend noch monoton steigend, so können wir versuchen, dass Intervall so in Teilintervalle aufzuspalten, dass f in jedem Teilintervall monoton fallend oder monoton steigend ist. Da wir auf jedem dieser Teilintervalle das Integral nach der Formel (7.5) berechnen können, können wir dann auch insgesamt das Integral nach dieser Formel berechnen.

Aufgabe 62: Berechnen Sie das Integral

$$\int_0^b x^2 \, \mathrm{d}x$$

nach der in (7.5) angegebenen Formel.

Hinweis: Es gilt

$$\sum_{i=1}^{n} i^2 = \frac{n}{6} \cdot (n+1) \cdot (2 \cdot n+1).$$

**Definition 97 (Integral)** Ist  $f:[a,b] \to \mathbb{R}$  eine Funktion, so dass der Grenzwert

$$\lim_{n\to\infty}\sum_{i=1}^n f\Big(a+i\cdot\frac{b-a}{n}\Big)\cdot\frac{b-a}{n}$$

existiert, so nennen wir f integrierbar und definieren das Integral von f in dem Intervall [a,b] als

$$\int_{a}^{b} f(x) dx = \lim_{n \to \infty} \sum_{i=1}^{n} f\left(a + i \cdot \frac{b - a}{n}\right) \cdot \frac{b - a}{n}.$$

Der so eingeführte Integral-Begriff hat folgende Eigenschaften:

1. Linearität: Sind f und g zwei Funktionen, so dass das Integral über f bzw. g in dem Intervall [a,b] definiert ist und sind  $\alpha,\beta\in\mathbb{R}$ , so ist auch das Integral der Funktion

$$x \mapsto \alpha \cdot f(x) + \beta \cdot g(x)$$

definiert und es gilt

$$\int_a^b \alpha \cdot f(x) + \beta \cdot g(x) \, \mathrm{d}x = \alpha \cdot \int_a^b f(x) \, \mathrm{d}x + \beta \cdot \int_a^b g(x) \, \mathrm{d}x.$$

Diese Eigenschaft folgt aus der Tatsache, dass einerseits sowohl die Summe als auch das Produkt zweier konvergenter Folgen wieder konvergent sind und das andererseits im Falle konvergenter Folgen der Grenzwert sowohl mit der Summe als auch mit dem Produkt vertauscht werden kann.

2. Monotonie: Sind f und g zwei Funktionen, so dass das Integral über f und g in dem Intervall [a,b] definiert ist, so gilt:

$$(\forall x \in [a, b] : f(x) \le g(x)) \Rightarrow \int_a^b f(x) dx \le \int_a^b g(x) dx.$$

Auch diese Eigenschaft folgt aus der entsprechenden Eigenschaft konvergenter Folgen.

### Satz 98 (Mittelwert-Satz der Integral-Rechnung)

Es sei  $f:[a,b]\to\mathbb{R}$  eine stetige Funktion. Dann existiert ein  $\xi\in[a,b]$ , so dass gilt:

$$\int_{a}^{b} f(x) dx = f(\xi) \cdot (b - a).$$

**Beweis**: Da die Funktion f stetig ist, nimmt f auf dem Intervall [a,b] ein Minimum und ein Maximum in den Punkten  $x_{min}$  und  $x_{max}$  an. Dann gilt

$$\forall x \in [a, b] : f(x_{min}) \le f(x) \le f(x_{max}).$$

Aufgrund der Monotonie des Integral-Operators folgt daraus sofort

$$\int_{a}^{b} f(x_{min}) dx \le \int_{a}^{b} f(x) dx \le \int_{a}^{b} f(x_{max}) dx$$

$$\Leftrightarrow f(x_{min}) \cdot (b - a) \le \int_{a}^{b} f(x) dx \le f(x_{max}) \cdot (b - a)$$

$$\Leftrightarrow f(x_{min}) \le \frac{1}{b - a} \cdot \int_{a}^{b} f(x) dx \le f(x_{max})$$

Die obige Ungleichungskette zeigt, dass

$$\frac{1}{b-a} \cdot \int_{a}^{b} f(x) \, \mathrm{d}x \in \left[ f(x_{min}), f(x_{max}) \right]$$

gilt. Aufgrund des Zwischenwert-Satzes für stetige Funktionen (Satz 63 auf Seite 67) nimmt die stetige Funktion f jeden Wert in dem Intervall  $[f(x_{min}), f(x_{max})]$  an. Also gibt es ein  $\xi \in [a, b]$ , so dass

$$f(\xi) = \frac{1}{b-a} \cdot \int_a^b f(x) \, \mathrm{d}x$$

gilt und dass ist äquivalent zu

$$f(\xi) \cdot (b-a) = \int_a^b f(x) \, \mathrm{d}x.$$

Der Mittelwert-Satz versetzt uns in die Lage, einen Zusammenhang zwischen Differential-Rechnung und Integral-Rechnung herzustellen.

#### Satz 99 (Ableitung von Integralen)

Die Funktion  $f:[a,b]\to\mathbb{R}$  sei stetig. Definieren wir für  $x\in[a,b]$  die Funktion  $F:[a,b]\to\mathbb{R}$  durch

$$F(x) := \int_{a}^{x} f(t) \, \mathrm{d}t,$$

so ist die Funktion F im Intervall [a,b] differenzierbar und es gilt

$$\frac{\mathrm{d}F}{\mathrm{d}x}(x) = f(x).$$

Beweis: Es gilt

$$\begin{split} &\frac{\mathrm{d}F}{\mathrm{d}x}(x) \\ &= \lim_{h \to 0} \frac{F(x+h) - F(x)}{h} \\ &= \lim_{h \to 0} \frac{\int_a^{x+h} f(t) \, \mathrm{d}t - \int_a^x f(t) \, \mathrm{d}t}{h} \quad \text{nach Definition von } F \\ &= \lim_{h \to 0} \frac{1}{h} \int_x^{x+h} f(t) \, \mathrm{d}t \\ &= \lim_{h \to 0} \frac{1}{h} \cdot (x+h-x) \cdot f(\xi_h) \quad \quad \text{nach dem Mittelwertsatz für ein } \xi_h \in [x,x+h] \\ &= \lim_{h \to 0} f(\xi_h) \\ &= f(x) \quad \qquad \text{wegen } \xi_h \in [x,x+h]. \end{split}$$

Damit ist die Behauptung bewiesen.

Bemerkung: Der letzte Satz zeigt uns, dass der Differentiations-Operator

$$\frac{\mathrm{d}}{\mathrm{d}x} := \left( f \mapsto \frac{\mathrm{d}f}{\mathrm{d}x} \right)$$

zu dem Integral-Operator

$$\int_{a}^{x} \cdot dt := \left( f \mapsto \int_{a}^{x} f(t) dt \right)$$

invers ist: Wenden wir auf eine Funktion zunächst den Integral-Operator an und wenden wir dann auf die resultierende Funktion den Differentiations-Operator an, so erhalten wir wieder die ursprüngliche Funktion:

$$\boxed{\frac{\mathrm{d}}{\mathrm{d}x} \int_{a}^{x} f(t) \, \mathrm{d}t = f(x).}$$

Diese Aussage lässt sich im Wesentlichen auch umkehren. Diese Umkehrung ist der Hauptsatz der Differential- und Integral-Rechnung. Bevor wir diesen Satz in Angriff nehmen können, benötigen wir noch eine Definition.

#### **Definition 100 (Stamm-Funktion)**

Ist  $f:[a,b]\to\mathbb{R}$  eine Funktion, so nennen wir die Funktion  $F:[a,b]\to\mathbb{R}$  eine Stamm-Funktion von f, falls F differenzierbar ist und

$$\frac{\mathrm{d}F}{\mathrm{d}x}(x) = f(x)$$

gilt. In diesem Fall schreiben wir auch  $F(x) = \int f(x) \, \mathrm{d}x$ . Der Ausdruck  $\int f(x) \, \mathrm{d}x$  wird als *unbestimmtes*Integral bezeichnet.

Die Schreibweise  $F(x)=\int f(x)\,\mathrm{d}x$  ist problematisch, denn die Stamm-Funktion einer gegebenen Funktion ist nicht eindeutig. Ist F(x) eine Stamm-Funktion von f(x) und definieren wir die Funktion G durch G(x):=F(x)+c für eine beliebige Konstante c, so ist natürlich auch G(x) eine Stamm-Funktion von f, denn es gilt

$$\frac{\mathrm{d}G}{\mathrm{d}x}(x) = \frac{\mathrm{d}F}{\mathrm{d}x}(x) + \frac{\mathrm{d}c}{\mathrm{d}x} = f(x) + 0 = f(x).$$

Umgekehrt gilt, dass zwei verschiedene Stamm-Funktionen zu einer Funktion f sich nur um eine Konstante unterscheiden. Dies sehen wir wie folgt: Angenommen,  $F_1$  und  $F_2$  seien zwei Stamm-Funktionen einer Funktion f, es gelte also

$$\frac{\mathrm{d}F_1}{\mathrm{d}x}(x) = f(x)$$
 und  $\frac{\mathrm{d}F_2}{\mathrm{d}x}(x) = f(x)$ .

Dann definieren wir die Funktion H als  $H(x) := F_1(x) - F_2(x)$ . Damit gilt

$$\frac{\mathrm{d}H}{\mathrm{d}x}(x) = \frac{\mathrm{d}F_1}{\mathrm{d}x}(x) - \frac{\mathrm{d}F_2}{\mathrm{d}x}(x) = f(x) - f(x) = 0.$$

Nach Lemma 83 gibt es nun eine Konstante c, so dass H(x) = c gilt. Daraus folgt dann

$$F_1(x) - F_2(x) = c$$
, also  $F_1(x) = F_2(x) + c$ 

und das heißt gerade, dass sich die beiden Stamm-Funktionen  $F_1$  und  $F_2$  nur um eine Konstante unterscheiden.

Sie fragen sich vermutlich, warum wir bei einer Stamm-Funktion das Integral-Zeichen verwenden. Der Hauptsatz der Differential- und Integral-Rechnung gibt darauf eine Antwort. Gleichzeitig ist dieser Satz das zentrale Ergebnis dieser Vorlesung. Historisch wurde dieser Satz unabhängig sowohl von Gottfried Wilhelm Leibniz als auch von Issac Newton gefunden. Die Entdeckung dieses Satzes war für die Analysis von fundamentaler Bedeutung, denn dieser Satz ermöglicht die Berechnung vieler Integrale.

#### Satz 101 (Hauptsatz der Differential- und Integral-Rechnung)

Die Funktion  $f:[a,b]\to\mathbb{R}$  sei stetig,  $F:[a,b]\to\mathbb{R}$  sei eine Stamm-Funktion von f und es gelte  $u,v\in[a,b]$ . Dann gilt

$$\int_{u}^{v} f(x) dx = F(v) - F(u).$$

**Beweis**: Definieren wir die Funktion G(x) durch

$$G(x) := \int_a^x f(t) dt$$
 für alle  $x \in [a, b]$ ,

so besagt Satz 99, dass die Funktion G eine Stamm-Funktion der Funktion f ist. Ist nun F eine beliebige weitere Stamm-Funktion von f, so haben wir gerade gesehen, dass die Stamm-Funktionen G und F sich nur um eine Konstante c unterscheiden können, es gilt also

$$F(x) = G(x) + c.$$

Damit haben wir

$$F(v) - F(u) = G(v) + c - (G(u) + c)$$

$$= G(v) - G(u)$$

$$= \int_{a}^{v} f(t) dt - \int_{a}^{u} f(t) dt$$

$$= \int_{u}^{v} f(t) dt.$$

Der letzte Satz gibt Anlass zu einer Schreibweise. Für eine Funktion F definieren wir

$$F(x)\Big|_{u}^{v} := F(v) - F(u).$$

Den letzten Satz können wir eine wichtige Schlussfolgerung ziehen: Ist  $f:[a,b]\to\mathbb{R}$  eine differenzierbare Funktion, so ist f offenbar eine Stamm-Funktion der Funktion f'(x). Also gilt:

$$\int_{u}^{v} f'(x) dx = f(v) - f(u) = f(x) \Big|_{u}^{v}$$
(7.6)

Dies zeigt uns, dass der Integral-Operator in gewisser Weise zum Differential-Operator invers ist.

## 7.2 Regeln zur Berechnung von Integralen

Der Hauptsatz der Differential- und Integral-Rechnung ermöglicht es, Regeln zur Berechnung von Integralen aufzustellen. Tabelle 7.1 zeigt die Stamm-Funktionen der wichtigsten Funktionen. Um diese Tabelle zu verifizieren reicht es aus, die in der rechten Spalte der Tabelle angegebene Funktion nach x zu differenzieren. Wir führen dies exemplarisch für den Eintrag  $\ln(x)$  vor. Es gilt

$$\begin{array}{lcl} \frac{\mathrm{d}}{\mathrm{d}x} \big( x \cdot \ln(x) - x \big) & = & \frac{\mathrm{d}}{\mathrm{d}x} \big( x \cdot \ln(x) \big) - \frac{\mathrm{d}}{\mathrm{d}x} x \\ \\ & = & 1 \cdot \ln(x) + x \cdot \frac{1}{x} - 1 & (\mathsf{Produkt-Regel}) \\ \\ & = & \ln(x) + 1 - 1 \\ \\ & = & \ln(x) \end{array}$$

Damit ist gezeigt, dass  $\int \ln(x) dx = x \cdot \ln(x) - x$  gilt. Die übrigen Einträge der Tabelle können auf ähnliche Weise verifiziert werden.

Bemerkenswert ist vielleicht noch die Stamm-Funktion der Funktion  $x\mapsto \frac{1}{x}$ : Für x>0 gilt sicher

$$\frac{\mathrm{d}}{\mathrm{d}x}\ln(x) = \frac{1}{x}$$

Außerdem gilt nach der Ketten-Regel für x < 0

$$\frac{\mathrm{d}}{\mathrm{d}x}\ln(-x) = -1 \cdot \frac{1}{-x} = \frac{1}{x}.$$

Diese beiden Gleichungen können wir zu

$$\frac{\mathrm{d}}{\mathrm{d}x}\ln(|x|) = \frac{1}{x}$$

zusammen fassen und folglich haben wir

$$\int \frac{1}{x} \, \mathrm{d}x = \ln(|x|).$$

Wir können die einzelnen Einträge der Tabelle zwar durch Differenzieren leicht verifizieren, aber dabei

Funktion $f(x)$	Stamm-Funktion $\int f(x) dx$
$x^{\alpha} \text{ mit } \alpha \neq -1$	$\frac{1}{\alpha+1} \cdot x^{\alpha+1}$
$\frac{1}{x}$	$\ln( x )$
$\exp(x)$	$\exp(x)$
$\sin(x)$	$-\cos(x)$
$\cos(x)$	$\sin(x)$
$\tan(x)$	$-\ln( \cos(x) )$
$\ln(x)$	$x \cdot \ln(x) - x$
$\frac{1}{1+x^2}$	$\arctan(x)$
$\frac{1}{\sqrt{1-x^2}}$	$\arcsin(x)$
$\frac{1}{\sqrt{1+x^2}}$	$\ln\left(x+\sqrt{1+x^2}\right)$
$\arctan(x)$	$x \cdot \arctan(x) - \frac{1}{2} \cdot \ln(1+x^2)$

Tabelle 7.1: Tabelle einiger Integrale

bleibt die Frage offen, wie die Einträge dieser Tabelle gefunden wurden. Wir stellen jetzt einige Sätze auf, mit deren Hilfe wir Stamm-Funktionen gegebener Funktionen berechnen können. Wir erhalten diese Sätze indem wir die Regeln, die wir zur Differenzierung aufgestellt haben, umdrehen.

#### 7.2.1 Die Substitutions-Regel

Wir beginnen mit der Ketten-Regel. Es gilt:

$$\frac{\mathrm{d}}{\mathrm{d}x}h(f(x)) = f'(x) \cdot h'(f(x))$$

Also ist die Funktion  $x\mapsto h(f(x))$  eine Stamm-Funktion der Funktion  $x\mapsto f'(x)\cdot h'(f(x))$ . Nach dem Hauptsatz gilt dann

$$\int_{a}^{b} f'(x) \cdot h'(f(x)) dx = h(f(b)) - h(f(a))$$

$$(7.7)$$

Wir definieren nun g(x):=h'(x). Dann ist h eine Stamm-Funktion der Funktion g, es gilt also  $h(x)=\int g(x)\,\mathrm{d}x\,+\,d$  , was wir nach dem Hauptsatz auch als

$$h(f(b)) - h(f(a)) = \int_{f(a)}^{f(b)} g(x) dx$$

$$(7.8)$$

schreiben können. Ersetzen wir in Gleichung (7.7) h' durch g so erhalten wir zusammen mit Gleichung

(7.8) die Substitutions-Regel:

$$\int_{a}^{b} f'(x) \cdot g(f(x)) dx = \int_{f(a)}^{f(b)} g(x) dx$$

$$(7.9)$$

Sie können sich die Substitutions-Regel mit Hilfe der folgenden suggestiven Pseudo-Ableitung leicht merken. Wir gehen von dem unbestimmten Integral

$$\int g(y) \, \mathrm{d}y$$

aus. Hier führen wir die Variablen-Transformation y = f(x) durch. Dann gilt

$$\frac{\mathrm{d}y}{\mathrm{d}x} = f'(x)$$

Wir rechnen nun mit dem Ausdruck  $\frac{\mathrm{d}y}{\mathrm{d}x}$  so, als ob es ein gewöhnlicher Bruch wäre und stellen die letzte Gleichung nach  $\mathrm{d}y$  um. Dann haben wir

$$dy = f'(x) \cdot dx$$

Ersetzen wir in dem ursprünglichen Integral  $\mathrm{d}y$  durch diesen Ausdruck, so haben wir

$$\int g(y) \, \mathrm{d}y = \int g(f(x)) \cdot f'(x) \, \mathrm{d}x$$

Das ist aber genau die Substitutions-Regel für unbestimmte Integrale.

**Aufgabe 63**: Berechnen Sie das Integral  $\int_0^x \tan(t) dt$  mit Hilfe der Substitutions-Regel.

Lösung: Es gilt:

$$\int_0^x \tan(t) dt = \int_0^x \frac{\sin(t)}{\cos(t)} dt$$

$$= -\int_0^x (-\sin(t)) \cdot \frac{1}{\cos(t)} dt$$

$$= -\int_{\cos(0)}^{\cos(x)} \frac{1}{y} dy$$

$$= -\left(\ln(|\cos(x)|) - \ln(|\cos(x)|)\right)$$

$$= \ln(|\cos(0)|) - \ln(|\cos(x)|)$$

$$= \ln(1) - \ln(|\cos(x)|)$$

$$= -\ln(|\cos(x)|)$$

Damit ist gezeigt, dass die Funktion  $x \mapsto -\ln(|\cos(x)|)$  eine Stamm-Funktion der Funktion  $x \mapsto \tan(x)$  ist:

$$\int \tan(x) dx = -\ln(|\cos(x)|) + c.$$

Wir zeigen, wie sich die Stamm-Funktion von tan(x) suggestiver berechnen lässt. Bei dem Integral

$$\int \frac{\sin(t)}{\cos(t)} \, \mathrm{d}t$$

führen wir die Variablen-Transformation  $x = \cos(t)$  durch. Dann gilt

$$\frac{\mathrm{d}x}{\mathrm{d}t} = -\sin(t) \iff \mathrm{d}t = \frac{\mathrm{d}x}{-\sin(t)}.$$

Ersetzen wir in dem Integral

$$\int \frac{\sin(t)}{\cos(t)} dt \quad \text{ den Ausdruck } dt \text{ durch } \quad \frac{dx}{-\sin(t)}$$

und cos(t) durch x, so erhalten wir

$$\int \frac{\sin(t)}{\cos(t)} dt = \int \frac{\sin(t)}{x} \cdot \frac{dx}{-\sin(t)} = -\int \frac{1}{x} dx = -\ln(|x|) = -\ln(|\cos(t)|).$$

Das Rechnen mit den *infinitesimalen* Größen  $\mathrm{d}x$  und  $\mathrm{d}t$  ist offensichtlich intuitiver als die formale Anwendung der Substitutions-Regel.

Aufgabe 64: Bei den folgenden Aufgaben dürfen Sie die Substitutions-Regel in suggestiver Weise benutzen.

(a) Berechnen Sie das Integral

$$\int \frac{x}{1+x^2} \, \mathrm{d}x.$$

(b) Berechnen Sie das Integral

$$\int \frac{x}{\sqrt{1+x^2}} \, \mathrm{d}x.$$

(c) Berechnen Sie das Integral

$$\int_0^1 (x-1)^8 \cdot (x+1) \, \mathrm{d}x.$$

**Hinweis**: Überlegen Sie, wie Sie sich durch Anwendung der Substitutions-Regel eine längliche Rechnung ersparen können.

#### 7.2.2 Partielle Integration

Als nächstes überlegen wir, wie wir aus der Produkt-Regel der Differential-Rechnung eine Regel zur Berechnung von Integralen gewinnen können. Es gilt

$$\frac{\mathrm{d}}{\mathrm{d}x}\Big(u(x)\cdot v(x)\Big) = u'(x)\cdot v(x) + u(x)\cdot v'(x) \qquad \text{(Umstellen)}$$

$$\Leftrightarrow u'(x)\cdot v(x) = \frac{\mathrm{d}}{\mathrm{d}x}\Big(u(x)\cdot v(x)\Big) - u(x)\cdot v'(x) \qquad \text{(Stamm-Funktion)}$$

$$\Leftrightarrow \int u'(x)\cdot v(x)\,\mathrm{d}x = \int \frac{\mathrm{d}}{\mathrm{d}x}\Big(u(x)\cdot v(x)\Big)\,\mathrm{d}x - \int u(x)\cdot v'(x)\,\mathrm{d}x$$

Die Stamm-Funktion von  $\frac{\mathrm{d}}{\mathrm{d}x}\Big(u(x)\cdot v(x)\Big)$  ist natürlich  $u(x)\cdot v(x)$ , also haben wir

$$\int u'(x) \cdot v(x) \, \mathrm{d}x = u(x) \cdot v(x) - \int u(x) \cdot v'(x) \, \mathrm{d}x$$
(7.10)

gefunden. Diese Gleichung setzt die Stamm-Funktionen von  $u'(x) \cdot v(x)$  und  $u(x) \cdot v'(x)$  in Beziehung: Die Stamm-Funktion der ersten Funktion kann auf die Stamm-Funktion der zweiten Funktion zurück geführt werden. Die Regel zur partiellen Integration lässt sich nicht nur für die Berechnung der Stamm-Funktion eines Produkts einsetzen, sondern sie wird auch benutzt um die Integrale von Umkehr-Funktionen zu bestimmen. Als Beispiel zeigen wir, wie sich das Integral der Funktion  $\ln(x)$ 

 $\Diamond$ 

mittels partieller Integration bestimmen lässt.

$$\int \ln(x) dx = \int 1 \cdot \ln(x) dx$$

$$= x \cdot \ln(x) - \int x \cdot \frac{d}{dx} \ln(x) dx$$

$$= x \cdot \ln(x) - \int x \cdot \frac{1}{x} dx$$

$$= x \cdot \ln(x) - \int 1 dx$$

$$= x \cdot \ln(x) - x$$

**Aufgabe 65**: Berechnen Sie die Stamm-Funktion  $\int \arctan(x) dx$ .

Aufgabe 66: Berechnen Sie die folgenden Integrale:

(a) 
$$\int x \cdot e^x \, \mathrm{d}x,$$

(b) 
$$\int x^2 \cdot e^x \, \mathrm{d}x,$$

(c) 
$$\int x^3 \cdot e^x \, \mathrm{d}x,$$

(d) 
$$\int x^n \cdot e^x dx$$
 für beliebige  $n \in \mathbb{N}$ .

#### 7.2.3 Das Integral von Umkehr-Funktionen\*

Wir zeigen noch einen anderen Weg, mit dem das Integral der Umkehr-Funktion einer Funktion berechnet werden kann. Es sei also eine Funktion  $f:[a,b]\to\mathbb{R}$  geben, die eine Umkehr-Funktion hat. Wir setzen zur Vereinfachung jetzt voraus, dass die Funktion f monoton steigend ist, wenn f monoton fallend ist, liegen die Dinge analog. Die Umkehr-Funktion von f sei die Funktion

$$g: \big[f(a),f(b)\big] \to \mathbb{R} \text{, } \quad \text{für alle } x \in [a,b] \text{ gilt also } g\big(f(x)\big) = x.$$

Analog gilt dann für alle  $y \in [f(a), f(b)]$  die Gleichung f(g(y)) = y. Abbildung 7.3 zeigt die Funktion. Durch Spiegelung an der Winkelhalbierung geht die Funktion f in die Umkehr-Funktion über, wenn wir also die y-Achse als x-Achse ansehen, zeigt die Abbildung die Umkehr-Funktion. Wir betrachten jetzt die Fläche des Rechtecks, dessen linke unter Ecke im Ursprung des Koordinaten-Systems liegt und dessen rechte obere Ecke die Koordinaten  $\langle b, f(b) \rangle$  hat. Dieses Rechtecks hat den Flächeninhalt  $b \cdot f(b)$ . Diese Fläche setzt sich aus drei Teilen zusammen, die in der Figur unterschiedlich markiert sind.

- 1. Links unten findet sich ein kleines Rechteck, das mit diagonalen Streifen markiert ist. Die linke untere Ecke dieses Rechtecks liegt ebenfalls im Ursprung des Koordinaten-Systems, die rechte obere Ecke hat die Koordinaten  $\langle a, f(a) \rangle$ . Damit hat dieses Rechteck die Fläche  $a \cdot f(a)$ .
- 2. Die vertikal schraffierte Fläche ist die Fläche unter der Kurve f(x) und ist folglich gegeben durch das Integral

$$\int_a^b f(x) \, \mathrm{d}x.$$

3. Die horizontal schraffierte Fläche ist die Fläche unter der Kurve g(y) der Umkehr-Funktion und ist daher gegeben durch

$$\int_{f(a)}^{f(b)} g(y) \, \mathrm{d}y.$$

Natürlich ist die gesamte Fläche des Rechtecks die Summe aller drei Teile, es gilt also

$$b \cdot f(b) = a \cdot f(a) + \int_{a}^{b} f(t) dt + \int_{f(a)}^{f(b)} g(t) dt$$
(7.11)



Abbildung 7.3: Die Funktion  $f:[a,b] \to \mathbb{R}$ 

Ersetzen wir in dieser Gleichung b durch x und stellen die Gleichung nach dem ersten Integral um, so erhalten wir

$$\int_{a}^{x} f(t) dt = x \cdot f(x) - a \cdot f(a) - \int_{f(a)}^{f(x)} g(t) dt$$
(7.12)

Sind wir nur an Stamm-Funktionen interessiert, so können wir den konstanten Term  $a\cdot f(a)$  weglassen. Dann schreibt sich die letzte Gleichung als

$$\int f(x) dx = x \cdot f(x) - G(f(x)) \quad \text{mit } G(x) := \int g(x) dx. \tag{7.13}$$

**Beispiel**: Wir betrachten die Funktion  $f(x) = \ln(x)$  mit der Umkehr-Funktion  $g(x) = \exp(x)$ . Wegen  $\int \exp(x) dx = \exp(x)$  gilt

$$\int \ln(x) = x \cdot \ln(x) - \exp(\ln(x)) = x \cdot \ln(x) - x.$$

#### 7.2.4 Berechnung der Fläche eines Kreises

Wir zeigen, wie sich der Flächen-Inhalt eines Kreises berechnen lässt. Ein Kreis vom Radius 1 kann nach dem Satz des Pythagoras in der Koordinaten-Ebene durch die Relation  $x^2+y^2=1$  dargestellt werden. Lösen wir diese Gleichung nach x auf, so wird der Kreis durch die beiden Funktionen  $x\mapsto \sqrt{1-x^2}$  und  $x\mapsto -\sqrt{1-x^2}$  für  $x\in [-1,1]$  beschrieben. Wir beschränken uns nun auf den Viertelkreis im ersten Quadranten der Koordinaten-Ebene. Die Fläche dieses Viertelkreises ist durch das Integral

$$I := \int_0^1 \sqrt{1 - x^2} \, \mathrm{d}x$$

gegeben, welches wir nun berechnen. Zunächst führen wir die Koordinaten-Transformation  $x=\sin(t)$  durch. Dann erhalten wir

$$\frac{\mathrm{d}x}{\mathrm{d}t} = \cos(t)$$
, also  $\mathrm{d}x = \cos(t) \cdot \mathrm{d}t$ .

Wegen  $0 = \sin(0)$  und  $1 = \sin(\pi/2)$  haben wir

$$I = \int_0^{\frac{\pi}{2}} \sqrt{1 - \sin^2(t)} \cdot \cos(t) dt = \int_0^{\frac{\pi}{2}} \cos(t) \cdot \cos(t) dt.$$

Dieses Integral versuchen wir nun mit partieller Integration zu vereinfachen. Wir setzen in Gleichung 7.10  $u'(t) := \cos(t)$  und  $v(t) = \cos(t)$ . Wegen  $u(t) = \sin(t)$  und  $v'(t) = -\sin(t)$  erhalten wir dann

$$I = \sin(t) \cdot \cos(t) \Big|_{0}^{\frac{\pi}{2}} + \int_{0}^{\frac{\pi}{2}} \sin(t) \cdot \sin(t) dt = \int_{0}^{\frac{\pi}{2}} \sin^{2}(t) dt$$

Damit haben wir jetzt

$$I = \int_0^{\frac{\pi}{2}} \cos^2(t) \, dt = \int_0^{\frac{\pi}{2}} \sin^2(t) \, dt$$

Daraus folgt

$$\Leftrightarrow 2 \cdot I = \int_0^{\frac{\pi}{2}} \cos^2(t) \, dt + \int_0^{\frac{\pi}{2}} \sin^2(t) \, dt$$

$$\Leftrightarrow 2 \cdot I = \int_0^{\frac{\pi}{2}} \left(\cos^2(t) + \sin^2(t)\right) \, dt$$

$$\Leftrightarrow 2 \cdot I = \int_0^{\frac{\pi}{2}} 1 \, dt$$

$$\Leftrightarrow 2 \cdot I = t \Big|_0^{\frac{\pi}{2}}$$

$$\Leftrightarrow 2 \cdot I = \frac{\pi}{2}$$

$$\Leftrightarrow I = \frac{\pi}{4}$$

Damit haben wir für die Fläche eines Viertelkreises den Wert  $\frac{\pi}{4}$  gefunden, der ganze Kreis hat also die Fläche  $\pi$ .

## 7.3 Berechnung der Bogenlänge

Gelegentlich tritt das Problem auf, die Länge der Strecke zu berechnen, die durch einen Funktions-Graphen beschrieben wird. Geht es darum, die Bogenlänge des Graphen der Funktion  $f:[a,b]\to\mathbb{R}$  in dem Intervall [a,b] zu berechnen, so zerlegen wir das Intervall in [a,b] in n Teilintervalle der Länge

$$h = \frac{b-a}{n}.$$

Das Teilstück des Graphen, das sich von dem Punkt  $\langle x, f(x) \rangle$  bis zu dem Punkt  $\langle x+h, f(x+h) \rangle$  erstreckt, kann für kleine Werte von h näherungsweise durch die Sekante von dem Punkt  $\langle x, f(x) \rangle$  zu dem Punkt  $\langle x+h, f(x+h) \rangle$  approximiert werden. Nach dem Satz des Pythagoras hat diese Sekante die Länge

$$ds = \sqrt{h^2 + (f(x+h) - f(x))^2}.$$

Nach Definition der Ableitung von f gilt für kleine Werte von h

$$\frac{f(x+h) - f(x)}{h} \approx f'(x).$$

Also haben wir

$$f(x+h) - f(x) \approx f'(x) \cdot h.$$

Setzen wir diesen Wert in der obigen Formel für ein, so erhalten wir

$$ds \approx \sqrt{h^2 + (f'(x) \cdot h)^2} = h \cdot \sqrt{1 + (\frac{\mathrm{d}f}{\mathrm{d}x})^2}.$$

Die Länge l des gesamten Funktions-Graphen erhalten wir, wenn wir diesen Ausdruck von a bis b aufintegrieren:

$$l = \int_{a}^{b} \sqrt{1 + \left(\frac{\mathrm{d}f}{\mathrm{d}x}\right)^{2}} \,\mathrm{d}x$$

**Beispiel**: Wir berechnen die Länge l des Kreisbogens, der durch die Funktion  $f:[0,1]\to\mathbb{R}$  mit

$$f(x) = \sqrt{1 - x^2}$$

definiert ist. Anschaulich sollte diese Länge ein Viertel des Umfangs eines Kreises mit Radius 1 betragen. Es gilt

$$\frac{\mathrm{d}f}{\mathrm{d}x} = \frac{1}{2} \cdot \frac{-2 \cdot x}{\sqrt{1 - x^2}} = \frac{-x}{\sqrt{1 - x^2}}.$$

Also haben wir für die Länge

$$l = \int_0^1 \sqrt{1 + \frac{x^2}{1 - x^2}} \, dx$$
$$= \int_0^1 \frac{1}{\sqrt{1 - x^2}} \, dx$$

An dieser Stelle wenden wir die Substitutions-Regel

$$\int_{a}^{b} f'(x) \cdot g(f(x)) dx = \int_{f(a)}^{f(b)} g(x) dx$$

an, wobei wir

$$f(x) := \sin(x), \quad g(x) := \frac{1}{\sqrt{1 - x^2}}, \quad a := 0 \quad \text{ und } \quad b := \frac{\pi}{2}$$

setzen. Wegen

$$f'(x) = \cos(x)$$
,  $\sin(0) = 0$  und  $\sin(\pi/2) = 1$ 

folgt dann

 $\Diamond$ 

$$l = \int_0^{\pi/2} \cos(x) \cdot \frac{1}{\sqrt{1 - \sin^2(x)}} dx$$

$$= \int_0^{\pi/2} \cos(x) \cdot \frac{1}{\cos(x)} dx$$

$$= \int_0^{\pi/2} 1 dx$$

$$= x \Big|_0^{\pi/2}$$

$$= \frac{\pi}{2}$$

und das ist genau der Umfang eines Viertel-Kreises.

**Aufgabe 67**: Berechnen Sie die Bogenlänge der Parabel  $x \mapsto x^2$  im Intervall [0,1].

**Hinweis**: Diese Aufgabe ist zwar etwas anspruchsvoller, aber dafür ist die Lösung umso lehrreicher. Es ist sinnvoll, die Lösung in die folgenden Schritte aufzuteilen:

(a) Zunächst definieren wir die beiden Funktionen  $\sinh(x)$  (lese: Sinus Hyperbolicus) und  $\cosh(x)$  (lese: Cosinus Hyperbolicus) wie folgt:

$$\sinh(x) = \frac{1}{2} \cdot \left(e^x - e^{-x}\right) \quad \text{ und } \quad \cosh(x) = \frac{1}{2} \cdot \left(e^x + e^{-x}\right).$$

(b) Die Umkehrfunktion der Funktion  $x\mapsto \sinh(x)$  können Sie auf den natürlichen Logarithmus zurück führen, indem Sie die Gleichung

$$y = \frac{1}{2} \cdot \left( e^x - e^{-x} \right)$$

nach x auflösen. Setzen Sie zunächst  $\alpha:=e^x$ , so erhalten Sie eine quadratische Gleichung für  $\alpha$  in Abhängigkeit von y. Wenn Sie aus dieser Gleichung  $\alpha$  berechnet haben, dann finden Sie anschließend x nach der Formel  $x=\ln(\alpha)$ .

Die Umkehrfunktion, die wir auf diesem Weg berechnet haben, ist als *Areasinus Hyperbolicus* bekannt und wird von uns als  $\mathtt{arsinh}(x)$  geschrieben. In der angelsächsischen Literatur findet sich auch die Schreibweise  $\sinh^{-1}(x)$  für diese Funktion.

(c) Dann zeigen wir

$$\frac{\mathrm{d}}{\mathrm{d}x}\sinh(x) = \cosh(x)$$
 und  $\frac{\mathrm{d}}{\mathrm{d}x}\cosh(x) = \sinh(x)$ .

(d) Weiter zeigen wir durch rein algebraische Umformungen, dass

$$1 + \sinh^2(x) = \cosh^2(x)$$

für alle  $x \in \mathbb{R}$  gilt.

(e) Nun berechnen wir das Integral

$$I(x) := \int_0^x \cosh^2(t) \, \mathrm{d}t$$

mit Hilfe einer partiellen Integration, wobei wir im Verlaufe der Rechnung an geeigneter Stelle die Identität  $\cosh^2(x) = 1 + \sinh^2(x)$  berücksichtigen.

(f) Das bei der Berechnung der Bogenlänge der Parabel auftretende Integral kann nun vermittels einer Substitution auf das Integral I(x) zurück geführt werden.

## 7.4 Uneigentliche Integrale

Ist bei dem Ausdruck  $\int_a^b f(x) \, \mathrm{d}x$  die Funktion f an einer der Intervall-Grenzen nicht definiert, so bezeichnen wir den Ausdruck als uneigentliches Integral. Wir betrachten nur den Fall, dass die Funktion f nur in dem halboffenen Intervall (a,b] definiert ist, während f in dem Punkt a nicht definiert sein soll. Beispielsweise ist die Funktion  $x\mapsto \frac{1}{\sqrt{x}}$  im Punkt x=0 nicht definiert. In diesem Fall definieren wir

$$\int_{a}^{b} f(x) \, \mathrm{d}x := \lim_{\substack{h \to 0 \\ h > 0}} \int_{a+h}^{b} f(x) \, \mathrm{d}x.$$

Wir betrachten als Beispiel das Integral der Funktion  $x \mapsto \frac{1}{\sqrt{x}}$  in dem Intervall [0,1]. Es gilt

$$\int_0^1 \frac{1}{\sqrt{x}} \, \mathrm{d}x = \lim_{h \to 0 \atop h > 0} \int_h^1 \frac{1}{\sqrt{x}} \, \mathrm{d}x = \lim_{h \to 0 \atop h > 0} 2 \cdot \sqrt{x} \, \Big|_h^1 = \lim_{h \to 0 \atop h > 0} 2 \cdot \sqrt{1} - 2 \cdot \sqrt{h} = 2.$$

Ein anderer Fall liegt vor, wenn eine der Integrations-Grenzen den Wert Unendlich hat. Wir betrachten nur den Fall  $b=\infty$ . In diesem Fall definieren wir

$$\int_{a}^{\infty} f(t) dt := \lim_{x \to \infty} \int_{a}^{x} f(t) dt.$$

Wir betrachten als Beispiel die Funktion  $x\mapsto \frac{1}{x^2}$  in dem Intervall  $[1,\infty)$ . Es gilt

$$\int_{1}^{\infty} \frac{1}{t^{2}} dt = \lim_{x \to \infty} \int_{1}^{x} \frac{1}{t^{2}} dt = \lim_{x \to \infty} -\frac{1}{t} \Big|_{1}^{x} = \lim_{x \to \infty} -\frac{1}{x} + \frac{1}{1} = 1.$$

Indem wir Reihen und uneigentliche Integrale in Beziehung setzen, können wir unter Umständen leicht sehen, dass eine Reihe konvergiert, denn es gilt der folgende Satz.

Satz 102 (Integral-Vergleichskriterium) Es sei  $f:[1,\infty)\to\mathbb{R}_+$  eine monoton fallende Funktion. Dann gilt

$$\boxed{\lim_{n \to \infty} \sum_{i=1}^n f(i) \text{ existiert} \quad \text{g.d.w.} \quad \lim_{x \to \infty} \int\limits_1^x f(t) \, \mathrm{d}t \text{ existiert.}}$$

**Beweis**: Für alle  $i \in \mathbb{N}$  mit i > 1 und alle  $x \in [i-1,i]$  gelten die Ungleichungen

$$i-1 \le x$$
 und  $x \le i$ .

Da die Funktion f monoton fallend ist, folgt daraus

$$f(i) \le f(x)$$
 und  $f(x) \le f(i-1)$ .

Aus der Monotonie des Integral-Operators folgt nun

$$\int_{i-1}^{i} f(i) dx \le \int_{i-1}^{i} f(x) dx \quad \text{und} \quad \int_{i-1}^{i} f(x) dx \le \int_{i-1}^{i} f(i-1) dx$$

Das Integral über die konstanten Funktionen  $x\mapsto f(i)$  bzw.  $x\mapsto f(i-1)$  liefert nur den konstanten Funktions-Wert multipliziert mit der Länge des Intervalls, die natürlich 1 ist. Also haben wir die Ungleichungen

$$f(i) \le \int_{i-1}^{i} f(x) \, \mathrm{d}x \quad \text{ und } \quad \int_{i-1}^{i} f(x) \, \mathrm{d}x \le f(i-1)$$

gezeigt. Summieren wir diese Ungleichungen für alle i aus der Menge  $\{2, \dots, n\}$ , so erhalten wir

$$\sum_{i=2}^n f(i) \le \int_1^n \!\! f(x) \, \mathrm{d}x \quad \text{ und } \quad \int_1^n \!\! f(x) \, \mathrm{d}x \le \sum_{i=2}^n f(i-1)$$

Bei der ersten Ungleichung addieren wir noch f(1), bei der zweiten Ungleichung ersetzen wir die Summations-Variable i durch i+1 und erhalten:

$$\sum_{i=1}^{n} f(i) \le f(1) + \int_{1}^{n} f(x) \, \mathrm{d}x \quad \text{und} \quad \int_{1}^{n} f(x) \, \mathrm{d}x \le \sum_{i=1}^{n-1} f(i)$$

Falls nun das Integral  $\int_{1}^{\infty} f(x) dx$  existiert, so gilt

$$\sum_{i=1}^{n} f(i) \le f(1) + \int_{1}^{n} f(x) \, \mathrm{d}x \le f(1) + \int_{1}^{\infty} f(x) \, \mathrm{d}x$$

Damit ist dann die Folge

$$\left(\sum_{i=1}^{n} f(i)\right)_{n \in \mathbb{N}}$$

monoton und beschränkt, folglich konvergent. Existiert umgekehrt der Grenzwert  $\sum_{i=1}^{\infty} f(i)$ , so ist aufgrund der zweiten Ungleichung auch die Folge

$$\left(\int_{1}^{n} f(x) \, \mathrm{d}x\right)_{n \in \mathbb{N}}$$

beschränkt. Da diese Folge außerdem monoton ist, folgt die Konvergenz.

Beispiel: Wir betrachten das Integral

$$I(\alpha) := \int\limits_{1}^{\infty} \frac{1}{t^{\alpha}} \, \mathrm{d}t \quad \text{ für } \alpha > 0.$$

Falls  $\alpha \neq 1$  ist, gilt

$$I(\alpha) = \int_{1}^{\infty} \frac{1}{t^{\alpha}} dt$$

$$= \lim_{x \to \infty} \int_{1}^{x} \frac{1}{t^{\alpha}} dt = \lim_{x \to \infty} \frac{t^{1-\alpha}}{1-\alpha} \Big|_{1}^{x}$$

$$= \lim_{x \to \infty} \frac{x^{1-\alpha} - 1}{1-\alpha}.$$

Im Falle  $\alpha = 1$  haben wir

$$I(\alpha) = \ln(x)$$
.

Nun hängt alles davon ab, ob  $\alpha < 1$ ,  $\alpha = 1$  oder  $\alpha > 1$  ist.

1. Falls  $\alpha < 1$  ist, haben wir  $1 - \alpha > 0$  und damit gilt

$$I(\alpha) = \lim_{x \to \infty} \frac{x^{1-\alpha} - 1}{1 - \alpha} = \infty$$

Also konvergiert die Summe

$$\sum_{i=1}^{\infty} \frac{1}{i^{\alpha}}$$

in diesem Fall nicht.

2. Falls  $\alpha = 1$  ist, gilt

$$I(1) = \lim_{x \to \infty} \int_{1}^{x} \frac{1}{t} dt = \lim_{x \to \infty} \ln(x) = \infty$$

Im letzten Schritt haben wir hier ausgenutzt, dass

$$\lim_{x \to \infty} \ln(x) = \infty$$

gilt. Das folgt daraus, dass die Funktion  $x\mapsto \ln(x)$  einerseits monoton steigend ist und dass andererseits

$$\ln(\exp(n)) = n$$
 für alle  $n \in \mathbb{N}$ 

gilt, denn die letzte Gleichung zeigt, dass die Funktion  $x\mapsto \ln(x)$  beliebig groß wird.

Insgesamt können wir nun aus dem Integral-Vergleichskriterium folgern, dass die harmonische Reihe divergiert:

$$\sum_{i=1}^{\infty} \frac{1}{i} = \infty.$$

3. Falls  $\alpha > 1$  ist, haben wir  $1 - \alpha < 0$  und damit gilt

$$I(\alpha) = \lim_{x \to \infty} \frac{x^{1-\alpha} - 1}{1 - \alpha} = \frac{1}{\alpha - 1}$$

In diesem Fall konvergiert also die Summe

$$\sum_{i=1}^{\infty} \frac{1}{i^{\alpha}}.$$

Aufgabe 68: Untersuchen Sie mit Hilfe des Integral-Vergleichskriteriums, ob die Reihe

$$\sum_{n=1}^{\infty} \frac{1}{n \cdot (n+1)}$$
 konvergiert.

## 7.5 Numerische Integration\*

Die Gleichung  $x = \cos(x)$  haben wir zwar numerisch lösen können, aber wir waren nicht in der Lage, einen algebraischen Ausdruck für die Lösung anzugeben. Auch bei der Integration von Funktionen ist es nicht immer möglich, einen algebraischen Ausdruck für die Stamm-Funktion einer Funktion anzugeben. Beispielsweise konnte Liouville (Joseph Liouville, 1809 – 1882) beweisen, dass das unbestimmte Integral

$$\int \exp(-x^2) \, \mathrm{d}x$$

nicht auf die uns bisher bekannten Funktionen zurück geführt werden kann [9]. Für die praktische Berechnung von Integralen benötigen wir daher numerische Methoden.

#### 7.5.1 Die Trapez-Regel\*

Die wohl naheliegenste Methode besteht darin, die zu integrierende Funktion stückweise linear zu interpolieren und dann das zur berechnende Integral durch das Integral der stückweise linearen Funktion zu approximieren. Ist das Integral  $\int_a^b f(t) \, \mathrm{d}t$  zu berechnen, so wird zunächst das Intervall [a,b] in n gleich große Teilintervalle zerlegt. Das i-te Teilintervall ist  $[a+(i-1)\cdot h,a+i\cdot h]$  mit  $h:=\frac{b-a}{n}$  und  $i=1,\cdots,n$ . Wir setzen  $x_i:=a+i\cdot h$ . Innerhalb des i-ten Teilintervalls wird die Funktion f(x) dann durch die Gerade

$$g(x) = f(x_{i-1}) \cdot \frac{x - x_i}{x_{i-1} - x_i} + f(x_i) \cdot \frac{x - x_{i-1}}{x_i - x_{i-1}}$$

approximiert. Das Integral über g(x) im Intervall  $[x_{i-1}, x_i]$  ist dann

$$\int_{x_{i-1}}^{x_i} g(x) dx$$

$$= \int_{x_{i-1}}^{x_i} f(x_{i-1}) \cdot \frac{x - x_i}{x_{i-1} - x_i} + f(x_i) \cdot \frac{x - x_{i-1}}{x_i - x_{i-1}} dx$$

$$= \frac{f(x_{i-1})}{x_{i-1} - x_i} \cdot \int_{x_{i-1}}^{x_i} (x - x_i) dx + \frac{f(x_i)}{x_i - x_{i-1}} \cdot \int_{x_{i-1}}^{x_i} (x - x_{i-1}) dx$$

$$= \frac{f(x_{i-1})}{x_{i-1} - x_i} \cdot \frac{1}{2} \cdot (x - x_i)^2 \Big|_{x_{i-1}}^{x_i} + \frac{f(x_i)}{x_i - x_{i-1}} \cdot \frac{1}{2} \cdot (x - x_{i-1})^2 \Big|_{x_{i-1}}^{x_i}$$

$$= -\frac{f(x_{i-1})}{x_{i-1} - x_i} \cdot \frac{1}{2} \cdot (x_{i-1} - x_i)^2 + \frac{f(x_i)}{x_i - x_{i-1}} \cdot \frac{1}{2} \cdot (x_i - x_{i-1})^2$$

$$= \frac{1}{2} \cdot f(x_{i-1}) \cdot (x_i - x_{i-1}) + \frac{1}{2} \cdot f(x_i) \cdot (x_i - x_{i-1})$$

$$= \frac{1}{2} \cdot \left(f(x_i) + f(x_{i-1})\right) \cdot (x_i - x_{i-1})$$

Die letzte Formel lässt sich geometrisch deuten, denn der Ausdruck

$$\frac{1}{2} \cdot (f(x_i) + f(x_{i-1})) \cdot (x_i - x_{i-1})$$

beschreibt gerade die Fläche eines Trapezes mit der Breite  $h=x_i-x_{i-1}$  und Seiten der Länge  $f(x_i)$  und  $f(x_{i-1})$ . Daher wird dieses Verfahren zur Berechnung eines Integrals auch als *Trapez-Regel* bezeichnet. Um das Integral über das gesamte Intervall [a,b] zu berechnen, müssen wir die Integrale über die einzelnen Intervalle lediglich aufsummieren. Wir erhalten dann

$$\int_{a}^{b} f(x) dx \approx \sum_{i=1}^{n} \frac{1}{2} \cdot (f(x_{i}) + f(x_{i-1})) \cdot (x_{i} - x_{i-1})$$

$$= \sum_{i=1}^{n} \frac{1}{2} \cdot (f(a + i \cdot h) + f(a + (i - 1) \cdot h)) \cdot h$$

$$= \left(\frac{1}{2} \cdot f(a) + \sum_{i=1}^{n-1} f(a + i \cdot \frac{b - a}{n}) + \frac{1}{2} \cdot f(b)\right) \cdot \frac{b - a}{n}$$

Abbildung 7.4 auf Seite 158 zeigt die numerische Berechnung des Integrals  $\int_0^1 \exp(x^2) \, \mathrm{d}x$  mit Hilfe der Trapez-Regel. In diesem Fall ist n=3. Führen wir die Berechnung tatsächlich aus, so erhalten wir die Näherung

$$\int_{0}^{1} \exp(-x^2) \, \mathrm{d}x \approx 0.7399864752 \cdots$$

Der exakte Wert ist 0.7468241328, unter Berücksichtigung der Tatsache, dass wir n=3 gewählt haben ist die Näherung also gar nicht so schlecht. Erhöhen wir n auf den Wert 300, so erhalten wir mit der Trapez-Regel die Näherung 0.7468234519, der Fehler ist dann also kleiner als  $10^{-6}$ . Im nächsten Satz geben wir eine theoretische Analyse des Fehlers.

**Satz 103** Ist die Funktion  $f:[a,b]\to\mathbb{R}$  zweimal differenzierbar, gilt

$$\left|f^{(2)}(x)\right| \leq K \quad \text{ für alle } x \in [a,b]$$



Abbildung 7.4: Berechnung des Integrals  $\int_0^1 \exp(-x^2) dx$  mit Hilfe der Trapez-Regel.

und definieren wir gemäß der Trapez-Regel

$$I_{\mathsf{Trapez}} := \left(\frac{1}{2} \cdot f(a) + \sum_{i=1}^{n-1} f\left(a + i \cdot \frac{b-a}{n}\right) + \frac{1}{2} \cdot f(b)\right) \cdot \frac{b-a}{n}$$

so kann der Unterschied zwischen dem exakten Integral und der Näherung  $I_{\sf Trapez}$  wie folgt abgeschätzt werden:

$$\left| \int_a^b f(x) \, \mathrm{d}x - I_{\mathsf{Trapez}} \right| \, \leq \, \frac{K}{12} \cdot \frac{(b-a)^3}{n^2}$$

**Beweis**: Bei der Ableitung der Trapez-Regel haben wir f(x) durch ein lineares Polynom interpoliert. Nach Satz 87 gilt für den Unterschied zwischen f(x) und dem interpolierenden Polynom p(x) vom Grad n

$$f(x) - p(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \cdot \prod_{i=0}^{n} (x - x_i).$$

Dabei ist  $\xi$  ein nicht näher bekannter Wert aus dem Intervall [a,b]. Bei linearer Interpolation ist n=1 und also haben wir

$$f(x) - p(x) = \frac{f^{(2)}(\xi)}{2} \cdot (x - x_{i-1}) \cdot (x - x_i).$$

Aufgrund der Voraussetzung über die zweite Ableitung von f(x) haben wir also

$$|f(x) - p(x)| \le \frac{K}{2} \cdot |(x - x_{i-1}) \cdot (x - x_i)|$$
 (7.14)

In dem Intervall  $[x_{i-1}, x_i]$  gilt  $x - x_{i-1} \ge 0$  und  $x - x_i \le 0$ , also haben wir

$$|(x - x_{i-1}) \cdot (x - x_i)| = -(x - x_{i-1}) \cdot (x - x_i).$$

Integrieren wir die Ungleichung 7.14 in dem Intervall  $[x_{i-1}, x_i]$ , so erhalten wir

 $\Diamond$ 

$$\left| \int_{x_{i-1}}^{x_i} f(x) \, dx - \int_{x_{i-1}}^{x_i} p(x) \, dx \right|$$

$$\leq \int_{x_{i-1}}^{x_i} \left| f(x) \, dx - p(x) \right| \, dx$$

$$\leq \frac{K}{2} \cdot \int_{x_{i-1}}^{x_i} \left| (x - x_{i-1}) \cdot (x - x_i) \right| \, dx$$

$$\leq -\frac{K}{2} \cdot \int_{x_{i-1}}^{x_i} (x - x_{i-1}) \cdot (x - x_i) \, dx$$

$$= -\frac{K}{2} \cdot \frac{-1}{6} \cdot (x_i - x_{i-1})^3$$

$$= \frac{K}{12} \cdot (x_i - x_{i-1})^3$$

Diese Ungleichung gilt nun für jedes  $i=1,\cdots,n$ . Summieren wir diese Ungleichungen für alle Intervalle auf, so erhalten wir

$$\left| \int_{a}^{b} f(x) \, \mathrm{d}x - I_{\mathsf{Trapez}} \right| \leq \sum_{i=1}^{n} \frac{K}{12} \cdot (x_{i} - x_{i-1})^{3}$$

$$\leq \sum_{i=1}^{n} \frac{K}{12} \cdot \left(\frac{b-a}{n}\right)^{3}$$

$$\leq n \cdot \frac{K}{12} \cdot \left(\frac{b-a}{n}\right)^{3}$$

$$\leq \frac{K}{12} \cdot \frac{(b-a)^{3}}{n^{2}}$$

Falls wir also die Zahl der Intervalle verzehnfachen, sinkt der Fehler auf ein Hundertstel.

**Aufgabe 69**: Berechnen Sie, in wieviele Teilintervalle das Intervall [0,1] aufgeteilt werden muss, wenn das Integral

$$\int_0^1 e^{-x^2} \, \mathrm{d}x$$

mit Hilfe der Trapez-Regel mit einer Genauigkeit von  $10^{-6}$  berechnet werden soll.

#### 7.5.2 Die Simpson'sche Regel\*

Anstatt die zu integrierende Funktion f durch ein lineares Polynom zu interpolieren, können wir f auch durch ein Polynom zweiten Grades interpolieren. Wir brauchen dann natürlich drei Stützstellen. Daher integrieren wir jetzt nicht mehr über ein Intervall  $[x_{i-1},x_i]$ , sondern nehmen stattdessen das Intervall  $[x_{i-1},x_{i+1}]$  und benutzen  $x_{i-1},x_i$  und  $x_{i+1}$  als Stützstellen. Die Funktion f(x) approximieren wir in dem Intervall mit der Methode von Lagrange nach der Formel

$$p(x) = f(x_{i-1}) \cdot \frac{(x - x_i) \cdot (x - x_{i+1})}{(x_{i-1} - x_i) \cdot (x_{i-1} - x_{i+1})}$$

$$+ f(x_i) \cdot \frac{(x - x_{i-1}) \cdot (x - x_{i+1})}{(x_i - x_{i-1}) \cdot (x_i - x_{i+1})}$$

$$+ f(x_{i+1}) \cdot \frac{(x - x_{i-1}) \cdot (x - x_i)}{(x_{i+1} - x_{i-1}) \cdot (x_{i+1} - x_i)}$$

Setzen wir hier  $x_{i-1} = x_i - h$  und  $x_{i+1} = x_i + h$  und integrieren dann p(x) in dem Intervall  $[x_i - h, x_i + h]$ , so erhalten wir mit Hilfe von *SymPy* das Ergebnis

$$\int_{x_{i-1}}^{x_{i+1}} p(x) \, \mathrm{d}x = \frac{1}{6} \cdot \left( f(x_{i-1}) + 4 \cdot f(x_i) + f(x_{i+1}) \right) \cdot (x_{i+1} - x_{i-1})$$

Unterteilen wir das Intervall [a,b] lediglich in zwei Teilintervalle  $[a,\frac{a+b}{2}]$  und  $[\frac{a+b}{2},b]$ , so können wir die obige Formel direkt verwenden. Wir erhalten dann die *Kepler'sche Fassregel* (Johannes Kepler, 1571 – 1630).

$$\int_{a}^{b} f(x) dx \approx \frac{1}{6} \cdot \left( f(a) + 4 \cdot f\left(\frac{a+b}{2}\right) + f(b) \right) \cdot (b-a) \tag{7.15}$$

Berechnen wir das Integral  $\int_0^1 \exp(-x^2) dx$  mit dieser Regel, so erhalten wir 0.7471804290 und der Fehler ist bereits kleiner als  $4 \cdot 10^{-4}$ .

Unterteilen wir das Intervall [a,b] in n Intervalle und ist darüber hinaus n eine gerade Zahl, so können wir die Regel 7.15 jeweils auf die beiden benachbarten Intervalle  $[x_{2\cdot i},x_{2\cdot i+1}]$  und  $[x_{2\cdot i+1},x_{2\cdot i+2}]$  anwenden, wobei der Index i über alle Elemente der Menge  $\{0,\cdots,(n-1)/2\}$  läuft. Setzen wir  $h:=\frac{b-a}{n}$  und  $x_i:=a+i\cdot h$ , so erhalten wir die Formel

$$\int_{a}^{b} f(x) dx \approx \frac{h}{3} \cdot \sum_{i=0}^{(n-1)/2} \left( f(x_{2\cdot i}) + 4 \cdot f(x_{2\cdot i+1}) + f(x_{2\cdot i+2}) \right)$$

$$= \frac{h}{3} \cdot \left( f(x_{0}) + 4 \cdot \sum_{i=0}^{(n-1)/2} f(x_{2\cdot i+1}) + 2 \cdot \sum_{i=1}^{(n-1)/2} f(x_{2\cdot i}) + f(x_{n}) \right)$$
(7.16)

Die obige Formel trägt den Namen Simpson'sche Regel (Thomas Simpson, 1710 - 1761). Falls die Funktion f insgesamt viermal differenzierbar ist und falls darüber hinaus die vierte Ableitung von f der Ungleichung

$$|f^{(4)}(x)| \le K$$

genügt, so lässt sich der Fehler, der bei der Verwendung der Simpson'schen Regel entsteht, durch

$$\frac{K}{180} \cdot \frac{(b-a)^5}{n^4}$$

abschätzen. Verdoppeln wir die Zahl n der Intervalle, so verkleinert sich der Fehler also um das 16-fache! Wählen wir beispielsweise n=20 und berechnen das Integral  $\int_0^1 \exp(-x^2) \, \mathrm{d}x$ , so erhalten wir den Wert 0.746824183 und der Fehler ist kleiner als  $10^{-7}$ .

#### Aufgabe 70:

(a) Berechnen Sie mit Hilfe der Kepler'schen Fass-Regel eine Approximation für das Integral

$$\int_0^{\frac{1}{2}} \sin(x) \, \mathrm{d}x.$$

- (b) Geben Sie eine möglichst genaue Abschätzung für den Approximations-Fehler.
- (c) Vergleichen Sie ihr Ergebnis mit dem exakten Wert.

 $\Diamond$ 

Aufgabe 71: Gegenstand dieser Aufgabe ist die numerische Berechnung der Summe

$$\sum_{k=1}^{\infty} \frac{1}{k^2}.$$

Gehen Sie zur Berechnung dieser Summe in folgenden Schritten vor.

(a) Approximieren Sie die Rest-Summe  $\sum_{k=n}^{\infty} \frac{1}{k^2}$  durch ein geeignetes Integral.

$$\mbox{Hinweis: Es gilt } f(k) = \int_{k-\frac{1}{2}}^{k+\frac{1}{2}} f(k) \, \mathrm{d}t \approx \int_{k-\frac{1}{2}}^{k+\frac{1}{2}} f(t) \, \mathrm{d}t.$$

(b) Berechnen Sie eine obere Abschätzung für den Approximations-Fehler, den Sie bei der Integration in Teil (a) erhalten.

Hinweis: Schätzen Sie die auftretenden Summen durch Integrale nach oben ab.

- (c) Berechnen Sie, wir groß Sie n wählen müssen, damit der Approximations-Fehler kleiner als  $10^{-6}$  bleibt.
- (d) Geben Sie nun einen Näherungs-Wert für die Summe  $\sum_{k=1}^{\infty} \frac{1}{k^2}$  an, der sich von dem exakten Ergebnis um weniger als  $10^{-6}$  unterscheidet.

# Kapitel 8

# Die Kreiszahl $\pi$ und die Euler'sche Zahl e sind irrational\*

In diesem Kapitel zeigen wir, dass sowohl die Kreiszahl  $\pi$ , die als Fläche eines Kreises mit dem Radius 1 definiert ist, als auch die Euler'sche Zahl e, die als Grenzwert der Reihe

$$\exp(1) := \sum_{k=0}^{\infty} \frac{1}{k!}$$

festgelegt ist, irrational sind. Da der Nachweis der Irrationalität von e einfacher ist, beginnen wir damit.

### 8.1 Die Euler'sche Zahl e ist irrational

Nach Definition von e gilt

$$e = \sum_{k=0}^{\infty} \frac{1}{k!}.$$

Für alle  $n \in \mathbb{N}$  definieren wir die n-te Partial-Summe  $s_n$  als

$$s_n := \sum_{k=0}^{n} \frac{1}{k!}$$
.

Als nächstes definieren wir für alle natürlichen Zahlen  $n \in \mathbb{N}$  den n-ten Rest

$$r_n := e - s_n = \sum_{k=0}^{\infty} \frac{1}{k!} - \sum_{k=0}^{n} \frac{1}{k!} = \sum_{k=n+1}^{\infty} \frac{1}{k!}$$

Offenbar gilt

$$0 < r_n, \tag{8.1}$$

denn der n-te Rest  $r_n$  enthält auf jeden Fall den Term  $\frac{1}{(n+1)!}$  und der ist positiv. Wir wollen nun den n-ten Rest  $r_n$  nach oben hin abschätzen. Dazu benötigen wir zunächst die folgende Abschätzung, die für alle k>n+1 gültig ist:

$$\begin{array}{cccc} & \frac{(n+1)!}{k!} & < & \frac{1}{(n+1)^{k-(n+1)}} \\ \Leftrightarrow & \frac{k!}{(n+1)!} & > & (n+1)^{k-(n+1)} \\ \Leftrightarrow & \underbrace{(n+2)\cdot(n+3)\cdot\ldots\cdot(k-1)\cdot k}_{k-(n+1) \text{ Faktoren}} & > & \underbrace{(n+1)\cdot\ldots\cdot(n+1)}_{k-(n+1) \text{ Faktoren}} \end{array}$$

Die letzte Ungleichung ist richtig, denn die Faktoren auf der linken Seite haben die Form (n+1)+i

mit  $i \in \{1, \dots, k - (n+1)\}$  und offenbar gilt

$$(n+1)+i > n+1$$
 für  $i \in \{1, \dots, k-(n+1)\}$ ,

so dass zu jedem Faktor in dem Produkt auf der linken Seite ein kleinerer Faktor auf der rechten Seite korrespondiert. Falls k=(n+1) ist, gilt

$$\frac{(n+1)!}{k!} = \frac{1}{(n+1)^{k-(n+1)}} = 1,$$

was man unmittelbar durch Einsetzen bestätigen kann. Wir haben also insgesamt Folgendes gezeigt:

$$\frac{(n+1)!}{k!} < \frac{1}{(n+1)^{k-(n+1)}} \quad \text{für alle } k > n+1$$
 (8.2)

und für k=n+1 haben wir die Gleichheit beider Seiten. Nun gilt für alle  $n\in\mathbb{N}$  mit  $n\geq 1$  die folgende Ungleichungs-Kette:

$$r_n = \sum_{k=n+1}^{\infty} \frac{1}{k!}$$

$$= \frac{1}{(n+1)!} \cdot \sum_{k=n+1}^{\infty} \frac{(n+1)!}{k!}$$

$$< \frac{1}{(n+1)!} \cdot \sum_{k=n+1}^{\infty} \frac{1}{(n+1)^{k-(n+1)}} \quad \text{(nach Gleichung (8.2))}$$

$$= \frac{1}{(n+1)!} \cdot \sum_{k=0}^{\infty} \frac{1}{(n+1)^k} \quad \text{(Index-Verschiebung)}$$

$$= \frac{1}{(n+1)!} \cdot \frac{1}{1 - \frac{1}{n+1}} \quad \text{(geometrische Reihe)}$$

$$= \frac{1}{(n+1)!} \cdot \frac{1}{\frac{n+1-1}{n+1}} \quad \text{(Hauptnenner)}$$

$$= \frac{1}{(n+1)!} \cdot \frac{n+1}{n}$$

$$= \frac{1}{n! \cdot n}$$

Multiplizieren wir die resultierende Ungleichung mit n!, so sehen wir, dass

$$n! \cdot r_n < \frac{1}{n}$$

gilt. Fassen wir diese Gleichung zusammen mit der Gleichung (8.1), so haben wir insgesamt

$$0 < n! \cdot r_n < \frac{1}{n} \quad \text{falls } n \ge 1 \text{ ist.} \tag{8.3}$$

Damit ist aber klar, dass der Ausdruck  $n! \cdot r_n$  für  $n \geq 1$  keine natürliche Zahl sein kann.

**Theorem 104** Die Eulersche Zahl e ist irrational.

**Beweis**: Wir nehmen an, dass e rational ist. Dann gibt es natürliche Zahlen  $p,q\in\mathbb{N}$  mit  $q\geq 1$  und  $e=\frac{p}{a}$ .

Wir betrachten den Ausdruck  $q! \cdot r_q = q! \cdot (e-s_q)$  und setzten dort für e den Wert  $\frac{p}{q}$  ein:

$$q! \cdot r_q = q! \cdot \left(\frac{p}{q} - \sum_{k=0}^{q} \frac{1}{k!}\right) = (q-1)! \cdot p - \sum_{k=0}^{q} \frac{q!}{k!} \in \mathbb{Z},$$

denn  $(q-1)! \cdot p$  ist auf jeden Fall eine natürliche Zahl und für  $k \leq q$  hat der Ausdruck  $\frac{q!}{k!}$  die Form

$$\frac{q!}{k!} = \frac{1 \cdot 2 \cdot \ldots \cdot k \cdot (k+1) \cdot (k+2) \cdot \ldots \cdot (q-1) \cdot q}{1 \cdot 2 \cdot \ldots \cdot k} = (k+1) \cdot (k+2) \cdot \ldots \cdot (q-1) \cdot q$$

und das ist ebenfalls eine natürliche Zahl. Damit haben wir aber einen Widerspruch, denn die Aussagen

$$0 < q! \cdot r_q < \frac{1}{q} \quad \text{ und } \quad q! \cdot r_q \in \mathbb{Z}$$

sind unvereinbar.

#### 8.2 Die Kreiszahl $\pi$ ist irrational\*

Zur Vorbereitung des Beweises benötigen wir das folgende Lemma.

**Lemma 105** Die Funktion  $f:\mathbb{R}\to\mathbb{R}$  sei beliebig oft differenzierbar. Dann gilt für alle natürlichen Zahlen n

$$\int_0^{\pi} f(x) \cdot \sin(x) \, dx = \sum_{k=0}^n (-1)^k \cdot \left( f^{(2k)}(\pi) + f^{(2k)}(0) \right) + (-1)^{n+1} \cdot \int_0^{\pi} f^{(2n+2)}(x) \cdot \sin(x) \, dx.$$

Beweis: Zur Abkürzung definieren wir

$$I := \int_0^{\pi} f(x) \cdot \sin(x) \, dx$$

und

$$S_n := \sum_{k=0}^n (-1)^k \cdot \left( f^{(2k)}(\pi) + f^{(2k)}(0) \right) + (-1)^{n+1} \cdot \int_0^\pi f^{(2n+2)}(x) \cdot \sin(x) \, dx.$$

Die Behauptung

$$I = S_n$$

wird nun durch Induktion nach n bewiesen. Dabei werden wir sowohl im Induktions-Anfang als auch im Induktions-Schritt zwei partielle Integrationen durchführen.

I.A.: n = 0.

Nach Definition von I gilt

$$I = \int_0^{\pi} f(x) \cdot \sin(x) \, dx$$

Wir integrieren partiell und setzen u(x) = f(x) und  $v'(x) = \sin(x)$ . Dann gilt u'(x) = f'(x) und  $v(x) = -\cos(x)$ . Also haben wir

$$I = -f(x) \cdot \cos(x) \Big|_0^{\pi} + \int_0^{\pi} f'(x) \cdot \cos(x).$$

Für den ersten Summanden auf der rechten Seite dieser Gleichung finden wir

$$-f(x) \cdot \cos(x)\Big|_{0}^{\pi} = -f(\pi) \cdot \cos(\pi) + f(0) \cdot \cos(0) = f(\pi) + f(0).$$

Um das verbleibende Integral zu berechnen führen wir eine erneute partielle Integration durch, bei der wir diesmal u(x)=f'(x) und  $v'(x)=\cos(x)$  setzen. Dann gilt  $u'(x)=f^{(2)}(x)$  und  $v(x)=\sin(x)$ . Wegen

$$\sin(\pi) = \sin(0) = 0$$

finden wir damit für das Integral I den Wert

$$I = f(\pi) + f(0) - \int_0^{\pi} f^{(2)}(x) \cdot \sin(x) dx.$$

Auf der anderen Seite haben wir

$$S_0 = \sum_{k=0}^{0} (-1)^k \cdot \left( f^{(2k)}(\pi) + f^{(2k)}(0) \right) + (-1)^{0+1} \cdot \int_0^{\pi} f^{(2\cdot 0+2)}(x) \cdot \sin(x) \, dx$$

$$= (-1)^0 \cdot \left( f^{(0)}(\pi) + f^{(0)}(0) \right) - \int_0^{\pi} f^{(2)}(x) \cdot \sin(x) \, dx$$

$$= f(\pi) + f(0) - \int_0^{\pi} f^{(2)}(x) \cdot \sin(x) \, dx$$

$$= I$$

I.S.:  $n \mapsto n+1$ 

Zur Abkürzung definieren wir

$$J_n = \int_0^{\pi} f^{(2n+2)}(x) \cdot \sin(x) \, dx$$

Wir berechnen  $J_n$  durch partielle Integration und setzen  $u(x):=f^{(2n+2)}(x)$  und  $v'(x):=\sin(x)$ . Dann haben wir  $u'(x)=f^{(2n+3)}(x)$  und  $v(x)=-\cos(x)$ . Das liefert

$$J_n = -f^{(2n+2)}(x) \cdot \cos(x) \Big|_0^{\pi} + \int_0^{\pi} f^{(2n+3)}(x) \cdot \cos(x) \, dx.$$

Wegen  $\cos(\pi) = -1$  und  $\cos(0) = 1$  vereinfacht sich der erste Summand auf der rechten Seite wie folgt:

$$-f^{(2n+2)}(x)\cdot\cos(x)\Big|_0^\pi = f^{(2n+2)}(\pi) + f^{(2n+2)}(0).$$

Das auf der rechten Seite der obigen Gleichung verbleibende Integral berechnen wir durch eine weitere partielle Integration. Diesmal setzen wir  $u(x)=f^{(2n+3)}(x)$  und  $v'(x)=\cos(x)$ . Dann haben wir  $u'(x)=f^{(2n+3)}(x)$  und  $v(x)=\sin(x)$  und für das Integral finden wir

$$\int_0^{\pi} f^{(2n+3)}(x) \cdot \cos(x) \, dx = f^{(2n+3)}(x) \cdot \sin(x) \Big|_0^{\pi} - \int_0^{\pi} f^{(2n+4)}(x) \cdot \sin(x) \, dx$$
$$= -\int_0^{\pi} f^{(2n+4)}(x) \cdot \sin(x) \, dx$$

Insgesamt haben wir damit für  $J_n$  den Ausdruck

$$J_n = f^{(2n+2)}(\pi) + f^{(2n+2)}(0) - \int_0^{\pi} f^{(2n+4)}(x) \cdot \sin(x) dx$$
$$= f^{(2n+2)}(\pi) + f^{(2n+2)}(0) - J_{n+1}$$

gefunden. Jetzt rechnen wir wie folgt:

$$I \stackrel{IV}{=} \sum_{k=0}^{n} (-1)^k \cdot \left( f^{(2k)}(\pi) + f^{(2k)}(0) \right) + (-1)^{n+1} \cdot J_n$$

$$= \sum_{k=0}^{n} (-1)^k \cdot \left( f^{(2k)}(\pi) + f^{(2k)}(0) \right) + (-1)^{n+1} \cdot \left( f^{(2n+2)}(\pi) + f^{(2n+2)}(0) - J_{n+1} \right)$$

$$= \sum_{k=0}^{n+1} (-1)^k \cdot \left( f^{(2k)}(\pi) + f^{(2k)}(0) \right) + (-1)^{n+2} \cdot J_{n+1} = S_{n+1}$$

Damit haben wir gezeigt, dass  $I = S_{n+1}$  gilt und die Induktion ist abgeschlossen.

**Theorem 106** Die Kreiszahl  $\pi$  ist irrational.

**Beweis**: Wir führen den Beweis indirekt und nehmen an, dass  $\pi \in \mathbb{Q}$  ist. Dann gibt es Zahlen  $p,q \in \mathbb{N}$  mit

$$\pi = \frac{p}{q}.$$

Für beliebige  $n \in \mathbb{N}$  definieren wir das Polynom  $g_n(x)$  wie folgt:

$$g_n(x) := \frac{1}{n!} \cdot x^n \cdot (p - q \cdot x)^n.$$

Es gilt

$$g_n(\pi - x) = \frac{1}{n!} \cdot \left(\frac{p}{q} - x\right)^n \cdot \left(p - q \cdot \left(\frac{p}{q} - x\right)\right)^n$$

$$= \frac{1}{n!} \cdot \left(\frac{p}{q} - x\right)^n \cdot (q \cdot x)^n$$

$$= \frac{1}{n!} \cdot (p - q \cdot x)^n \cdot x^n$$

$$= g_n(x)$$

Diese Gleichung überträgt sich natürlich auf die Ableitungen und daher haben wir

$$g_n^{(k)}(\pi - x) = (-1)^k \cdot g_n^{(k)}(x).$$

Offenbar ist  $g_n$  ein Polynom vom Grad  $2 \cdot n$  und damit ist klar, dass  $g_n^{(2n+2)}(x) = 0$  ist. Setzen wir in der Behauptung des letzten Lemmas für f die Funktion  $g_n(x)$  ein, so folgt daher

$$\int_0^{\pi} g_n(x) \cdot \sin(x) \, dx = \sum_{k=0}^n (-1)^k \cdot \left( g_n^{(2k)}(\pi) + g_n^{(2k)}(0) \right).$$

Wir zeigen, dass alle Summanden in der Summe auf der rechten Seite dieser Gleichung ganze Zahlen sind. Dabei reicht es aus, dies für die Summanden der Form  $g_n^{(2k)}(0)$  zu zeigen, denn es gilt

$$g_n^{(2k)}(\pi) = (-1)^{2 \cdot k} \cdot g_n^{(2k)}(\pi - \pi) = g_n^{(2k)}(0).$$

Wir zeigen mit Hilfe einer Fallunterscheidung, dass  $g_n^{(k)}(0) \in \mathbb{N}$  für alle  $k \in \mathbb{N}$  gilt.

1. Fall: k < n.

Da das Polynom  $g_n(x)$  die Form

$$g_n(x) = \frac{1}{n!} \cdot \sum_{i=n}^{2 \cdot n} c_i \cdot x^i$$

mit Koeffizienten  $c_i \in \mathbb{Z}$  hat, folgt, dass für k < n

$$g_n^{(k)}(x) = \frac{1}{n!} \cdot \sum_{i=n}^{2 \cdot n} \frac{i!}{(i-k)!} \cdot c_i \cdot x^{i-k}$$

gilt. Jeder Term dieser Summe enthält mindestens den Faktor x. Setzen wir hier für x den Wert 0 ein, so wird daher jeder Term in der Summe 0. Damit gilt

$$g_n^{(k)}(0) = 0 \in \mathbb{N}.$$

2. Fall:  $k \geq n$ .

Diesmal verschwinden beim Ableiten alle Summanden mit Index i < k. Wir haben also

$$g_n^{(k)}(x) = \frac{1}{n!} \cdot \sum_{i=k}^{2 \cdot n} \frac{i!}{(i-k)!} \cdot c_i \cdot x^{i-k}$$

$$= \sum_{i=k}^{2 \cdot n} \frac{k!}{n!} \cdot \frac{i!}{k! \cdot (i-k)!} \cdot c_i \cdot x^{i-k}$$

$$= \sum_{i=k}^{2 \cdot n} \frac{k!}{n!} \cdot \binom{i}{k} \cdot c_i \cdot x^{i-k}$$

Für x = 0 folgt dann

$$g_n^{(k)}(0) = \frac{k!}{n!} \cdot {k \choose k} \cdot c_k = \frac{k!}{n!} \cdot c_k \in \mathbb{Z},$$

denn wenn  $k \ge n$  ist, ist  $\frac{k!}{n!}$  eine natürliche Zahl.

Insgesamt wissen wir jetzt, dass das Integral

$$I_n := \int_0^{\pi} g_n(x) \cdot \sin(x) \, dx$$

für alle  $n \in \mathbb{N}$  eine ganze Zahl ist. Für alle  $x \in [0, \pi]$  gilt nun

$$0 \le \sin(x)$$
 und  $0 \le g_n(x)$ .

Also muss auch

$$0 < I_r$$

gelten. Die Ungleichung ist echt, denn die beiden Funktionen  $\sin(x)$  und  $g_n(x)$  haben nur bei x=0 und  $x=\pi$  eine Nullstelle. Außerdem gilt für alle  $x\in[0,\pi]$ 

$$\sin(x) \le 1$$
 und  $g_n(x) \le \frac{1}{n!} \cdot \pi^n \cdot p^n$ .

Die letzte dieser beiden Ungleichungen folgt aus der Tatsache, dass einerseits  $x \le \pi$  und andererseits  $p-q\cdot x \le p$  ist. Aus den beiden oberen Ungleichungen folgt durch Integration

$$0 \le I_n \le \pi \cdot \frac{\pi^n \cdot p^n}{n!}$$

Nun gilt

$$\lim_{n \to \infty} \pi \cdot \frac{\pi^n \cdot p^n}{n!} = 0$$

Daher gibt es ein  $n \in \mathbb{N}$ , so dass  $\pi \cdot \frac{\pi^n \cdot p^n}{n!} < 1$  ist und für dieses n haben wir

$$0 < I_n < 1$$

Das ist aber ein Widerspruch dazu, dass wir oben nachgewiesen haben, dass  $I_n$  eine ganze Zahl ist.  $\square$ 

#### 8.3 Transzendente Zahlen

#### Definition 107 (Algebraische Zahlen)

Eine Zahl  $r \in \mathbb{R}$  heißt *algebraisch* genau dann, wenn es ein Polynom

$$p(x) = \sum\limits_{i=0}^n a_i \cdot x^i \quad \text{ mit } a_i \in \mathbb{Z} \text{ für alle } i = 0, 1, \cdots, n$$

gibt, so dass r Nullstelle des Polynoms p ist, es muss also gelten

$$p(r) = \sum_{i=0}^{n} a_i \cdot r^i = 0.$$

Bei der obigen Definition ist die Forderung, dass die Koeffizienten  $a_i$  ganze Zahlen sind, entscheidend, denn sonst könnten wir zu beliebigem  $r \in \mathbb{R}$  einfach das Polynom

$$p_r(x) := x - r$$

definieren und offenbar gilt  $p_r(r) = 0$ . Ein solches Polynom ist zur Definition einer algebraischen Zahl aber nur zugelassen, wenn r eine ganze Zahl ist.

**Beispiel**: Jede rationale Zahl r ist eine algebraische Zahl, denn wenn  $r \in \mathbb{Q}$  ist, dann gibt es ganze Zahlen a und b mit  $b \neq 0$ , so dass

$$r = \frac{a}{b}$$

gilt. Damit können wir ein Polynom p als

$$p(x) := a - b \cdot x$$

definieren. Für dieses Polynom gilt dann

$$p(r) = p\left(\frac{a}{b}\right) = a - b \cdot \frac{a}{b} = a - a = 0$$

und damit ist gezeigt, dass jede rationale Zahl r algebraisch ist. Der Begriff der algebraischen Zahlen ist also eine Verallgemeinerung des Begriffs der rationalen Zahlen.

**Beispiel**: Die Zahl  $\sqrt{2}$  ist eine algebraische Zahl, denn wenn wir das Polynom p als

$$p(x) := x^2 - 2$$

definieren, gilt offenbar

$$p(\sqrt{2}) = (\sqrt{2})^2 - 2 = 2 - 2 = 0.$$

Dieses Beispiel zeigt, dass es sich bei dem Begriff der algebraischen Zahlen um eine <u>echte</u> Verallgemeinerung des Begriffs der rationalen Zahlen handelt, denn wir haben ja bereits im ersten Semester gesehen, dass die Zahl  $\sqrt{2}$  keine rationale Zahl ist.

**Aufgabe 72\***: Zeigen Sie, dass die Zahl  $\sqrt{2} + \sqrt{3}$  eine algebraische Zahl ist. Zeigen Sie außerdem, dass diese Zahl keine rationale Zahl ist.

**Definition 108 (Transzendente Zahl)** Eine Zahl  $x \in \mathbb{R}$  ist genau dann *transzendent*, wenn x nicht algebraisch ist.

Es lässt sich zeigen, dass die Menge aller Polynome mit ganzzahligen Koeffizienten abzählbar ist. Damit ist natürlich auch die Menge der algebraischen Zahlen abzählbar. Da die Menge der reellen Zahlen überabzählbar ist, muss es also sehr viele reelle Zahlen geben, die transzendent sind. Allerdings ist der Nachweis der Transzendenz einer Zahl in der Regel recht aufwändig.

#### Theorem 109 (Charles Hermite, 1873)

Die Eulersche Zahl e ist transzendent.

#### Theorem 110 (Ferdinand von Lindemann, 1882)

Die Kreiszahl  $\pi$  ist transzendent.

Leider bleibt in dieser Vorlesung keine Zeit mehr zum Nachweis dieser beiden Theoreme. Unter

finden Sie eine Ausarbeitung des Nachweises der Transzendenz von e, einen Nachweis der Transzendenz von  $\pi$  finden Sie in dem folgenden Artikel von Herrn Prof. Fritsch:

http://www.mathematik.uni-muenchen.de/~fritsch/pi.pdf.

**Aufgabe 73**\*: Zeigen Sie, dass für alle natürlichen Zahlen  $n \in \mathbb{N}$ 

$$\int_0^\infty t^n \cdot e^{-t} dt = n!$$

gilt.

Bemerkung: Die letzte Gleichung motiviert die folgende Definition der Gamma-Funktion. Wir setzen

$$\Gamma(x) := \int_0^\infty t^{x-1} \cdot e^{-t} dt.$$

Mit dieser Definition gilt

$$\Gamma(n+1) = n!$$

und daher können wir die Gamma-Funktion als eine Erweiterung der Fakultäts-Funktion auf die natürlichen Zahlen auffassen.

# Kapitel 9

# Fourier-Analyse

Bei der Fourier-Analyse (Jean Baptiste Joseph Fourier; 1768 - 1830) zerlegen wir eine periodische Funktion in Sinus-Schwingungen verschiedener Frequenzen. Dieses Verfahren wird in der Praxis zur Tonund Bild-Verarbeitung eingesetzt. Außerdem ist die Fourier-Analyse ein wichtiges Hilfsmittel zur Lösung von Differential-Gleichungen. Im Rahmen dieser Vorlesung werden wir die Fourier-Analyse allerdings nur zur Berechnung unendlichen Reihen einsetzen, denn für die anderen Anwendungen reicht die Zeit nicht aus.

Bei der Fourier-Analyse gehen wir davon aus, dass eine Funktion  $f:\mathbb{R}\to\mathbb{R}$  gegeben ist, die periodisch mit der Periode  $2\cdot\pi$  ist, d. h. es gilt

$$\forall x \in \mathbb{R} : f(x+2 \cdot \pi) = f(x).$$

Ein triviales Beispiel für eine periodische Funktion ist die konstante Funktion  $x\mapsto c$ . Das typische Beispiel einer periodischen Funktion ist die Funktion  $x\mapsto \sin(x)$ , denn es gilt  $\sin(x+2\cdot\pi)=\sin(x)$ . Genauso ist auch die Funktion  $x\mapsto \cos(x)$  periodisch mit der Periode  $2\cdot\pi$ . Weitere Beispiele für periodische Funktionen sind die Funktionen

$$x \mapsto \sin(n \cdot x)$$
 und  $x \mapsto \cos(n \cdot x)$  für  $n \in \mathbb{N}$ .

Aus diesen Funktionen lassen sich weitere periodische Funktionen durch Linear-Kombination erhalten, denn wenn f und g zwei periodische Funktionen mit der Periode  $2 \cdot \pi$  sind, so ist natürlich auch die Funktion

$$x \mapsto \alpha \cdot f(x) + \beta \cdot g(x)$$
 für  $\alpha, \beta \in \mathbb{R}$ 

eine periodische Funktion der Periode  $2 \cdot \pi$ . Die grundlegende Idee bei der Fourier-Analyse besteht nun darin, dass sich jede halbwegs normale<sup>1</sup> periodische Funktion der Periode  $2 \cdot \pi$  als unendliche Linear-Kombination der oben vorgestellten Funktionen darstellen lässt. Genauer definieren wir folgendes:

**Definition 111 (Fourier-Reihe)** Es seien  $(a_n)_{n\in\mathbb{N}_0}$  und  $(b_n)_{n\in\mathbb{N}^*}$  Folgen reeller Zahlen. Dann bezeichnen wir den Ausdruck

$$\boxed{\frac{1}{2} \cdot a_0 + \sum_{k=1}^{\infty} a_k \cdot \cos(k \cdot x) + \sum_{k=1}^{\infty} b_k \cdot \sin(k \cdot x)}$$
(9.1)

als die mit den Folgen  $\left(a_n\right)_{n\in\mathbb{N}^*}$  und  $\left(b_n\right)_{n\in\mathbb{N}^*}$  gebildete Fourier-Reihe.

<sup>&</sup>lt;sup>1</sup> Es gibt periodische Funktionen, die sich nicht in einer Fourier-Reihe entwickeln lassen. Diese Funktionen sind aber relativ exotisch, so dass wir uns damit nicht weiter befassen.

## 9.1 Berechnung der Fourier-Koeffizienten

Die zentrale Frage bei der Fourier-Analyse ist es, für eine gegebene periodische Funktion f die Fourier-Koeffizienten  $a_k$  und  $b_k$  zu berechnen. Ist f eine periodische Funktion mit der Periode  $2 \cdot \pi$  und gilt

$$f(x) = \frac{1}{2} \cdot a_0 + \sum_{k=1}^{\infty} a_k \cdot \cos(k \cdot x) + \sum_{k=1}^{\infty} b_k \cdot \sin(k \cdot x),$$
 (9.2)

so können wir den Koeffizienten  $a_0$  dadurch gewinnen, dass wir die Funktion f(x) in dem Intervall  $[0, 2 \cdot \pi]$  integrieren. Wir erhalten dann

$$\int_0^{2 \cdot \pi} f(x) \, \mathrm{d}x \ = \ \frac{1}{2} \cdot a_0 \cdot \int_0^{2 \cdot \pi} 1 \, \mathrm{d}x \ + \ \int_0^{2 \cdot \pi} \sum_{k=1}^{\infty} a_k \cdot \cos(k \cdot x) \, \mathrm{d}x \ + \ \int_0^{2 \cdot \pi} \sum_{k=1}^{\infty} b_k \cdot \sin(k \cdot x) \, \mathrm{d}x$$

Das erste Integral auf der rechten Seite können wir ausführen, die anderen Integrale vertauschen wir mit den unendlichen Reihen<sup>2</sup>. Das liefert

$$\int_0^{2 \cdot \pi} f(x) \, \mathrm{d}x = \frac{1}{2} \cdot a_0 \cdot 2 \cdot \pi + \sum_{k=1}^{\infty} a_k \cdot \int_0^{2 \cdot \pi} \cos(k \cdot x) \, \mathrm{d}x + \sum_{k=1}^{\infty} b_k \cdot \int_0^{2 \cdot \pi} \sin(k \cdot x) \, \mathrm{d}x$$
 (9.3)

Nun gilt für alle  $k \in \mathbb{N}$  mit  $k \ge 1$ 

$$\int_{0}^{2 \cdot \pi} \sin(k \cdot x) \, \mathrm{d}x = -\frac{1}{k} \cdot \cos(k \cdot x) \Big|_{0}^{2 \cdot \pi}$$

$$= -\frac{1}{k} \cdot \left( \cos(k \cdot 2 \cdot \pi) - \cos(0) \right) = -\frac{1}{k} \cdot (1 - 1) = 0,$$
(9.4)

denn  $\cos(k\cdot 2\cdot \pi)=\cos(0)=1$ . Genauso sehen wir für alle  $k\geq 1$ 

$$\int_0^{2\cdot \pi} \cos(k\cdot x) \, \mathrm{d}x = \frac{1}{k} \cdot \sin(k\cdot x) \Big|_0^{2\cdot \pi} = \frac{1}{k} \cdot \left(\sin(k\cdot 2\cdot \pi) - \sin(0)\right) = 0,\tag{9.5}$$

denn  $\sin(k \cdot 2 \cdot \pi) = \sin(0) = 0$ . Setzen wir die Gleichungen (9.5) und (9.4) in Gleichung (9.2) ein, so erhalten wir die Gleichung

$$\int_0^{2 \cdot \pi} f(x) \, \mathrm{d}x = \pi \cdot a_0 \quad \text{bzw.} \quad a_0 = \frac{1}{\pi} \int_0^{2 \cdot \pi} f(x) \, \mathrm{d}x \tag{9.6}$$

Damit haben wir den Koeffizienten  $a_0$  bestimmt. Um die Koeffizienten  $a_k$  für  $k \geq 0$  zu bestimmen, multiplizieren wir die Gleichung (9.2) mit  $\cos(n \cdot x)$ , wobei  $n \in \mathbb{N}$  ist. Anschließend integrieren wir über das Intervall  $[0, 2 \cdot \pi]$ . Dann haben wir

$$\int_0^{2 \cdot \pi} f(x) \cdot \cos(n \cdot x) \, \mathrm{d}x = \frac{1}{2} \cdot a_0 \int_0^{2 \cdot \pi} \cos(n \cdot x) \, \mathrm{d}x$$

$$+ \int_0^{2 \cdot \pi} \cos(n \cdot x) \cdot \sum_{k=1}^{\infty} a_k \cdot \cos(k \cdot x) \, \mathrm{d}x$$

$$+ \int_0^{2 \cdot \pi} \cos(n \cdot x) \cdot \sum_{k=1}^{\infty} b_k \cdot \sin(k \cdot x) \, \mathrm{d}x$$

<sup>&</sup>lt;sup>2</sup> Eine genaue Analyse, wann diese Vertauschung zulässig ist, geht über den Rahmen dieser Vorlesung hinaus.

Vertauschen wir Integration und Summation, so erhalten wir

$$\int_{0}^{2 \cdot \pi} f(x) \cdot \cos(n \cdot x) \, \mathrm{d}x = \frac{1}{2} \cdot a_{0} \int_{0}^{2 \cdot \pi} \cos(n \cdot x) \, \mathrm{d}x$$

$$+ \sum_{k=1}^{\infty} a_{k} \cdot \int_{0}^{2 \cdot \pi} \cos(n \cdot x) \cdot \cos(k \cdot x) \, \mathrm{d}x$$

$$+ \sum_{k=1}^{\infty} b_{k} \cdot \int_{0}^{2 \cdot \pi} \cos(n \cdot x) \cdot \sin(k \cdot x) \, \mathrm{d}x$$

$$(9.7)$$

Wir berechnen als nächstes die Integrale, die in dieser Formel auftreten. Das erste Integral hat nach Gleichung (9.5) den Wert 0. Zur Berechnung der anderen Integrale definieren wir

$$I_{n,k} := \int_0^{2\cdot \pi} \cos(n\cdot x) \cdot \cos(k\cdot x) \,\mathrm{d}x \quad \text{ und } \quad J_{n,k} := \int_0^{2\cdot \pi} \sin(n\cdot x) \cdot \sin(k\cdot x) \,\mathrm{d}x$$

Wir berechnen  $I_{n,k}$  durch partielle Integration. Für  $n \neq 0$  gilt

$$I_{n,k} = \int_0^{2 \cdot \pi} \cos(n \cdot x) \cdot \cos(k \cdot x) dx$$

$$= \frac{1}{n} \cdot \sin(n \cdot x) \cdot \cos(k \cdot x) \Big|_0^{2 \cdot \pi} + \frac{k}{n} \cdot \int_0^{2 \cdot \pi} \sin(n \cdot x) \cdot \sin(k \cdot x) dx$$

$$= \frac{k}{n} \cdot J_{n,k}.$$

Damit haben wir  $I_{n,k}$  auf  $J_{n,k}$  zurück geführt. Jetzt berechnen wir  $J_{n,k}$  durch partielle Integration. Für  $n \neq 0$  gilt

$$J_{n,k} = \int_0^{2 \cdot \pi} \sin(n \cdot x) \cdot \sin(k \cdot x) dx$$

$$= -\frac{1}{n} \cdot \cos(n \cdot x) \cdot \sin(k \cdot x) \Big|_0^{2 \cdot \pi} + \frac{k}{n} \cdot \int_0^{2 \cdot \pi} \cos(n \cdot x) \cdot \cos(k \cdot x) dx$$

$$= \frac{k}{n} \cdot I_{n,k}$$

Damit haben wir die Berechnung von  $J_{n,k}$  auf  $I_{n,k}$  zurück geführt. Insgesamt haben wir die Gleichungen

$$I_{n,k} = \frac{k}{n} \cdot J_{n,k}$$
 und  $J_{n,k} = \frac{k}{n} \cdot I_{n,k}$ 

gefunden. Setzen wir die zweite Gleichung in die erste Gleichung ein, so folgt

$$I_{n,k} = \frac{k^2}{n^2} \cdot I_{n,k}$$
 also  $\left(1 - \frac{k^2}{n^2}\right) \cdot I_{n,k} = 0.$ 

Falls  $k \neq n$  ist, folgt daraus sofort

$$I_{n,k} = 0$$
 und  $J_{n,k} = 0$  für  $n \neq k$ .

In dem Fall k=n hat die bisherige Rechnung uns nicht viel weiter gebracht. In diesem Fall wissen wir lediglich, dass  $I_{n,n}=J_{n,n}$  gilt. Hier hilft uns eine Addition weiter:

$$2 \cdot I_{n,n} = I_{n,n} + J_{n,n}$$

$$= \int_0^{2 \cdot \pi} \cos(n \cdot x) \cdot \cos(n \cdot x) dx + \int_0^{2 \cdot \pi} \sin(n \cdot x) \cdot \sin(n \cdot x) dx$$

$$= \int_0^{2 \cdot \pi} \left(\cos^2(n \cdot x) + \sin^2(n \cdot x)\right) dx$$

$$= \int_0^{2 \cdot \pi} 1 dx$$

$$= 2 \cdot \pi$$

Teilen wir beide Seiten der Gleichung durch 2, so erhalten wir als Ergebnis

$$I_{n,n} = \int_0^{2 \cdot \pi} \cos(n \cdot x) \cdot \cos(n \cdot x) \, \mathrm{d}x = \pi.$$

Wegen  $J_{n,n} = I_{n,n}$  gilt auch

$$J_{n,n} = \int_0^{2 \cdot \pi} \sin(n \cdot x) \cdot \sin(n \cdot x) dx = \pi.$$

Insgesamt haben wir also

$$I_{n,k} = J_{n,k} = \pi \cdot \delta_{n,k}$$
,

wobei  $\delta_{n,k}$  das früher definierte Kronecker-Delta bezeichnet, für das die Gleichung

$$\delta_{n,k} = \begin{cases} 1 & \text{falls } n = k \text{ ist,} \\ 0 & \text{falls } n \neq k \text{ ist} \end{cases}$$

gilt. Um die Gleichung 9.7 nach den Koeffizienten  $a_k$  auflösen zu können, müssen wir noch die Integrale

$$H_{n,k} := \int_0^{2 \cdot \pi} \cos(n \cdot x) \cdot \sin(k \cdot x) \, \mathrm{d}x$$

berechnen. Wir könnten dieses Integral auf dieselbe Art berechnen, mit der wir oben die Integrale  $\int_0^{2 \cdot \pi} \cos(n \cdot x) \cdot \cos(k \cdot x) \, \mathrm{d}x$  und  $\int_0^{2 \cdot \pi} \sin(n \cdot x) \cdot \sin(k \cdot x) \, \mathrm{d}x$  berechnet haben. Es gibt aber noch einen anderen Weg, den wir jetzt aufzeigen. Aus dem Additions-Theorem für die Sinus-Funktion

$$\sin(\alpha + \beta) = \sin(\alpha) \cdot \cos(\beta) + \cos(\alpha) \cdot \sin(\beta)$$

folgt sofort

$$\sin(\alpha) \cdot \cos(\beta) = \frac{1}{2} \cdot \sin(\alpha + \beta) + \frac{1}{2} \cdot \sin(\alpha - \beta).$$

Damit gilt

$$H_{n,k} = \int_0^{2 \cdot \pi} \cos(n \cdot x) \cdot \sin(k \cdot x) dx$$
$$= \frac{1}{2} \cdot \int_0^{2 \cdot \pi} \sin((k+n) \cdot x) dx + \frac{1}{2} \cdot \int_0^{2 \cdot \pi} \sin((k-n) \cdot x) dx$$
$$= 0$$

nach Gleichung (9.4). Für n > 0 schreibt sich damit die Formel 9.7 wie folgt

$$\int_{0}^{2 \cdot \pi} f(x) \cdot \cos(n \cdot x) \, \mathrm{d}x = \frac{1}{2} \cdot a_0 \int_{0}^{2 \cdot \pi} \cos(n \cdot x) \, \mathrm{d}x$$

$$+ \sum_{k=1}^{\infty} a_k \cdot \int_{0}^{2 \cdot \pi} \cos(n \cdot x) \cdot \cos(k \cdot x) \, \mathrm{d}x$$

$$+ \sum_{k=1}^{\infty} b_k \cdot \int_{0}^{2 \cdot \pi} \cos(n \cdot x) \cdot \sin(k \cdot x) \, \mathrm{d}x$$

$$= 0 + \sum_{k=1}^{\infty} a_k \cdot I_{n,k} + \sum_{k=1}^{\infty} b_k \cdot H_{n,k}$$

$$= \sum_{k=1}^{\infty} a_k \cdot \pi \cdot \delta_{n,k} + \sum_{k=1}^{\infty} b_k \cdot 0$$

$$= a_n \cdot \pi$$

Damit haben wir für den Fourier-Koeffizienten  $a_n$  die Formel

$$a_n = \frac{1}{\pi} \cdot \int_0^{2 \cdot \pi} f(x) \cdot \cos(n \cdot x) \, \mathrm{d}x \tag{9.8}$$

gefunden. Vergleichen wir diese Formel mit der Formel 9.6, so sehen wir, dass diese Gleichung auch für n=0 richtig ist. Um die Koeffizienten  $b_n$  zu berechnen, multiplizieren wir die Gleichung 9.1 mit  $\sin(n\cdot x)$  und integrieren über das Intervall  $[0,2\cdot\pi]$ . Dann erhalten wir nach einer Rechnung, die ganz analog zur Berechnung der Koeffizienten  $a_k$  verläuft, das Ergebnis

$$b_n = \frac{1}{\pi} \int_0^{2 \cdot \pi} f(x) \cdot \sin(n \cdot x) \, \mathrm{d}x. \tag{9.9}$$

# 9.2 Konvergenz\*

Wir müssen noch die Frage beantworten, für welche Funktionen f die mit Hilfe der Gleichungen (9.8) (9.9) und (9.1) aufgestellte Fourier-Reihe gegen f konvergiert. Wir wollen uns mit einem Satz begnügen, der im Wesentlichen auf Dirichlet (Johann Peter Gustav Lejeune Dirichlet; 1805 - 1859) zurück geht. Zuvor benötigen wir noch zwei Definitionen.

**Definition 112 (Einschränkung einer Funktion)** Ist  $f: \mathbb{R} \to \mathbb{R}$  eine Funktion und ist [a,b] ein nicht-leeres Intervall, so definieren wir die *Einschränkung* von f auf [a,b] als die Funktion

$$f \upharpoonright_{[a,b]} : [a,b] \to \mathbb{R}$$
 mit  $f \upharpoonright_{[a,b]} (x) = f(x)$  für alle  $x \in [a,b]$ .

**Definition 113 (stetig differenzierbar)** Eine Funktion  $f:[a,b] \to \mathbb{R}$  ist stetig differenzierbar falls f differenzierbar ist und außerdem die Ableitung  $f':[a,b] \to \mathbb{R}$  stetig ist.

**Definition 114 (stückweise stetig differenzierbar)** Eine Funktion  $f:[0,2\cdot\pi]\to\mathbb{R}$  ist *stückweise stetig differenzierbar* falls es Zahlen  $x_0,\,x_1,\,\cdots,\,x_n$  gibt mit

$$0 = x_0 \le x_1 \le x_2 \cdots \le x_{n-1} \le x_n = 2 \cdot \pi$$

gibt, so dass für alle  $i = 1, \dots, n$  gilt:

$$f \upharpoonright_{[x_{i-1},x_{i}]}$$
 ist stetig differenzierbar.

Ein Beispiel für eine stückweise stetige Funktion sehen Sie in Abbildung 9.1. Die Ableitung dieser Funktion weist in den Punkten 0,  $\pi$  und  $-\pi$  Sprünge auf.

#### Satz 115 Es gelte

- 1.  $f: \mathbb{R} \to \mathbb{R}$  ist stetig mit der Periode  $2 \cdot \pi$ ,
- 2.  $f \upharpoonright_{[0,2\pi]}$  ist stückweise stetig differenzierbar,

3. 
$$a_k = \frac{1}{\pi} \cdot \int_0^{2 \cdot \pi} f(x) \cdot \cos(k \cdot x) \, \mathrm{d}x$$
 für  $k \in \mathbb{N}_0$ ,

4. 
$$b_k = \frac{1}{\pi} \cdot \int_0^{2 \cdot \pi} f(x) \cdot \sin(k \cdot x) dx$$
 für  $k \in \mathbb{N}$ .

Dann gilt

$$f(x) = \frac{1}{2} \cdot a_0 + \sum_{k=1}^{\infty} a_k \cdot \cos(k \cdot x) + \sum_{k=1}^{\infty} b_k \cdot \sin(k \cdot x).$$

Der Beweis dieses Satzes benötigt Hilfsmittel, die im Rahmen der Vorlesung nicht eingeführt werden können.

## 9.3 Beispiele

Um es gleich bei der Berechnung der Fourier-Koeffizienten einfacher zu haben, definieren wir für eine Funktion  $f: \mathbb{R} \to \mathbb{R}$  die Begriffe gerade und ungerade:

- 1. f ist gerade g.d.w.  $\forall x \in \mathbb{R} : f(-x) = f(x)$ .
- 2. f ist ungerade g.d.w.  $\forall x \in \mathbb{R} : f(-x) = -f(x)$ .

Ist die Funktion  $f: \mathbb{R} \to \mathbb{R}$  ungerade und ist f integrierbar, so gilt für beliebige Zahlen a

$$\int_{-a}^{a} f(x) \, \mathrm{d}x = 0. \tag{9.10}$$

Beweis: Es gilt

$$\int_{-a}^{a} f(x) dx = \int_{-a}^{0} f(x) dx + \int_{0}^{a} f(x) dx.$$

In dem Integral über das Intervall [-a,0] führen wir die Variablen-Transformation y=-x durch. Dann gilt  $\mathrm{d}y=-\mathrm{d}x$ , und  $y(-a)=a,\ y(0)=0.$  Damit gilt

$$\int_{-a}^{0} f(x) dx = -\int_{a}^{0} f(-y) dy = \int_{0}^{a} f(-y) dy = -\int_{0}^{a} f(y) dy = -\int_{0}^{a} f(x) dx$$

Also haben wir insgesamt

$$\int_{-a}^{a} f(x) dx = \int_{-a}^{0} f(x) dx + \int_{0}^{a} f(x) dx = -\int_{0}^{a} f(x) dx + \int_{0}^{a} f(x) dx = 0.$$

Ist die Funktion  $f: \mathbb{R} \to \mathbb{R}$  gerade, so kann ein Integral über ein zum Punkt x=0 symmetrisches Intervall wie folgt vereinfacht werden:

$$\int_{-a}^{a} f(x) \, \mathrm{d}x = 2 \cdot \int_{0}^{a} f(x) \, \mathrm{d}x. \tag{9.11}$$

Aufgabe 74: Beweisen Sie die Gleichung 9.11.

 $\Diamond$ 

**Satz 116** Ist die Funktion  $f: \mathbb{R} \to \mathbb{R}$  periodisch mit der Periode  $2 \cdot \pi$ , so gilt

$$\int_{0}^{2 \cdot \pi} f(x) \, \mathrm{d}x = \int_{-\pi}^{\pi} f(x) \, \mathrm{d}x \tag{9.12}$$

Aufgabe 75: Beweisen Sie den letzten Satz.

Die letzten beiden Gleichungen können wir zusammenfassen.

**Korollar 117** Ist die Funktion  $f: \mathbb{R} \to \mathbb{R}$  einerseits periodisch mit der Periode  $2 \cdot \pi$  und andererseits ungerade, so gilt

$$\int_{0}^{2 \cdot \pi} f(x) \, \mathrm{d}x = 0 \tag{9.13}$$

Beweis: Es gilt

$$\int_0^{2 \cdot \pi} f(x) \, \mathrm{d}x = \int_{-\pi}^{\pi} f(x) \, \mathrm{d}x = 0.$$

**Korollar 118** Ist die Funktion  $f: \mathbb{R} \to \mathbb{R}$  einerseits periodisch mit der Periode  $2 \cdot \pi$  und andererseits gerade, so gilt

$$\int_{0}^{2 \cdot \pi} f(x) \, \mathrm{d}x = 2 \cdot \int_{0}^{\pi} f(x) \, \mathrm{d}x \tag{9.14}$$

Beweis: Es gilt

$$\int_0^{2 \cdot \pi} f(x) \, \mathrm{d}x = \int_{-\pi}^{\pi} f(x) \, \mathrm{d}x = 2 \cdot \int_0^{\pi} f(x) \, \mathrm{d}x.$$

#### 9.3.1 Fourier-Analyse der Sägezahn-Funktion

Wir berechnen als erstes die Fourier-Reihe für die *Sägezahn*-Funktion  $s: \mathbb{R} \to \mathbb{R}$ , die im Intervall  $[0, 2 \cdot \pi]$  wie folgt definiert ist:

$$s(x) = \left\{ \begin{array}{ll} x & \text{falls } x \leq \pi, \\ 2 \cdot \pi - x & \text{falls } x \geq \pi. \end{array} \right.$$

Diese Funktion wird periodisch auf ganz  $\mathbb{R}$  fortgesetzt. Abbildung 9.1 zeigt diese Funktion. Wir berechnen nun die Fourier-Koeffizienten dieser Funktion.

1. Die Koeffizienten  $a_n$  ergeben sich als

$$a_n = \frac{1}{\pi} \cdot \int_0^{2 \cdot \pi} s(x) \cdot \cos(n \cdot x) \, \mathrm{d}x = \frac{2}{\pi} \cdot \int_0^{\pi} s(x) \cdot \cos(n \cdot x) \, \mathrm{d}x = \frac{2}{\pi} \cdot \int_0^{\pi} x \cdot \cos(n \cdot x) \, \mathrm{d}x,$$

denn die Funktion  $x\mapsto s(x)\cdot\cos(n\cdot x)\,\mathrm{d}x$  ist einerseits periodisch mit der Periode  $2\cdot\pi$  und andererseits gerade. Im Falle n=0 haben wir

$$a_0 = \frac{2}{\pi} \cdot \int_0^{\pi} x \cdot \cos(0 \cdot x) \, dx = \frac{2}{\pi} \cdot \int_0^{\pi} x \, dx = \frac{2}{\pi} \cdot \frac{x^2}{2} \Big|_0^{\pi} = \frac{2}{\pi} \cdot \frac{\pi^2}{2} = \pi.$$

Andernfalls berechnen wir das Integral mit Hilfe partieller Integration. Wir setzen  $u'(x)=\cos(nx)$  und v(x)=x. Dann gilt  $u(x)=\frac{1}{n}\cdot\sin(n\cdot x)$  und v'(x)=1, also haben wir für  $n\geq 1$ 



Abbildung 9.1: Die Sägezahn-Funktion.

$$a_n = \frac{2}{\pi} \cdot \left( x \cdot \frac{1}{n} \sin(n \cdot x) \Big|_0^{\pi} - \frac{1}{n} \cdot \int_0^{\pi} \sin(n \cdot x) \, \mathrm{d}x \right)$$
$$= \frac{2}{\pi} \cdot \left( 0 + \frac{1}{n^2} \cdot \cos(n \cdot x) \Big|_0^{\pi} \right)$$
$$= \frac{2}{\pi} \cdot \frac{1}{n^2} \cdot \left( (-1)^n - 1 \right),$$

denn  $\cos(n \cdot \pi) = (-1)^n$ . Damit haben wir insgesamt

$$a_0=\pi, \quad a_{2\cdot n+1}=\frac{-4}{\pi\cdot n^2} \quad \text{ und } \quad a_{2\cdot (n+1)}=0 \quad \text{ für } n\in \mathbb{N}.$$

2. Die Koeffizienten  $b_n$  ergeben sich als

$$b_n = \frac{1}{\pi} \cdot \int_0^{2 \cdot \pi} s(x) \cdot \sin(n \cdot x) \, \mathrm{d}x = 0$$

denn die Funktion  $s(x)\cdot\sin(n\cdot x)$  ist sowohl periodisch mit der Periode  $2\cdot\pi$  als auch ungerade. Insgesamt haben wir jetzt die Formel

$$s(x) = \frac{\pi}{2} - \frac{4}{\pi} \cdot \sum_{k=0}^{\infty} \frac{1}{(2 \cdot k + 1)^2} \cdot \cos((2 \cdot k + 1) \cdot x)$$

gefunden. Setzen wir hier für x den Wert  $\pi$  ein, so ergibt sich wegen  $\cos \left( (2 \cdot k + 1) \cdot \pi \right) = -1$ 

$$\pi = \frac{\pi}{2} - \frac{4}{\pi} \cdot \sum_{k=0}^{\infty} \frac{1}{(2 \cdot k + 1)^2} \cdot \cos((2 \cdot k + 1) \cdot \pi)$$

$$\Leftrightarrow \frac{\pi}{2} = \frac{4}{\pi} \cdot \sum_{k=0}^{\infty} \frac{1}{(2 \cdot k + 1)^2}$$

$$\Leftrightarrow \frac{\pi^2}{8} = \sum_{k=0}^{\infty} \frac{1}{(2 \cdot k + 1)^2}.$$

Damit sind wir jetzt in der Lage, die Reihe

$$\sigma := \sum_{n=1}^{\infty} \frac{1}{n^2}$$

zu berechnen. Zunächst zerlegen wir die Reihe in einen Teil, der nur über die geraden Indices läuft und einen Teil, der über die ungeraden Indices läuft:

$$\sigma = \sum_{n=1}^{\infty} \frac{1}{(2 \cdot n)^2} + \sum_{n=0}^{\infty} \frac{1}{(2 \cdot n + 1)^2}$$

$$\Leftrightarrow \sigma = \frac{1}{4} \cdot \sum_{n=1}^{\infty} \frac{1}{n^2} + \frac{\pi^2}{8}$$

$$\Leftrightarrow \sigma = \frac{1}{4} \cdot \sigma + \frac{\pi^2}{8}$$

$$\Leftrightarrow \frac{3}{4} \cdot \sigma = \frac{\pi^2}{8}$$

$$\Leftrightarrow \sigma = \frac{\pi^2}{6}$$

Damit haben wir also die Formel

$$\sum_{n=1}^{\infty} \frac{1}{n^2} = \frac{\pi^2}{6}$$

gezeigt. Die Frage nach dem Wert dieser Reihe war 1644 als *Basel'sches Problem* von Pietro Mengoli gestellt worden. Führende Mathematiker des 17-ten Jahrhunderts hatten sich erfolglos mit dieser Frage beschäftigt. Im Jahre 1735 gelang es Leonard Euler (1707 - 1783), dieses Problem zu lösen.

**Aufgabe 76**: Die Funktion p sei auf dem Intervall  $[-\pi, \pi]$  definiert durch  $p(x) = x^2$ .

Die Funktion werde so auf  $\mathbb R$  fortgesetzt, dass die resultierende Funktion die Periode  $2 \cdot \pi$  hat.

- (a) Berechnen Sie die Fourier-Reihe von p.
- (b) Berechnen Sie mit Hilfe der Fourier-Reihe von p einen Wert für die Reihe

$$\sum_{n=1}^{\infty} \frac{1}{n^2}.$$

# Kapitel 10

# Rundungsfehler

Die meisten komplexen Probleme lassen sich nur mit numerischen Verfahren lösen. Wir haben bereits verschiedene numerische Verfahren kennengelernt, beispielsweise Verfahren zur Berechnung von Nullstellen sowie Verfahren zur numerischen Integration. Allen diesen Verfahren ist gemeinsam, dass zwei verschiedene Arten von Fehlern auftreten:

1. Ein Approximations-Fehler tritt auf, wenn wir einen Wert  $\lambda$  berechnen wollen, zu dessen Berechnung wir nur eine Näherungsformel existiert. Oft ist der Approximations-Fehler ein Abbruch-Fehler, der seine Ursache darin hat, dass wir nur endlich viele Glieder einer unendlichen Reihe berechnen können. Wollen wir beispielsweise die Euler'sche Zahl e nach der Formel

$$e = \sum_{k=0}^{\infty} \frac{1}{k!}$$

berechnen, so können wir auf dem Rechner diese Summe nicht gegen unendlich laufen lassen, sondern müssen die Summe nach endlich vielen Gliedern abbrechen, wir berechnen also als Approximation für e eine Reihe der Form

$$e_n := \sum_{k=0}^n \frac{1}{k!}$$

und müssen dann n so groß wählen, dass der Abbruch-Fehler

$$e - e_n = \sum_{k=n+1}^{\infty} \frac{1}{k!}$$

unterhalb einer vorgegeben Schranke bleibt.

2. Zusätzlich zum Approximations-Fehler gibt es noch die Rundungsfehler, die im Laufe der Rechnung entstehen. Diese Rundungsfehler haben Ihre Ursache darin, dass Fließkomma-Zahlen auf dem Rechner mit einer vorgegebenen Genauigkeit dargestellt werden. Rechnen wir in der Sprache Java mit einer Fließkomma-Zahl vom Typ float, so stehen zur Darstellung der Stellen hinter dem Komma lediglich 23 Bits zur Verfügung. Werden nun zwei solche Zahlen multipliziert, so könnten bis zu 47 Bits notwendig sein, um alle Stellen hinter dem Komma korrekt wiedergeben zu können. Da aber zum Abspeichern des Ergebnisses lediglich 23 Bits zur Verfügung stehen, um die Ziffern hinter dem Komma abzuspeichern, bleibt nichts anderes übrig, als das Ergebnis auf 23 Bits zu runden. Der dadurch entstehende Fehler wird als Rundungsfehler bezeichnet.

Die Auswirkungen von Rundungsfehlern werden oft unterschätzt. Unter

findet sich eine Liste der 20 spektakulärsten Software-Fehler, die Katastrophen ausgelöst haben. In mehreren Fällen waren Rundungsfehler ein Teil des Problems. Um einen ersten Eindruck von der Wirkung

von Rundungsfehlern zu bekommen, betrachten wir das in Abbildung 10.1 gezeigte *Java*-Programm zur Berechnung der harmonischen Reihe

$$\sum_{n=1}^{\infty} \frac{1}{n}$$

```
public static float harmonic() {
        float oldSum = 0.0F;
        float sum
                      = 1.0F;
                      = 1;
        int
               n
        while (oldSum < sum) {</pre>
             oldSum = sum;
                   += 1.0F/n;
             sum
                   += 1;
             if (n % 100000 == 0) {
                 System.out.println("n = " + n + ", sum = " + sum);
             }
11
        System.out.println("n = " + n + ", sum = " + sum);
13
        return sum;
    };
15
```

Abbildung 10.1: Berechnung von  $\sum_{n=1}^{\infty} \frac{1}{n}$ .

Sie erwarten jetzt vielleicht, dass diese Programm nie terminiert, aber wenn wir dieses Programm laufen lassen, dann erhalten wir nach wenigen Sekunden die Meldung:

$$sum = 16.0, n = 1673864.$$

Da wir früher bewiesen haben, dass die Partialsummen

$$s_n := \sum_{k=1}^n \frac{1}{k}$$

für wachsende Werte von n beliebig groß werden, fragen wir uns, was bei der Rechnung schief gelaufen ist. Die Antwort ist, dass für n=1673864 der Wert  $\frac{1}{n}$  so klein ist, dass die Summe

$$16.0 + \frac{1}{n}$$

so nahe bei 16 liegt, dass sie auf den Wert 16 abgerundet wird. Um diesen Effekt näher zu beschreiben, definiert man für einen vorgegebenen Rechner die sogenannte *Maschinen-Konstante eps* als die kleinste positive Zahl, die, wenn sie auf diesem Rechner zu 1 addiert wird, eine Ergebnis größer als 1 ergibt. Die formale Definition lautet

$$eps := \min(\{x \in \mathbb{R} \mid x > 0 \land 1 \oplus x > 1\}).$$

Hier bezeichnet  $\oplus$  die auf dem Rechner implementierte Addition. Abbildung 10.2 zeigt ein zwei Funktionen zur Berechnung der Maschinen-Konstante bei einfacher und doppelter Genauigkeit. Bei der im IEEE-Standard 754 definierten 32-Bit-Architektur erhalten wir für *eps* den Wert

$$eps_{32} = 1.1920929E-7$$
,

Bei einer 64-Bit-Architektur lautet das Ergebnis

$$eps_{64} = 2.220446049250313E-16$$
,

Bei modernen Rechnern, die den IEEE-Standard 754 implementieren, können wir davon ausgehen, dass der relative Rundungsfehler bei der Ausführung einer Grundrechenoperation durch die Maschinen-

```
public static float singlePrecisionEps() {
        float eps = 1.0F;
2
        float old = eps;
        while (1.0F + eps > 1.0F) {
            old = eps;
            eps *= 0.5F;
        return old;
    };
9
    public static double doublePrecisionEps() {
        double eps = 1.0;
11
        double old = eps;
12
        while (1.0 + eps > 1.0) {
13
            old = eps;
            eps *= 0.5;
15
        return old;
17
    };
```

Abbildung 10.2: Berechnung der Maschinen-Konstante eps.

#### Konstante eps beschränkt ist.

Leider muss die Vorlesung aus Zeitgründen an dieser Stelle enden. Der interessierten Leser sei daher auf die Literatur, insbesondere den Artikel von Goldberg [10] verwiesen.

# Literaturverzeichnis

- [1] Forster, Otto: Analysis I, Differential- und Integralrechnung einer Veränderlichen. Vieweg & Teubner, 11te Auflage, 2011.
- [2] Grauert, Hans und Ingo Lieb: Differential- und Integralrechnung I. Springer, 1967.
- [3] Courant, Richard: Differential and Integral Calculus, volume 1. Blackie & Son Limited, 2nd edition, 1937
- [4] Wrede, Robert and Murray Spiegel: *Advanced Calculus*. The McGraw-Hill Companies, 3rd edition, 2010.
- [5] Landau, Edmund: *Grundlagen der Analysis*. Akademische Verlagsgesellschaft, 1930. http://www.scribd.com/doc/2452802/Landau-Edmund-Grundlagen-der-Analysis.
- [6] Rudin, Walter: Principles of Mathematical Analysis. McGraw-Hill International, 3rd edition, 1976.
- [7] Dedekind, Richard: Stetigkeit und irrationale Zahlen. Friedrich Vieweg und Sohn, 1872.
- [8] Dowell, M. and P. Jarrat: A modified regula falsi method for computing the root of an equation. BIT Numerical Mathematics, 11(2):168–174, 1971.
- [9] Rosenlicht, Maxwell: *Integration in finite terms*. The American Mathematical Monthly, 79(9):963–972, November 1972.
- [10] Goldberg, David: What every computer scientist should know about floating-point arithmetic. ACM Computing Surveys, 23(1):5–48, 1991. Available from http://www.validlab.com/goldberg/paper.ps.